

Guía de Repaso — Examen Final

Estadística 2026-II — Pontificia Universidad Javeriana

Fecha del examen: 27 de noviembre, 2026

Repositorio del curso: <https://github.com/polanco-jaime/Curso-Estadistica-2026-3>

Índice

1. Resumen de Conceptos Clave	2
1.1. Unidad 1: Estadística Descriptiva y Probabilidad	2
1.2. Unidad 2: Estimación	2
1.3. Unidad 3: Pruebas de Hipótesis	2
1.4. Unidad 4: Regresión Lineal	3
1.5. Diagnósticos de Regresión	3
1.6. Errores Estándar Robustos	4
1.7. Presentación de Resultados	4
2. Fórmulas Importantes	5
2.1. Unidad 1: Descriptiva	5
2.2. Unidad 2: Estimación	5
2.3. Unidad 3: Pruebas	5
2.4. Unidad 4: Regresión	5
3. Problemas de Práctica	6
3.1. Problema 1: Repaso de Descriptiva	6
3.2. Problema 2: Repaso de Correlación	6
3.3. Problema 3: Repaso de TCL	6
3.4. Problema 4: Repaso de Intervalos de Confianza	6
3.5. Problema 5: Repaso de Prueba t	6
3.6. Problema 6: Repaso de ANOVA	7
3.7. Problema 7: Regresión Simple	7
3.8. Problema 8: Regresión Múltiple	7
3.9. Problema 9: Multicolinealidad	8
3.10. Problema 10: Heterocedasticidad	8
3.11. Problema 11: Observaciones Influyentes	8
3.12. Problema 12: Comparación de Modelos	9
4. Soluciones y Pistas	10
4.1. Problema 1	10
4.2. Problema 2	10
4.3. Problema 3	10
4.4. Problema 4	10
4.5. Problema 5	10
4.6. Problema 6	10
4.7. Problema 7	10
4.8. Problema 8	11

4.9. Problema 9	11
4.10. Problema 10	11
4.11. Problema 11	11
4.12. Problema 12	11

1. Resumen de Conceptos Clave

1.1. Unidad 1: Estadística Descriptiva y Probabilidad

Conceptos clave:

- Medidas de tendencia central: media, mediana, moda
- Medidas de dispersión: varianza, DE, IQR
- Medidas de forma: asimetría, curtosis
- Visualización: histogramas, boxplots, scatter plots
- Correlación: Pearson (lineal), Spearman (monótona)
- Paradoja de Simpson: variables de confusión
- Distribución normal: propiedades, z-scores
- TCL: distribución de $\bar{X}$, error estándar

1.2. Unidad 2: Estimación

Conceptos clave:

- Estimación puntual vs. intervalo
- IC para media (distribución t)
- IC para proporción (distribución normal)
- Interpretación de nivel de confianza
- Margen de error y tamaño de muestra

1.3. Unidad 3: Pruebas de Hipótesis

Conceptos clave:

- Hipótesis nula y alternativa
- Valor p e interpretación
- Errores tipo I (α) y tipo II (β)
- Prueba t: una muestra, dos muestras
- ANOVA y pruebas post-hoc (Tukey)
- Chi-cuadrado para independencia
- Pruebas no paramétricas: Mann-Whitney, Kruskal-Wallis
- Tamaño de efecto: Cohen's d, Cramér's V
- Potencia estadística

1.4. Unidad 4: Regresión Lineal

Regresión simple:

$$Y = \beta_0 + \beta_1 X + \epsilon$$

- β_0 : intercepto (valor de Y cuando $X = 0$)
- β_1 : pendiente (cambio en Y por unidad de cambio en X)
- ϵ : error aleatorio

Regresión múltiple:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \epsilon$$

- Cada β_j es el efecto de X_j sobre Y , *manteniendo constantes* las demás variables
- Permite controlar variables de confusión

R-cuadrado (R^2): Proporción de varianza en Y explicada por el modelo.

- Rango: 0 a 1
- $R^2 = 0,45$ significa que el modelo explica 45 % de la varianza
- R^2 ajustado penaliza por número de predictores

Prueba F global: Evalúa si el modelo completo es significativo.

- H_0 : todos los $\beta_j = 0$ (modelo no explica nada)
- H_a : al menos un $\beta_j \neq 0$

Prueba t individual: Evalúa si un predictor específico es significativo.

- H_0 : $\beta_j = 0$ (el predictor X_j no tiene efecto)
- H_a : $\beta_j \neq 0$

1.5. Diagnósticos de Regresión

Multicolinealidad: Predictores altamente correlacionados entre sí.

- Problema: coeficientes inestables, errores estándar inflados
- Detección: VIF (Variance Inflation Factor)
- $VIF < 5$: no hay problema; $VIF > 10$: multicolinealidad severa

Heterocedasticidad: Varianza de errores no constante.

- Detección: gráfico de residuos vs. ajustados (patrón de embudo); prueba de Breusch-Pagan
- Consecuencia: errores estándar incorrectos, inferencia inválida
- Solución: errores estándar robustos (HC3)

Observaciones influyentes:

- **Leverage:** qué tan extremo es un valor de X
- **Cook's D:** mide influencia global de una observación

- Cook's $D > 1$ (o $> 4/n$): observación potencialmente problemática

Normalidad de residuos:

- Verificar con Q-Q plot o prueba de Shapiro-Wilk
- Violaciones leves: OLS aún es robusto con muestras grandes
- Violaciones severas: considerar transformaciones

1.6. Errores Estándar Robustos

Cuando hay heterocedasticidad, los errores estándar OLS estándar son incorrectos. Los errores robustos (HC3) corrigen esto sin cambiar los coeficientes.

Cuándo usar:

- Gráfico de residuos muestra patrón de varianza no constante
- Breusch-Pagan significativo ($p < 0,05$)

Interpretación:

- Los coeficientes no cambian
- Errores estándar y valores p pueden cambiar
- Intervalos de confianza más confiables

1.7. Presentación de Resultados

Tabla de regresión debe incluir:

- Coeficientes estimados
- Errores estándar (entre paréntesis o con $\pm$)
- Valores p o estrellas de significancia (* $p < 0,05$, ** $p < 0,01$, *** $p < 0,001$)
- R^2 y R^2 ajustado
- Tamaño de muestra n
- Nota sobre tipo de errores estándar (OLS o robustos)

2. Fórmulas Importantes

2.1. Unidad 1: Descriptiva

Media: $\bar{x} = \frac{1}{n} \sum x_i$

Varianza: $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$

Correlación de Pearson: $r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$

Z-score: $z = \frac{x - \mu}{\sigma}$

TCL: $\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$

2.2. Unidad 2: Estimación

IC para media: $\bar{x} \pm t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}}$

IC para proporción: $\hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

2.3. Unidad 3: Pruebas

Estadístico t: $t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$ (una muestra)

Estadístico t: $t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$ (dos muestras)

ANOVA F: $F = \frac{MS_{between}}{MS_{within}}$

Chi-cuadrado: $\chi^2 = \sum \frac{(O-E)^2}{E}$

Cohen's d: $d = \frac{\bar{x}_1 - \bar{x}_2}{s_{pooled}}$

Cramér's V: $V = \sqrt{\frac{\chi^2}{n \cdot \min(r-1, c-1)}}$

2.4. Unidad 4: Regresión

Modelo simple: $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

Coefficientes OLS:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

R-cuadrado: $R^2 = 1 - \frac{SS_{residual}}{SS_{total}} = \frac{SS_{regression}}{SS_{total}}$

R-cuadrado ajustado: $R_{adj}^2 = 1 - \frac{(1-R^2)(n-1)}{n-k-1}$

donde k es el número de predictores.

VIF: $VIF_j = \frac{1}{1-R_j^2}$

donde R_j^2 es el R^2 de regesar X_j sobre los demás predictores.

3. Problemas de Práctica

3.1. Problema 1: Repaso de Descriptiva

Se analizaron los puntajes en Ciencias Naturales (Saber 11) para 400 estudiantes. Se obtuvo: media = 51.2, mediana = 53.0, DE = 13.5, asimetría = -0.28.

Preguntas:

- a) ¿Qué indica la relación entre media y mediana?
- b) ¿Aproximadamente qué porcentaje de estudiantes tiene puntajes entre 37.7 y 64.7?

3.2. Problema 2: Repaso de Correlación

La correlación entre puntaje de Matemáticas Saber 11 y Razonamiento Cuantitativo Saber Pro es $r = 0,62$ ($n = 1500$, $p < 0,001$).

Preguntas:

- a) Interprete la magnitud y dirección de la correlación.
- b) ¿Puede concluir que mayor puntaje en Saber 11 causa mayor puntaje en Saber Pro?

3.3. Problema 3: Repaso de TCL

Los puntajes en Lectura Crítica (Saber Pro) tienen media $\mu = 152$ y DE $\sigma = 19$. Se toma una muestra de $n = 100$ estudiantes.

Preguntas:

- a) ¿Cuál es la distribución de $\bar{X}$?
- b) ¿Cuál es la probabilidad de que $\bar{X} > 155$?

3.4. Problema 4: Repaso de Intervalos de Confianza

Una muestra de $n = 50$ estudiantes de Negocios Internacionales tiene puntaje promedio en Inglés (Saber Pro) de $\bar{x} = 168,5$ con $s = 22,3$.

Preguntas:

- a) Construya un IC del 95 % para la media poblacional.
- b) Interprete el intervalo.

3.5. Problema 5: Repaso de Prueba t

Se comparan puntajes en Competencias Ciudadanas entre hombres ($n_1 = 200$, $\bar{x}_1 = 145,2$, $s_1 = 17,8$) y mujeres ($n_2 = 220$, $\bar{x}_2 = 151,3$, $s_2 = 16,4$). La prueba t arroja $p = 0,0008$.

Preguntas:

- a) ¿Cuál es la conclusión a $\alpha = 0,05$?
- b) Si Cohen's $d = 0,35$, ¿cómo interpretaría el tamaño de efecto?

3.6. Problema 6: Repaso de ANOVA

Se comparan puntajes en Razonamiento Cuantitativo entre cuatro departamentos. ANOVA arroja $F = 8,92$, $p = 0,0002$. Tukey muestra que Cundinamarca (media = 158) difiere significativamente de Chocó (media = 142) y Guajira (media = 138), pero no de Valle (media = 155).

Preguntas:

- a) ¿Cuál es la conclusión del ANOVA?
- b) ¿Qué departamentos tienen desempeño similar?

3.7. Problema 7: Regresión Simple

Se ajusta un modelo de regresión simple para predecir el puntaje en Saber Pro Inglés (Y) a partir del puntaje en Saber 11 Inglés (X):

$$\hat{Y} = 85,3 + 1,42 \cdot X$$

$R^2 = 0,48$, $n = 800$, todos los coeficientes significativos ($p < 0,001$).

Preguntas:

- a) Interprete el coeficiente $\hat{\beta}_1 = 1,42$.
- b) Interprete el intercepto $\hat{\beta}_0 = 85,3$.
- c) ¿Qué porcentaje de varianza en Saber Pro Inglés es explicado por Saber 11 Inglés?
- d) Prediga el puntaje en Saber Pro para un estudiante con puntaje 50 en Saber 11.

3.8. Problema 8: Regresión Múltiple

Se ajusta un modelo para predecir puntaje en Razonamiento Cuantitativo (Saber Pro) usando:

- X_1 : puntaje en Matemáticas Saber 11
- X_2 : estrato (1-6)

Resultados ($n = 500$):

Variable	Coeficiente	Error Est.	Valor p
Intercepto	65.2	8.5	$< 0,001$
Mat. Saber 11	1.25	0.12	$< 0,001$
Estrato	3.80	0.85	$< 0,001$

$R^2 = 0,56$, $R^2_{adj} = 0,55$, $F = 315,8$, $p < 0,001$.

Preguntas:

- a) Interprete el coeficiente de Matemáticas Saber 11.
- b) Interprete el coeficiente de Estrato.
- c) ¿El modelo global es significativo? ¿Cómo lo sabe?
- d) Compare este $R^2 = 0,56$ con el $R^2 = 0,48$ del Problema 7. ¿Qué indica?

3.9. Problema 9: Multicolinealidad

Se ajusta un modelo con tres predictores. Los VIF son:

- $VIF(\text{Ingresos familiares}) = 8.5$
- $VIF(\text{Nivel educativo padre}) = 8.2$
- $VIF(\text{Estrato}) = 2.1$

Preguntas:

- a) ¿Hay evidencia de multicolinealidad problemática?
- b) ¿Qué variables están probablemente correlacionadas?
- c) ¿Qué estrategia recomendaría?

3.10. Problema 10: Heterocedasticidad

Se ajusta un modelo de regresión. El gráfico de residuos vs. ajustados muestra un patrón de embudo (varianza creciente). La prueba de Breusch-Pagan arroja $p = 0,002$.

Se recalculan los errores estándar usando HC3 (robustos):

	Coef.	SE (OLS)	SE (Robusto)
Intercepto	125.3	5.2	6.8
Puntaje S11	0.85	0.08	0.12

Preguntas:

- a) ¿Hay evidencia de heterocedasticidad?
- b) ¿Cómo cambian los errores estándar al usar HC3?
- c) ¿Por qué es importante usar errores robustos en este caso?

3.11. Problema 11: Observaciones Influyentes

En un modelo con $n = 120$, se detectan tres observaciones con Cook's $D > 1$. Al remover estas observaciones y re-ajustar, el coeficiente de interés cambia de $\hat{\beta}_1 = 2,35$ ($p = 0,08$) a $\hat{\beta}_1 = 1,12$ ($p = 0,001$).

Preguntas:

- a) ¿Qué indica un Cook's $D > 1$?
- b) ¿Cómo afectaron las observaciones influyentes al resultado original?
- c) ¿Qué debería hacer el investigador?

3.12. Problema 12: Comparación de Modelos

Un investigador ajusta tres modelos para predecir puntaje en Saber Pro:

Modelo	Predictores	R^2	R^2_{adj}	AIC
M1	Saber 11 Mat.	0.42	0.42	4850
M2	M1 + Estrato	0.51	0.50	4720
M3	M2 + Tipo IES + Depto.	0.53	0.51	4710

Preguntas:

- a) ¿Por qué el R^2 siempre aumenta al agregar predictores?
- b) ¿Qué modelo tiene mejor ajuste considerando parsimonia (simplicidad)?
- c) ¿Vale la pena la complejidad adicional de M3 vs. M2?

4. Soluciones y Pistas

4.1. Problema 1

- a) Media < mediana sugiere ligera asimetría negativa (cola izquierda), confirmado por skewness = -0,28.
- b) $[\bar{x} - s, \bar{x} + s] = [37,7, 64,7]$ cubre $\mu \pm 1\sigma \approx 68\%$ bajo normalidad.

4.2. Problema 2

- a) $r = 0,62$ es correlación positiva moderada-fuerte. Estudiantes con alto puntaje en Saber 11 Mat. tienden a tener alto puntaje en Saber Pro Razonamiento.
- b) No. Correlación no implica causalidad. Variables como habilidad matemática general, calidad educativa, y nivel socioeconómico pueden influir en ambos puntajes.

4.3. Problema 3

- a) Por TCL, $\bar{X} \sim N(152, 19/\sqrt{100}) = N(152, 1,9)$.
- b) $z = (155 - 152)/1,9 \approx 1,58$. $P(\bar{X} > 155) = P(Z > 1,58) \approx 0,057$ (5.7%).
En R: `1 - pnorm(155, 152, 1.9)`

4.4. Problema 4

- a) $t_{0,025,49} \approx 2,01$. $IC = 168,5 \pm 2,01 \cdot (22,3/\sqrt{50}) = 168,5 \pm 6,34 = [162,2, 174,8]$.
En R: `t.test(datos)$conf.int`
- b) Con 95 % de confianza, el puntaje promedio poblacional en Inglés para estudiantes de NI está entre 162.2 y 174.8.

4.5. Problema 5

- a) $p = 0,0008 < 0,05$: rechazamos H_0 . Hay diferencia significativa; mujeres tienen puntaje promedio mayor (151.3 vs. 145.2).
- b) Cohen's $d = 0,35$ es un efecto pequeño-mediano. La diferencia es significativa pero la magnitud práctica es modesta.

4.6. Problema 6

- a) $F = 8,92$, $p = 0,0002 < 0,05$: hay diferencias significativas entre departamentos.
- b) Cundinamarca y Valle tienen desempeño similar (no difieren significativamente). Chocó y Guajira también probablemente son similares entre sí (ambos menores que Cundinamarca).

4.7. Problema 7

- a) Por cada punto adicional en Saber 11 Inglés, se espera un aumento de 1.42 puntos en Saber Pro Inglés.
- b) Cuando el puntaje en Saber 11 es 0, se predice 85.3 en Saber Pro. (Nota: esto es extrapolación fuera del rango de datos; tiene poco sentido práctico).
- c) $R^2 = 0,48$ significa que el puntaje en Saber 11 explica 48 % de la varianza en Saber Pro.
- d) $\hat{Y} = 85,3 + 1,42(50) = 85,3 + 71 = 156,3$.

4.8. Problema 8

- a) Por cada punto adicional en Mat. Saber 11, el puntaje en Razonamiento Cuantitativo aumenta 1.25 puntos, *manteniendo constante el estrato*.
- b) Por cada nivel adicional de estrato, el puntaje aumenta 3.80 puntos, *manteniendo constante el puntaje en Mat. Saber 11*.
- c) Sí, es significativo. $F = 315,8$, $p < 0,001$ indica que el modelo completo explica varianza significativa.
- d) Agregar estrato aumentó R^2 de 0.48 a 0.56, explicando 8 % adicional de varianza. El modelo múltiple es superior.

4.9. Problema 9

- a) Sí. $VIF > 5$ para Ingresos y Educación padre indica multicolinealidad problemática.
- b) Ingresos familiares y nivel educativo del padre están altamente correlacionados entre sí (lógico: familias con mayores ingresos tienden a tener padres con mayor educación).
- c) Remover uno de los dos predictores correlacionados (decidir cuál es más teóricamente relevante), o crear un índice compuesto de nivel socioeconómico.

4.10. Problema 10

- a) Sí. Gráfico de embudo y Breusch-Pagan ($p = 0,002 < 0,05$) indican heterocedasticidad.
- b) Los errores estándar robustos son mayores (6.8 vs. 5.2 para intercepto; 0.12 vs. 0.08 para pendiente). Esto refleja la mayor incertidumbre real.
- c) Los errores OLS subestiman la incertidumbre, llevando a ICs demasiado estrechos y valores p demasiado pequeños (falsos positivos). Los errores robustos corrigen esto.

4.11. Problema 11

- a) Cook's $D > 1$ (o $> 4/n \approx 0,033$ en este caso) indica que la observación tiene gran influencia en los coeficientes estimados.
- b) Las observaciones influyentes inflaron el coeficiente (de 1.12 a 2.35) y redujeron la significancia (de $p = 0,001$ a $p = 0,08$). Estaban distorsionando el resultado.
- c) Investigar las observaciones influyentes: ¿Son errores de datos? ¿Representan casos especiales? Si son datos válidos, reportar resultados con y sin ellas. El resultado sin influyentes (1.12, $p = 0,001$) parece más confiable.

4.12. Problema 12

- a) R^2 nunca disminuye al agregar predictores porque el modelo siempre puede asignar coeficiente 0 al nuevo predictor (en el peor caso). Por eso R^2_{adj} es mejor para comparar.
- b) M2 tiene buen balance: $R^2_{adj} = 0,50$ (solo 0.01 menos que M3) pero es más simple. AIC también favorece a M2 (menor es mejor; $M2 = 4720$ vs. $M3 = 4710$, diferencia pequeña).
- c) Probablemente no. M3 agrega complejidad (dos predictores adicionales) por ganancia mínima (R^2_{adj} sube solo de 0.50 a 0.51, AIC baja solo 10 puntos). M2 parece mejor opción por parsimonia.

Recomendaciones Finales

1. Repasar las guías de Parcial 1 y Parcial 2 como base.
2. Practicar interpretación de salidas de regresión en R (`summary(modelo)`).
3. Familiarizarse con diagnósticos: `plot(modelo)`, `vif()`, `bptest()`, gráficos de residuos.
4. Entender la diferencia entre significancia estadística y relevancia práctica.
5. Practicar la redacción de conclusiones en lenguaje claro, no solo técnico.

¡Mucho éxito en el examen final!