

Guía de Repaso — Parcial 1

Estadística 2026-II — Pontificia Universidad Javeriana

Fecha del examen: 4 de septiembre, 2026

Repositorio del curso: <https://github.com/polanco-jaime/Curso-Estadistica-2026-3>

Índice

1. Resumen de Conceptos Clave	2
1.1. Estadística Descriptiva	2
1.2. Visualización de Datos	2
1.3. Correlación	2
1.4. Distribución Normal	2
1.5. Teorema Central del Límite (TCL)	3
2. Fórmulas Importantes	4
2.1. Estadística Descriptiva	4
2.2. Correlación	4
2.3. Distribución Normal	4
3. Problemas de Práctica	5
3.1. Problema 1: Estadística Descriptiva	5
3.2. Problema 2: Interpretación de Visualizaciones	5
3.3. Problema 3: Correlación	5
3.4. Problema 4: Paradoja de Simpson	6
3.5. Problema 5: Cálculos con Distribución Normal	6
3.6. Problema 6: Teorema Central del Límite	6
3.7. Problema 7: Aplicación Integrada	7
3.8. Problema 8: Análisis de Datos en R	7
4. Soluciones y Pistas	8
4.1. Problema 1	8
4.2. Problema 2	8
4.3. Problema 3	8
4.4. Problema 4	8
4.5. Problema 5	8
4.6. Problema 6	9
4.7. Problema 7	9
4.8. Problema 8	9

1. Resumen de Conceptos Clave

1.1. Estadística Descriptiva

Medidas de tendencia central:

- **Media ($\bar{x}$):** promedio aritmético, sensible a valores extremos
- **Mediana:** valor que divide los datos en dos mitades, robusta a outliers
- **Moda:** valor más frecuente en el conjunto de datos

Medidas de dispersión:

- **Varianza (s^2):** dispersión promedio al cuadrado
- **Desviación estándar (s):** raíz cuadrada de la varianza, en las mismas unidades que los datos
- **Rango intercuartílico (IQR):** diferencia entre Q3 y Q1, robusta a outliers

Medidas de forma:

- **Asimetría (skewness):** positiva (cola derecha), negativa (cola izquierda), cero (simétrica)
- **Curtosis:** mide el “peso” de las colas; alta curtosis indica colas pesadas

1.2. Visualización de Datos

Histograma: muestra la distribución de frecuencias de una variable continua

Boxplot (diagrama de caja): muestra Q1, mediana, Q3, valores mínimo/máximo y outliers

Scatter plot (diagrama de dispersión): muestra la relación entre dos variables continuas

1.3. Correlación

Correlación de Pearson (r): mide la relación lineal entre dos variables continuas

- Rango: $-1 \leq r \leq 1$
- $r > 0$: relación positiva; $r < 0$: relación negativa; $r = 0$: sin relación lineal
- Sensible a outliers y relaciones no lineales

Correlación de Spearman (ρ): mide la relación monótona usando rangos

- Robusta a outliers y transformaciones monótonas
- Útil para relaciones no lineales pero monótonas

Paradoja de Simpson: una tendencia que aparece en varios grupos puede desaparecer o revertirse cuando se combinan los grupos. Siempre considerar variables de confusión (ej. tipo de IES, estrato, departamento).

1.4. Distribución Normal

Propiedades:

- Simétrica alrededor de la media μ
- Totalmente especificada por media μ y desviación estándar σ
- Regla empírica: 68 % de datos dentro de $\mu \pm \sigma$, 95 % dentro de $\mu \pm 2\sigma$, 99.7 % dentro de $\mu \pm 3\sigma$

Estandarización (z-score):

$$z = \frac{x - \mu}{\sigma}$$

Convierte cualquier normal a una normal estándar con $\mu = 0$ y $\sigma = 1$.

1.5. Teorema Central del Límite (TCL)

El TCL establece que la distribución de la media muestral $\bar{X}$ se aproxima a una distribución normal cuando el tamaño de muestra n es suficientemente grande, independientemente de la forma de la distribución poblacional.

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

donde μ es la media poblacional y σ es la desviación estándar poblacional.

Implicaciones:

- Permite usar la distribución normal para hacer inferencias sobre medias muestrales
- $n \geq 30$ generalmente es suficiente (menor si la población es aproximadamente normal)
- El error estándar de la media es $\sigma/\sqrt{n}$

2. Fórmulas Importantes

2.1. Estadística Descriptiva

Media:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Varianza muestral:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Desviación estándar muestral:

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Asimetría:

$$\text{Skewness} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$

Curtosis:

$$\text{Kurtosis} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4}$$

2.2. Correlación

Correlación de Pearson:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

2.3. Distribución Normal

Z-score:

$$z = \frac{x - \mu}{\sigma}$$

Distribución de la media muestral (TCL):

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Error estándar de la media:

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

3. Problemas de Práctica

3.1. Problema 1: Estadística Descriptiva

Se analizó el puntaje en la prueba de Matemáticas del examen Saber 11 para una muestra de 500 estudiantes de Bogotá. Los resultados fueron:

Estadístico	Valor
Media	58.4
Mediana	60.0
Desviación estándar	12.5
Asimetría	-0,35
Curtosis	2.8

Preguntas:

- ¿Qué indica la relación entre media y mediana sobre la forma de la distribución?
- ¿Cómo interpretaría el valor de asimetría?
- ¿Qué porcentaje aproximado de estudiantes tendría puntajes entre 45.9 y 70.9 (suponiendo distribución aproximadamente normal)?

3.2. Problema 2: Interpretación de Visualizaciones

Se crearon boxplots comparando los puntajes de Lectura Crítica en Saber 11 por estrato socioeconómico (1-2, 3-4, 5-6). Los resultados muestran:

- Estrato 1-2: Mediana = 48, $Q1 = 42$, $Q3 = 54$, varios outliers superiores
- Estrato 3-4: Mediana = 56, $Q1 = 50$, $Q3 = 62$, pocos outliers
- Estrato 5-6: Mediana = 65, $Q1 = 60$, $Q3 = 70$, sin outliers visibles

Preguntas:

- ¿Qué estrato muestra mayor variabilidad en los puntajes?
- ¿Cuál es el rango intercuartílico (IQR) para el estrato 3-4?
- ¿Qué indican los outliers en el estrato 1-2?

3.3. Problema 3: Correlación

Un estudio analizó la relación entre el puntaje de Inglés en Saber 11 (MOD_INGLES_PUNT) y el puntaje de Inglés en Saber Pro para 2,000 estudiantes. Los resultados fueron:

- Correlación de Pearson: $r = 0,68$
- Correlación de Spearman: $\rho = 0,72$

Preguntas:

- ¿Cómo interpretaría el valor de $r = 0,68$?
- ¿Por qué la correlación de Spearman es ligeramente mayor?
- ¿Puede concluir que un alto puntaje en Saber 11 *causa* un alto puntaje en Saber Pro? ¿Por qué?

3.4. Problema 4: Paradoja de Simpson

Se analizó la relación entre horas de estudio semanal y puntaje en Saber Pro para estudiantes de dos universidades:

Universidad Pública:

- Correlación horas-puntaje: $r = 0,45$ (positiva)

Universidad Privada:

- Correlación horas-puntaje: $r = 0,38$ (positiva)

Datos combinados (ambas universidades):

- Correlación horas-puntaje: $r = -0,12$ (negativa)

Información adicional:

- Estudiantes de universidad pública: media de horas = 15, puntaje medio = 48
- Estudiantes de universidad privada: media de horas = 8, puntaje medio = 62

Preguntas:

- a) ¿Por qué la correlación combinada es negativa cuando ambas correlaciones dentro de cada grupo son positivas?
- b) ¿Qué variable de confusión está presente?
- c) ¿Cuál correlación debería usar para entender la relación entre horas de estudio y puntaje?

3.5. Problema 5: Cálculos con Distribución Normal

Los puntajes en la prueba de Razonamiento Cuantitativo de Saber Pro se distribuyen aproximadamente normal con media $\mu = 150$ y desviación estándar $\sigma = 20$.

Preguntas:

- a) ¿Qué porcentaje de estudiantes obtiene un puntaje superior a 170?
- b) ¿Qué puntaje separa el 25 % inferior del 75 % superior?
- c) Un estudiante obtuvo un puntaje de 185. ¿Cuál es su z-score? ¿Qué indica este valor?

Nota: En R, usar `pnorm()` y `qnorm()` para estos cálculos.

3.6. Problema 6: Teorema Central del Límite

Una universidad desea estimar el puntaje promedio de sus estudiantes en Lectura Crítica (Saber Pro). Se sabe que la distribución de puntajes en la población estudiantil tiene media $\mu = 155$ y desviación estándar $\sigma = 18$.

Se toma una muestra aleatoria de $n = 64$ estudiantes.

Preguntas:

- a) ¿Cuál es la distribución de la media muestral $\bar{X}$? Especifique la media y el error estándar.
- b) ¿Cuál es la probabilidad de que la media muestral sea mayor a 158?
- c) Si el tamaño de muestra aumenta a $n = 256$, ¿cómo cambiaría el error estándar? ¿Qué implica esto para la precisión de la estimación?

3.7. Problema 7: Aplicación Integrada

Un investigador estudia la relación entre el puntaje de Ciencias Naturales en Saber 11 y el departamento de origen (Cundinamarca vs. Antioquia). Obtiene los siguientes resultados:

Cundinamarca ($n = 800$):

- Media = 52.3, DE = 11.2

Antioquia ($n = 750$):

- Media = 54.8, DE = 10.8

Preguntas:

- a) ¿Qué departamento muestra mayor variabilidad en los puntajes?
- b) Si se selecciona aleatoriamente un estudiante de Cundinamarca con puntaje 63.5, ¿cuál es su z-score?
- c) ¿Es apropiado usar el TCL para describir la distribución de la media muestral en cada departamento? ¿Por qué?

3.8. Problema 8: Análisis de Datos en R

Se le proporciona un conjunto de datos `saber11` con las variables: `PUNT_MATEMATICAS`, `ESTU_GENERO`, `FAMI ESTRATOVIVIENDA`.

Preguntas:

- a) Escriba el código R para calcular la media, mediana y desviación estándar de `PUNT_MATEMATICAS`.
- b) Escriba el código R para crear un boxplot de `PUNT_MATEMATICAS` por `ESTU_GENERO`.
- c) Escriba el código R para calcular la correlación de Pearson entre `PUNT_MATEMATICAS` y otra variable numérica (asuma que existe `PUNT_LECTURA`).

4. Soluciones y Pistas

4.1. Problema 1

- a) La media (58.4) es menor que la mediana (60.0), lo que sugiere una ligera asimetría negativa (cola izquierda).
- b) Asimetría = $-0,35$ confirma asimetría negativa leve; hay más datos concentrados en valores altos con una cola hacia valores bajos.
- c) Aproximadamente 68 %. El rango $[\bar{x} - s, \bar{x} + s] = [45,9, 70,9]$ corresponde a $\mu \pm 1\sigma$ bajo normalidad.

4.2. Problema 2

- a) Estrato 1-2 muestra mayor variabilidad: $IQR = Q3 - Q1 = 54 - 42 = 12$, comparado con 12 (estrato 3-4) y 10 (estrato 5-6). Además tiene outliers.
- b) $IQR = 62 - 50 = 12$.
- c) Los outliers superiores indican estudiantes de estrato bajo con puntajes excepcionalmente altos (posiblemente talento excepcional o acceso a mejores recursos educativos).

4.3. Problema 3

- a) $r = 0,68$ indica una correlación positiva moderada-fuerte. Estudiantes con alto puntaje en Saber 11 tienden a tener alto puntaje en Saber Pro.
- b) Spearman mayor sugiere que la relación monótona es más fuerte que la relación lineal; puede haber leve no linealidad o algunos outliers que afectan a Pearson.
- c) No. Correlación no implica causalidad. Otras variables (habilidad académica general, nivel socioeconómico, calidad de la IES) pueden explicar ambos puntajes.

4.4. Problema 4

- a) Es un ejemplo de la Paradoja de Simpson. Las universidades públicas y privadas tienen diferentes niveles base de puntajes y horas de estudio. Al combinar, la diferencia entre grupos domina la relación dentro de grupos.
- b) Tipo de universidad (pública vs. privada) es la variable de confusión.
- c) Las correlaciones dentro de cada grupo (0.45 y 0.38) son las relevantes para entender la relación verdadera entre horas y puntaje, controlando por tipo de IES.

4.5. Problema 5

- a) $z = (170 - 150)/20 = 1$. $P(X > 170) = P(Z > 1) = 1 - 0.8413 = 0.1587$, es decir, 15.87 %.
En R: `1 - pnorm(170, 150, 20)`.
- b) El percentil 25 (Q1). En R: `qnorm(0.25, 150, 20) ≈ 136,5`.
- c) $z = (185 - 150)/20 = 1,75$. El estudiante está 1.75 desviaciones estándar por encima de la media; es un puntaje alto (percentil ≈ 96).

4.6. Problema 6

- a) Por el TCL, $\bar{X} \sim N(\mu = 155, SE = \sigma/\sqrt{n} = 18/\sqrt{64} = 18/8 = 2,25)$.
- b) $z = (158 - 155)/2,25 = 1,33$. $P(\bar{X} > 158) = P(Z > 1,33) \approx 0,0918$, es decir, 9.18 %. En R: `1 - pnorm(158, 155, 2.25)`.
- c) Nuevo $SE = 18/\sqrt{256} = 18/16 = 1,125$. El error estándar se reduce a la mitad, mejorando la precisión (distribución de $\bar{X}$ más concentrada alrededor de μ).

4.7. Problema 7

- a) Cundinamarca muestra mayor variabilidad (DE = 11.2 vs. 10.8).
- b) $z = (63,5 - 52,3)/11,2 = 1,0$. El estudiante está 1 desviación estándar por encima de la media de Cundinamarca.
- c) Sí. Ambos tamaños de muestra ($n = 800,750$) son mucho mayores que 30, suficiente para que el TCL garantice que $\bar{X}$ sea aproximadamente normal.

4.8. Problema 8

a)

```
media <- mean(saber11$PUNT_MATEMATICAS, na.rm = TRUE)
mediana <- median(saber11$PUNT_MATEMATICAS, na.rm = TRUE)
de <- sd(saber11$PUNT_MATEMATICAS, na.rm = TRUE)
```

b)

```
boxplot(PUNT_MATEMATICAS ~ ESTU_GENERO,
        data = saber11,
        main = "Puntaje Matematicas por Genero",
        xlab = "Genero", ylab = "Puntaje")
```

c)

```
correlacion <- cor(saber11$PUNT_MATEMATICAS,
                   saber11$PUNT_LECTURA,
                   use = "complete.obs")
```