

PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ciencias Económicas y Administrativas

Estadística 2026-II — Prof. Jaime Polanco Jiménez

Problem Set 2

Correlación y Paradoja de Simpson

Asignado: Agosto 14 (Sesión 2) | Entrega: Agosto 21 (Sesión 3)

Repositorio: <https://github.com/polanco-jaime/Curso-Estadistica-2026-3>

Instrucciones. Este Problem Set es individual y se resuelve en R. La entrega es digital al inicio de la clase indicada. El código R debe incluirse.

Datos

Los datos se encuentran en el repositorio del curso en formato Parquet:

```
library(arrow)
saber_pro <- read_parquet("datos/saber_pro/saber_pro.parquet")
```

Diccionario de variables utilizadas:

Variable	Descripción	Tipo
MOD_INGLES_PUNT	Puntaje módulo de inglés	Numérico
MOD_RAZONA_CUANTITAT_PUNT	Puntaje razonamiento cuantitativo	Numérico
MOD_Lectura_CRITICA_PUNT	Puntaje lectura crítica	Numérico
MOD_COMPETEN_CIUdADA_PUNT	Puntaje competencias ciudadanas	Numérico
MOD_COMUNICA_ESCRITA_PUNT	Puntaje comunicación escrita	Numérico
MOD_INGLES_DESEM	Nivel MCER (A-, A1, A2, B1, B+)	Categorico
ESTU_GENERO	Género del estudiante	Categorico
INST_ORIGEN	Tipo de IES: Oficial / Privada	Categorico
FAMI ESTRATOVIVIENDA	Estrato socioeconómico (1-6)	Ordinal

Enunciado

- a) **Matriz de correlaciones:** usando los datos de Saber Pro, calcule la matriz de correlaciones de Pearson y de Spearman para los 5 módulos:

- MOD_INGLES_PUNT
- MOD_RAZONA_CUANTITAT_PUNT
- MOD_Lectura_CRITICA_PUNT
- MOD_COMPETEN_CIUdADA_PUNT
- MOD_COMUNI_ESCRITA_PUNT

Visualice ambas matrices con `corrplot` o un heatmap. ¿Qué pares de módulos tienen mayor y menor correlación? ¿Hay diferencias importantes entre Pearson y Spearman? ¿Por qué?

- b) **Tabla de contingencia:** construya una tabla de contingencia cruzando género (ESTU_GENERO) con nivel de inglés según el MCER (A−, A1, A2, B1, B+). Calcule las frecuencias absolutas y relativas. ¿Hay algún patrón visible?
- c) **Paradoja de Simpson:** demuestre la Paradoja de Simpson con datos ICFES. Busque una relación entre dos variables que cambie de dirección (o desaparezca) al controlar por una tercera variable.
- Sugerencia:* compare la correlación entre MOD_INGLES_PUNT y otra variable a nivel agregado vs. desagregado por tipo de IES (pública/privada) o por estrato.
- Presente gráficos que ilustren claramente cómo la relación se invierte o modifica al condicionar.
- d) **Conclusiones:** en un párrafo, explique por qué la Paradoja de Simpson es relevante para el análisis de política educativa. ¿Qué riesgos implica no controlar por variables confusoras?

Cada entrega completa suma +0.0625 a la nota final.