

PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ciencias Económicas y Administrativas

Estadística 2026-II — Prof. Jaime Polanco Jiménez

Problem Set 2

Correlación y Paradoja de Simpson

Asignado: Agosto 14 (Sesión 2) | Entrega: Agosto 21 (Sesión 3)

Repositorio: <https://github.com/polanco-jaime/Curso-Estadistica-2026-3>

Instrucciones. Este Problem Set es individual y se resuelve en R sobre microdatos ICFES. La entrega es digital al inicio de la clase indicada. El código R debe incluirse.

Enunciado

- a) **Matriz de correlaciones:** usando los datos de Saber Pro para Negocios Internacionales (NI), calcule la matriz de correlaciones de Pearson y de Spearman para los 5 módulos:

- MOD_INGLES_PUNT
- MOD_RAZONA_CUANTITAT_PUNT
- MOD_LECTURA_CRITICA_PUNT
- MOD_COMPETEN_CIUADADA_PUNT
- MOD_COMUNI_ESCRITA_PUNT

Visualice ambas matrices con `corrplot` o un heatmap. ¿Qué pares de módulos tienen mayor y menor correlación? ¿Hay diferencias importantes entre Pearson y Spearman? ¿Por qué?

- b) **Tabla de contingencia:** construya una tabla de contingencia cruzando género (ESTU_GENERO) con nivel de inglés según el MCER (A−, A1, A2, B1, B+). Calcule las frecuencias absolutas y relativas. ¿Hay algún patrón visible?
- c) **Paradoja de Simpson:** demuestre la Paradoja de Simpson con datos ICFES. Busque una relación entre dos variables que cambie de dirección (o desaparezca) al controlar por una tercera variable.

Sugerencia: compare la correlación entre MOD_INGLES_PUNT y otra variable a nivel agregado vs. desagregado por tipo de IES (pública/privada) o por estrato.

Presente gráficos que ilustren claramente cómo la relación se invierte o modifica al condicionar.

- d) **Conclusiones:** en un párrafo, explique por qué la Paradoja de Simpson es relevante para el análisis de política educativa. ¿Qué riesgos implica no controlar por variables confusoras?

Cada entrega completa suma +0.0625 a la nota final.