

PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ciencias Económicas y Administrativas

Estadística 2026-II — Prof. Jaime Polanco Jiménez

Problem Set 6

ANOVA, Pruebas No Paramétricas y Asociación Categórica

Asignado: Septiembre 25 (Sesión 6) | Entrega: Octubre 2 (Sesión 7)

Repositorio: <https://github.com/polanco-jaime/Curso-Estadistica-2026-3>

Instrucciones. Este Problem Set es individual y se resuelve en R. **Fecha límite de entrega:** el día anterior a la sesión indicada, a más tardar a las 11:59 p.m. (hora Colombia, UTC−5). Entregas tardías pierden el bono. El código R debe incluirse.

Datos

Los datos se encuentran en el repositorio del curso en formato Parquet:

```
library(arrow)
saber_pro <- read_parquet("datos/saber_pro/saber_pro.parquet")
```

Diccionario de variables utilizadas:

Variable	Descripción	Tipo
MOD_INGLES_PUNT	Puntaje módulo de inglés	N Numérico
MOD_INGLES_DESEM	Nivel MCER (A−, A1, A2, B1, B+)	C Categórico
FAMI ESTRATOVIVIENDA	Estrato socioeconómico (1–6)	O Ordinal
ESTU_GENERO	Género del estudiante	C Categórico

Enunciado

En este Problem Set explorará diferencias en el puntaje de inglés según diferentes variables categóricas, usando ANOVA, pruebas no paramétricas y medidas de asociación.

- 1) **ANOVA de una vía por estrato socioeconómico:** ¿varía el puntaje de inglés en Saber Pro (MOD_INGLES_PUNT) según el estrato socioeconómico de los estudiantes?

- a) Plantee las hipótesis del ANOVA:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k \quad \text{vs.} \quad H_1 : \text{al menos una media difiere}$$

donde k es el número de estratos.

- b) Verifique los supuestos del ANOVA:

- Normalidad por grupo (prueba de Shapiro-Wilk o Q-Q plots)
- Homocedasticidad (prueba de Levene)

- c) Aplique ANOVA usando `aov()` y reporte la tabla ANOVA (fuentes de variación, sumas de cuadrados, F , p -valor).

- d) Si rechaza H_0 : ¿cuál es el porcentaje de variabilidad explicado por el estrato (η^2)?

- 2) **Comparaciones múltiples con Tukey HSD:** si el ANOVA fue significativo, identifique cuáles pares de estratos difieren.

- a) Aplique la prueba de Tukey HSD (`TukeyHSD()`).
 - b) Reporte los intervalos de confianza ajustados al 95 % para todas las comparaciones por pares.
 - c) ¿Cuáles pares de estratos muestran diferencias significativas?
 - d) Grafique los intervalos de confianza de Tukey.
- 3) **Prueba de Mann-Whitney por género:** ¿difiere el puntaje de inglés entre hombres y mujeres en Saber Pro?
- a) Justifique por qué puede ser apropiado usar una prueba no paramétrica (Mann-Whitney) en lugar de la prueba t .
 - b) Plantee H_0 y H_1 en términos de medianas o rangos.
 - c) Aplique `wilcox.test()` y reporte el estadístico W y el p -valor.
 - d) Interprete el resultado: ¿rechaza H_0 al 5 %? ¿Qué grupo tiene mayor puntaje mediano?
- 4) **Prueba χ^2 de independencia: género $\times$ nivel MCER:** ¿existe asociación entre el género y el nivel de inglés según el MCER (A–, A1, A2, B1, B2) en Saber Pro?
- a) Construya una tabla de contingencia cruzando género con nivel MCER (`table()`).
 - b) Plantee H_0 (independencia) y H_1 (asociación).
 - c) Aplique la prueba χ^2 de independencia (`chisq.test()`) y reporte el estadístico χ^2 , grados de libertad y p -valor.
 - d) Verifique el supuesto: ¿todas las frecuencias esperadas son ≥ 5 ?
- 5) **Tamaño del efecto: V de Cramér:** cuantifique la fuerza de la asociación género–MCER.
- a) Calcule la V de Cramér:

$$V = \sqrt{\frac{\chi^2}{n \cdot (k - 1)}}$$
 donde $k = \text{mín}(\text{filas}, \text{columnas})$.
 - b) Interprete V según la convención (débil: $V < 0,1$; moderada: $0,1 \leq V < 0,3$; fuerte: $V \geq 0,3$).
 - c) ¿La asociación encontrada (si es significativa) tiene relevancia práctica?
- 6) **Conclusiones:** sintetice los hallazgos:
- a) ¿El estrato socioeconómico explica diferencias en el puntaje de inglés? ¿Cuáles estratos difieren?
 - b) ¿Existe brecha de género en inglés en Saber Pro?
 - c) ¿El nivel de inglés MCER está asociado con el género?

Cada entrega completa suma +0,0625 a la nota final.