

# PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ciencias Económicas y Administrativas

Estadística 2026-II — Prof. Jaime Polanco Jiménez

## Problem Set 7

Bondad de Ajuste y Regresión Lineal Simple

Asignado: Octubre 16 (Sesión 9) | Entrega: Octubre 30 (Sesión 10)

*Plazo extendido: 2 semanas*

---

Repositorio: <https://github.com/polanco-jaime/Curso-Estadistica-2026-3>

**Instrucciones.** Este Problem Set es individual y se resuelve en R. **Fecha límite de entrega: el día anterior a la sesión indicada, a más tardar a las 11:59 p.m. (hora Colombia, UTC−5).** Entregas tardías pierden el bono. El código R debe incluirse.

### Datos

Este PS utiliza los tres datasets del repositorio del curso:

```
library(arrow)
saber_pro <- read_parquet("datos/saber_pro/saber_pro.parquet")
saber11 <- read_parquet("datos/saber11/saber11.parquet")
cruce <- read_parquet("datos/cruce/cruce_saber11_saberpro.parquet")
```

### Diccionario de variables utilizadas:

| Variable               | Dataset   | Descripción                       | Tipo       |
|------------------------|-----------|-----------------------------------|------------|
| MOD_INGLES_PUNT        | Saber Pro | Puntaje módulo de inglés          | Numérico   |
| MOD_INGLES_DESEM       | Saber Pro | Nivel MCER (A−, A1, A2, B1, B+)   | Categorico |
| PUNT_INGLES            | Saber 11  | Puntaje prueba de inglés          | Numérico   |
| estu_consecutivo_sb11  | Cruce     | Llave para vincular con Saber 11  | ID         |
| estu_consecutivo_sbpro | Cruce     | Llave para vincular con Saber Pro | ID         |

*Para cruzar las bases, use el archivo de cruce que vincula **ESTU\_CONSECUTIVO** de Saber 11 con **ESTU\_CONSECUTIVO** de Saber Pro.*

### Enunciado

En este Problem Set evaluará si la distribución de niveles de inglés según el MCER es uniforme, y estimará un modelo de regresión lineal simple para predecir el rendimiento en Saber Pro a partir de Saber 11.

- 1) **Prueba  $\chi^2$  de bondad de ajuste:** ¿los niveles de inglés según el Marco Común Europeo de Referencia (MCER) se distribuyen uniformemente entre los estudiantes?
  - a) Construya una tabla de frecuencias observadas para los niveles MCER (A−, A1, A2, B1, B2) en la variable **MOD\_INGLES\_DESEM**.
  - b) Plantee las hipótesis:

$$H_0 : p_1 = p_2 = \dots = p_5 = \frac{1}{5} \quad \text{vs.} \quad H_1 : \text{al menos una } p_i \text{ difiere de } \frac{1}{5}$$

- c) Calcule las frecuencias esperadas bajo  $H_0$  (distribución uniforme).

- d) Aplique la prueba  $\chi^2$  de bondad de ajuste usando `chisq.test()` y reporte el estadístico  $\chi^2$ , grados de libertad y  $p$ -valor.
- e) ¿Rechaza  $H_0$  al nivel  $\alpha = 0,05$ ? Interprete el resultado: ¿qué niveles MCER están sobrerrepresentados o subrepresentados?

2) **Regresión lineal simple (OLS):** estime un modelo para predecir el puntaje de inglés en Saber Pro (`MOD_INGLES_PUNT`) a partir del puntaje de inglés en Saber 11 (`PUNT_INGLES`).

- a) Prepare los datos: cruce las bases de Saber 11 y Saber Pro usando el archivo de cruce (`cruce_saber11_saberpro.parquet`). Filtre estudiantes con datos completos en ambas pruebas.
- b) Grafique un diagrama de dispersión (scatterplot) de `PUNT_INGLES` (eje  $x$ ) vs. `MOD_INGLES_PUNT` (eje  $y$ ). ¿Observa una relación lineal?
- c) Estime el modelo OLS:

$$\text{MOD\_INGLES\_PUNT}_i = \beta_0 + \beta_1 \text{PUNT\_INGLES}_i + \varepsilon_i$$

usando `lm()` y presente el `summary()` completo.

- d) Interprete los coeficientes  $\hat{\beta}_0$  y  $\hat{\beta}_1$ :
  - ¿Qué representa  $\hat{\beta}_0$  (intercepto)?
  - ¿Qué representa  $\hat{\beta}_1$  (pendiente)? Si el puntaje de Saber 11 aumenta en 10 puntos, ¿cuánto se espera que aumente el puntaje de Saber Pro?

3) **Diagnóstico de residuos:** evalúe la calidad del ajuste del modelo OLS.

- a) Calcule los residuos  $\hat{\varepsilon}_i = y_i - \hat{y}_i$  y grafique:
  - Residuos vs. valores ajustados  $\hat{y}_i$
  - Q-Q plot de residuos
- b) Interprete los gráficos: ¿los residuos parecen cumplir los supuestos de linealidad, homocedasticidad y normalidad?
- c) Identifique las 3 observaciones con mayor residuo absoluto (outliers potenciales). ¿Qué características tienen?

4) **Bondad de ajuste ( $R^2$ ):** evalúe el poder explicativo del modelo.

- a) Reporte el coeficiente de determinación  $R^2$  y el  $R^2$  ajustado.
- b) Interprete  $R^2$ : ¿qué porcentaje de la variabilidad en el puntaje de Saber Pro es explicado por el puntaje de Saber 11?
- c) ¿El modelo tiene un buen ajuste? Justifique.

5) **Predicción:** use el modelo estimado para predecir el puntaje de Saber Pro de un estudiante que obtuvo 75 puntos en inglés en Saber 11.

- a) Calcule la predicción puntual  $\hat{y}$ .
- b) Calcule un intervalo de confianza al 95 % para la predicción usando `predict()` con `interval = "prediction"`.
- c) Interprete el intervalo: ¿en qué rango se espera que esté el puntaje de Saber Pro con 95 % de confianza?

6) **Conclusiones:** sintetice los hallazgos:

- a) ¿La distribución de niveles MCER es uniforme?

- b) ¿El puntaje de Saber 11 es un buen predictor del puntaje de Saber Pro en inglés?
- c) ¿Qué limitaciones tiene el modelo OLS simple estimado?

---

Cada entrega completa suma +0,0625 a la nota final.