

PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ciencias Económicas y Administrativas

Estadística 2026-II — Prof. Jaime Polanco Jiménez

Problem Set 7

Bondad de Ajuste y Regresión Lineal Simple

Asignado: Octubre 16 (Sesión 9) | Entrega: Octubre 30 (Sesión 10)

Plazo extendido: 2 semanas

Repositorio: <https://github.com/polanco-jaime/Curso-Estadistica-2026-3>

Instrucciones. Este Problem Set es individual y se resuelve en R. La entrega es digital al inicio de la clase indicada. El código R debe incluirse.

Datos

Este PS utiliza los tres datasets del repositorio del curso:

```
library(arrow)
saber_pro <- read_parquet("datos/saber_pro/saber_pro.parquet")
saber11 <- read_parquet("datos/saber11/saber11.parquet")
cruce <- read_parquet("datos/cruce/cruce_saber11_saberpro.parquet")
```

Diccionario de variables utilizadas:

Variable	Dataset	Descripción	Tipo
MOD_INGLES_PUNT	Saber Pro	Puntaje módulo de inglés	Numérico
MOD_INGLES_DESEM	Saber Pro	Nivel MCER (A-, A1, A2, B1, B+)	Categorico
PUNT_INGLES	Saber 11	Puntaje prueba de inglés	Numérico
estu_consecutivo_sb11	Cruce	Llave para vincular con Saber 11	ID
estu_consecutivo_sbpro	Cruce	Llave para vincular con Saber Pro	ID

*Para cruzar las bases, use el archivo de cruce que vincula **ESTU_CONSECUTIVO** de Saber 11 con **ESTU_CONSECUTIVO** de Saber Pro.*

Enunciado

En este Problem Set evaluará si la distribución de niveles de inglés según el MCER es uniforme, y estimará un modelo de regresión lineal simple para predecir el rendimiento en Saber Pro a partir de Saber 11.

- 1) **Prueba χ^2 de bondad de ajuste:** ¿los niveles de inglés según el Marco Común Europeo de Referencia (MCER) se distribuyen uniformemente entre los estudiantes?

- a) Construya una tabla de frecuencias observadas para los niveles MCER (A-, A1, A2, B1, B2) en la variable **MOD_INGLES_DESEM**.
- b) Plantee las hipótesis:

$$H_0 : p_1 = p_2 = \dots = p_5 = \frac{1}{5} \quad \text{vs.} \quad H_1 : \text{al menos una } p_i \text{ difiere de } \frac{1}{5}$$

- c) Calcule las frecuencias esperadas bajo H_0 (distribución uniforme).

- d) Aplique la prueba χ^2 de bondad de ajuste usando `chisq.test()` y reporte el estadístico χ^2 , grados de libertad y p -valor.
- e) ¿Rechaza H_0 al nivel $\alpha = 0,05$? Interprete el resultado: ¿qué niveles MCER están sobrerrepresentados o subrepresentados?

2) **Regresión lineal simple (OLS):** estime un modelo para predecir el puntaje de inglés en Saber Pro (`MOD_INGLES_PUNT`) a partir del puntaje de inglés en Saber 11 (`PUNT_INGLES`).

- a) Prepare los datos: cruce las bases de Saber 11 y Saber Pro usando el archivo de cruce (`cruce_saber11_saberpro.parquet`). Filtre estudiantes con datos completos en ambas pruebas.
- b) Grafique un diagrama de dispersión (scatterplot) de `PUNT_INGLES` (eje x) vs. `MOD_INGLES_PUNT` (eje y). ¿Observa una relación lineal?
- c) Estime el modelo OLS:

$$\text{MOD_INGLES_PUNT}_i = \beta_0 + \beta_1 \text{PUNT_INGLES}_i + \varepsilon_i$$

usando `lm()` y presente el `summary()` completo.

- d) Interprete los coeficientes $\hat{\beta}_0$ y $\hat{\beta}_1$:
 - ¿Qué representa $\hat{\beta}_0$ (intercepto)?
 - ¿Qué representa $\hat{\beta}_1$ (pendiente)? Si el puntaje de Saber 11 aumenta en 10 puntos, ¿cuánto se espera que aumente el puntaje de Saber Pro?

3) **Diagnóstico de residuos:** evalúe la calidad del ajuste del modelo OLS.

- a) Calcule los residuos $\hat{\varepsilon}_i = y_i - \hat{y}_i$ y grafique:
 - Residuos vs. valores ajustados $\hat{y}_i$
 - Q-Q plot de residuos
- b) Interprete los gráficos: ¿los residuos parecen cumplir los supuestos de linealidad, homocedasticidad y normalidad?
- c) Identifique las 3 observaciones con mayor residuo absoluto (outliers potenciales). ¿Qué características tienen?

4) **Bondad de ajuste (R^2):** evalúe el poder explicativo del modelo.

- a) Reporte el coeficiente de determinación R^2 y el R^2 ajustado.
- b) Interprete R^2 : ¿qué porcentaje de la variabilidad en el puntaje de Saber Pro es explicado por el puntaje de Saber 11?
- c) ¿El modelo tiene un buen ajuste? Justifique.

5) **Predicción:** use el modelo estimado para predecir el puntaje de Saber Pro de un estudiante que obtuvo 75 puntos en inglés en Saber 11.

- a) Calcule la predicción puntual $\hat{y}$.
- b) Calcule un intervalo de confianza al 95 % para la predicción usando `predict()` con `interval = "prediction"`.
- c) Interprete el intervalo: ¿en qué rango se espera que esté el puntaje de Saber Pro con 95 % de confianza?

6) **Conclusiones:** sintetice los hallazgos:

- a) ¿La distribución de niveles MCER es uniforme?

- b) ¿El puntaje de Saber 11 es un buen predictor del puntaje de Saber Pro en inglés?
- c) ¿Qué limitaciones tiene el modelo OLS simple estimado?

Cada entrega completa suma +0,0625 a la nota final.