

PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ciencias Económicas y Administrativas

Estadística 2026-II — Prof. Jaime Polanco Jiménez

Problem Set 8

Regresión Lineal Múltiple y Diagnósticos Avanzados

Asignado: Octubre 30 (Sesión 10) | Entrega: Noviembre 13 (Sesión 12)

Plazo extendido: 2 semanas

Repositorio: <https://github.com/polanco-jaime/Curso-Estadistica-2026-3>

Instrucciones. Este Problem Set es individual y se resuelve en R. La entrega es digital al inicio de la clase indicada. El código R debe incluirse. Este PS integra los conceptos de regresión múltiple y diagnósticos avanzados como cierre del curso.

Datos

Este PS utiliza los tres datasets del repositorio del curso:

```
library(arrow)
saber_pro <- read_parquet("datos/saber_pro/saber_pro.parquet")
saber11   <- read_parquet("datos/saber11/saber11.parquet")
cruce     <- read_parquet("datos/cruce/cruce_saber11_saberpro.parquet")
```

Diccionario de variables utilizadas:

Variable	Dataset	Descripción	Tipo
MOD_INGLES_PUNT	Saber Pro	Puntaje inglés (variable dependiente)	Numérico
PUNT_INGLES	Saber 11	Puntaje inglés	Numérico
PUNT_MATEMATICAS	Saber 11	Puntaje matemáticas	Numérico
PUNT_LECTURA_CRITICA	Saber 11	Puntaje lectura crítica	Numérico
PUNT_SOCIALES_CIUDADANAS	Saber 11	Puntaje sociales y ciudadanas	Numérico
PUNT_C_NATURALES	Saber 11	Puntaje ciencias naturales	Numérico
estu_consecutivo_sb11	Cruce	Llave para vincular con Saber 11	ID
estu_consecutivo_sbpro	Cruce	Llave para vincular con Saber Pro	ID

Use el archivo de *cruce* para vincular *ESTU_CONSECUTIVO* de *Saber 11* con *ESTU_CONSECUTIVO* de *Saber Pro*.

Enunciado

En este Problem Set (capstone) estimará un modelo de regresión lineal múltiple para predecir el puntaje de inglés en Saber Pro usando múltiples regresores de Saber 11, y realizará un diagnóstico exhaustivo del modelo.

- 1) **Modelo OLS múltiple con regresores de Saber 11:** estime un modelo para predecir `MOD_INGLES_PUNT` (Saber Pro) usando **al menos 4 regresores** del examen Saber 11:
 - a) Seleccione 4 o más variables de Saber 11 como regresores. Sugerencias:
 - `PUNT_INGLES` (inglés)
 - `PUNT_MATEMATICAS` (matemáticas)
 - `PUNT_LECTURA_CRITICA` (lectura crítica)

- PUNT_SOCIALES_CIUDADANAS (sociales y ciudadanas)
- PUNT_C_NATURALES (ciencias naturales)

b) Estime el modelo OLS:

$$\text{MOD_INGLES_PUNT}_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

usando `lm()` y presente el `summary()` completo.

c) Interprete cada coeficiente $\hat{\beta}_j$ en contexto. ¿Cuál regresor tiene el mayor efecto sobre el puntaje de inglés en Saber Pro?

2) **Multicolinealidad: Factor de Inflación de la Varianza (VIF):** evalúe si existe multicolinealidad entre los regresores.

- a) Calcule el VIF para cada regresor usando `car::vif()`.
- b) Reporte los valores de VIF. ¿Hay algún regresor con $\text{VIF} > 5$ o $\text{VIF} > 10$?
- c) Si hay multicolinealidad alta, ¿qué implica para la precisión de las estimaciones de los coeficientes?
- d) ¿Considera necesario eliminar algún regresor del modelo? Justifique.

3) **Sesgo por variable omitida (OV):** compare el coeficiente de PUNT_INGLES en dos modelos para ilustrar el sesgo por omisión de variables:

a) Estime un modelo simple:

$$\text{MOD_INGLES_PUNT}_i = \gamma_0 + \gamma_1 \text{PUNT_INGLES}_i + u_i$$

- b) Compare $\hat{\gamma}_1$ (modelo simple) con $\hat{\beta}_1$ (modelo múltiple del punto 1).
- c) ¿Cambió el coeficiente? ¿En qué dirección (aumentó o disminuyó)?
- d) Explique el sesgo por variable omitida: ¿por qué el modelo simple sobrestima o subestima el efecto de PUNT_INGLES?

4) **Diagnósticos gráficos: 4 gráficos base:** produzca los 4 gráficos diagnósticos estándar de `plot(modelo)` para el modelo múltiple:

- a) Residuos vs. valores ajustados
- b) Q-Q plot de residuos
- c) Scale-Location (raíz de residuos estandarizados vs. ajustados)
- d) Residuos vs. leverage (con curvas de distancia de Cook)

Interprete cada gráfico: ¿qué supuesto evalúa (linealidad, homocedasticidad, normalidad, observaciones influyentes) y qué concluye?

5) **Prueba de heterocedasticidad (Breusch-Pagan):** evalúe si los errores tienen varianza constante.

a) Plantee las hipótesis:

$$H_0 : \text{homocedasticidad} \quad \text{vs.} \quad H_1 : \text{heterocedasticidad}$$

- b) Aplique la prueba de Breusch-Pagan usando `lmtest::bptest()`.
- c) Reporte el estadístico de prueba y el p -valor.
- d) ¿Rechaza H_0 al 5 %? ¿Qué implica para los errores estándar OLS si hay heterocedasticidad?

- 6) **Observaciones influyentes: distancia de Cook:** identifique observaciones que tienen influencia desproporcionada en el modelo.
- Calcule la distancia de Cook para cada observación usando `cooks.distance()`.
 - Identifique las 5 observaciones más influyentes (mayor distancia de Cook).
 - ¿Alguna observación supera el umbral $D_i > 4/n$?
 - Examine esas observaciones: ¿qué características tienen? ¿Son outliers genuinos o datos atípicos válidos?
- 7) **Errores estándar robustos (HC1):** si detectó heterocedasticidad, reestime los errores estándar usando la corrección de Huber-White.
- Use `sandwich::vcovHC()` con `type = "HC1"` para calcular la matriz de varianza-covarianza robusta.
 - Reporte los coeficientes con errores estándar robustos usando `lmtest::coeftest()`.
 - Compare los errores estándar OLS (del punto 1) con los robustos. ¿Cuáles son más grandes?
 - ¿Cambian las conclusiones de significancia estadística para algún regresor?
- 8) **Bondad de ajuste y comparación de modelos:** evalúe el poder explicativo del modelo.
- Reporte R^2 y R^2 ajustado del modelo múltiple.
 - Compare el R^2 del modelo múltiple con el R^2 del modelo simple del punto 3. ¿Cuánto aumenta el poder explicativo al incluir más regresores?
 - ¿El aumento en R^2 justifica la complejidad adicional del modelo? (Use el criterio del R^2 ajustado).
- 9) **Conclusiones y recomendaciones finales:** sintetice el análisis completo.
- ¿Cuáles son los principales determinantes del puntaje de inglés en Saber Pro para estudiantes?
 - ¿El modelo cumple razonablemente los supuestos de Gauss-Markov? ¿Qué violaciones identificó?
 - Si tuviera que recomendar un solo ajuste al modelo para mejorar su validez, ¿cuál sería? (Ejemplos: eliminar un regresor por VIF alto, usar errores robustos, excluir outliers, transformar variables).
 - ¿El modelo tiene utilidad práctica para predecir el rendimiento en Saber Pro de futuros estudiantes?

Cada entrega completa suma +0,0625 a la nota final.