

PONTIFICIA UNIVERSIDAD JAVERIANA

Facultad de Ciencias Económicas y Administrativas

Estadística 2026-II — Prof. Jaime Polanco Jiménez

Problem Set 8

Regresión Lineal Múltiple y Diagnósticos Avanzados

Asignado: Octubre 30 (Sesión 10) | Entrega: Noviembre 13 (Sesión 12)

Plazo extendido: 2 semanas

Repositorio: <https://github.com/polanco-jaime/Curso-Estadistica-2026-3>

Instrucciones. Este Problem Set es individual y se resuelve en R. **Fecha límite de entrega:** el día anterior a la sesión indicada, a más tardar a las 11:59 p.m. (hora Colombia, UTC−5). Entregas tardías pierden el bono. El código R debe incluirse. Este PS integra los conceptos de regresión múltiple y diagnósticos avanzados como cierre del curso.

Datos

Este PS utiliza los tres datasets del repositorio del curso:

```
library(arrow)
saber_pro <- read_parquet("datos/saber_pro/saber_pro.parquet")
saber11   <- read_parquet("datos/saber11/saber11.parquet")
cruce     <- read_parquet("datos/cruce/cruce_saber11_saberpro.parquet")
```

Diccionario de variables utilizadas:

Variable	Dataset	Descripción	Tipo
MOD_INGLES_PUNT	Saber Pro	Puntaje inglés (variable dependiente)	Numérico
PUNT_INGLES	Saber 11	Puntaje inglés	Numérico
PUNT_MATEMATICAS	Saber 11	Puntaje matemáticas	Numérico
PUNT_LECTURA_CRITICA	Saber 11	Puntaje lectura crítica	Numérico
PUNT_SOCIALES_CIUDADANAS	Saber 11	Puntaje sociales y ciudadanas	Numérico
PUNT_C_NATURALES	Saber 11	Puntaje ciencias naturales	Numérico
estu_consecutivo_sb11	Cruce	Llave para vincular con Saber 11	ID
estu_consecutivo_sbpro	Cruce	Llave para vincular con Saber Pro	ID

Use el archivo de cruce para vincular ESTU_CONSECUTIVO de Saber 11 con ESTU_CONSECUTIVO de Saber Pro.

Enunciado

En este Problem Set (capstone) estimará un modelo de regresión lineal múltiple para predecir el puntaje de inglés en Saber Pro usando múltiples regresores de Saber 11, y realizará un diagnóstico exhaustivo del modelo.

- 1) **Modelo OLS múltiple con regresores de Saber 11:** estime un modelo para predecir MOD_INGLES_PUNT (Saber Pro) usando **al menos 4 regresores** del examen Saber 11:

a) Seleccione 4 o más variables de Saber 11 como regresores. Sugerencias:

- PUNT_INGLES (inglés)
- PUNT_MATEMATICAS (matemáticas)

- PUNT_LECTURA_CRITICA (lectura crítica)
- PUNT_SOCIALES_CIUDADANAS (sociales y ciudadanas)
- PUNT_C_NATURALES (ciencias naturales)

b) Estime el modelo OLS:

$$\text{MOD_INGLES_PUNT}_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

usando `lm()` y presente el `summary()` completo.

c) Interprete cada coeficiente $\hat{\beta}_j$ en contexto. ¿Cuál regresor tiene el mayor efecto sobre el puntaje de inglés en Saber Pro?

2) **Multicolinealidad: Factor de Inflación de la Varianza (VIF):** evalúe si existe multicolinealidad entre los regresores.

- a) Calcule el VIF para cada regresor usando `car::vif()`.
- b) Reporte los valores de VIF. ¿Hay algún regresor con $\text{VIF} > 5$ o $\text{VIF} > 10$?
- c) Si hay multicolinealidad alta, ¿qué implica para la precisión de las estimaciones de los coeficientes?
- d) ¿Considera necesario eliminar algún regresor del modelo? Justifique.

3) **Sesgo por variable omitida (OVB):** compare el coeficiente de PUNT_INGLES en dos modelos para ilustrar el sesgo por omisión de variables:

a) Estime un modelo simple:

$$\text{MOD_INGLES_PUNT}_i = \gamma_0 + \gamma_1 \text{PUNT_INGLES}_i + u_i$$

- b) Compare $\hat{\gamma}_1$ (modelo simple) con $\hat{\beta}_1$ (modelo múltiple del punto 1).
- c) ¿Cambió el coeficiente? ¿En qué dirección (aumentó o disminuyó)?
- d) Explique el sesgo por variable omitida: ¿por qué el modelo simple sobrestima o subestima el efecto de PUNT_INGLES?

4) **Diagnósticos gráficos: 4 gráficos base:** produzca los 4 gráficos diagnósticos estándar de `plot(modelo)` para el modelo múltiple:

- a) Residuos vs. valores ajustados
- b) Q-Q plot de residuos
- c) Scale-Location (raíz de residuos estandarizados vs. ajustados)
- d) Residuos vs. leverage (con curvas de distancia de Cook)

Interprete cada gráfico: ¿qué supuesto evalúa (linealidad, homocedasticidad, normalidad, observaciones influyentes) y qué concluye?

5) **Prueba de heterocedasticidad (Breusch-Pagan):** evalúe si los errores tienen varianza constante.

a) Plantee las hipótesis:

$$H_0 : \text{homocedasticidad} \quad \text{vs.} \quad H_1 : \text{heterocedasticidad}$$

- b) Aplique la prueba de Breusch-Pagan usando `lmtest::bptest()`.
- c) Reporte el estadístico de prueba y el p -valor.

- d) ¿Rechaza H_0 al 5 %? ¿Qué implica para los errores estándar OLS si hay heterocedasticidad?
- 6) **Observaciones influyentes: distancia de Cook:** identifique observaciones que tienen influencia desproporcionada en el modelo.
- Calcule la distancia de Cook para cada observación usando `cooks.distance()`.
 - Identifique las 5 observaciones más influyentes (mayor distancia de Cook).
 - ¿Alguna observación supera el umbral $D_i > 4/n$?
 - Examine esas observaciones: ¿qué características tienen? ¿Son outliers genuinos o datos atípicos válidos?
- 7) **Errores estándar robustos (HC1):** si detectó heterocedasticidad, reestime los errores estándar usando la corrección de Huber-White.
- Use `sandwich::vcovHC()` con `type = "HC1"` para calcular la matriz de varianza-covarianza robusta.
 - Reporte los coeficientes con errores estándar robustos usando `lmtest::coeftest()`.
 - Compare los errores estándar OLS (del punto 1) con los robustos. ¿Cuáles son más grandes?
 - ¿Cambian las conclusiones de significancia estadística para algún regresor?
- 8) **Bondad de ajuste y comparación de modelos:** evalúe el poder explicativo del modelo.
- Reporte R^2 y R^2 ajustado del modelo múltiple.
 - Compare el R^2 del modelo múltiple con el R^2 del modelo simple del punto 3. ¿Cuánto aumenta el poder explicativo al incluir más regresores?
 - ¿El aumento en R^2 justifica la complejidad adicional del modelo? (Use el criterio del R^2 ajustado).
- 9) **Conclusiones y recomendaciones finales:** sintetice el análisis completo.
- ¿Cuáles son los principales determinantes del puntaje de inglés en Saber Pro para estudiantes?
 - ¿El modelo cumple razonablemente los supuestos de Gauss-Markov? ¿Qué violaciones identificó?
 - Si tuviera que recomendar un solo ajuste al modelo para mejorar su validez, ¿cuál sería? (Ejemplos: eliminar un regresor por VIF alto, usar errores robustos, excluir outliers, transformar variables).
 - ¿El modelo tiene utilidad práctica para predecir el rendimiento en Saber Pro de futuros estudiantes?

Cada entrega completa suma +0,0625 a la nota final.