

Sesión 1: Estadística Descriptiva Numérica

Introducción al curso y medidas numéricas

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Vie 31 jul 2026

Agenda

Introducción al curso

Medidas de tendencia central

Medidas de dispersión

Forma de la distribución

Percentiles y cuartiles

Aplicación con datos ICFES

Resumen y próxima sesión

¿Qué es la estadística?

Definición

La estadística es la ciencia de recolectar, organizar, analizar e interpretar datos para tomar decisiones informadas bajo incertidumbre.

Estadística Descriptiva

- Resumir y visualizar datos
- Medidas numéricas (media, mediana, desviación estándar)
- Gráficos (histogramas, box plots, scatter plots)
- Describe lo que ya tenemos

Estadística Inferencial

- Generalizar desde una muestra a la población
- Intervalos de confianza
- Pruebas de hipótesis
- Regresión y predicción
- Infiere sobre lo que no observamos

Datos ICFES: Saber 11 y Saber Pro

¿Qué es el ICFES?

Instituto Colombiano para la Evaluación de la Educación. Realiza exámenes estandarizados para evaluar la calidad educativa en Colombia.

- **Saber 11:** examen al finalizar la educación media (bachillerato)
 - Módulos: Lectura Crítica, Matemáticas, Sociales, Ciencias Naturales, Inglés
 - Usado para admisión universitaria
- **Saber Pro:** examen al finalizar la educación superior (último año de pregrado)
 - Módulos genéricos: Lectura Crítica, Razonamiento Cuantitativo, Competencias Ciudadanas, Comunicación Escrita, Inglés
 - Módulos específicos por programa (ej: Gestión Financiera para NI)

En este curso trabajaremos con datos reales de estudiantes del programa de Negocios Internacionales (NI)

Variable central: MOD_INGLES_PUNT

¿Por qué el puntaje de inglés?

Para estudiantes de Negocios Internacionales, la competencia en inglés es un **proxy de competitividad internacional**:

- Comunicación con clientes y proveedores internacionales
- Acceso a información y literatura de negocios global
- Movilidad laboral y oportunidades en empresas multinacionales
- Negociación en mercados internacionales

Preguntas que exploraremos:

- ¿Cuál es el puntaje promedio en inglés de estudiantes de NI?
- ¿Cómo varía según tipo de institución (pública vs privada)?
- ¿Cómo varía según estrato socioeconómico?
- ¿Está relacionado con el desempeño en Saber 11?
- ¿Hay diferencias regionales (por departamento)?

Software: R y RStudio

¿Qué es R?

- Lenguaje de programación estadística
- Software libre y de código abierto
- Más de 19,000 paquetes disponibles
- Estándar en investigación y análisis de datos

¿Qué es RStudio?

- Entorno de desarrollo integrado (IDE) para R
- Editor de código, consola, gráficos, ayuda
- Gestión de proyectos
- Integración con Git, Markdown, Shiny

Instalación:

1. Descargar R desde <https://cran.r-project.org>
2. Descargar RStudio desde <https://posit.co/download/rstudio-desktop/>

```
# Primeros comandos en R  
2 + 3  
x <- 10
```

Tipos de datos

Datos categóricos (cualitativos)

Describen cualidades o características. No tienen un orden numérico natural.

- **Nominal**: sin orden (ej: tipo de IES [pública, privada], departamento)
- **Ordinal**: con orden (ej: estrato [1, 2, 3, 4, 5, 6], nivel educativo)

Datos cuantitativos (numéricos)

Representan cantidades medibles.

- **Intervalo**: diferencias significativas, pero no hay cero absoluto (ej: temperatura en °C)
- **Razón**: hay cero absoluto, se pueden hacer cocientes (ej: puntajes ICFES, edad, ingreso)

Ejemplo

MOD_INGLÉS_PUNTES es cuantitativa de razón (0 = ausencia total de conocimiento).

Datos de corte transversal vs series de tiempo

Corte transversal (cross-section)

- Observaciones de múltiples unidades en un **único momento en el tiempo**
- Ejemplo: puntajes Saber Pro 2024 de todos los estudiantes de NI
- Nos permite comparar entre individuos, instituciones, regiones

Series de tiempo (time series)

- Observaciones de una unidad a lo largo del **tiempo**
- Ejemplo: puntaje promedio en inglés de NI entre 2015 y 2025
- Nos permite identificar tendencias, estacionalidad

En este curso

Trabajaremos principalmente con **datos de corte transversal**: estudiantes de NI en Saber Pro 2023 y 2024.

Media aritmética

Definición

La **media aritmética** (o promedio) es la suma de los valores dividida por el número de observaciones.

Media muestral (estadístico):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

donde n = tamaño de la muestra

Media poblacional (parámetro):

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$

donde N = tamaño de la población

Ejemplo: puntajes de inglés de 5 estudiantes NI

Puntajes Saber Pro: 145, 160, 155, 170, 150

$$\bar{x} = \frac{145 + 160 + 155 + 170 + 150}{5} = \frac{780}{5} = 156$$

Media aritmética en R

```
# Cargar datos (ejemplo simulado)
library(tidyverse)

# Vector de puntajes
puntajes <- c(145, 160, 155, 170, 150, 162, 158, 149, 165, 153)

# Calcular la media
mean(puntajes)
# [1] 156.7

# Con datos faltantes (NA), usar na.rm = TRUE
puntajes_na <- c(145, 160, NA, 170, 150)
mean(puntajes_na, na.rm = TRUE)
# [1] 156.25

# Cargar datos ICFES completos
icfes <- read_csv("datos/saber_pro_ni_2024.csv")
mean(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
```

Media ponderada

Definición

La **media ponderada** asigna pesos diferentes a cada observación según su importancia.

$$\bar{x}_w = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$$

donde w_i es el peso de la observación i

Ejemplo: índice de calificaciones de NI

Estadística I tiene tres componentes:

- Talleres: 3.8 (peso 25 %)
- Parcial: 4.2 (peso 35 %)
- Proyecto final: 4.5 (peso 40 %)

$$\bar{x}_w = \frac{0,25(3,8) + 0,35(4,2) + 0,40(4,5)}{0,25 + 0,35 + 0,40} = \frac{4,22}{1} = 4,22$$

Mediana

Definición

La **mediana** es el valor que divide los datos ordenados en dos mitades iguales. 50 % de las observaciones están por debajo y 50 % por encima.

Procedimiento:

1. Ordenar los datos de menor a mayor
2. Si n es impar: la mediana es el valor central
3. Si n es par: la mediana es el promedio de los dos valores centrales

Ejemplo (n impar):

Datos: 145, 150, 155, 160, 170

Mediana = 155

Ejemplo (n par):

Datos: 145, 150, 155, 160, 165, 170

Mediana = $(155+160)/2 = 157.5$

Propiedad clave

La mediana es **robusta a outliers** (valores extremos no la afectan mucho).

Mediana en R

```
# Vector de puntajes
puntajes <- c(145, 150, 155, 160, 170)
median(puntajes)
# [1] 155

# Puntajes con un valor extremo
puntajes_outlier <- c(145, 150, 155, 160, 250)
mean(puntajes_outlier) # [1] 172 (afectada por el outlier)
median(puntajes_outlier) # [1] 155 (no afectada)

# Con datos ICFES
median(icfes$MOD_INGLES_PUNT, na.rm = TRUE)

# Comparar media vs mediana
summary(icfes$MOD_INGLES_PUNT)
```

Interpretación: Si $\text{media} > \text{mediana}$, distribución sesgada a la derecha (cola larga hacia valores altos). Si $\text{media} < \text{mediana}$, sesgada a la izquierda.

Moda

Definición

La **moda** es el valor que aparece con mayor frecuencia en los datos.

- Datos pueden ser **unimodales** (una moda), **bimodales** (dos modas), o **multimodales**
- Es la única medida de tendencia central aplicable a datos categóricos
- Para datos continuos, es más útil identificar la región con mayor concentración

Ejemplo

Puntajes: 150, 155, 155, 160, 155, 165, 170, 155

Moda = 155 (aparece 4 veces)

Ejemplo bimodal

Estrato: 2, 2, 2, 3, 4, 5, 5, 5, 6

Modas = 2 y 5 (ambas aparecen 3 veces)

Moda en R

```
# R no tiene una funcion integrada para moda
# Opcion 1: usar table() para ver frecuencias
puntajes <- c(150, 155, 155, 160, 155, 165, 170, 155)
table(puntajes)
# puntajes
# 150 155 160 165 170
#   1   4   1   1   1

# Opcion 2: funcion personalizada
moda <- function(x) {
  freq <- table(x)
  as.numeric(names(freq)[which.max(freq)])
}
moda(puntajes)
# [1] 155

# Para categoricas
table(icfes$ESTU_DEPTO_RESIDE)
# Muestra frecuencia por departamento
```

¿Cuándo usar cada medida?

Medida	Cuándo usar	Ventajas / Desventajas
Media	Distribuciones simétricas, datos numéricos	Usa toda la información; sensible a outliers
Mediana	Distribuciones sesgadas, presencia de outliers	Robusta; ignora valores extremos
Moda	Datos categóricos, distribuciones multimodales	Única para categorías; puede no existir o no ser única

Regla práctica

- Distribución simétrica: $\text{media} \approx \text{mediana} \approx \text{moda}$
- Sesgada a la derecha: $\text{moda} < \text{mediana} < \text{media}$
- Sesgada a la izquierda: $\text{media} < \text{mediana} < \text{moda}$

Rango

Definición

El **rango** es la diferencia entre el valor máximo y el valor mínimo.

$$\text{Rango} = \text{máx}(x) - \text{mín}(x)$$

- Medida más simple de dispersión
- Muy sensible a outliers (basta un valor extremo para inflarlo)
- No usa información de los valores intermedios

Ejemplo

Puntajes: 145, 150, 155, 160, 170

Rango = $170 - 145 = 25$ puntos

Ejemplo con outlier

Puntajes: 145, 150, 155, 160, 250

Rango = $250 - 145 = 105$ puntos (mucho mayor)

Rango intercuartílico (IQR)

Definición

El **rango intercuartílico** (IQR) es la diferencia entre el tercer cuartil (Q_3) y el primer cuartil (Q_1). Contiene el 50 % central de los datos.

$$IQR = Q_3 - Q_1$$

- Robusto a outliers (ignora el 25 % más bajo y el 25 % más alto)
- Usado en box plots para identificar outliers
- Outlier si: $x < Q_1 - 1,5 \times IQR$ o $x > Q_3 + 1,5 \times IQR$

Ejemplo

Si $Q_1 = 150$ y $Q_3 = 165$:

$$IQR = 165 - 150 = 15$$

$$\text{Límite inferior outlier: } 150 - 1.5(15) = 127.5$$

$$\text{Límite superior outlier: } 165 + 1.5(15) = 187.5$$

Rango e IQR en R

```
# Rango
puntajes <- c(145, 150, 155, 160, 165, 170)
range(puntajes)
# [1] 145 170
diff(range(puntajes))
# [1] 25

# Rango intercuartilico
IQR(puntajes)
# [1] 15

# Cuartiles
quantile(puntajes, probs = c(0.25, 0.75))
# 25% 75%
# 151.25 163.75

# Con datos ICFES
summary(icfes$MOD_INGLES_PUNT)
IQR(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
```

Varianza

Definición

La **varianza** mide la dispersión promedio de los datos respecto a la media. Es el promedio de las desviaciones cuadradas.

Varianza muestral:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Varianza poblacional:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

¿Por qué $n - 1$ y no n ?

Dividir por $n - 1$ (grados de libertad) hace que s^2 sea un **estimador insesgado** de σ^2 .
Dividir por n subestimaría la varianza poblacional sistemáticamente.

Propiedades:

- Siempre $s^2 \geq 0$

- Unidades: cuadrado de las unidades originales (puntos²)

Desviación estándar

Definición

La **desviación estándar** es la raíz cuadrada positiva de la varianza. Mide la dispersión en las mismas unidades que los datos.

Desviación estándar muestral:

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Desviación estándar poblacional:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

Interpretación:

- Mide cuánto se desvían los datos de la media **en promedio**
- s pequeña: datos concentrados cerca de $\bar{x}$
- s grande: datos dispersos, alejados de $\bar{x}$
- Mismas unidades que los datos originales (más interpretable que s^2)

Varianza y desviación estándar en R (1/2)

```
puntajes <- c(145, 150, 155, 160, 165, 170)

# Varianza (usa n-1)
var(puntajes)
# [1] 104.1667

# Desviacion estandar
sd(puntajes)
# [1] 10.20621

# Verificar que sd = sqrt(var)
sqrt(var(puntajes))
# [1] 10.20621
```

Varianza y desviación estándar en R (2/2)

```
# Calculo manual (para entender)
puntajes <- c(145, 150, 155, 160, 165, 170)
n <- length(puntajes)
media <- mean(puntajes)
varianza_manual <- sum((puntajes - media)^2) / (n - 1)
varianza_manual
# [1] 104.1667

# Con datos ICFES
sd(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
```

Coeficiente de variación

Definición

El **coeficiente de variación** (CV) expresa la desviación estándar como porcentaje de la media. Permite comparar la dispersión relativa de variables con diferentes unidades o escalas.

$$CV = \frac{s}{\bar{x}} \times 100 \%$$

Interpretación:

- CV bajo ($< 15 \%$): datos homogéneos, poca variabilidad relativa
- CV medio ($15\text{-}30 \%$): variabilidad moderada
- CV alto ($> 30 \%$): datos heterogéneos, alta variabilidad relativa
- Sólo válido para variables de razón ($\bar{x} > 0$)

Ejemplo

Si $\bar{x} = 157$ puntos y $s = 20$ puntos:

$$CV = (20/157) \times 100 \% = 12,7 \% \text{ (variabilidad baja/moderada)}$$

Coeficiente de variación en R

```
# R no tiene funcion integrada para CV  
# Funcion personalizada  
cv <- function(x, na.rm = FALSE) {  
  (sd(x, na.rm = na.rm) / mean(x, na.rm = na.rm)) * 100  
}  
  
puntajes <- c(145, 150, 155, 160, 165, 170)  
cv(puntajes)  
# [1] 6.52  
  
# Comparar CV de ingles vs matematicas  
cv_ingles <- cv(icfes$MOD_INGLES_PUNT, na.rm = TRUE)  
cv_matematicas <- cv(icfes$MOD_RAZONA_CUANTITAT_PUNT, na.rm = TRUE)  
  
cat("CV Ingles:", round(cv_ingles, 2), "%\n")  
cat("CV Matematicas:", round(cv_matematicas, 2), "%\n")  
  
# ¿Cual tiene mayor variabilidad relativa?
```

Puntajes estandarizados (z-scores)

Definición

El **puntaje estandarizado** o **z-score** indica cuántas desviaciones estándar se encuentra una observación por encima (o por debajo) de la media.

$$z_i = \frac{x_i - \bar{x}}{s}$$

Propiedades:

- Sin unidades (adimensional)
- Media de los z-scores = 0
- Desviación estándar de los z-scores = 1
- $z > 0$: observación por encima de la media
- $z < 0$: observación por debajo de la media
- $|z| > 2$: observación inusual
- $|z| > 3$: posible outlier

Z-scores en R (1/2)

```
puntajes <- c(130, 140, 150, 155, 160, 170, 185)

# Funcion para calcular z-scores
z_scores <- function(x) {
  (x - mean(x)) / sd(x)
}

z <- z_scores(puntajes)
z
# [1] -1.456 -0.873 -0.291 0.000 0.291 0.873 1.456

# Verificar propiedades
mean(z) # [1] 0 (aproximadamente)
sd(z)   # [1] 1
```

Z-scores en R (2/2)

```
# Identificar outliers ( $|z| > 3$ )
puntajes <- c(130, 140, 150, 155, 160, 170, 185)
z <- (puntajes - mean(puntajes)) / sd(puntajes)
outliers <- puntajes[abs(z) > 3]
outliers

# Con datos ICFES
icfes <- icfes %>%
  mutate(z_ingles = (MOD_INGLES_PUNT - mean(MOD_INGLES_PUNT, na.rm=T)) /
                 sd(MOD_INGLES_PUNT, na.rm=T))
```

Teorema de Chebyshev

Teorema de Chebyshev

Para **cualquier distribución**, al menos $1 - \frac{1}{k^2}$ de las observaciones caen dentro de k desviaciones estándar de la media, donde $k > 1$.

k	Intervalo	% mínimo de datos
1.5	$\bar{x} \pm 1,5s$	$1 - 1/(1,5)^2 = 55,6 \%$
2	$\bar{x} \pm 2s$	$1 - 1/4 = 75 \%$
3	$\bar{x} \pm 3s$	$1 - 1/9 = 88,9 \%$
4	$\bar{x} \pm 4s$	$1 - 1/16 = 93,75 \%$

Importante


Este teorema aplica a **cualquier distribución** (no requiere normalidad). Es una cota conservadora: distribuciones específicas pueden tener proporciones mayores.

Regla empírica (68-95-99.7)

Regla empírica

Para distribuciones **aproximadamente normales** (en forma de campana):

- Aproximadamente 68 % de los datos caen dentro de $\bar{x} \pm 1s$
- Aproximadamente 95 % de los datos caen dentro de $\bar{x} \pm 2s$
- Aproximadamente 99.7 % de los datos caen dentro de $\bar{x} \pm 3s$



Importante: Sólo aplica a distribuciones aproximadamente normales.

Asimetría (skewness)

Definición

La **asimetría** mide el grado de simetría de una distribución.

$$g_1 = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$

Simétrica ($g_1 \approx 0$)

Visualización generada en R
con `plot()` y `hist()`
Media = Mediana

Asimetría positiva

($g_1 > 0$)
Cola larga a la derecha
Media > Mediana

Asimetría negativa

($g_1 < 0$)
Cola larga a la izquierda
Media < Mediana

Interpretación:

- $|g_1| < 0,5$: aproximadamente simétrica
- $0,5 \leq |g_1| < 1$: asimetría moderada
- $|g_1| \geq 1$: asimetría pronunciada

Curtosis

Definición

La **curtosis** mide el peso de las colas y la altura del pico de una distribución, comparado con la distribución normal.

$$g_2 = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 - 3$$

(El -3 es para que la distribución normal tenga curtosis $= 0$)

- **Leptocúrtica** ($g_2 > 0$): colas pesadas, pico alto, más concentrada que la normal
- **Mesocúrtica** ($g_2 \approx 0$): similar a la normal
- **Platocúrtica** ($g_2 < 0$): colas ligeras, pico bajo, más plana que la normal

Importancia práctica:

- $g_2 > 0$ indica mayor presencia de valores extremos (riesgo financiero)
- Afecta la validez de pruebas estadísticas que asumen normalidad

Asimetría y curtosis en R (1/2)

```
# Instalar y cargar paquete moments
install.packages("moments")
library(moments)

puntajes <- c(130, 135, 140, 145, 150, 155, 160, 165, 190)

# Asimetria
skewness(puntajes)
# [1] 0.847 (asimetria positiva moderada)

# Curtosis (exceso de curtosis)
kurtosis(puntajes) - 3
# [1] -0.312 (aproximadamente mesocurtica)
```

Asimetría y curtosis en R (2/2)

```
# Con datos ICFES
skewness(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
kurtosis(icfes$MOD_INGLES_PUNT, na.rm = TRUE) - 3

# Interpretacion
if (skewness(icfes$MOD_INGLES_PUNT, na.rm=T) > 0) {
  print("Distribucion sesgada a la derecha")
}
```

Detección de outliers

Métodos para detectar outliers

1. Método IQR (box plot):

- Outlier si: $x < Q_1 - 1,5 \times IQR$ o $x > Q_3 + 1,5 \times IQR$
- Outlier extremo si: $x < Q_1 - 3 \times IQR$ o $x > Q_3 + 3 \times IQR$

2. Método z-score:

- Inusual si: $|z| > 2$
- Outlier si: $|z| > 3$

3. Método de desviación absoluta mediana (MAD):

- Más robusto que z-score para distribuciones no normales

¿Qué hacer con outliers?

- Verificar si es un error de medición o entrada de datos
- Investigar si representa un fenómeno real
- Considerar análisis con y sin outliers

Percentiles

Definición

El **percentil** p es el valor tal que al menos el $p\%$ de las observaciones son menores o iguales a él.

Ejemplos:

- Percentil 25 (P_{25}) = Q_1 (primer cuartil): 25 % de los datos están por debajo
- Percentil 50 (P_{50}) = Q_2 = mediana: 50 % de los datos están por debajo
- Percentil 75 (P_{75}) = Q_3 (tercer cuartil): 75 % de los datos están por debajo
- Percentil 90 (P_{90}): 90 % de los datos están por debajo

Interpretación

Si un estudiante está en el percentil 80 en inglés, significa que superó al 80 % de los estudiantes y el 20 % restante obtuvo puntajes mayores o iguales.

Deciles: dividen los datos en 10 partes ($D_1, D_2, \dots, D_9$)

Quintiles: dividen los datos en 5 partes (Q_1, Q_2, Q_3, Q_4)

Cuartiles y five-number summary

Cuartiles

Los **cuartiles** dividen los datos ordenados en cuatro partes iguales:

- Q_1 : primer cuartil (25 %)
- Q_2 : segundo cuartil (50 %) = mediana
- Q_3 : tercer cuartil (75 %)

Five-number summary

Resumen de 5 números que describe la distribución:

$$\{\text{mín}, Q_1, Q_2, Q_3, \text{máx}\}$$

Ejemplo

Five-number summary de puntajes de inglés:

$\{100, 145, 157, 168, 200\}$

Percentiles y cuartiles en R

```
puntajes <- c(120, 130, 140, 145, 150, 155, 160, 165, 170, 180)
```

```
# Cuartiles
```

```
quantile(puntajes)
```

```
# 0% 25% 50% 75% 100%
```

```
# 120 141 152 163 180
```

```
# Percentiles específicos
```

```
quantile(puntajes, probs = c(0.10, 0.25, 0.50, 0.75, 0.90))
```

```
# 10% 25% 50% 75% 90%
```

```
# 130 141 152 163 174
```

```
# Five-number summary
```

```
fivenum(puntajes)
```

```
# [1] 120 140 152 165 180
```

```
# Summary completo (incluye media)
```

```
summary(puntajes)
```

```
# Min. 1st Qu. Median Mean 3rd Qu. Max.
```

```
# 120 141 152 151 163 180
```

Ejemplo completo: cargar y explorar datos

```
# Cargar librerias
library(tidyverse)

# Cargar datos
icfes <- read_csv("datos/saber_pro_ni_2024.csv")

# Dimension de los datos
dim(icfes)
# [1] 3245 42

# Primeras filas
head(icfes)

# Estructura
str(icfes)

# Resumen de variables numericas
summary(icfes %>% select(MOD_INGLES_PUNT, MOD_LECTURA_CRITICA_PUNT,
                        MOD_RAZONA_CUANTITAT_PUNT))
```

Medidas descriptivas para MOD_INGLES_PUNT

```
# Medidas de tendencia central
media_ingles <- mean(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
mediana_ingles <- median(icfes$MOD_INGLES_PUNT, na.rm = TRUE)

cat("Media:", round(media_ingles, 2), "\n")
cat("Mediana:", round(mediana_ingles, 2), "\n")

# Medidas de dispersion
sd_ingles <- sd(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
var_ingles <- var(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
cv_ingles <- (sd_ingles / media_ingles) * 100

cat("Desviacion estandar:", round(sd_ingles, 2), "\n")
cat("Varianza:", round(var_ingles, 2), "\n")
cat("CV:", round(cv_ingles, 2), "%\n")

# Forma
library(moments)
skew_ingles <- skewness(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
kurt_ingles <- kurtosis(icfes$MOD_INGLES_PUNT, na.rm = TRUE) - 3
```


Desagregación por tipo de IES

```
# Comparar puntajes por tipo de institucion
icfes %>%
  group_by(INST_CHARACTER_ACADEMICO) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT, na.rm = TRUE),
    mediana = median(MOD_INGLES_PUNT, na.rm = TRUE),
    sd = sd(MOD_INGLES_PUNT, na.rm = TRUE),
    cv = (sd / media) * 100,
    min = min(MOD_INGLES_PUNT, na.rm = TRUE),
    max = max(MOD_INGLES_PUNT, na.rm = TRUE)
  ) %>%
  arrange(desc(media))

# Resultado esperado:
# INST_CHARACTER_ACADEMICO n media mediana sd cv min max
# Universidad (privada) 1850 162.3 161.0 18.5 11.4 110 200
# Universidad (publica) 950 157.8 156.0 19.2 12.2 105 198
# Inst. Tecnica/Tecnologica 445 148.5 147.0 20.1 13.5 100 195
```

Desagregación por estrato

```
# Comparar puntajes por estrato socioeconomico
icfes %>%
  filter(!is.na(FAMI ESTRATOVIVIENDA)) %>%
  group_by(FAMI ESTRATOVIVIENDA) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT, na.rm = TRUE),
    mediana = median(MOD_INGLES_PUNT, na.rm = TRUE),
    sd = sd(MOD_INGLES_PUNT, na.rm = TRUE),
    Q1 = quantile(MOD_INGLES_PUNT, 0.25, na.rm = TRUE),
    Q3 = quantile(MOD_INGLES_PUNT, 0.75, na.rm = TRUE),
    IQR = Q3 - Q1
  ) %>%
  arrange(FAMI ESTRATOVIVIENDA)

# ¿Hay una relacion clara entre estrato y puntaje de ingles?
# ¿Como varia la dispersion entre estratos?
```

Tabla resumen consolidada

```
# Funcion para calcular todas las estadisticas
```

```
estadisticas_completas <- function(x) {  
  tibble(  
    n = sum(!is.na(x)),  
    media = mean(x, na.rm = TRUE),  
    mediana = median(x, na.rm = TRUE),  
    sd = sd(x, na.rm = TRUE),  
    cv = (sd / media) * 100,  
    min = min(x, na.rm = TRUE),  
    Q1 = quantile(x, 0.25, na.rm = TRUE),  
    Q3 = quantile(x, 0.75, na.rm = TRUE),  
    max = max(x, na.rm = TRUE),  
    IQR = Q3 - Q1,  
    asimetria = skewness(x, na.rm = TRUE),  
    curtosis = kurtosis(x, na.rm = TRUE) - 3  
  )  
}
```

```
# Aplicar a puntaje de ingles
```

```
estadisticas_completas(icfes$MOD_INGLES_PUNT)
```

Resumen de la sesión

Conceptos clave cubiertos:

1. **Introducción:** estadística descriptiva vs inferencial, datos ICFES, tipos de datos
2. **Tendencia central:** media, mediana, moda
3. **Dispersión:** rango, IQR, varianza, desviación estándar, CV
4. **Forma:** z-scores, Chebyshev, regla empírica, asimetría, curtosis
5. **Posición:** percentiles, cuartiles, five-number summary
6. **Aplicación:** análisis completo de MOD_INGLES_PUNT

Para la próxima sesión

- Repasar funciones de R: `mean()`, `median()`, `sd()`, `quantile()`, `summary()`
- Traer computadora con R y RStudio instalados
- Descargar los datos ICFES del repositorio del curso

Próxima sesión: Estadística Descriptiva Gráfica

Vie 14 ago 2026

Temas a cubrir:

- Distribuciones de frecuencia
- Visualización de una variable: histogramas, box plots, density plots
- Visualización de dos variables: scatter plots, heatmaps
- Covarianza y correlación (Pearson y Spearman)
- Paradoja de Simpson
- Pipeline completo de análisis exploratorio de datos (EDA)

Paquetes de R a instalar:

```
install.packages(c("ggplot2", "dplyr", "corrplot", "GGally"))
```