

Sesión 1: Estadística Descriptiva Numérica

Introducción al curso y medidas numéricas

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Vie 31 jul 2026

Agenda

Introducción al curso

Medidas de tendencia central

Medidas de dispersión

Forma de la distribución

Percentiles y cuartiles

Aplicación con datos ICFES

Resumen y próxima sesión

¿Qué es la estadística?

Definición

La estadística es la ciencia de recolectar, organizar, analizar e interpretar datos para tomar decisiones informadas bajo incertidumbre.

Estadística Descriptiva

- Resumir y visualizar datos
- Medidas numéricas (media, mediana, desviación estándar)
- Gráficos (histogramas, box plots, scatter plots)
- Describe lo que ya tenemos

Estadística Inferencial

- Generalizar desde una muestra a la población
- Intervalos de confianza
- Pruebas de hipótesis
- Regresión y predicción
- Infiere sobre lo que no observamos

Datos ICFES: Saber 11 y Saber Pro

¿Qué es el ICFES?

Instituto Colombiano para la Evaluación de la Educación. Realiza exámenes estandarizados para evaluar la calidad educativa en Colombia.

- **Saber 11:** examen al finalizar la educación media (bachillerato)
 - Módulos: Lectura Crítica, Matemáticas, Sociales, Ciencias Naturales, Inglés
 - Usado para admisión universitaria
- **Saber Pro:** examen al finalizar la educación superior (último año de pregrado)
 - Módulos genéricos: Lectura Crítica, Razonamiento Cuantitativo, Competencias Ciudadanas, Comunicación Escrita, Inglés
 - Módulos específicos por programa (ej: Gestión Financiera para Ciencias Económicas)

Datos ICFES: enfoque del curso

En este curso trabajaremos con datos reales de estudiantes del programa de Ciencias Económicas y Administrativas

Nuestros datos

- Saber Pro 2023 y 2024 — programa de Ciencias Económicas y Administrativas
- Saber 11 enlazado para los mismos estudiantes
- Almacenados en Google BigQuery (proyecto ph-jabri)

Variable central: MOD_INGLES_PUNT

¿Por qué el puntaje de inglés?

Para estudiantes de Ciencias Económicas y Administrativas, la competencia en inglés es un **proxy de competitividad internacional**:

- Comunicación con clientes y proveedores internacionales
- Acceso a información y literatura de negocios global
- Movilidad laboral y oportunidades en empresas multinacionales
- Negociación en mercados internacionales

Preguntas que exploraremos

A lo largo del curso, usaremos MOD_INGLES_PUNT para responder:

1. ¿Cuál es el puntaje promedio en inglés de estudiantes de Ciencias Económicas?
2. ¿Cómo varía según tipo de institución (pública vs privada)?
3. ¿Cómo varía según estrato socioeconómico?
4. ¿Está relacionado con el desempeño en Saber 11?
5. ¿Hay diferencias regionales (por departamento)?

Hoy comenzamos con las preguntas 1–3, usando estadística descriptiva numérica.

Software: R y RStudio

¿Qué es R?

- Lenguaje de programación estadística
- Software libre y de código abierto
- Más de 19,000 paquetes disponibles
- Estándar en investigación y análisis de datos

¿Qué es RStudio?

- Entorno de desarrollo integrado (IDE) para R
- Editor de código, consola, gráficos, ayuda
- Gestión de proyectos
- Integración con Git, Markdown, Shiny

Instalación:

1. Descargar R desde <https://cran.r-project.org>
2. Descargar RStudio desde <https://posit.co/download/rstudio-desktop/>

Primeros pasos en R

```
# Primeros comandos en R
2 + 3
x <- 10
x * 2

# Tipos basicos
nombre <- "Jaime"      # character
edad <- 25              # numeric
activo <- TRUE          # logical

# Vectores
puntajes <- c(145, 160, 155, 170, 150)
length(puntajes)
```

Tipos de datos

Datos categóricos (cualitativos)

Describen cualidades o características. No tienen un orden numérico natural.

- **Nominal:** sin orden (ej: tipo de IES [pública, privada], departamento)
- **Ordinal:** con orden (ej: estrato [1, 2, 3, 4, 5, 6], nivel educativo)

Datos cuantitativos (numéricos)

Representan cantidades medibles.

- **Intervalo:** diferencias significativas, pero no hay cero absoluto (ej: temperatura en °C)
- **Razón:** hay cero absoluto, se pueden hacer cocientes (ej: puntajes ICFES, edad, ingreso)

Tipos de datos: ejemplos con ICFES

Clasificación de variables del dataset

MOD_INGLES_PUNT es cuantitativa de razón (0 = ausencia total de conocimiento).
ESTU_TIPOREMUNERACION es categórica nominal.

Variable	Tipo	Escala
MOD_INGLES_PUNT	Cuantitativa	Razón
FAMI_ESTRATOVIVIENDA	Categórica	Ordinal
ESTU_DEPTO_RESIDE	Categórica	Nominal
INST_CHARACTER_ACADEMICO	Categórica	Nominal

Datos de corte transversal vs series de tiempo

Corte transversal (cross-section)

- Observaciones de múltiples unidades en un **único momento en el tiempo**
- Ejemplo: puntajes Saber Pro 2024 de todos los estudiantes de Ciencias Económicas
- Nos permite comparar entre individuos, instituciones, regiones

Series de tiempo (time series)

- Observaciones de una unidad a lo largo del **tiempo**
- Ejemplo: puntaje promedio en inglés de Ciencias Económicas entre 2015 y 2025
- Nos permite identificar tendencias, estacionalidad

En este curso

Trabajaremos principalmente con **datos de corte transversal**: estudiantes de Ciencias Económicas en Saber Pro 2023 y 2024.

Media aritmética

Definición

La **media aritmética** (o promedio) es la suma de los valores dividida por el número de observaciones.

Media muestral (estadístico):

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

donde n = tamaño de la muestra

Media poblacional (parámetro):

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$

donde N = tamaño de la población

Notación: $\bar{x}$ (x-barra) para muestra, μ (mu) para población

Ejemplo: screen time semanal de 5 amigos

Horas diarias: 5, 7, 4, 8, 6 $\Rightarrow \bar{x} = (5 + 7 + 4 + 8 + 6)/5 = 6$ horas

Media aritmética: ejemplo

Minutos de música en Spotify en 5 días

Minutos escuchados: 45, 60, 55, 70, 50

$$\bar{x} = \frac{45 + 60 + 55 + 70 + 50}{5} = \frac{280}{5} = 56 \text{ min}$$

Propiedades de la media:

- Usa toda la información disponible (todos los valores)
- Es sensible a valores extremos (outliers)
- La suma de desviaciones respecto a la media es cero: $\sum (x_i - \bar{x}) = 0$

Media aritmética en R

```
# Vector de puntajes
puntajes <- c(145, 160, 155, 170, 150, 162, 158, 149, 165, 153)

# Calcular la media
mean(puntajes)
# [1] 156.7

# Con datos faltantes (NA), usar na.rm = TRUE
puntajes_na <- c(145, 160, NA, 170, 150)
mean(puntajes_na, na.rm = TRUE)
# [1] 156.25

# Cargar datos ICFES completos
library(tidyverse)
icfes <- read_csv("datos/saber_pro_ni_2024.csv")
mean(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
```

Nota: `na.rm = TRUE` elimina valores faltantes antes de calcular

Media ponderada

Definición

La **media ponderada** asigna pesos diferentes a cada observación según su importancia.

$$\bar{x}_w = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$$

donde w_i es el peso de la observación i

Media ponderada: ejemplo

Tu Spotify Wrapped: top 3 artistas

Tus artistas más escuchados con distinto % de tu tiempo total:

- Bad Bunny: rating 9.2 (50 % de tu tiempo)
- Karol G: rating 8.5 (30 % de tu tiempo)
- Feid: rating 7.8 (20 % de tu tiempo)

$$\bar{x}_w = \frac{0,50(9,2) + 0,30(8,5) + 0,20(7,8)}{1} = 8,71$$

La media simple daría: $(9,2 + 8,5 + 7,8)/3 = 8,50$. La ponderada refleja que escuchas más a Bad Bunny.

Mediana

Definición

La **mediana** es el valor que divide los datos ordenados en dos mitades iguales. 50 % de las observaciones están por debajo y 50 % por encima.

Procedimiento:

1. Ordenar los datos de menor a mayor
2. Si n es impar: la mediana es el valor central
3. Si n es par: la mediana es el promedio de los dos valores centrales

Ejemplo (n impar):

Seguidores en IG de 5 amigos:

280, 310, 350, 400, 520

Mediana = 350

Ejemplo (n par):

Seguidores de 6 amigos:

280, 310, 350, 400, 520, 610

Mediana = $(350+400)/2 = 375$

Propiedad clave

La mediana es **robusta a outliers**. Si un amigo tiene 50,000 seguidores porque se hizo viral, la media sube a locura, pero la mediana ni se entera.

Mediana en R

```
# Vector de puntajes
puntajes <- c(145, 150, 155, 160, 170)
median(puntajes)
# [1] 155

# Puntajes con un valor extremo
puntajes_outlier <- c(145, 150, 155, 160, 250)
mean(puntajes_outlier) # [1] 172 (afectada por el outlier)
median(puntajes_outlier) # [1] 155 (no afectada)

# Con datos ICFES
median(icfes$MOD_INGLES_PUNT, na.rm = TRUE)

# Comparar media vs mediana
summary(icfes$MOD_INGLES_PUNT)
```

Interpretación: Si $\text{media} > \text{mediana}$, distribución sesgada a la derecha (cola larga hacia valores altos). Si $\text{media} < \text{mediana}$, sesgada a la izquierda.

Moda

Definición

La **moda** es el valor que aparece con mayor frecuencia en los datos.

- Datos pueden ser **unimodales** (una moda), **bimodales** (dos modas), o **multimodales**
- Es la única medida de tendencia central aplicable a datos categóricos
- La canción más escuchada de tu playlist este mes = la moda

Unimodal

150, 155, 155, 160, 155, 165, 170, 155
Moda = 155 (aparece 4 veces)

Bimodal

2, 2, 2, 3, 4, 5, 5, 5, 6
Modas = 2 y 5 (3 veces c/u)

Moda en R

```
# R no tiene una funcion integrada para moda
# Opcion 1: usar table() para ver frecuencias
puntajes <- c(150, 155, 155, 160, 155, 165, 170, 155)
table(puntajes)
# puntajes
# 150 155 160 165 170
#   1   4   1   1   1

# Opcion 2: funcion personalizada
moda <- function(x) {
  freq <- table(x)
  as.numeric(names(freq)[which.max(freq)])
}
moda(puntajes)
# [1] 155

# Para categoricas
table(icfes$ESTU_DEPTO_RESIDE)
# Muestra frecuencia por departamento
```

¿Cuándo usar cada medida?

Medida	Cuándo usar	Ventajas / Desventajas
Media	Distribuciones simétricas, datos numéricos	Usa toda la información; sensible a outliers
Mediana	Distribuciones sesgadas, presencia de outliers	Robusta; ignora valores extremos
Moda	Datos categóricos, distribuciones multimodales	Única para categorías; puede no existir o no ser única

Regla práctica

- Distribución simétrica: $\text{media} \approx \text{mediana} \approx \text{moda}$
- Sesgada a la derecha: $\text{moda} < \text{mediana} < \text{media}$ (ej: likes en TikTok — muchos posts con pocos likes, pocos virales)
- Sesgada a la izquierda: $\text{media} < \text{mediana} < \text{moda}$

Rango

Definición

El **rango** es la diferencia entre el valor máximo y el valor mínimo.

$$\text{Rango} = \text{máx}(x) - \text{mín}(x)$$

- Medida más simple de dispersión
- Muy sensible a outliers (basta un valor extremo para inflarlo)
- No usa información de los valores intermedios

Screen time del grupo

Horas: 2, 4, 5, 7, 9

$$\text{Rango} = 9 - 2 = 7 \text{ h}$$

Un amigo dejó el cel en casa

Horas: 0, 4, 5, 7, 9

$$\text{Rango} = 9 - 0 = 9 \text{ h}$$

Rango intercuartílico (IQR)

Definición

El **rango intercuartílico** (IQR) es la diferencia entre el tercer cuartil (Q_3) y el primer cuartil (Q_1). Contiene el 50 % central de los datos.

$$\text{IQR} = Q_3 - Q_1$$

- Robusto a outliers (ignora el 25 % más bajo y el 25 % más alto)
- Usado en box plots para identificar outliers
- Outlier si: $x < Q_1 - 1,5 \times \text{IQR}$ o $x > Q_3 + 1,5 \times \text{IQR}$

Rango intercuartílico (IQR) (cont.)

Ejemplo: screen time diario (horas) de tu grupo

Si $Q1 = 3$ h y $Q3 = 7$ h:

$$IQR = 7 - 3 = 4 \text{ h}$$

Límite inferior outlier: $3 - 1,5(4) = -3$ (no aplica)

Límite superior outlier: $7 + 1,5(4) = 13$ h $\Rightarrow >13$ h sería atípico

Rango e IQR en R

```
# Rango
puntajes <- c(145, 150, 155, 160, 165, 170)
range(puntajes)
# [1] 145 170
diff(range(puntajes))
# [1] 25

# Rango intercuartilico
IQR(puntajes)
# [1] 15

# Cuartiles
quantile(puntajes, probs = c(0.25, 0.75))
# 25% 75%
# 151.25 163.75

# Con datos ICFES
summary(icfes$MOD_INGLES_PUNT)
IQR(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
```

Varianza

Definición

La **varianza** mide la dispersión promedio de los datos respecto a la media. Es el promedio de las desviaciones cuadradas.

Varianza muestral:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Varianza poblacional:

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

Propiedades: siempre $s^2 \geq 0$; unidades en cuadrado de las originales.

Intuición

Un artista de Spotify con streams diarios estables (poca varianza) vs uno que tuvo un hit viral un día y nada al siguiente (mucha varianza).

Varianza: grados de libertad

¿Por qué $n - 1$ y no n ?

Dividir por $n - 1$ (grados de libertad) hace que s^2 sea un **estimador insesgado** de σ^2 .
Dividir por n subestimaría la varianza poblacional sistemáticamente.

Intuición:

- Al estimar σ^2 , usamos $\bar{x}$ en lugar de μ
- Esto “consume” un grado de libertad
- Quedan $n - 1$ piezas de información independientes
- La corrección compensa el sesgo de usar una estimación ($\bar{x}$) en lugar del valor real (μ)

Desviación estándar

Definición

La **desviación estándar** es la raíz cuadrada positiva de la varianza. Mide la dispersión en las mismas unidades que los datos.

Desviación estándar muestral:

$$s = \sqrt{s^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Desviación estándar poblacional:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

Interpretación:

- Mide cuánto se desvían los datos de la media **en promedio**
- s pequeña: datos concentrados cerca de $\bar{x}$ (screen time estable cada día)
- s grande: datos dispersos, alejados de $\bar{x}$ (un día 1 h, otro día 10 h)
- Mismas unidades que los datos originales (más interpretable que s^2)

Varianza y desviación estándar en R (1/2)

```
puntajes <- c(145, 150, 155, 160, 165, 170)

# Varianza (usa n-1)
var(puntajes)
# [1] 104.1667

# Desviacion estandar
sd(puntajes)
# [1] 10.20621

# Verificar que sd = sqrt(var)
sqrt(var(puntajes))
# [1] 10.20621
```

Varianza y desviación estándar en R (2/2)

```
# Calculo manual (para entender)
puntajes <- c(145, 150, 155, 160, 165, 170)
n <- length(puntajes)
media <- mean(puntajes)
varianza_manual <- sum((puntajes - media)^2) / (n - 1)
varianza_manual
# [1] 104.1667

# Con datos ICFES
sd(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
```

Coeficiente de variación

Definición

El **coeficiente de variación** (CV) expresa la desviación estándar como porcentaje de la media. Compara dispersión relativa entre variables con distintas escalas.

$$CV = \frac{s}{\bar{x}} \times 100 \%$$

Interpretación:

- $CV < 15 \%$: datos homogéneos
- $CV 15\text{--}30 \%$: variabilidad moderada
- $CV > 30 \%$: datos heterogéneos

Sólo válido para variables de razón ($\bar{x} > 0$)

Ejemplo

$$\bar{x} = 157, s = 20$$

$$CV = \frac{20}{157} \times 100 \% = 12,7 \%$$

Coeficiente de variación en R

```
# R no tiene funcion integrada para CV  
# Funcion personalizada  
cv <- function(x, na.rm = FALSE) {  
  (sd(x, na.rm = na.rm) / mean(x, na.rm = na.rm)) * 100  
}  
  
puntajes <- c(145, 150, 155, 160, 165, 170)  
cv(puntajes)  
# [1] 6.52  
  
# Comparar CV de ingles vs matematicas  
cv_ingles <- cv(icfes$MOD_INGLES_PUNT, na.rm = TRUE)  
cv_matematicas <- cv(icfes$MOD_RAZONA_CUANTITAT_PUNT, na.rm = TRUE)  
  
cat("CV Ingles:", round(cv_ingles, 2), "%\n")  
cat("CV Matematicas:", round(cv_matematicas, 2), "%\n")  
  
# ¿Cual tiene mayor variabilidad relativa?
```

Puntajes estandarizados (z-scores)

Definición

El **puntaje estandarizado** o **z-score** indica cuántas desviaciones estándar se encuentra una observación por encima (o por debajo) de la media.

$$z_i = \frac{x_i - \bar{x}}{s}$$

Propiedades:

- Sin unidades (adimensional)
- Media de los z-scores = 0, desviación estándar = 1
- $z > 0$: por encima de la media; $z < 0$: por debajo
- $|z| > 2$: observación inusual; $|z| > 3$: posible outlier

Z-scores: ejemplo

Ejemplo: screen time diario entre tus amigos

Si $\bar{x} = 5$ h, $s = 1,2$ h, y tu screen time es $x = 8$ h:

$$z = \frac{8 - 5}{1,2} = 2,5$$

Estás 2.5 desviaciones estándar por encima de tus amigos. Eres un outlier de celular.

Utilidad

Los z-scores permiten:

- Comparar observaciones de variables con distintas escalas
- Identificar valores atípicos de forma objetiva
- Estandarizar datos antes de análisis multivariados

Z-scores en R (1/2)

```
puntajes <- c(130, 140, 150, 155, 160, 170, 185)

# Funcion para calcular z-scores
z_scores <- function(x) {
  (x - mean(x)) / sd(x)
}

z <- z_scores(puntajes)
z
# [1] -1.456 -0.873 -0.291 0.000 0.291 0.873 1.456

# Verificar propiedades
mean(z) # [1] 0 (aproximadamente)
sd(z)   # [1] 1
```

Z-scores en R (2/2)

```
# Identificar outliers ( $|z| > 3$ )
puntajes <- c(130, 140, 150, 155, 160, 170, 185)
z <- (puntajes - mean(puntajes)) / sd(puntajes)
outliers <- puntajes[abs(z) > 3]
outliers

# Con datos ICFES
icfes <- icfes %>%
  mutate(z_ingles = (MOD_INGLES_PUNT - mean(MOD_INGLES_PUNT, na.rm=T)) /
                 sd(MOD_INGLES_PUNT, na.rm=T))
```

Teorema de Chebyshev

Teorema de Chebyshev

Para **cualquier distribución**, al menos $1 - \frac{1}{k^2}$ de las observaciones caen dentro de k desviaciones estándar de la media, donde $k > 1$.

k	Intervalo	% mínimo de datos
1.5	$\bar{x} \pm 1,5s$	$1 - 1/(1,5)^2 = 55,6 \%$
2	$\bar{x} \pm 2s$	$1 - 1/4 = 75 \%$
3	$\bar{x} \pm 3s$	$1 - 1/9 = 88,9 \%$
4	$\bar{x} \pm 4s$	$1 - 1/16 = 93,75 \%$

Importante


Este teorema aplica a **cualquier distribución** (no requiere normalidad). Es una cota conservadora: distribuciones específicas pueden tener proporciones mayores.

Regla empírica (68-95-99.7)

Regla empírica

Para distribuciones **aproximadamente normales** (en forma de campana):

- Aproximadamente 68 % de los datos caen dentro de $\bar{x} \pm 1s$
- Aproximadamente 95 % de los datos caen dentro de $\bar{x} \pm 2s$
- Aproximadamente 99.7 % de los datos caen dentro de $\bar{x} \pm 3s$



Importante: Sólo aplica a distribuciones aproximadamente normales.

Asimetría (skewness)

Definición

La **asimetría** mide el grado de simetría de una distribución.

$$g_1 = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^3$$

Simétrica ($g_1 \approx 0$)

Visualización generada en R

con `plot()` y `hist()`

Media = Mediana

Asimetría positiva

($g_1 > 0$)

Cola larga a la derecha

Media > Mediana

Ej: likes en posts — la mayoría recibe pocos

Asimetría negativa

($g_1 < 0$)

Cola larga a la izquierda

Media < Mediana

Asimetría (skewness) (cont.)

Interpretación:

- $|g_1| < 0,5$: aproximadamente simétrica
- $0,5 \leq |g_1| < 1$: asimetría moderada
- $|g_1| \geq 1$: asimetría pronunciada

Curtosis

Definición

La **curtosis** mide el peso de las colas y la altura del pico de una distribución, comparado con la distribución normal.

$$g_2 = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 - 3$$

(El -3 es para que la distribución normal tenga curtosis $= 0$)

- **Leptocúrtica** ($g_2 > 0$): colas pesadas, pico alto, más concentrada que la normal
- **Mesocúrtica** ($g_2 \approx 0$): similar a la normal
- **Platocúrtica** ($g_2 < 0$): colas ligeras, pico bajo, más plana que la normal

Importancia práctica:

- $g_2 > 0$ indica mayor presencia de valores extremos (riesgo financiero)
- Afecta la validez de pruebas estadísticas que asumen normalidad

Asimetría y curtosis en R (1/2)

```
# Instalar y cargar paquete moments
install.packages("moments")
library(moments)

puntajes <- c(130, 135, 140, 145, 150, 155, 160, 165, 190)

# Asimetria
skewness(puntajes)
# [1] 0.847 (asimetria positiva moderada)

# Curtosis (exceso de curtosis)
kurtosis(puntajes) - 3
# [1] -0.312 (aproximadamente mesocurtica)
```

Asimetría y curtosis en R (2/2)

```
# Con datos ICFES
skewness(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
kurtosis(icfes$MOD_INGLES_PUNT, na.rm = TRUE) - 3

# Interpretacion
if (skewness(icfes$MOD_INGLES_PUNT, na.rm=T) > 0) {
  print("Distribucion sesgada a la derecha")
}
```

Detección de outliers: métodos

1. Método IQR (box plot):

- Outlier si: $x < Q_1 - 1,5 \times IQR$ o $x > Q_3 + 1,5 \times IQR$
- Outlier extremo si: $x < Q_1 - 3 \times IQR$ o $x > Q_3 + 3 \times IQR$

2. Método z-score:

- Inusual si: $|z| > 2$
- Outlier si: $|z| > 3$

3. Método de desviación absoluta mediana (MAD):

- Más robusto que z-score para distribuciones no normales

¿Qué hacer con outliers?

Protocolo para tratar valores atípicos

1. Verificar si es un error de medición o entrada de datos
2. Investigar si representa un fenómeno real
3. Considerar análisis con y sin outliers
4. Nunca eliminar sin justificación

Ejemplo

Ese post que se hizo viral con 50K likes cuando normalmente recibes 200. ¿Es un error? No, es un fenómeno real. Pero si tu dataset dice que un post tuvo -30 likes, eso sí es un error de datos.

Percentiles

Definición

El **percentil** p es el valor tal que al menos el $p\%$ de las observaciones son menores o iguales a él.

Percentiles clave:

- Percentil 25 (P_{25}) = Q_1 : 25 % de los datos están por debajo
- Percentil 50 (P_{50}) = Q_2 = mediana
- Percentil 75 (P_{75}) = Q_3 : 75 % de los datos están por debajo
- Percentil 90 (P_{90}): 90 % de los datos están por debajo

Deciles: dividen los datos en 10 partes ($D_1, D_2, \dots, D_9$)

Quintiles: dividen los datos en 5 partes

Percentiles: interpretación

Ejemplo: Spotify Wrapped

Spotify Wrapped te dice que estás en el **top 1 % de oyentes de Bad Bunny**. Eso es el percentil 99: escuchaste más que el 99 % de sus oyentes.

Nota

Los percentiles son especialmente útiles para:

- Comparar el rendimiento relativo de un estudiante
- Establecer puntos de corte (ej: becas para el top 10 %)
- Describir la distribución sin asumir normalidad

Cuartiles y five-number summary

Cuartiles

Los **cuartiles** dividen los datos ordenados en cuatro partes iguales:

- Q_1 : primer cuartil (25 %)
- Q_2 : segundo cuartil (50 %) = mediana
- Q_3 : tercer cuartil (75 %)

Five-number summary

Resumen de 5 números que describe la distribución:

$$\{\text{mín}, Q_1, Q_2, Q_3, \text{máx}\}$$

Five-number summary: ejemplo

Puntajes de inglés (Saber Pro)

Five-number summary: $\{100, 145, 157, 168, 200\}$

- 25 % de estudiantes obtuvo ≤ 145 puntos
- 50 % obtuvo ≤ 157 puntos (mediana)
- 75 % obtuvo ≤ 168 puntos

El five-number summary es la base del box plot, que veremos en la próxima sesión.

Percentiles y cuartiles en R (1/2)

```
puntajes <- c(120, 130, 140, 145, 150, 155, 160, 165, 170, 180)
```

```
# Cuartiles
```

```
quantile(puntajes)
```

```
# 0% 25% 50% 75% 100%
```

```
# 120 141 152 163 180
```

```
# Percentiles especificos
```

```
quantile(puntajes, probs = c(0.10, 0.25, 0.50, 0.75, 0.90))
```

```
# 10% 25% 50% 75% 90%
```

```
# 130 141 152 163 174
```

Percentiles y cuartiles en R (2/2)

```
# Five-number summary
fivenum(puntajes)
# [1] 120 140 152 165 180

# Summary completo (incluye media)
summary(puntajes)
#   Min. 1st Qu. Median   Mean 3rd Qu.   Max.
#   120    141    152    151    163    180

# Con datos ICFES
summary(icfes$MOD_INGLES_PUNT)
```

Ejemplo completo: cargar y explorar datos

```
# Cargar librerias
library(tidyverse)

# Cargar datos
icfes <- read_csv("datos/saber_pro_ni_2024.csv")

# Dimension de los datos
dim(icfes)
# [1] 3245 42

# Primeras filas
head(icfes)

# Estructura
str(icfes)

# Resumen de variables numericas
summary(icfes %>% select(MOD_INGLES_PUNT, MOD_LLECTURA_CRITICA_PUNT,
                        MOD_RAZONA_CUANTITAT_PUNT))
```

Descriptivas de MOD_INGLES_PUNT: tendencia central

```
# Medidas de tendencia central
media_ingles <- mean(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
mediana_ingles <- median(icfes$MOD_INGLES_PUNT, na.rm = TRUE)

cat("Media:", round(media_ingles, 2), "\n")
cat("Mediana:", round(mediana_ingles, 2), "\n")

# Medidas de dispersion
sd_ingles <- sd(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
var_ingles <- var(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
cv_ingles <- (sd_ingles / media_ingles) * 100

cat("Desviacion estandar:", round(sd_ingles, 2), "\n")
cat("Varianza:", round(var_ingles, 2), "\n")
cat("CV:", round(cv_ingles, 2), "%\n")
```

Descriptivas de MOD_INGLES_PUNT: forma

```
# Forma de la distribucion
library(moments)
skew_ingles <- skewness(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
kurt_ingles <- kurtosis(icfes$MOD_INGLES_PUNT, na.rm = TRUE) - 3

cat("Asimetria:", round(skew_ingles, 2), "\n")
cat("Curtosis:", round(kurt_ingles, 2), "\n")
```

Interpretación: Si la asimetría es positiva, hay una cola larga hacia puntajes altos. Si la curtosis es positiva, hay más valores extremos de lo esperado bajo normalidad.

Desagregación por tipo de IES

```
# Comparar puntajes por tipo de institucion
icfes %>%
  group_by(INST_CHARACTER_ACADEMICO) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT, na.rm = TRUE),
    mediana = median(MOD_INGLES_PUNT, na.rm = TRUE),
    sd = sd(MOD_INGLES_PUNT, na.rm = TRUE),
    cv = (sd / media) * 100,
    min = min(MOD_INGLES_PUNT, na.rm = TRUE),
    max = max(MOD_INGLES_PUNT, na.rm = TRUE)
  ) %>%
  arrange(desc(media))

# Resultado esperado:
# INST_CHARACTER_ACADEMICO n media mediana sd cv min max
# Universidad (privada) 1850 162.3 161.0 18.5 11.4 110 200
# Universidad (publica) 950 157.8 156.0 19.2 12.2 105 198
# Inst. Tecnica/Tecnologica 445 148.5 147.0 20.1 13.5 100 195
```


Desagregación por estrato

```
# Comparar puntajes por estrato socioeconomico
icfes %>%
  filter(!is.na(FAMI ESTRATOVIVIENDA)) %>%
  group_by(FAMI ESTRATOVIVIENDA) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT, na.rm = TRUE),
    mediana = median(MOD_INGLES_PUNT, na.rm = TRUE),
    sd = sd(MOD_INGLES_PUNT, na.rm = TRUE),
    Q1 = quantile(MOD_INGLES_PUNT, 0.25, na.rm = TRUE),
    Q3 = quantile(MOD_INGLES_PUNT, 0.75, na.rm = TRUE),
    IQR = Q3 - Q1
  ) %>%
  arrange(FAMI ESTRATOVIVIENDA)

# ?Hay una relacion clara entre estrato y puntaje de ingles?
# ?Como varia la dispersion entre estratos?
```

Tabla resumen: función personalizada

```
# Funcion para calcular todas las estadisticas
estadisticas_completas <- function(x) {
  tibble(
    n = sum(!is.na(x)),
    media = mean(x, na.rm = TRUE),
    mediana = median(x, na.rm = TRUE),
    sd = sd(x, na.rm = TRUE),
    cv = (sd / media) * 100,
    min = min(x, na.rm = TRUE),
    Q1 = quantile(x, 0.25, na.rm = TRUE),
    Q3 = quantile(x, 0.75, na.rm = TRUE),
    max = max(x, na.rm = TRUE),
    IQR = Q3 - Q1,
    asimetria = skewness(x, na.rm = TRUE),
    curtosis = kurtosis(x, na.rm = TRUE) - 3
  )
}
```

Tabla resumen: aplicación

```
# Aplicar a puntaje de ingles
estadisticas_completas(icfes$MOD_INGLES_PUNT)

# Aplicar a multiples variables
variables <- icfes %>%
  select(MOD_INGLES_PUNT, MOD_LECTURA_CRITICA_PUNT,
         MOD_RAZONA_CUANTITAT_PUNT)

variables %>%
  summarise(across(everything(), ~estadisticas_completas(.x)))
```

Tip: Esta función reusable les servirá en los Problem Sets y el proyecto final.

Resumen de la sesión

Conceptos clave cubiertos:

1. **Introducción:** estadística descriptiva vs inferencial, datos ICFES, tipos de datos
2. **Tendencia central:** media, mediana, moda
3. **Dispersión:** rango, IQR, varianza, desviación estándar, CV
4. **Forma:** z-scores, Chebyshev, regla empírica, asimetría, curtosis
5. **Posición:** percentiles, cuartiles, five-number summary
6. **Aplicación:** análisis completo de MOD_INGLES_PUNT

Para la próxima sesión

- Repasar funciones de R: `mean()`, `median()`, `sd()`, `quantile()`, `summary()`
- Traer computadora con R y RStudio instalados
- Descargar los datos ICFES del repositorio del curso

Próxima sesión: Estadística Descriptiva Gráfica

Vie 14 ago 2026

Temas a cubrir:

- Distribuciones de frecuencia
- Visualización de una variable: histogramas, box plots, density plots
- Visualización de dos variables: scatter plots, heatmaps
- Covarianza y correlación (Pearson y Spearman)
- Paradoja de Simpson
- Pipeline completo de análisis exploratorio de datos (EDA)

Paquetes de R a instalar:

```
install.packages(c("ggplot2", "dplyr", "corrplot", "GGally"))
```