

Sesión 2: Estadística Descriptiva Gráfica, Correlación y EDA

Visualización de datos, correlación y Paradoja de Simpson

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Vie 14 ago 2026

Agenda

Distribuciones de frecuencia

Visualización de una variable

Visualización de dos variables

Covarianza y correlación

Paradoja de Simpson

Pipeline completo de EDA

Resumen

Distribución de frecuencias

Definición

Una **distribución de frecuencias** es una tabla que organiza los datos en clases o categorías, mostrando cuántas observaciones caen en cada una.

Ejemplo: si encuestan a 30 compañeros sobre cuántas horas de TikTok ven al día, la tabla de frecuencias organiza esas respuestas en categorías (0–1h, 1–2h, 2–3h, ...) y cuenta cuántos caen en cada una.

Tipos de frecuencia:

- **Frecuencia absoluta** (f_i): número de observaciones en la clase i
- **Frecuencia relativa** (h_i): proporción, $h_i = f_i/n$
- **Frecuencia acumulada** (F_i): suma de frecuencias hasta la clase i
- **Frecuencia relativa acumulada** (H_i): proporción acumulada hasta i

Ejemplo: tabla de frecuencias

Puntajes de inglés agrupados

Clase	f_i	h_i	F_i	H_i
100–119	45	0.045	45	0.045
120–139	180	0.180	225	0.225
140–159	420	0.420	645	0.645
160–179	280	0.280	925	0.925
180–200	75	0.075	1000	1.000

Lectura: el 42 % de los estudiantes obtiene entre 140 y 159 puntos; el 64.5 % está por debajo de 160. La misma lógica aplica si agrupan el screen time diario del salón en intervalos.

Tablas de frecuencia en R

```
# Para variables categoricas: usar table()
tipo_ies <- c("Publica", "Privada", "Privada", "Publica",
             "Privada", "Privada", "Publica", "Privada")

# Frecuencias absolutas
table(tipo_ies)
# Privada Publica
#      5      3

# Frecuencias relativas
prop.table(table(tipo_ies))
# Privada Publica
# 0.625 0.375

# Con datos ICFES
freq_ies <- table(icfes$INST_CARACTER_ACADEMICO)
prop.table(freq_ies)
```

Distribución de frecuencias agrupadas (1/2)

```
# Para variables continuas: usar cut() para crear intervalos
puntajes <- icfes$MOD_INGLES_PUNT

# Crear intervalos
intervalos <- cut(puntajes,
                  breaks = seq(100, 200, by = 20),
                  include.lowest = TRUE,
                  right = FALSE)

# Tabla de frecuencias
freq_tabla <- table(intervalos)
freq_tabla

# Frecuencias relativas
prop.table(freq_tabla)
```

Distribución de frecuencias agrupadas (2/2)

```
# Tabla completa con frecuencias acumuladas  
library(tidyverse)  
tibble(  
  clase = names(freq_tabla),  
  f = as.numeric(freq_tabla),  
  h = f / sum(f),  
  F = cumsum(f),  
  H = cumsum(h)  
)
```

Histograma

Definición

Un **histograma** muestra la distribución de frecuencias de una variable continua mediante barras contiguas. Imaginen un histograma del screen time diario de todos en el salón: cada barra muestra cuántos caen en un rango de horas.

Componentes:

- **Bins** (intervalos): rangos en el eje x
- **Altura**: frecuencia o densidad
- Área total = 1 (con densidad)

Interpretación:

- Centro: ¿dónde se concentran?
- Dispersión: ¿qué tan amplia?
- Forma: ¿simétrica, sesgada?
- Outliers: ¿valores aislados?

Número de bins

Demasiados → ruido; muy pocos → se pierde detalle. **Regla de Sturges:**

$$k = 1 + 3,322 \log_{10}(n)$$

Histograma en R con ggplot2

```
library(ggplot2)

# Histograma basico
ggplot(icfes, aes(x = MOD_INGLES_PUNT)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  labs(title = "Distribucion de puntajes de ingles - Saber Pro NI",
       x = "Puntaje de ingles",
       y = "Frecuencia") +
  theme_minimal()

# Histograma con densidad
ggplot(icfes, aes(x = MOD_INGLES_PUNT)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30,
                fill = "steelblue", color = "white", alpha = 0.7) +
  geom_density(color = "red", linewidth = 1) +
  labs(title = "Distribucion de puntajes de ingles",
       x = "Puntaje", y = "Densidad") +
  theme_minimal()
```

Estimación de densidad kernel (KDE)

Kernel Density Estimation

Alternativa suavizada al histograma. Estima la función de densidad de probabilidad subyacente.

```
# Density plot
ggplot(icfes, aes(x = MOD_INGLES_PUNT)) +
  geom_density(fill = "lightblue", alpha = 0.5, color = "darkblue") +
  geom_vline(aes(xintercept = mean(MOD_INGLES_PUNT, na.rm = TRUE)),
             color = "red", linetype = "dashed", linewidth = 1) +
  geom_vline(aes(xintercept = median(MOD_INGLES_PUNT, na.rm = TRUE)),
             color = "green", linetype = "dashed", linewidth = 1) +
  labs(title = "Estimacion de densidad - puntaje de ingles",
       x = "Puntaje", y = "Densidad",
       caption = "Rojo = media, Verde = mediana") +
  theme_minimal()
```

Ventajas: suave, fácil de interpretar

Desventajas: sensible al parámetro de ancho de banda


Box plot (diagrama de caja)

Definición

Un **box plot** es un gráfico que muestra el five-number summary y los outliers.

Componentes:

- **Caja:** va desde Q1 hasta Q3 (contiene el 50 % central)
- **Línea en la caja:** mediana (Q2)
- **Bigotes:** se extienden hasta el valor más lejano dentro de $1.5 \times \text{IQR}$
- **Puntos:** outliers (fuera de los bigotes)



Ventajas: compacto, fácil comparar grupos, identifica outliers. Ej: comparar horas de sueño entre los que usan TikTok antes de dormir vs. los que no.

Box plot en R (1/2)

```
# Box plot basico (vertical)
ggplot(icfes, aes(y = MOD_INGLES_PUNT)) +
  geom_boxplot(fill = "lightblue", outlier.color = "red") +
  labs(title = "Box plot de puntajes de ingles",
        y = "Puntaje de ingles") +
  theme_minimal()

# Box plot horizontal
ggplot(icfes, aes(x = MOD_INGLES_PUNT)) +
  geom_boxplot(fill = "lightgreen", outlier.color = "red") +
  labs(title = "Puntajes de ingles - NI 2024",
        x = "Puntaje de ingles") +
  theme_minimal()
```

Box plot en R (2/2): identificar outliers

```
# Identificar outliers numericamente con metodo IQR
Q1 <- quantile(icfes$MOD_INGLES_PUNT, 0.25, na.rm = TRUE)
Q3 <- quantile(icfes$MOD_INGLES_PUNT, 0.75, na.rm = TRUE)
IQR_val <- Q3 - Q1

outliers <- icfes %>%
  filter(MOD_INGLES_PUNT < Q1 - 1.5*IQR_val |
         MOD_INGLES_PUNT > Q3 + 1.5*IQR_val)

cat("Numero de outliers:", nrow(outliers))
```

Box plot comparativo: por tipo de IES

```
# Comparar por tipo de IES
ggplot(icfes, aes(x = INST_CHARACTER_ACADEMICO,
                  y = MOD_INGLES_PUNT,
                  fill = INST_CHARACTER_ACADEMICO)) +
  geom_boxplot(outlier.color = "red", outlier.alpha = 0.5) +
  labs(title = "Puntajes de ingles por tipo de IES",
       x = "Tipo de institucion",
       y = "Puntaje de ingles") +
  theme_minimal() +
  theme(legend.position = "none",
        axis.text.x = element_text(angle = 45, hjust = 1))
```

Box plot comparativo: por estrato

```
# Comparar puntaje de ingles por estrato socioeconomico
icfes %>%
  filter(!is.na(FAMI ESTRATOVIVIENDA)) %>%
  ggplot(aes(x = factor(FAMI ESTRATOVIVIENDA),
                 y = MOD_INGLES_PUNT,
                 fill = factor(FAMI ESTRATOVIVIENDA))) +
  geom_boxplot() +
  labs(title = "Puntajes de ingles por estrato",
        x = "Estrato", y = "Puntaje de ingles") +
  theme_minimal() +
  theme(legend.position = "none")
```

Gráfico de barras: frecuencias

```
# Grafico de barras simple  
ggplot(icfes, aes(x = INST_CARACTER_ACADEMICO)) +  
  geom_bar(fill = "steelblue") +  
  labs(title = "Estudiantes NI por tipo de IES",  
        x = "Tipo de institucion", y = "Frecuencia") +  
  theme_minimal() +  
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```


Gráfico de barras: proporciones

```
# Con proporciones y etiquetas
icfes %>%
  count(INST_CHARACTER_ACADEMICO) %>%
  mutate(prop = n / sum(n)) %>%
  ggplot(aes(x = reorder(INST_CHARACTER_ACADEMICO, -prop),
               y = prop)) +
  geom_bar(stat = "identity", fill = "coral") +
  geom_text(aes(label = paste0(round(prop*100, 1), "%")),
            vjust = -0.5) +
  labs(title = "Proporcion de estudiantes por tipo de IES",
        x = "Tipo de institucion", y = "Proporcion") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```

Buenas prácticas de visualización

Principios de visualización efectiva

1. **Claridad:** título descriptivo, ejes etiquetados con unidades
2. **Simplicidad:** eliminar elementos innecesarios (chartjunk)
3. **Honestidad:** ejes que empiezan en cero (para barras), escalas apropiadas
4. **Accesibilidad:** paletas de colores amigables para daltónicos
5. **Contexto:** incluir leyenda, fuente de datos, notas explicativas

Errores comunes a evitar:

- Gráficos 3D innecesarios (distorsionan percepción)
- Demasiados colores (usar 3-5 máximo)
- Ejes truncados o escalas manipuladas para exagerar diferencias (esos gráficos engañosos que ven en Twitter/X con ejes manipulados)
- Gráficos de pastel con muchas categorías (preferir barras)
- Falta de contexto o unidades

Scatter plot (diagrama de dispersión)

Definición

Un **scatter plot** muestra la relación entre dos variables cuantitativas, con cada punto representando una observación. Ej: horas de estudio vs. nota del parcial — cada punto es un compañero del salón.

Qué buscar:

- **Dirección:** positiva, negativa o ninguna
- **Forma:** lineal, curva, sin patrón
- **Fuerza:** puntos cerca de una línea (fuerte) o dispersos (débil)
- **Outliers:** puntos alejados del patrón general

Scatter plot: ejemplo de interpretación

Saber 11 inglés (eje x) vs Saber Pro inglés (eje y)

- Dirección positiva: mejor Saber 11 $\rightarrow$ mejor Saber Pro
- Forma aproximadamente lineal
- Fuerza moderada a fuerte ($r \approx 0,6-0,7$)

La correlación cuantifica esta relación (ver sección siguiente).

Scatter plot en R

```
# Scatter plot basico
ggplot(icfes, aes(x = PUNT_INGLES_S11, y = MOD_INGLES_PUNT)) +
  geom_point(alpha = 0.3, color = "steelblue") +
  labs(title = "Relacion entre Saber 11 y Saber Pro (Ingles)",
        x = "Puntaje Saber 11 Ingles",
        y = "Puntaje Saber Pro Ingles") +
  theme_minimal()

# Con linea de tendencia
ggplot(icfes, aes(x = PUNT_INGLES_S11, y = MOD_INGLES_PUNT)) +
  geom_point(alpha = 0.3, color = "steelblue") +
  geom_smooth(method = "lm", color = "red", se = TRUE) +
  labs(title = "Relacion Saber 11 vs Saber Pro (Ingles)",
        x = "Saber 11 Ingles",
        y = "Saber Pro Ingles",
        caption = paste("r =",
                        round(cor(icfes$PUNT_INGLES_S11, icfes$MOD_INGLES_PUNT,
                                use = "complete.obs"), 3))) +
  theme_minimal()
```

Scatter plot: colorear por grupo

```
# Colorear por tipo de IES
ggplot(icfes, aes(x = PUNT_INGLES_S11,
                  y = MOD_INGLES_PUNT,
                  color = INST_CARACTER_ACADEMICO)) +
  geom_point(alpha = 0.4) +
  geom_smooth(method = "lm", se = FALSE) +
  labs(title = "S11 vs SPro por tipo de IES",
       x = "Saber 11 Ingles",
       y = "Saber Pro Ingles",
       color = "Tipo de IES") +
  theme_minimal()
```

Scatter plot: facetas por estrato

```
# Facetas por estrato socioeconomico
icfes %>%
  filter(!is.na(FAMI ESTRATOVIVIENDA),
         FAMI ESTRATOVIVIENDA %in% c(1,2,3,4,5,6)) %>%
  ggplot(aes(x = PUNT_INGLES_S11, y = MOD_INGLES_PUNT)) +
  geom_point(alpha = 0.3, color = "steelblue") +
  geom_smooth(method = "lm", color = "red", se = FALSE) +
  facet_wrap(~ FAMI ESTRATOVIVIENDA, nrow = 2) +
  labs(title = "Relacion S11 vs SPro por estrato",
       x = "Saber 11 Ingles", y = "Saber Pro Ingles") +
  theme_minimal()
```

Heatmap: puntaje promedio por departamento (1/2)

```
# Calcular puntaje promedio por departamento
mapa_depto <- icfes %>%
  filter(!is.na(ESTU_DEPTO_RESIDE)) %>%
  group_by(ESTU_DEPTO_RESIDE) %>%
  summarise(
    n = n(),
    puntaje_medio = mean(MOD_INGLES_PUNT, na.rm = TRUE)
  ) %>%
  arrange(desc(puntaje_medio))
```


Heatmap: puntaje promedio por departamento (2/2)

```
# Heatmap simple (solo tabla)
ggplot(mapa_depto %>% top_n(20, n),
       aes(x = reorder(ESTU_DEPTO_RESIDE, puntaje_medio),
           y = 1, fill = puntaje_medio)) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(puntaje_medio, 1)), color = "white") +
  scale_fill_gradient(low = "red", high = "green") +
  labs(title = "Puntaje promedio de ingles por departamento (Top 20)",
       x = "Departamento", fill = "Puntaje medio") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1),
        axis.title.y = element_blank(),
        axis.text.y = element_blank())
```

Barras lado a lado (dodge)

```
# Preparar datos: contar por tipo de IES y estrato
datos_barras <- icfes %>%
  filter(!is.na(FAMI_ESTRATOVIVIENDA),
         FAMI_ESTRATOVIVIENDA %in% c(2,3,4,5)) %>%
  count(INST_CARACTER_ACADEMICO, FAMI_ESTRATOVIVIENDA)

# Barras lado a lado
ggplot(datos_barras, aes(x = factor(FAMI_ESTRATOVIVIENDA),
                             y = n,
                             fill = INST_CARACTER_ACADEMICO)) +
  geom_bar(stat = "identity", position = "dodge") +
  labs(title = "Estudiantes por estrato y tipo IES",
       x = "Estrato", y = "Frecuencia", fill = "Tipo IES") +
  theme_minimal()
```

Barras apiladas (100 %)

```
# Barras apiladas proporcionales
ggplot(datos_barras, aes(x = factor(FAMI_ESTRATOVIVIENDA),
                             y = n,
                             fill = INST_CARACTER_ACADEMICO)) +
  geom_bar(stat = "identity", position = "fill") +
  labs(title = "Composicion por tipo IES segun estrato",
        x = "Estrato", y = "Proporcion", fill = "Tipo IES") +
  theme_minimal()
```

position = "dodge" compara magnitudes; position = "fill" compara composición relativa.

Tablas cruzadas con `table()`

```
# Tabla cruzada de dos variables categoricas
tabla_cruzada <- table(icfes$INST_CARACTER_ACADEMICO,
                      icfes$FAMI_ESTRATOVIVIENDA)

tabla_cruzada

# Proporciones por fila (suman 1 en cada fila)
prop.table(tabla_cruzada, margin = 1)

# Proporciones por columna (suman 1 en cada columna)
prop.table(tabla_cruzada, margin = 2)
```

Tablas cruzadas con tidyverse

```
# Proporciones por tipo de IES con tidyverse
icfes %>%
  filter(!is.na(FAMI_ESTRATOVIVIENDA)) %>%
  count(INST_CARACTER_ACADEMICO, FAMI_ESTRATOVIVIENDA) %>%
  group_by(INST_CARACTER_ACADEMICO) %>%
  mutate(proporcion = n / sum(n))

# Prueba chi-cuadrado de asociacion
chisq.test(tabla_cruzada)
```

Veremos pruebas de hipótesis formales en sesiones futuras.

Covarianza

Definición

La **covarianza** mide la variación conjunta de dos variables. Indica si tienden a variar juntas en la misma dirección o en direcciones opuestas.

Covarianza muestral:

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Interpretación:

- $s_{xy} > 0$: relación positiva (cuando x aumenta, y tiende a aumentar)
- $s_{xy} < 0$: relación negativa (cuando x aumenta, y tiende a disminuir)
- $s_{xy} \approx 0$: no hay relación lineal

Ejemplo: los likes y comentarios en un post de Instagram tienden a subir juntos → covarianza positiva.

Limitación

La magnitud de s_{xy} depende de las unidades de x e y. No se puede comparar entre pares de variables diferentes. **Solución: usar correlación.**

Correlación de Pearson

Definición

El **coeficiente de correlación de Pearson** (r) es la covarianza estandarizada. Mide la fuerza y dirección de la relación **lineal** entre dos variables.

$$r = \frac{s_{xy}}{s_x \cdot s_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Propiedades:

- Rango: $-1 \leq r \leq 1$
- $r = 1$: relación lineal positiva perfecta
- $r = -1$: relación lineal negativa perfecta
- $r = 0$: no hay relación lineal
- Sin unidades (adimensional)
- Simétrico: $r_{xy} = r_{yx}$

Interpretación de la correlación

Valor de $ r $	Interpretación
0,0 – 0,3	Débil o nula
0,3 – 0,5	Moderada débil
0,5 – 0,7	Moderada
0,7 – 0,9	Fuerte
0,9 – 1,0	Muy fuerte

Nota: estos rangos son guías orientativas, no reglas absolutas.

Ejemplo: $r = 0,8$ entre horas de estudio y nota del parcial indica una relación fuerte positiva: a más horas, mejor nota (en promedio).

Advertencias sobre la correlación

Tres advertencias clave

1. **Solo mide relaciones LINEALES**. Puede haber relaciones no lineales fuertes con $r \approx 0$.
2. **Correlación $\neq$ causalidad**. Puede deberse a variables confusoras, causalidad inversa o coincidencia.
3. **Outliers** pueden inflar o deflacionar r artificialmente.

Ejemplo: la correlación entre consumo de café y buenas notas es alta, pero la variable confusora es que los que toman más café también estudian más horas.

Correlación en R (1/2)

```
# Correlacion entre dos variables
cor(icfes$PUNT_INGLES_S11, icfes$MOD_INGLES_PUNT,
    use = "complete.obs")
# [1] 0.682
# use = "complete.obs" elimina pares con NA

# Matriz de correlacion de multiples variables
variables_interes <- icfes %>%
  select(MOD_INGLES_PUNT, MOD_LECTURA_CRITICA_PUNT,
         MOD_RAZONA_CUANTITAT_PUNT, MOD_COMPETEN_CIUADADA_PUNT,
         MOD_COMUNICACION_ESCRITA_PUNT)

matriz_cor <- cor(variables_interes, use = "complete.obs")
round(matriz_cor, 3)
```

Correlación en R (2/2): visualización

```
# Visualizar matriz de correlacion con corrplot  
library(corrplot)  
corrplot(matriz_cor, method = "color", type = "upper",  
         addCoef.col = "black", tl.col = "black",  
         tl.srt = 45, diag = FALSE)
```

corrplot permite ver patrones rápidamente: azul = positiva, rojo = negativa, intensidad = fuerza.

Correlación de Spearman

Definición

La **correlación de Spearman** (ρ , rho) es la correlación de Pearson aplicada a los **rangos** de los datos, no a los valores originales.

Cuándo usar Spearman:

- Relación monótonica pero no necesariamente lineal
- Datos ordinales
- Presencia de outliers (es más robusta)
- Distribuciones muy sesgadas

Interpretación: igual que Pearson (-1 a 1), pero mide asociación monótonica.

Ejemplos

Estrato (ordinal: 1, ..., 6) vs puntaje de inglés: Spearman es más apropiado que Pearson porque estrato es ordinal. Rating de un restaurante en Rappi (1–5 estrellas, ordinal) vs. precio del plato → Spearman es más apropiado que Pearson.

Correlación de Spearman en R

```
# Correlacion de Spearman
cor(icfes$FAMI ESTRATOVIVIENDA, icfes$MOD_INGLES_PUNT,
    method = "spearman", use = "complete.obs")
# [1] 0.428

# Comparar Pearson vs Spearman
cat("Pearson:", cor(icfes$FAMI ESTRATOVIVIENDA,
    icfes$MOD_INGLES_PUNT,
    use = "complete.obs"), "\n")
cat("Spearman:", cor(icfes$FAMI ESTRATOVIVIENDA,
    icfes$MOD_INGLES_PUNT,
    method = "spearman",
    use = "complete.obs"), "\n")
```

Matriz de correlación de Spearman

```
# Matriz de correlacion de Spearman
matriz_cor_spearman <- cor(variables_interes,
                           method = "spearman",
                           use = "complete.obs")

corrplot(matriz_cor_spearman, method = "circle",
         type = "upper", addCoef.col = "black")
```

Comparar las matrices de Pearson y Spearman permite detectar relaciones no lineales.

Ejemplo: correlación entre módulos Saber Pro

```
# Seleccionar los 5 modulos genericos (con alias cortos)
modulos <- icfes %>%
  select(Ingles = MOD_INGLES_PUNT,
         Lectura = MOD_LECTURA_CRITICA_PUNT,
         Cuant = MOD_RAZONA_CUANTITAT_PUNT,
         Ciudad = MOD_COMPETEN_CIUADADA_PUNT,
         Escrit = MOD_COMUNICACION_ESCRITA_PUNT)

# Matriz de correlacion
round(cor(modulos, use = "complete.obs"), 3)

# Visualizacion avanzada con GGally
library(GGally)
ggpairs(modulos,
        title = "Correlacion - Modulos Saber Pro")
```

Paradoja de Simpson

Definición

La **Paradoja de Simpson** ocurre cuando una tendencia que aparece en varios grupos **se invierte** cuando los grupos se combinan.

Implicaciones:

- Una relación puede cambiar de dirección al agregar o desagregar datos
- Controlando por una tercera variable (confusora), la relación puede invertirse
- Muestra la importancia de identificar variables confusoras
- Fundamental para el diseño de experimentos y análisis causal

Ejemplo cotidiano

Una app de delivery puede tener mejor rating **agregado** que otra, pero peor rating en cada categoría individual (comida, rapidez, empaque) — porque una app recibe más reseñas en categorías difíciles.

Lección clave

Ejemplo clásico: admisiones Berkeley 1973

Contexto: demanda por discriminación de género en admisiones de posgrado.

Datos agregados:

	Admitidos	Tasa de admisión
Hombres	1198 / 2691	44 %
Mujeres	557 / 1835	30 %

Conclusión agregada: parece haber sesgo contra mujeres (44 % vs 30 %).

Datos desagregados por departamento:

- En casi todos los departamentos, las mujeres tenían tasas de admisión **iguales o mayores**
- Pero las mujeres aplicaban más a departamentos muy competitivos (baja tasa de admisión)
- Los hombres aplicaban más a departamentos menos competitivos (alta tasa de admisión)

Variable confusora: competitividad del departamento

Ejemplo con datos ICFES (1/2)

```
# Ejemplo simulado: relacion entre estrato y puntaje  
# agregada vs desagregada por tipo de IES  
  
# Correlacion agregada (todos los estudiantes juntos)  
cor_agregada <- cor(icfes$FAMI ESTRATOVIVIENDA,  
                    icfes$MOD_INGLES_PUNT,  
                    use = "complete.obs")  
  
# Correlacion por tipo de IES  
cor_desagregada <- icfes %>%  
  group_by(INST_CARACTER_ACADEMICO) %>%  
  summarise(  
    n = n(),  
    cor = cor(FAMI ESTRATOVIVIENDA, MOD_INGLES_PUNT,  
              use = "complete.obs")  
  )
```

Ejemplo con datos ICFES (2/2)

```
# Scatter plot mostrando la paradoja
ggplot(icfes, aes(x = FAMI_ESTRATOVIVIENDA, y = MOD_INGLES_PUNT,
                  color = INST_CHARACTER_ACADEMICO)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm", se = FALSE) + # Lineas por grupo
  geom_smooth(aes(group = 1), method = "lm", color = "black",
              linetype = "dashed", se = FALSE) + # Linea agregada
  labs(title = "Paradoja de Simpson: estrato vs puntaje") +
  theme_minimal()
```

Por qué la regresión múltiple es necesaria

Problema fundamental

Las correlaciones bivariadas pueden ser engañosas:

- No controlan por variables confusoras
- No separan efectos de múltiples factores simultáneos
- Pueden reflejar asociaciones espurias

Solución: Regresión múltiple

- Estima el efecto de una variable **manteniendo otras constantes**
- Controla por variables confusoras
- Ejemplo: efecto de Saber 11 en Saber Pro, **controlando por** tipo de IES, estrato, género

Adelanto

En sesiones 5–6 estudiaremos regresión lineal simple y múltiple.

Flujo de trabajo EDA

Análisis Exploratorio de Datos (EDA)

Proceso iterativo para entender la estructura, patrones y anomalías en los datos **antes** de modelar. Es como cuando stalkean un perfil de Instagram: primero ven el feed general, luego las fotos, luego los comments, luego los tagged... El EDA hace lo mismo con datos.

Pipeline típico:

1. **Cargar:** importar datos, verificar dimensiones
2. **Limpiar:** identificar y tratar valores faltantes, duplicados, errores
3. **Transformar:** crear variables derivadas, recodificar, filtrar
4. **Resumir:** estadísticas descriptivas (media, mediana, sd, etc.)
5. **Visualizar:** histogramas, box plots, scatter plots, correlaciones
6. **Segmentar:** análisis por subgrupos (tipo IES, estrato, región)
7. **Identificar anomalías:** outliers, valores extremos, inconsistencias
8. **Documentar:** hallazgos clave, preguntas para investigar

EDA completo de ICFES NI: cargar y limpiar

```
library(tidyverse)
library(moments)
library(corrplot)

# 1. CARGAR
icfes <- read_csv("datos/saber_pro_ni_2024.csv")
dim(icfes) # dimension
glimpse(icfes) # estructura

# 2. LIMPIAR
# Valores faltantes
colSums(is.na(icfes))
# Eliminar filas con NA en variable clave
icfes_clean <- icfes %>%
  filter(!is.na(MOD_INGLES_PUNT))

# Duplicados
icfes_clean <- icfes_clean %>% distinct()
```

EDA completo de ICFES NI: transformar

```
# 3. TRANSFORMAR
icfes_clean <- icfes_clean %>%
  mutate(
    # Categoria de desempeno en ingles
    nivel_ingles = cut(MOD_INGLES_PUNT,
                      breaks = c(0, 140, 160, 180, 200),
                      labels = c("Bajo", "Medio", "Alto", "Superior")),
    # Promedio de modulos genericos
    promedio_modulos = (MOD_INGLES_PUNT + MOD_LECTURA_CRITICA_PUNT +
                       MOD_RAZONA_CUANTITAT_PUNT) / 3
  )
```

EDA completo: resumir

```
# 4. RESUMIR  
summary(icfes_clean$MOD_INGLES_PUNT)  
sd(icfes_clean$MOD_INGLES_PUNT)  
skewness(icfes_clean$MOD_INGLES_PUNT)
```


EDA completo: visualizar (histograma y box plot)

```
# 5. VISUALIZAR
# Histograma
ggplot(icfes_clean, aes(x = MOD_INGLES_PUNT)) +
  geom_histogram(bins = 30, fill = "steelblue") +
  theme_minimal()

# Box plot por tipo IES
ggplot(icfes_clean, aes(x = INST_CARACTER_ACADEMICO,
                        y = MOD_INGLES_PUNT)) +
  geom_boxplot() + theme_minimal()
```

EDA completo: visualizar (scatter y correlaciones)

```
# Scatter plot: Saber 11 vs Saber Pro
ggplot(icfes_clean, aes(x = PUNT_INGLES_S11, y = MOD_INGLES_PUNT)) +
  geom_point(alpha = 0.3) +
  geom_smooth(method = "lm") +
  theme_minimal()

# Matriz de correlacion
cor_matrix <- cor(icfes_clean %>%
  select(starts_with("MOD_")), use = "complete.obs")
corrplot(cor_matrix, method = "color")
```

EDA completo: segmentar

```
# 6. SEGMENTAR
# Por tipo de IES
icfes_clean %>%
  group_by(INST_CARACTER_ACADEMICO) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT),
    mediana = median(MOD_INGLES_PUNT),
    sd = sd(MOD_INGLES_PUNT),
    asimetria = skewness(MOD_INGLES_PUNT)
  )

# Por estrato
icfes_clean %>%
  filter(!is.na(FAMI ESTRATOVIVIENDA)) %>%
  group_by(FAMI ESTRATOVIVIENDA) %>%
  summarise(across(MOD_INGLES_PUNT,
                    list(media = mean, mediana = median, sd = sd)))
```

EDA completo: identificar anomalías

```
# 7. IDENTIFICAR ANOMALIAS
# Outliers (metodo IQR)
Q1 <- quantile(icfes_clean$MOD_INGLES_PUNT, 0.25)
Q3 <- quantile(icfes_clean$MOD_INGLES_PUNT, 0.75)
IQR_val <- Q3 - Q1
outliers <- icfes_clean %>%
  filter(MOD_INGLES_PUNT < Q1 - 1.5*IQR_val |
         MOD_INGLES_PUNT > Q3 + 1.5*IQR_val)
nrow(outliers)
```

Checklist EDA

Lista de verificación antes de modelar

- ☐ ¿Entiendo qué mide cada variable?
- ☐ ¿Cuántos valores faltantes hay? ¿Por qué faltan?
- ☐ ¿Hay duplicados?
- ☐ ¿Hay outliers? ¿Son errores o datos reales?
- ☐ ¿Cuál es la distribución de cada variable (forma, centro, dispersión)?
- ☐ ¿Hay relaciones entre variables? ¿Cuáles son las más fuertes?
- ☐ ¿Hay diferencias importantes entre subgrupos?
- ☐ ¿Hay variables confusoras que deba controlar?
- ☐ ¿Los datos son representativos de la población de interés?
- ☐ ¿Qué preguntas sustantivas puedo responder con estos datos?

Documentar hallazgos en un reporte o Rmarkdown!

Resumen de la sesión

Conceptos clave cubiertos:

1. **Distribuciones de frecuencia:** absolutas, relativas, acumuladas
2. **Visualización univariada:** histograma, density plot, box plot, barras
3. **Visualización bivariada:** scatter plot, heatmap, tablas cruzadas
4. **Covarianza y correlación:** Pearson (lineal), Spearman (monotónica)
5. **Paradoja de Simpson:** por qué desagregar es crucial
6. **Pipeline EDA:** cargar → limpiar → explorar → visualizar → reportar

Mensajes clave

- Visualizar siempre antes de resumir numéricamente
- Correlación $\neq$ causalidad
- Explorar subgrupos antes de agregar
- El EDA es iterativo, no lineal

Próxima sesión: Probabilidad, Normal y Muestreo

Vie 21 ago 2026

Temas a cubrir:

- Variables aleatorias y distribuciones de probabilidad
- Distribución normal: propiedades, cálculo de probabilidades, cuantiles
- Distribuciones t, chi-cuadrado y F
- Muestreo y distribución muestral de $\bar{X}$
- Teorema Central del Límite (fundamento de la inferencia)
- Propiedades de estimadores

Preparación:

- Repasar conceptos de probabilidad básica (si es necesario)
- Instalar paquete `moments` en R
- Familiarizarse con funciones `dnorm()`, `pnorm()`, `qnorm()`