

Sesión 3: Probabilidad, Distribución Normal y Muestreo

De la probabilidad al Teorema Central del Límite

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Vie 21 ago 2026

Agenda

Variables aleatorias

Distribución normal

Distribuciones chi-cuadrado, t y F

Muestreo y distribución muestral de $\bar{X}$

Teorema Central del Límite

Propiedades de estimadores

Resumen y conexión

Variable aleatoria

Definición

Una **variable aleatoria** es una función que asigna un valor numérico a cada resultado de un experimento aleatorio.

Notación: mayúsculas (X , Y , Z) para la variable aleatoria; minúsculas (x , y , z) para valores específicos.

Ejemplos

- X = puntaje de inglés en Saber Pro (valores entre 0 y 200)
- Y = número de estudiantes que aprueban (valores 0, 1, 2, ..., n)
- Z = horas diarias de *screen time* en el celular (valores ≥ 0)

Tipos:

- **Discreta:** valores separados, contables (ej: número de aprobados)
- **Continua:** cualquier valor en un intervalo (ej: puntaje, altura, tiempo)

Función de probabilidad (variable discreta)

Variable discreta: Función de probabilidad (pmf)

$$P(X = x)$$

Propiedades:

- $0 \leq P(X = x) \leq 1$
- $\sum_{\text{todos } x} P(X = x) = 1$

Ejemplo: X = resultado de un dado

$$P(X = k) = \frac{1}{6}, \quad k = 1, 2, 3, 4, 5, 6$$

Función de densidad (variable continua)

Variable continua: Función de densidad (pdf)

$$f(x)$$

Propiedades:

- $f(x) \geq 0$
- $\int_{-\infty}^{\infty} f(x)dx = 1$
- $P(a \leq X \leq b) = \int_a^b f(x)dx$

Importante: Para variables continuas,

$$P(X = x) = 0$$

Solo tiene sentido calcular $P(a \leq X \leq b)$

Valor esperado

Valor esperado (media poblacional)

El **valor esperado** de X , denotado $E(X)$ o μ , es el promedio ponderado de todos los valores posibles.

Discreta:

$$E(X) = \mu = \sum_{\text{todos } x} x \cdot P(X = x)$$

Continua:

$$E(X) = \mu = \int_{-\infty}^{\infty} x \cdot f(x) dx$$

Varianza

La **varianza** de X , denotada $\text{Var}(X)$ o σ^2 , mide la dispersión alrededor de μ .

$$\text{Var}(X) = \sigma^2 = E[(X - \mu)^2] = E(X^2) - [E(X)]^2$$

Desviación estándar: $\sigma = \sqrt{\sigma^2}$

Parámetros vs estadísticos

Nota: μ y σ son **parámetros poblacionales** (fijos, desconocidos). $\bar{x}$ y s son **estadísticos muestrales** (variables, observables).

Ejemplo: puntaje de inglés como variable aleatoria

Puntaje de inglés Saber Pro para NI como variable aleatoria continua X . De la misma forma, el *screen time* diario de cada estudiante del salón es una variable aleatoria continua.

Interpretación probabilística:

- X toma valores entre 0 y 200, con media μ y desviación estándar σ
- $P(X \leq 150)$ = proporción con puntaje ≤ 150
- $P(160 \leq X \leq 180)$ = proporción entre 160 y 180

Parámetros vs estadísticos (cont.)

Relación con estadística descriptiva:

- **Toda la población:** μ y σ se calculan directamente
- **Muestra:** estimamos μ con $\bar{x}$ y σ con s

Pregunta clave: ¿Cuál es la distribución de X ? Esto determina cómo calculamos probabilidades.

La distribución normal

Definición

La **distribución normal** (o gaussiana) es la distribución de probabilidad continua más importante en estadística.

Función de densidad:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}, \quad -\infty < x < \infty$$

Notación: $X \sim N(\mu, \sigma^2)$ (X sigue una distribución normal con media μ y varianza σ^2)

Parámetros:

- μ : media (centro de la distribución) σ : desviación estándar (dispersión) σ^2 : varianza

La distribución normal: ejemplo e intuición


Ejemplo cotidiano

El *screen time* diario de los estudiantes del salón sigue aproximadamente una campana de Gauss: la mayoría usa el celular entre 4 y 6 horas, y muy pocos están en los extremos (menos de 1 h o más de 9 h).

Importante: La normal está completamente determinada por μ y σ . Conociendo estos dos parámetros, podemos calcular cualquier probabilidad.

Propiedades de la distribución normal

1. **Forma de campana:** simétrica alrededor de μ
2. **Unimodal:** un solo pico en $x = \mu$
3. **Media = Mediana = Moda = μ**
4. **Asíntota:** las colas se acercan al eje x pero nunca lo tocan
5. **Área total = 1** (integra a 1)
6. **Puntos de inflexión:** en $\mu \pm \sigma$
7. **Regla 68-95-99.7:**
 - 68 % de los datos caen dentro de $\mu \pm 1\sigma$
 - 95 % caen dentro de $\mu \pm 2\sigma$
 - 99.7 % caen dentro de $\mu \pm 3\sigma$



Distribución normal estándar

Definición

La **distribución normal estándar** es una normal con $\mu = 0$ y $\sigma = 1$: $Z \sim N(0, 1)$

Función de densidad: $f(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$

Estandarización: Cualquier $X \sim N(\mu, \sigma^2)$ se transforma a:

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

¿Por qué es útil?

- Todas las probabilidades se calculan con una sola tabla (tabla Z)
- Permite comparar variables en escalas distintas (ej: tu puntaje Saber Pro vs tu número de seguidores en Instagram)
- Simplifica cálculos teóricos

Cálculo de probabilidades con la normal

Tipos de probabilidades:

1. $P(X \leq a)$: probabilidad de que X sea menor o igual a a
 - Área bajo la curva a la izquierda de a
2. $P(X \geq a)$: probabilidad de que X sea mayor o igual a a
 - $P(X \geq a) = 1 - P(X \leq a)$
3. $P(a \leq X \leq b)$: probabilidad de que X esté entre a y b
 - $P(a \leq X \leq b) = P(X \leq b) - P(X \leq a)$

Procedimiento general:

1. Identificar μ y σ de la distribución
2. Estandarizar: $z = (x - \mu)/\sigma$
3. Buscar en tabla Z o usar software

Ejemplo: probabilidades con puntaje de inglés

Problema

$X = \text{puntaje de inglés Saber Pro NI} \sim N(155, 20^2)$.

a) ¿Proporción con puntaje ≤ 150 ?

$$P(X \leq 150) = P\left(Z \leq \frac{150 - 155}{20}\right) = P(Z \leq -0,25) = 0,4013$$

Respuesta: Aproximadamente 40 % obtienen ≤ 150 .

b) ¿Proporción que supera 170?

$$P(X > 170) = 1 - P\left(Z \leq \frac{170 - 155}{20}\right) = 1 - P(Z \leq 0,75)$$

$P(Z \leq 0,75) = 0,7734$, entonces $P(X > 170) = 0,2266$

Respuesta: Aproximadamente 23 % superan 170.

Ejemplo: probabilidad en un intervalo


c) ¿Proporción entre 145 y 165?

$$P(145 \leq X \leq 165) = P(X \leq 165) - P(X \leq 145)$$

Estandarizando: $z_1 = (145 - 155)/20 = -0,5$, $z_2 = (165 - 155)/20 = 0,5$

$$P(-0,5 \leq Z \leq 0,5) = 0,6915 - 0,3085 = 0,3830$$

Respuesta: Aproximadamente 38 % obtienen entre 145 y 165.



Encontrar cuantiles (valores de x dada una probabilidad)

Problema inverso

En lugar de calcular $P(X \leq x)$ dado x , ahora queremos encontrar x dada la probabilidad.

Ejemplo: ¿Qué puntaje deja al 75 % de los estudiantes por debajo? (percentil 75)
Queremos encontrar x tal que $P(X \leq x) = 0,75$

Procedimiento:

1. Encontrar el valor z en la normal estándar tal que $P(Z \leq z) = 0,75$
2. Usar tabla Z inversa o R: $z = 0,674$
3. Desestandarizar: $x = \mu + z\sigma = 155 + 0,674(20) = 168,48$

Respuesta: El percentil 75 es 168.48 puntos. El 75 % de estudiantes obtiene ≤ 168.48 .

Otro ejemplo: ¿Qué puntaje deja al 90 % por debajo?

$$z = 1,282, x = 155 + 1,282(20) = 180,64$$

Funciones de la normal en R (1/2)

```
# dnorm(): funcion de densidad  $f(x)$ 
dnorm(155, mean = 155, sd = 20)
# [1] 0.01994711

# pnorm(): funcion de distribucion acumulada  $P(X \leq x)$ 
pnorm(150, mean = 155, sd = 20) #  $P(X \leq 150)$ 
# [1] 0.4012937

pnorm(170, mean = 155, sd = 20) #  $P(X \leq 170)$ 
# [1] 0.7733726

#  $P(X > 170)$ 
1 - pnorm(170, mean = 155, sd = 20)
# [1] 0.2266274
```

Funciones de la normal en R (2/2)

```
#  $P(145 \leq X \leq 165)$ 
pnorm(165, mean = 155, sd = 20) - pnorm(145, mean = 155, sd = 20)
# [1] 0.3829249

# qnorm(): cuantiles (inversa de pnorm)
qnorm(0.75, mean = 155, sd = 20) # percentil 75
# [1] 168.4898

qnorm(0.90, mean = 155, sd = 20) # percentil 90
# [1] 180.6311
```

`rnorm()`: generar valores aleatorios normales

```
set.seed(123)
muestra <- rnorm(n = 1000, mean = 155, sd = 20)

mean(muestra) # [1] 154.9176 (~155)
sd(muestra)   # [1] 19.82844 (~20)

# Histograma con curva teorica superpuesta
library(ggplot2)
ggplot(data.frame(x = muestra), aes(x = x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30,
    fill = "lightblue", color = "white") +
  stat_function(fun = dnorm, args = list(mean = 155, sd = 20),
    color = "red", linewidth = 1) +
  labs(title = "Muestra simulada vs N(155, 20^2)",
    x = "Puntaje", y = "Densidad") +
  theme_minimal()
```

Comparar datos reales con curva normal (1/2)

```
# Cargar datos reales de ICFES  
library(tidyverse)  
icfes <- read_csv("datos/saber_pro_ni_2024.csv")  
  
# Calcular media y sd muestrales  
mu_hat <- mean(icfes$MOD_INGLES_PUNT, na.rm = TRUE)  
sigma_hat <- sd(icfes$MOD_INGLES_PUNT, na.rm = TRUE)
```

Comparar datos reales con curva normal (2/2)

```
# Histograma de datos reales con curva normal teorica
ggplot(icfes, aes(x = MOD_INGLES_PUNT)) +
  geom_histogram(aes(y = after_stat(density)), bins = 40,
                 fill = "steelblue", color = "white", alpha = 0.7) +
  stat_function(fun = dnorm,
               args = list(mean = mu_hat, sd = sigma_hat),
               color = "red", linewidth = 1.2) +
  labs(title = "Distribucion real vs normal teorica",
       subtitle = paste("N(", round(mu_hat, 1), ",",
                        round(sigma_hat, 1), "^2)"),
       x = "Puntaje de ingles", y = "Densidad") +
  theme_minimal()

# ¿Los datos se parecen a una distribucion normal?
shapiro.test(sample(icfes$MOD_INGLES_PUNT, 5000))
```

Distribución chi-cuadrado (χ^2)

Definición

Si $Z_1, \dots, Z_k$ son independientes $N(0, 1)$, entonces $\chi^2 = Z_1^2 + \dots + Z_k^2 \sim \chi^2(k)$.

Propiedades:

- Solo valores positivos ($\chi^2 \geq 0$)
- Sesgada a la derecha
- $E(\chi^2) = k$, $\text{Var}(\chi^2) = 2k$
- Para k grande, se aproxima a la normal

Usos principales:

- Inferencia sobre varianzas:
 $(n-1)s^2/\sigma^2 \sim \chi^2(n-1)$
- Pruebas de bondad de ajuste
- Independencia en tablas de contingencia

Distribución chi-cuadrado en R (1/2)

```
library(ggplot2)

# Graficar chi-cuadrado para diferentes grados de libertad
x <- seq(0, 20, by = 0.1)
df_chisq <- data.frame(
  x = rep(x, 4),
  y = c(dchisq(x, df = 2), dchisq(x, df = 5),
        dchisq(x, df = 10), dchisq(x, df = 15)),
  df = rep(c("df = 2", "df = 5", "df = 10", "df = 15"),
           each = length(x))
)
```

Distribución chi-cuadrado en R (2/2)

```
ggplot(df_chisq, aes(x = x, y = y, color = df)) +  
  geom_line(linewidth = 1) +  
  labs(title = "Distribucion chi-cuadrado para varios gl",  
        x = "Valor", y = "Densidad", color = "Grados de libertad") +  
  theme_minimal()  
  
# Calcular probabilidades  
pchisq(10, df = 5) #  $P(\chi^2 \leq 10)$  con 5 gl  
# [1] 0.9247726  
  
# Cuantiles  
qchisq(0.95, df = 5) # percentil 95 con 5 gl  
# [1] 11.0705
```


Distribución t de Student

Definición

Si $Z \sim N(0, 1)$ y $V \sim \chi^2(k)$ son independientes, entonces $t = Z/\sqrt{V/k} \sim t(k)$.

Propiedades:

- Simétrica alrededor de 0
- Colas más pesadas que la normal
- $E(t) = 0$ (si $k > 1$)
- $\text{Var}(t) = k/(k-2)$ (si $k > 2$)
- $t(k) \rightarrow N(0, 1)$ cuando $k \rightarrow \infty$
- Para $k \geq 30$, $\approx$ normal

Uso principal:

- Inferencia sobre medias cuando σ es desconocida:

$$\frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t(n-1)$$

- ICs y pruebas de hipótesis para medias

¿De dónde viene la distribución t?

Motivación histórica:

Cuando queremos inferir sobre la media poblacional μ :

- Si conocemos σ : $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$
- Pero en la práctica, σ es desconocido, usamos s
- Reemplazar σ por s introduce incertidumbre adicional
- William Gosset (seudónimo “Student”) descubrió en 1908 que:

$$\frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t(n - 1)$$

Consecuencias:

- Para muestras pequeñas ($n < 30$), la distribución t tiene colas más pesadas
- Intervalos de confianza son más anchos (reflejan mayor incertidumbre)
- A medida que n crece, $s \rightarrow \sigma$ y $t \rightarrow N(0, 1)$

Distribución t : muestra pequeña vs grande

Ejemplo: muestra pequeña vs grande

Si le preguntas a 5 amigos cuántas horas de Netflix ven, la variabilidad es alta y usas t .
Si encuestas a 200 estudiantes, $s \approx \sigma$ y la t se parece a la normal.

Por eso usamos t en lugar de Z cuando estimamos σ con s

Distribución t en R (1/2)

```
# Comparar t con diferentes gl vs normal estandar
x <- seq(-4, 4, by = 0.05)
df_t <- data.frame(
  x = rep(x, 4),
  y = c(dt(x, df = 1), dt(x, df = 5), dt(x, df = 30), dnorm(x)),
  dist = rep(c("t(1)", "t(5)", "t(30)", "N(0,1)"),
             each = length(x))
)

ggplot(df_t, aes(x = x, y = y, color = dist, linetype = dist)) +
  geom_line(linewidth = 1) +
  scale_linetype_manual(values = c("solid", "solid", "solid", "dashed")) +
  labs(title = "Distribucion t vs Normal estandar",
       subtitle = "Nota: colas mas pesadas para t con gl bajos",
       x = "Valor", y = "Densidad") +
  theme_minimal()
```

Distribución t en R (2/2)

```
# Probabilidades y cuantiles
pt(2, df = 10) #  $P(t \leq 2)$  con 10 gl
# [1] 0.9634783

qt(0.975, df = 10) # percentil 97.5% (para IC 95%)
# [1] 2.228139

qt(0.975, df = 30) # con 30 gl
# [1] 2.042272

qnorm(0.975) # normal estandar
# [1] 1.959964
```

Distribución F de Fisher

Definición

Si $U \sim \chi^2(k_1)$ y $V \sim \chi^2(k_2)$ son independientes, entonces

$$F = \frac{U/k_1}{V/k_2} \sim F(k_1, k_2)$$

sigue una distribución F con k_1 y k_2 grados de libertad (numerador y denominador).

Propiedades:

- Solo valores positivos ($F \geq 0$)
- Asimétrica (sesgada a la derecha)
- Depende de dos parámetros: k_1 (gl numerador) y k_2 (gl denominador)

Usos principales:

- Comparar varianzas de dos poblaciones: $\frac{s_1^2/\sigma_1^2}{s_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$
- ANOVA (análisis de varianza): comparar medias de k grupos
- Pruebas de significancia global en regresión lineal múltiple

Distribución F en R (1/2)

```
# Graficar F con diferentes grados de libertad
x <- seq(0, 5, by = 0.05)
df_f <- data.frame(
  x = rep(x, 3),
  y = c(df(x, df1 = 5, df2 = 10),
        df(x, df1 = 10, df2 = 20),
        df(x, df1 = 20, df2 = 30)),
  df_pair = rep(c("F(5, 10)", "F(10, 20)", "F(20, 30)"),
                each = length(x))
)
```

Distribución F en R (2/2)

```
ggplot(df_f, aes(x = x, y = y, color = df_pair)) +  
  geom_line(linewidth = 1) +  
  labs(title = "Distribucion F para varios grados de libertad",  
        x = "Valor", y = "Densidad",  
        color = "Grados de libertad") +  
  theme_minimal()  
  
# Probabilidades  
pf(2.5, df1 = 5, df2 = 20) #  $P(F \leq 2.5)$   
# [1] 0.9345867  
  
# Cuantiles (valores criticos para pruebas)  
qf(0.95, df1 = 5, df2 = 20) # percentil 95  
# [1] 2.710588
```


Población vs muestra

Población

- Conjunto completo de elementos
- Parámetros (fijos, desconocidos):
 - Media: μ
 - Desv. estándar: σ
 - Proporción: p
- Notación: N = tamaño poblacional

Muestra

- Subconjunto de la población
- Estadísticos (variables, observables):
 - Media: $\bar{x}$
 - Desv. estándar: s
 - Proporción: $\hat{p}$
- Notación: n = tamaño muestral

Objetivo de la estadística inferencial

Usar estadísticos muestrales ($\bar{x}$, s , $\hat{p}$) para hacer inferencias sobre parámetros poblacionales (μ , σ , p).


Población vs muestra: ejemplo

Ejemplo concreto

- **Población:** todos los estudiantes de NI en Colombia ($N \approx 50,000$)
- **Muestra:** 500 estudiantes seleccionados aleatoriamente de la base ICFES
- Estimamos μ (puntaje medio poblacional) con $\bar{x}$ (puntaje medio muestral)

Analogía

Es como hacer una encuesta a 30 compañeros del salón sobre cuántas horas de Netflix ven al mes, en lugar de preguntarle a toda la universidad.



Muestreo aleatorio simple

Definición

En el **muestreo aleatorio simple** (MAS), cada elemento de la población tiene la misma probabilidad de ser seleccionado, y cada muestra del mismo tamaño tiene igual probabilidad.

Supuestos clave:

1. Las observaciones son **independientes** entre sí
2. Cada observación proviene de la **misma distribución** (población)
3. Notación: $X_1, X_2, \dots, X_n$ son i.i.d. (independientes e idénticamente distribuidas)

Consecuencias:

- Evita sesgos de selección
- Permite generalizar de la muestra a la población
- Fundamento matemático de la inferencia estadística

Muestreo aleatorio simple: ejemplo

Ejemplo

Quieres saber cuántas horas semanales dedican los javerianos a TikTok. Si solo encuestas a tus amigos cercanos (sesgo de selección), el resultado no representa a toda la universidad. El MAS evita ese problema.

En la práctica: muestreo aleatorio perfecto es difícil. A veces usamos muestreo estratificado, por conglomerados, etc., pero MAS es el punto de partida teórico.

Distribución muestral de $\bar{X}$

Concepto fundamental

La **distribución muestral de $\bar{X}$** es la distribución de probabilidad de todas las posibles medias muestrales de tamaño n que podríamos obtener de una población.

Experimento mental:

1. Tomar una muestra aleatoria de tamaño n y calcular $\bar{x}$
2. Devolver la muestra a la población
3. Repetir pasos 1-2 infinitas veces
4. La distribución de todos esos $\bar{x}$ es la distribución muestral de $\bar{X}$

Propiedades (para cualquier población con media μ y varianza σ^2):

$$E(\bar{X}) = \mu$$

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \text{DE}(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

Error estándar: $\text{SE}(\bar{X}) = \sigma/\sqrt{n}$ (desviación estándar de $\bar{X}$)

Interpretación del error estándar

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

Mensajes clave:

1. $\bar{X}$ es menos variable que X : $SE(\bar{X}) = \sigma/\sqrt{n} < \sigma$
2. SE disminuye con $\sqrt{n}$, no con n : para reducir SE a la mitad, se necesitan $4\times$ más observaciones
3. Más grande la muestra, más precisa la estimación:
 - $n = 25$: $SE = \sigma/5$; $n = 100$: $SE = \sigma/10$; $n = 400$: $SE = \sigma/20$

Ejemplo

Si $\sigma = 20$ puntos y $n = 100$: $SE = 20/10 = 2$ puntos.

La media muestral típicamente difiere de μ en ≈ 2 puntos.

Encuestar a 100 compañeros sobre su *screen time* da una estimación bastante precisa del promedio de toda la universidad.

Teorema Central del Límite (TCL)

Teorema Central del Límite

Si $X_1, X_2, \dots, X_n$ es una muestra aleatoria de una población con media μ y desviación estándar σ (finitos), entonces para n suficientemente grande:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{aprox.} \quad \Longleftrightarrow \quad Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) \quad \text{aprox.}$$

Mensajes clave:

1. No importa la forma de la distribución original: sesgada, bimodal, uniforme, etc.
2. Para n grande, $\bar{X}$ es aproximadamente normal

TCL: ejemplo con TikTok

Ejemplo: sesiones de TikTok

El tiempo por sesión de TikTok NO es normal (muchas sesiones cortas, pocas muy largas). Pero si promedias el tiempo de 30 sesiones y repites muchas veces, esos promedios sí forman una campana. Eso es el TCL.

Intuición: No importa que la distribución individual sea rara. Al promediar muchas observaciones, el resultado siempre converge a una forma de campana.

TCL: ¿cuándo es n “suficientemente grande”?

Depende de la forma de la distribución original:

- Población normal: $\bar{X}$ es **exactamente** normal para cualquier n
- Población simétrica: $n \approx 15$ suele ser suficiente
- Población muy sesgada: puede necesitarse $n \geq 50$ o más
- Regla práctica general: $n \geq 30$

Forma de la población	n mínimo aprox.
Normal	cualquier n
Simétrica	~ 15
Moderadamente sesgada	~ 30
Muy sesgada	≥ 50

¿Por qué el TCL es tan importante?

El TCL es el teorema más importante de la estadística

Razones:

1. Fundamento de la inferencia:

- Intervalos de confianza para medias
- Pruebas de hipótesis sobre medias
- Tamaño de muestra para precisión deseada

2. Universalidad:

- Aplica a cualquier población (con media y varianza finitas)
- No necesitamos conocer la distribución poblacional

3. Justifica el uso de la distribución normal:

- Muchos fenómenos naturales y sociales son sumas o promedios
- Por el TCL, tienden a ser normales

4. Permite aproximaciones:

- Binomial $\rightarrow$ Normal (para n grande)
- Poisson $\rightarrow$ Normal (para λ grande)

El TCL en la vida real

Sin el TCL, la inferencia estadística sería muchísimo más complicada.

Ejemplo: Spotify y YouTube

Los algoritmos de recomendación de Spotify y YouTube promedian miles de interacciones de usuarios. Gracias al TCL, esos promedios se comportan como normales, lo que permite calcular intervalos de confianza y tomar decisiones.

Simulación TCL paso 1: población no normal (1/2)

```
library(tidyverse)

# Cargar datos Saber 11 (poblacion)
# Supongamos que tenemos puntajes de Saber 11 Ingles (no normales)
saber11 <- read_csv("datos/saber_11_2023.csv")

# Parametros poblacionales
mu <- mean(saber11$PUNT_INGLES, na.rm = TRUE)
sigma <- sd(saber11$PUNT_INGLES, na.rm = TRUE)
cat("Media poblacional:", round(mu, 2), "\n")
cat("DE poblacional:", round(sigma, 2), "\n")

# Verificar asimetria
library(moments)
skewness(saber11$PUNT_INGLES, na.rm = TRUE)
# [1] 0.42 (positiva, sesgada a la derecha)
```

Simulación TCL paso 1: población no normal (2/2)

```
# Graficar la distribucion poblacional
ggplot(saber11, aes(x = PUNT_INGLES)) +
  geom_histogram(aes(y = after_stat(density)), bins = 50,
    fill = "steelblue", color = "white") +
  geom_density(color = "red", linewidth = 1) +
  labs(title = "Distribucion poblacional de Saber 11 Ingles",
    subtitle = "Nota: NO es normal (sesgada a la derecha)",
    x = "Puntaje", y = "Densidad") +
  theme_minimal()
```

Simulación TCL paso 2: muestrear (1/2)

```
# Funcion para tomar una muestra y calcular su media
tomar_muestra_y_promediar <- function(datos, n) {
  muestra <- sample(datos, size = n, replace = FALSE)
  mean(muestra, na.rm = TRUE)
}

# Simular 2000 muestras de tamaño n = 30
set.seed(456)
n <- 30
num_simulaciones <- 2000

medias_n30 <- replicate(num_simulaciones,
                        tomar_muestra_y_promediar(saber11$PUNT_INGLES, n))
```

Simulación TCL paso 2: muestrear (2/2)

```
# Estadísticas de la distribución muestral
mean(medias_n30) # Debe estar cerca de mu
sd(medias_n30)   # Debe estar cerca de sigma/sqrt(n)

cat("Media de las medias muestrales:", round(mean(medias_n30), 2), "\n")
cat("DE de las medias muestrales:", round(sd(medias_n30), 2), "\n")
cat("SE teorico (sigma/sqrt(n)):", round(sigma/sqrt(n), 2), "\n")

# Comparacion
# mean(medias_n30) ~ mu (insesgado)
# sd(medias_n30) ~ sigma/sqrt(n) (error estandar)
```

Simulación TCL paso 3: visualizar normalidad (1/2)

```
# Graficar la distribucion de medias muestrales (n=30)
df_medias <- data.frame(medias = medias_n30)

ggplot(df_medias, aes(x = medias)) +
  geom_histogram(aes(y = after_stat(density)), bins = 40,
    fill = "lightgreen", color = "white", alpha = 0.7) +
  stat_function(fun = dnorm,
    args = list(mean = mu, sd = sigma/sqrt(n)),
    color = "red", linewidth = 1.2) +
  labs(title = paste("Distribucion muestral de X-barra (n =", n, ")"),
    subtitle = "Curva roja: N(mu, sigma^2/n) teorica",
    x = "Media muestral", y = "Densidad") +
  theme_minimal()
```


Simulación TCL paso 3: visualizar normalidad (2/2)

```
# Observacion: !La distribucion de medias ES aproximadamente normal,  
# aunque la poblacion original NO lo era!  
# Esto es el Teorema Central del Limite en accion.  
  
# Verificar normalidad con QQ-plot  
ggplot(df_medias, aes(sample = medias)) +  
  stat_qq() + stat_qq_line(color = "red") +  
  labs(title = "QQ-plot de medias muestrales") +  
  theme_minimal()
```

Simulación TCL paso 4: efecto de n (1/2)

```
# Repetir para diferentes tamanos de muestra: n = 10, 30, 100, 500
tamanos <- c(10, 30, 100, 500)
resultados <- list()

set.seed(789)
for (n in tamanos) {
  medias <- replicate(2000,
                      tomar_muestra_y_promediar(saber11$PUNT_INGLES, n))
  resultados[[paste0("n_", n)]] <- data.frame(
    medias = medias,
    n = paste("n =", n),
    se_teorico = sigma / sqrt(n)
  )
}

df_todas <- bind_rows(resultados)
```

Simulación TCL paso 4: efecto de n (2/2)

```
# Graficar todas juntas
ggplot(df_todas, aes(x = medias)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30,
                 fill = "steelblue", alpha = 0.6) +
  facet_wrap(~ n, scales = "free", ncol = 2) +
  labs(title = "Efecto del tamaño de muestra en la distribución de X-barra",
       x = "Media muestral", y = "Densidad") +
  theme_minimal()

# Observacion: a mayor n, la distribución es mas concentrada (menor SE)
# y mas normal
```

Comparación SE teórico vs simulado (1/2)

```
# Comparar SE teorico vs simulado para cada n
comparacion_se <- df_todas %>%
  group_by(n) %>%
  summarise(
    SE_simulado = sd(medias),
    SE_teorico = first(se_teorico)
  ) %>%
  mutate(diferencia = abs(SE_simulado - SE_teorico))

comparacion_se
```

```
# Resultado esperado:
#   n          SE_simulado SE_teorico diferencia
#   n = 10          3.15         3.16         0.01
#   n = 30          1.83         1.83         0.00
#   n = 100         1.00         1.00         0.00
#   n = 500         0.45         0.45         0.00
```

Comparación SE teórico vs simulado (2/2)

```
# Conclusion: el SE teorico (sigma/sqrt(n)) predice muy bien  
# la variabilidad de X-barra  
  
# Grafico de barras comparando SE  
ggplot(comparacion_se, aes(x = n)) +  
  geom_col(aes(y = SE_teorico), fill = "red", alpha = 0.5, width = 0.4) +  
  geom_col(aes(y = SE_simulado), fill = "blue", alpha = 0.5,  
            width = 0.4, position = position_nudge(x = 0.3)) +  
  labs(title = "SE teorico vs simulado",  
        y = "Error estandar") +  
  theme_minimal()
```

¿Qué es un estimador?

Definición

Un **estimador** es una fórmula para aproximar un parámetro poblacional desconocido a partir de datos muestrales.

Notación:

- Parámetro (desconocido): θ (puede ser μ , σ^2 , p , etc.)
- Estimador (función de los datos): $\hat{\theta}$ (ej: $\bar{X}$, s^2 , $\hat{p}$)
- Estimación (valor numérico): $\hat{\theta} = 155,3$ puntos

Ejemplos de estimadores

- $\hat{\mu} = \bar{X} = \frac{1}{n} \sum X_i$ (ej: promedio de *screen time* de 50 compañeros)
- $\hat{\sigma}^2 = s^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$
- $\hat{p} = X/n$ (ej: proporción de compañeros que usan Duolingo)

Pregunta: ¿Cómo sabemos si un estimador es “bueno”? → Propiedades deseables

Propiedad 1: Insesgamiento

Definición

Un estimador $\hat{\theta}$ es **insesgado** si $E(\hat{\theta}) = \theta$. En promedio, el estimador acierta al valor verdadero.

Sesgo: $\text{Sesgo}(\hat{\theta}) = E(\hat{\theta}) - \theta$

Ejemplos

- $\bar{X}$ es insesgado para μ : $E(\bar{X}) = \mu$
- $s^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ es insesgado para σ^2
- $\frac{1}{n} \sum (X_i - \bar{X})^2$ es **sesgado**: $E = \frac{n-1}{n} \sigma^2 < \sigma^2$ (por eso usamos $n - 1$)

Insesgamiento no garantiza precisión en una muestra individual, pero sí “en promedio”.

Propiedad 2: Eficiencia

Definición

Entre dos estimadores insesgados de θ , el más **eficiente** es el que tiene menor varianza.

Si $E(\hat{\theta}_1) = E(\hat{\theta}_2) = \theta$ y $\text{Var}(\hat{\theta}_1) < \text{Var}(\hat{\theta}_2)$, entonces $\hat{\theta}_1$ es más eficiente

Interpretación:

- Menor varianza = estimaciones más consistentes entre muestras
- Menor varianza = intervalos de confianza más estrechos

Ejemplo

Para estimar μ de una distribución normal:

- Media muestral: $\text{Var}(\bar{X}) = \sigma^2/n$
- Mediana muestral: $\text{Var}(\text{mediana}) \approx 1,57\sigma^2/n$

$\bar{X}$ es más eficiente que la mediana (para normales).

Propiedad 3: Consistencia

Definición

$\hat{\theta}_n$ es **consistente** si $\hat{\theta}_n \xrightarrow{P} \theta$ cuando $n \rightarrow \infty$.

Interpretación: con más datos, el estimador se acerca al valor verdadero.

Condición suficiente: $\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta$ y $\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$

Ejemplos

- $\bar{X}$: $E(\bar{X}) = \mu$ y $\text{Var}(\bar{X}) = \sigma^2/n \rightarrow 0$ (consistente)
- s^2 es consistente para σ^2

Todos los estimadores comunes que usamos son consistentes.

Resumen: propiedades de estimadores

Propiedad	Significado	Ejemplo
Insesgamiento	$E(\hat{\theta}) = \theta$	$\bar{X}$, s^2 , $\hat{p}$
Eficiencia	Menor varianza (más preciso)	$\bar{X}$ vs mediana
Consistencia	$\hat{\theta}_n \rightarrow \theta$ cuando $n \rightarrow \infty$	$\bar{X}$, s^2 , $\hat{p}$

Trade-off sesgo-varianza

Un estimador ligeramente sesgado puede tener menor varianza y ser preferible (ej: regresión ridge). En este curso usamos estimadores insesgados.

Resumen de la sesión

Conceptos clave cubiertos:

1. **Variables aleatorias:** discretas vs continuas, $E(X)$, $\text{Var}(X)$
2. **Distribución normal:** $N(\mu, \sigma^2)$, propiedades, cálculo de probabilidades
 - `pnorm()`, `qnorm()`, `dnorm()`, `rnorm()`
3. **Distribuciones t, chi-cuadrado, F:** de dónde vienen, para qué sirven
4. **Muestreo:** población vs muestra, distribución muestral de $\bar{X}$
 - $E(\bar{X}) = \mu$, $\text{SE}(\bar{X}) = \sigma/\sqrt{n}$
5. **Teorema Central del Límite:** $\bar{X} \sim N(\mu, \sigma^2/n)$ para n grande
 - Fundamento de toda la inferencia estadística
6. **Propiedades de estimadores:** insesgamiento, eficiencia, consistencia

La distribución normal + TCL = fundamento de la inferencia

Conexión fundamental

1. Muchas variables en la naturaleza son normales (o aproximadamente)
 - Alturas, pesos, puntajes de pruebas, errores de medición, etc.
2. Incluso cuando la población NO es normal, $\bar{X}$ sí lo es (TCL)
 - Para $n \geq 30$, $\bar{X} \sim N(\mu, \sigma^2/n)$ aproximadamente
3. Conociendo la distribución de $\bar{X}$, podemos:
 - Construir **intervalos de confianza**: ¿entre qué valores está μ con 95 % de confianza?
 - Hacer **pruebas de hipótesis**: ¿es $\mu = 150$ compatible con nuestros datos?
 - Calcular **tamaños de muestra**: ¿cuántos estudiantes necesito para estimar μ con margen de error ± 2 puntos?

Sin el TCL, necesitaríamos conocer la distribución poblacional exacta para hacer inferencia. Gracias al TCL, no es necesario.

Próxima sesión: Intervalos de Confianza

Fecha: próxima sesión (según calendario)

Temas a cubrir:

- Concepto de intervalo de confianza (IC)
- IC para la media (varianza conocida y desconocida)
- IC para la proporción
- IC para la diferencia de medias (dos muestras)
- Interpretación correcta de ICs
- Determinación del tamaño de muestra

Preparación:

- Repasar `qnorm()`, `qt()`, `pnorm()`, `pt()`
- Asegurarse de entender el error estándar: $SE = \sigma / \sqrt{n}$
- Repasar el TCL: $\bar{X} \sim N(\mu, \sigma^2/n)$ para n grande

El intervalo de confianza es la aplicación más directa del TCL y la distribución normal