

Sesión 4: Estimación Puntual e Intervalos de Confianza

De estimadores puntuales a intervalos para medias y varianzas

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Viernes 11 de septiembre de 2026

Agenda

Estimación Puntual

Lógica de los Intervalos de Confianza

IC para la Media: σ Conocida

IC para la Media: σ Desconocida (Distribución t)

IC para la Varianza (Distribución χ^2)

Forest Plot Departamental

Resumen: ¿Cuándo usar z , t , χ^2 ?

Conclusiones

Parámetros vs Estadísticos: Repaso

Conceptos fundamentales

- **Parámetro:** característica numérica de la *población*
 - Ejemplos: μ (media poblacional), σ^2 (varianza poblacional), p (proporción poblacional)
 - Usualmente **desconocidos** (¿cuál es la media verdadera de inglés de TODOS los estudiantes de NI en Colombia?)
- **Estadístico:** característica numérica de la *muestra*
 - Ejemplos: $\bar{x}$ (media muestral), s^2 (varianza muestral), $\hat{p}$ (proporción muestral)
 - Son **observables** (calculamos $\bar{x}$ con nuestra muestra)

Problema central de la inferencia: usar estadísticos para aprender sobre parámetros

¿Qué es la Estimación Puntual?

Definition (Estimación puntual)

Es el proceso de usar un **estadístico muestral** para aproximar el valor de un **parámetro poblacional**.

Estimadores comunes:

$\bar{x}$ estima μ

s^2 estima σ^2

s estima σ

$\hat{p}$ estima p

Notación:

- $\hat{\theta}$ = estimador puntual del parámetro θ
- Ejemplo: $\hat{\mu} = \bar{x}$
- $\hat{\sigma}^2 = s^2$

Limitación: un solo número no captura la incertidumbre de la estimación

Estimación puntual: ejemplo cotidiano

Ejemplo: Spotify y la estimación

Spotify estima tu “perfil musical” con un conjunto de parámetros. Cada canción que escuchas es un dato. $\hat{\theta}$ es la mejor aproximación de tus gustos basada en esos datos.

Idea clave: un estimador puntual nos da un solo número. Pero ¿qué tan cerca está del valor real? Para responder esa pregunta, necesitamos **intervalos de confianza**.

Propiedades Deseables de un Estimador

1. Insesgamiento (unbiasedness)

- Un estimador $\hat{\theta}$ es insesgado si $E(\hat{\theta}) = \theta$
- Su valor esperado (promedio a largo plazo) es igual al parámetro
- Ejemplos: $E(\bar{x}) = \mu$, $E(s^2) = \sigma^2$

2. Eficiencia

- Entre dos estimadores insesgados, preferimos el de **menor varianza**
- Menor varianza $\Rightarrow$ estimaciones más concentradas alrededor del parámetro
- Ejemplo: $\bar{x}$ es más eficiente que la mediana para estimar μ en distribuciones normales

3. Consistencia

- A medida que $n \rightarrow \infty$, el estimador converge al parámetro
- $\bar{x} \xrightarrow{P} \mu$ cuando $n \rightarrow \infty$
- Ejemplo: entre más canciones le das “like” en Spotify, mejor estima tus gustos musicales

Ejemplo: Estimación Puntual con Datos ICFES

Contexto: Queremos estimar la media poblacional de MOD_INGLES_PUNT para estudiantes de NI en Colombia.

```
# Cargar datos
icfes_ni <- read.csv("datos/icfes_ni_2023.csv")

# Estimacion puntual de mu
mu_estimado <- mean(icfes_ni$MOD_INGLES_PUNT, na.rm = TRUE)
cat("Estimacion puntual de mu:", round(mu_estimado, 2))

# Estimacion puntual de sigma^2
sigma2_estimado <- var(icfes_ni$MOD_INGLES_PUNT, na.rm = TRUE)
cat("\nEstimacion puntual de sigma^2:", round(sigma2_estimado, 2))

# Estimacion puntual de sigma
sigma_estimado <- sd(icfes_ni$MOD_INGLES_PUNT, na.rm = TRUE)
cat("\nEstimacion puntual de sigma:", round(sigma_estimado, 2))
```

Pregunta: ¿Qué tan confiables son estas estimaciones? ¿Cuánto error hay?

De Estimación Puntual a Intervalos

Estimación puntual:

- $\hat{\mu} = 162,5$ puntos
- Un solo valor
- No cuantifica incertidumbre

¿Es μ exactamente 162.5?

No, pero probablemente está cerca.

Intervalo de confianza:

- (159,8, 165,2) puntos
- Un rango de valores plausibles
- Cuantifica incertidumbre

Estamos **95 % confiados** de que μ está en ese intervalo.

Ejemplo: “el *screen time* promedio del salón está entre 4.2 y 5.8 horas”.

Transición

Pasamos de un **punto** (estimación puntual) a un **intervalo** (estimación por intervalo) que refleja nuestra incertidumbre.

¿Qué es un Intervalo de Confianza?

Definition (Intervalo de confianza)

Un **intervalo de confianza (IC)** para un parámetro θ al nivel $(1 - \alpha) \times 100 \%$ es un rango de valores que, si repitiéramos el muestreo muchas veces, contendría al parámetro verdadero en $(1 - \alpha) \times 100 \%$ de las muestras.

Estructura general:

$$\text{IC} = \text{Estimación puntual} \pm \text{Margen de error}$$

Nivel de confianza

- $(1 - \alpha)$ = nivel de confianza (típicamente 0.90, 0.95, 0.99)
- α = nivel de significancia (típicamente 0.10, 0.05, 0.01)
- Ejemplo: IC al 95 % $\Rightarrow (1 - \alpha) = 0,95$, $\alpha = 0,05$

Interpretación Correcta del IC

Interpretación CORRECTA

“Si tomáramos 100 muestras aleatorias diferentes y construyéramos un IC al 95 % con cada una, esperaríamos que aproximadamente **95 de esos intervalos** contengan el parámetro verdadero μ .”

Interpretación alternativa correcta


“Estamos 95 % confiados de que el *screen time* promedio de los javerianos está entre 4.2 y 5.8 horas.”

Interpretación INCORRECTA

NO: “Hay un 95 % de probabilidad de que μ esté en (a, b) ”.

¿Por qué es incorrecta? Porque μ es un valor *fijo* (aunque desconocido), no una variable aleatoria. El intervalo es lo que varía de muestra a muestra.

Visualización del Concepto de IC



En este ejemplo, 7 de 8 IC (87.5 %) contienen a μ . Con más muestras, converge a 95 %.

Margen de Error

Definition (Margen de error)

La mitad del ancho del intervalo de confianza. Para la media con σ conocida:

$$E = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

Componentes:

- $z_{\alpha/2}$ = valor crítico de la distribución normal estándar
- $\frac{\sigma}{\sqrt{n}}$ = error estándar de $\bar{x}$
- Mayor confianza $(1 - \alpha) \Rightarrow$ mayor $z_{\alpha/2} \Rightarrow$ mayor E
- Mayor $n \Rightarrow$ menor E

Trade-off: Confianza vs Precisión

Trade-off: Confianza vs Precisión

- Más confianza (ej. 99 %) $\Rightarrow$ intervalo más ancho
- Menos confianza (ej. 90 %) $\Rightarrow$ intervalo más estrecho

Analogía

Predecir la hora exacta a la que un amigo llega a clase es difícil. Pero decir “llega entre 6:55 y 7:10” es más seguro. Entre más amplio el rango, más confianza, pero menos precisión.

IC para μ con σ Conocida

Supuestos:

- Muestra aleatoria simple de tamaño n
- Población normal O $n \geq 30$ (TLC)
- Desviación estándar poblacional σ conocida

Fórmula del IC al $(1 - \alpha) \times 100 \%$


$$\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \iff \left(\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right)$$

Fundamento: Por el TLC, $\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$, entonces $Z = \frac{\bar{x} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$.

Valores Críticos de z

Nivel de confianza	$(1 - \alpha)$	$\alpha/2$	$z_{\alpha/2}$
90 %	0.90	0.05	1.645
95 %	0.95	0.025	1.960
99 %	0.99	0.005	2.576

Interpretación: Para un IC al 95 %, usamos $z_{0,025} = 1,96$, que deja 2.5 % en cada cola de la distribución normal estándar.



Cálculo de Valores Críticos en R

```
# Valor critico para IC al 95 %  
z_95 <- qnorm(0.975) # P(Z <= z) = 0.975  
cat("z para 95%:", z_95)  
# Resultado: 1.959964  
  
# Valor critico para IC al 99 %  
z_99 <- qnorm(0.995) # P(Z <= z) = 0.995  
cat("\nz para 99%:", z_99)  
# Resultado: 2.575829  
  
# Valor critico para IC al 90 %  
z_90 <- qnorm(0.95) # P(Z <= z) = 0.95  
cat("\nz para 90%:", z_90)  
# Resultado: 1.644854
```

Nota: Usamos `qnorm(1 -  $\alpha/2$ )` porque queremos el cuantil superior que deja $\alpha/2$ en la cola derecha.

Ejemplo Numérico: IC con σ Conocida

Escenario: Supongamos que de censos anteriores sabemos que $\sigma = 18$ para MOD_INGLES_PUNT en NI. Tenemos una muestra de $n = 120$ estudiantes con $\bar{x} = 162,5$.

Calcular IC al 95 % – paso 1: datos y valor crítico.

```
# Datos
xbar <- 162.5
sigma <- 18
n <- 120
confianza <- 0.95
alpha <- 1 - confianza

# Valor critico
z_critico <- qnorm(1 - alpha/2)

# Error estandar
ee <- sigma / sqrt(n)
```

Ejemplo Numérico: IC con σ Conocida (cont.)

Paso 2: Margen de error y límites del intervalo.

```
# Margen de error
E <- z_critico * ee

# Límites del IC
ic_inferior <- xbar - E
ic_superior <- xbar + E

cat("IC al 95 %: (", round(ic_inferior, 2), ",",
    round(ic_superior, 2), ")")
# IC al 95 %: ( 159.28 , 165.72 )
```

Resultado

IC al 95 % para μ : (159,28, 165,72) puntos, con margen de error $E = 3,22$.

Interpretación del Resultado

Resultado

IC al 95 % para μ : (159,28, 165,72) puntos

Interpretación correcta:

- Estamos 95 % confiados de que la media poblacional de MOD_INGLES_PUNT para estudiantes de NI está entre 159.28 y 165.72 puntos.
- Si repitiéramos el muestreo 100 veces, aproximadamente 95 de los intervalos contruidos contendrían el verdadero valor de μ .

Implicación práctica:

- El margen de error es $E = 3,22$ puntos
- ¿Es suficientemente preciso para nuestros propósitos?
- Si necesitamos más precisión, podemos aumentar n

El IC en la vida real

Ejemplo: encuestas electorales

Las encuestas electorales reportan “el candidato A tiene 48 % $\pm$ 3 %”. Ese $\pm$ 3 % es el margen de error de un IC, igual al que acabamos de calcular.

Otros ejemplos cotidianos de IC:

- Reportes de salud: “el consumo promedio de cafeína de universitarios colombianos es 180 $\pm$ 25 mg/día”
- Apps de delivery: “tiempo estimado: 25–35 minutos” (intervalo de confianza implícito)

El Problema: σ Desconocida

Situación real: En la práctica, **casi nunca** conocemos σ .

Solución: Usar la desviación estándar muestral s en lugar de σ .

Consecuencia

Al reemplazar σ por s , introducimos una fuente adicional de variabilidad. El estadístico

$$t = \frac{\bar{x} - \mu}{s/\sqrt{n}}$$

ya NO sigue una distribución normal estándar, sino una **distribución t de Student** con $n - 1$ grados de libertad.

σ Desconocida: analogía

Analogía


Imagina que quieres estimar el promedio de horas de sueño de tu salón, pero no conoces qué tan dispersos son los datos (σ). Solo tienes s de tu muestra. Esa incertidumbre extra es la que captura la distribución t .

Resumen: Cuando σ es desconocida, usamos s y la distribución t en lugar de la normal estándar Z . Esto produce intervalos más anchos, especialmente con muestras pequeñas.

Distribución t de Student

Características:

- Simétrica, centrada en 0
- Forma de campana (similar a $N(0, 1)$)
- **Colas más pesadas** que la normal
- Depende de los grados de libertad (gl) $= n - 1$
- Con n grande, $t(n - 1) \approx N(0, 1)$



La t con pocos gl tiene colas más anchas.

Implicación: Para el mismo nivel de confianza, los valores críticos $t_{\alpha/2, n-1}$ son **mayores** que $z_{\alpha/2}$, lo que resulta en intervalos **más anchos**.

IC para μ con σ Desconocida

Supuestos:

- Muestra aleatoria simple de tamaño n
- Población normal (más importante cuando n es pequeño)
- σ desconocida

Fórmula del IC al $(1 - \alpha) \times 100 \%$

$$\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$$

donde:

- $t_{\alpha/2, n-1}$ = valor crítico de la distribución t con $n - 1$ grados de libertad
- s = desviación estándar muestral
- $\frac{s}{\sqrt{n}}$ = error estándar estimado de $\bar{x}$

Comparación de Valores Críticos: z vs t

gl	n	$t_{0,025,n-1}$	$z_{0,025}$	Diferencia
5	6	2.571	1.960	+31 %
10	11	2.228	1.960	+14 %
20	21	2.086	1.960	+6 %
30	31	2.042	1.960	+4 %
60	61	2.000	1.960	+2 %
∞	∞	1.960	1.960	0 %

Observación: Con $n \geq 30$, la diferencia es pequeña ($< 5 \%$), pero sigue siendo mejor usar t cuando σ es desconocida.

Cálculo de Valores Críticos t en R

```
# Valor critico t para IC al 95% con diferentes gl
gl_valores <- c(5, 10, 20, 30, 60, 120)
alpha <- 0.05

resultados <- data.frame(
  gl = gl_valores,
  n = gl_valores + 1,
  t_critico = qt(1 - alpha/2, df = gl_valores),
  z_critico = qnorm(1 - alpha/2)
)

resultados$diferencia <-
  (resultados$t_critico / resultados$z_critico - 1) * 100

print(round(resultados, 3))
```

Función clave: `qt(p, df)` devuelve el cuantil p de la distribución t con df grados de libertad.

Ejemplo: IC para la Media de MOD_INGLES_PUNT en NI

Datos reales: Muestra de $n = 120$ estudiantes de NI.

```
# Cargar datos
icfes_ni <- read.csv("datos/icfes_ni_2023.csv")

# Calcular estadísticos muestrales
ingles <- icfes_ni$MOD_INGLES_PUNT
n <- length(ingles)
xbar <- mean(ingles, na.rm = TRUE)
s <- sd(ingles, na.rm = TRUE)
```

IC para la Media de MOD_INGLES_PUNT: cálculo

```
# IC al 95% usando la formula
alpha <- 0.05
gl <- n - 1
t_critico <- qt(1 - alpha/2, df = gl)
ee <- s / sqrt(n)
E <- t_critico * ee

ic_inf <- xbar - E
ic_sup <- xbar + E

cat("n =", n, "\nxbar =", round(xbar, 2),
    "\ns =", round(s, 2))
cat("\nIC al 95%: (", round(ic_inf, 2), ",",
    round(ic_sup, 2), ")")
```

Nota: Usamos la distribución t porque σ es desconocida y la estimamos con s .

Método Directo con `t.test()`

R tiene una función integrada que calcula el IC automáticamente:

```
# Metodo directo: t.test()
resultado <- t.test(ingles, conf.level = 0.95)
print(resultado)

# Extraer solo el IC
ic <- resultado$conf.int
cat("IC al 95 %:", round(ic, 2))

# Cambiar el nivel de confianza
ic_99 <- t.test(ingles, conf.level = 0.99)$conf.int
cat("\nIC al 99 %:", round(ic_99, 2))

ic_90 <- t.test(ingles, conf.level = 0.90)$conf.int
cat("\nIC al 90 %:", round(ic_90, 2))
```

Ventaja: `t.test()` también realiza una prueba de hipótesis (que veremos en sesiones futuras).

Interpretación del Output de `t.test()`

One Sample `t`-test

```
data: ingles
t = 42.356, df = 119, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 159.28 165.72
sample estimates:
mean of x
 162.50
```

Elementos clave:

- **`t = 42.356`**: estadístico t para prueba $H_0 : \mu = 0$ (no relevante aquí)
- **`df = 119`**: grados de libertad ($n - 1$)
- **95 % CI: (159.28, 165.72)**: ¡el intervalo de confianza!
- **mean of x = 162.50**: estimación puntual $\bar{x}$

IC para la Varianza σ^2

Motivación: A veces queremos estimar la **variabilidad** poblacional, no solo la media.

Aplicaciones:

- Educación: ¿qué tan heterogéneo es el rendimiento en inglés entre estudiantes de NI?
- Comercio internacional: volatilidad de la TRM para planear importaciones
- Logística: variabilidad en tiempos de entrega de Rappi — si la varianza es alta, no puedes confiar en la hora estimada

Distribución muestral de s^2

Distribución muestral de s^2

Si la población es normal, entonces:

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi^2(n-1)$$


donde $\chi^2(n-1)$ es la distribución chi-cuadrado con $n-1$ grados de libertad.

Este resultado nos permite construir intervalos de confianza para σ^2 usando la distribución χ^2 .

Distribución Chi-Cuadrado (χ^2)

Características:

- **Asimétrica** (sesgada a la derecha)
- Solo valores positivos ($\chi^2 \geq 0$)
- Depende de los gl
- Con gl grandes, se aproxima a la normal



Implicación: El IC para σ^2 será **asimétrico**.

Nota: A diferencia de z y t , la χ^2 NO es simétrica; los valores críticos no son opuestos.

Fórmula del IC para σ^2

Supuestos:

- Muestra aleatoria simple de tamaño n
- Población **normal** (más importante que para la media)

IC al $(1 - \alpha) \times 100 \%$ para σ^2

$$\left(\frac{(n-1)s^2}{\chi_{\alpha/2, n-1}^2}, \quad \frac{(n-1)s^2}{\chi_{1-\alpha/2, n-1}^2} \right)$$

Valores críticos:

- $\chi_{\alpha/2, n-1}^2$ = valor que deja $\alpha/2$ en la cola **derecha** (cuantil superior)
- $\chi_{1-\alpha/2, n-1}^2$ = valor que deja $\alpha/2$ en la cola **izquierda** (cuantil inferior)

IC para σ : Tomar raíz cuadrada de los límites.

Ejemplo: IC para la Varianza de MOD_INGLES_PUNT

```
# Datos
n <- 120
s2 <- var(ingles, na.rm = TRUE)
gl <- n - 1
alpha <- 0.05

# Valores criticos chi-cuadrado
chi2_inf <- qchisq(alpha/2, df = gl) # Cola izquierda
chi2_sup <- qchisq(1 - alpha/2, df = gl) # Cola derecha

# IC para sigma^2
ic_var_inf <- (gl * s2) / chi2_sup
ic_var_sup <- (gl * s2) / chi2_inf
```

IC para la Varianza: resultado

```
cat("s^2 =", round(s2, 2))
cat("\nIC al 95 % para sigma^2: (",
    round(ic_var_inf, 2), ",", round(ic_var_sup, 2), ")")

# IC para sigma (tomar raiz cuadrada)
ic_sd_inf <- sqrt(ic_var_inf)
ic_sd_sup <- sqrt(ic_var_sup)

cat("\nIC al 95 % para sigma: (",
    round(ic_sd_inf, 2), ",", round(ic_sd_sup, 2), ")")
```

Nota: El IC para σ se obtiene tomando raíz cuadrada de los límites del IC para σ^2 .

Asimetría del IC para σ^2

Ejemplo numérico: Supongamos $n = 120$, $s^2 = 324$ (entonces $s = 18$).

- $\chi^2_{0,025,119} = 152,22$ (cola derecha)
- $\chi^2_{0,975,119} = 89,39$ (cola izquierda)

IC para σ^2 :

$$\left(\frac{119 \times 324}{152,22}, \frac{119 \times 324}{89,39} \right) = (253,5, 431,6)$$

IC para σ :

$$(\sqrt{253,5}, \sqrt{431,6}) = (15,9, 20,8)$$

Observación: La estimación puntual $s = 18$ NO está en el centro del intervalo (15.9, 20.8) debido a la asimetría de la distribución χ^2 .

IC por Departamento: Motivación

Pregunta: ¿El nivel de inglés varía significativamente entre departamentos de Colombia?

Estrategia:

1. Calcular IC al 95 % para μ en cada departamento
2. Visualizar todos los IC en un **forest plot**
3. Comparar: si dos intervalos NO se solapan, hay evidencia de diferencia

Aplicación: Identificar regiones con rendimiento excepcionalmente alto o bajo en inglés para diseñar políticas educativas focalizadas.

Cálculo de IC por Departamento en R

```
library(dplyr)

# Calcular IC por departamento
ic_deptos <- icfes_ni %>%
  group_by(ESTU_DEPTO_RESIDE) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT, na.rm = TRUE),
    sd = sd(MOD_INGLES_PUNT, na.rm = TRUE),
    ee = sd / sqrt(n),
    gl = n - 1,
    t_critico = qt(0.975, df = gl),
    ic_inf = media - t_critico * ee,
    ic_sup = media + t_critico * ee
  ) %>%
  filter(n >= 30) # Solo deptos con muestra suficiente

# Ver primeros resultados
head(ic_deptos)
```

Crear Forest Plot con ggplot2

```
library(ggplot2)

# Ordenar por media para mejor visualizacion
ic_deptos <- ic_deptos %>%
  arrange(media)

# Forest plot
ggplot(ic_deptos, aes(x = media, y = reorder(ESTU_DEPTO_RESIDE, media))) +
  geom_point(size = 3, color = "steelblue") +
  geom_errorbarh(aes(xmin = ic_inf, xmax = ic_sup),
    height = 0.3, color = "steelblue") +
  geom_vline(xintercept = mean(ic_deptos$media),
    linetype = "dashed", color = "red") +
  labs(x = "Media de MOD_INGLES_PUNT (IC 95%)",
    y = "Departamento",
    title = "Intervalos de Confianza por Departamento",
    subtitle = "Estudiantes de Negocios Internacionales") +
  theme_minimal()
```


Interpretación del Forest Plot

Elementos visuales:

- **Punto:** estimación puntual $\bar{x}$ para cada departamento
- **Barra horizontal:** IC al 95 %
- **Línea vertical roja:** media nacional (de los departamentos con $n \geq 30$)

Interpretación:

- Departamentos con IC que NO cruzan la línea roja son significativamente diferentes de la media nacional
- Si dos IC NO se solapan, hay evidencia de diferencia entre esos departamentos
- IC más anchos $\Rightarrow$ muestras más pequeñas o mayor variabilidad

Ejemplo hipotético:

- Bogotá: IC = (168, 172) $\Rightarrow$ significativamente superior
- Chocó: IC = (140, 148) $\Rightarrow$ significativamente inferior

Identificar Departamentos Atípicos

```
# Media nacional (ponderada por n)  
media_nacional <- weighted.mean(ic_deptos$media, ic_deptos$n)
```

```
# Departamentos significativamente superiores  
superiores <- ic_deptos %>%  
  filter(ic_inf > media_nacional) %>%  
  select(ESTU_DEPTO_RESIDE, media, ic_inf, ic_sup)
```

```
cat("Departamentos significativamente superiores:\n")  
print(superiores)
```

```
# Departamentos significativamente inferiores  
inferiores <- ic_deptos %>%  
  filter(ic_sup < media_nacional) %>%  
  select(ESTU_DEPTO_RESIDE, media, ic_inf, ic_sup)
```

```
cat("\nDepartamentos significativamente inferiores:\n")  
print(inferiores)
```

Comparación Visual: Ancho de los IC

```
# Calcular ancho del IC
ic_deptos <- ic_deptos %>%
  mutate(ancho_ic = ic_sup - ic_inf)

# Grafico: ancho vs tamaño de muestra
ggplot(ic_deptos, aes(x = n, y = ancho_ic)) +
  geom_point(size = 3, alpha = 0.6) +
  geom_smooth(method = "lm", se = FALSE,
              color = "red", linetype = "dashed") +
  labs(x = "Tamaño de muestra (n)",
       y = "Ancho del IC",
       title = "Relacion entre n y Precision",
       subtitle = "Ancho del IC = f(1/sqrt(n))") +
  theme_minimal()
```


Relación esperada: $\text{Ancho} = 2 \times t_{\alpha/2} \times \frac{s}{\sqrt{n}}$, entonces el ancho $\propto 1/\sqrt{n}$.

Tabla Resumen de Intervalos de Confianza

Parámetro	Condición	Distribución	Fórmula
μ	σ conocida	z (normal)	$\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$
μ	σ desconocida	$t(n-1)$	$\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$
σ^2	Población normal	$\chi^2(n-1)$	$\left(\frac{(n-1)s^2}{\chi_{\alpha/2}^2}, \frac{(n-1)s^2}{\chi_{1-\alpha/2}^2} \right)$

Nota: En la práctica, casi siempre usamos la distribución t para la media, porque σ es desconocida.

Diagrama de Flujo para Elegir el IC



Regla práctica: Si estás estimando μ y no te dicen explícitamente que σ es conocida, **usa la distribución t .**

Supuestos y Robustez

Método	Supuesto clave	Robustez
IC para μ (z o t)	Normalidad de la población O $n \geq 30$ (TLC)	Robusta con n grande incluso si la población no es normal
IC para σ^2 (χ^2)	Población normal	NO robusta . Sensible a desviaciones de normalidad

Recomendaciones:

- Para μ : si $n < 30$, verificar normalidad con QQ-plot o Shapiro-Wilk
- Para σ^2 : siempre verificar normalidad, considerar métodos bootstrap si hay dudas

Resumen de la Sesión

Hoy aprendimos:

1. **Estimación puntual:** usar $\bar{x}$ para estimar μ , s^2 para estimar σ^2
2. **Intervalos de confianza:** cuantificar incertidumbre alrededor de la estimación
3. **IC para μ :**
 - Con σ conocida: distribución z
 - Con σ desconocida: distribución t (caso real)
4. **IC para σ^2 :** distribución χ^2 (asimétrico)
5. **Forest plots:** comparar IC entre grupos (departamentos)

Próxima sesión: IC para proporciones, tamaño de muestra, y muestreo estratificado.

Ejercicios para la Próxima Clase

Con los datos de ICFES:

1. Calcular IC al 95 % y 99 % para la media de MOD_RAZONA_CUANTITAT en NI
2. Calcular IC al 95 % para la desviación estándar de MOD_INGLES_PUNT
3. Crear un forest plot comparando IC de inglés entre tipo de IES (pública vs privada)
4. Investigar: ¿Cuántos departamentos tienen IC que NO se solapan con Bogotá?
5. **Desafío:** Calcular el IC para la *mediana* usando bootstrap (investigar método)

Lectura: Anderson et al., Capítulo 8 (Intervalos de Confianza)

¡Gracias por su atención!

Preguntas y discusión