

Sesión 5: IC para Proporciones y Tamaño de Muestra

Completando la caja de herramientas de estimación

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Viernes 18 de septiembre de 2026

Agenda

IC para Proporciones

Tamaño de Muestra para Medias

Tamaño de Muestra para Proporciones

Muestreo Estratificado y Consideraciones Prácticas

Resumen de toda la Unidad 2

Conclusiones

Motivación: Estimar Proporciones

Ejemplos de proporciones en educación:

- ¿Qué proporción de estudiantes de NI alcanza nivel B1 en inglés?
- ¿Qué porcentaje de estudiantes aprueba el examen ICFES con más de 300 puntos globales?
- ¿Cuál es la tasa de deserción en el primer año?

Diferencia con medias:

- Variable de interés: **categorica binaria** (éxito/fracaso, sí/no)
- Codificación: 1 = éxito, 0 = fracaso
- Proporción muestral: $\hat{p} = \frac{\text{número de éxitos}}{n} = \frac{x}{n}$

Objetivo: Construir IC para la proporción poblacional p .

Proporción Muestral $\hat{p}$

Definition (Proporción muestral)

$$\hat{p} = \frac{x}{n}$$

donde:

- x = número de éxitos en la muestra
- n = tamaño de la muestra
- $\hat{p}$ estima la proporción poblacional p

Ejemplo: En una muestra de $n = 200$ estudiantes de NI, 140 superan B1 en inglés.

$$\hat{p} = \frac{140}{200} = 0,70 = 70 \%$$

Conexión con Bernoulli: Cada estudiante es un ensayo Bernoulli con probabilidad p de éxito. Entonces $x \sim \text{Binomial}(n, p)$.

Distribución Muestral de $\hat{p}$

Propiedades:

- Valor esperado: $E(\hat{p}) = p$ (insesgado)
- Varianza: $\text{Var}(\hat{p}) = \frac{p(1-p)}{n}$
- Desviación estándar (error estándar): $\text{DE}(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}$

Teorema Central del Límite para proporciones

Si n es suficientemente grande, entonces:

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right) \quad \text{aproximadamente}$$

Es decir:

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1) \quad \text{aproximadamente}$$

Condición de Aplicabilidad

¿Cuándo es válida la aproximación normal?

Regla empírica

La aproximación normal es adecuada si:

$$n \cdot \hat{p} \geq 5 \quad \text{y} \quad n \cdot (1 - \hat{p}) \geq 5$$

Interpretación:

- Necesitamos al menos 5 éxitos y 5 fracasos en la muestra
- Garantiza que la distribución binomial no esté muy sesgada

Ejemplo: $n = 200$, $\hat{p} = 0,70$

- $n \cdot \hat{p} = 200 \times 0,70 = 140 \geq 5 \quad \checkmark$
- $n \cdot (1 - \hat{p}) = 200 \times 0,30 = 60 \geq 5 \quad \checkmark$
- Aproximación normal es válida

IC para una Proporción

Problema: La fórmula teórica requiere conocer p , pero eso es lo que queremos estimar.

Solución: Reemplazar p por $\hat{p}$ en el error estándar.

IC al $(1 - \alpha) \times 100 \%$ para p

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Equivalentemente:

$$\left(\hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right)$$

Nota: Usamos z (no t) porque la fórmula del error estándar ya usa $\hat{p}$ como estimador de p .

Ejemplo: Proporción de Estudiantes que Superan B1

Contexto: En los datos ICFES, definimos éxito como $\text{MOD_INGLES_PUNT} \geq 160$ (aproximadamente B1).

```
# Cargar datos
icfes_ni <- read.csv("datos/icfes_ni_2023.csv")

# Crear variable binaria (1 = supera B1, 0 = no supera)
icfes_ni$supera_B1 <- ifelse(icfes_ni$MOD_INGLES_PUNT >= 160, 1, 0)

# Calcular proporción muestral
n <- nrow(icfes_ni)
x <- sum(icfes_ni$supera_B1, na.rm = TRUE)
p_hat <- x / n

cat("Tamano de muestra:", n)
cat("\nExitos (supera B1):", x)
cat("\nProporción muestral:", round(p_hat, 4))

# Verificar condición de aplicabilidad
cat("\nn*p_hat =", n * p_hat)
cat("\nn*(1-p_hat) =", n * (1 - p_hat))
```


Calcular IC Manualmente

```
# IC al 95% usando la formula
alpha <- 0.05
z_critico <- qnorm(1 - alpha/2)

# Error estandar
ee <- sqrt(p_hat * (1 - p_hat) / n)

# Margen de error
E <- z_critico * ee

# Limites del IC
ic_inf <- p_hat - E
ic_sup <- p_hat + E

cat("Error estandar:", round(ee, 4))
cat("\nMargen de error:", round(E, 4))
cat("\nIC al 95%: (", round(ic_inf, 4), ",",
    round(ic_sup, 4), ")")
cat("\nEn porcentaje: (", round(ic_inf*100, 2), "%,",
    round(ic_sup*100, 2), "%)")
```

Usar `prop.test()` en R

R tiene funciones integradas para IC de proporciones:

```
# Metodo 1: prop.test() (usa correccion de continuidad)
resultado_prop <- prop.test(x, n, conf.level = 0.95)
print(resultado_prop)

# Extraer IC
ic_prop <- resultado_prop$conf.int
cat("\nIC con prop.test():", round(ic_prop, 4))

# Metodo 2: binom.test() (metodo exacto, recomendado para n pequeno)
resultado_binom <- binom.test(x, n, conf.level = 0.95)
ic_binom <- resultado_binom$conf.int
cat("\nIC con binom.test():", round(ic_binom, 4))
```

Diferencias:

- `prop.test()`: usa aproximación normal con corrección de continuidad
- `binom.test()`: usa distribución binomial exacta (mejor para n pequeño)

Interpretación del Resultado

Ejemplo hipotético: $n = 500$, $x = 360$, $\hat{p} = 0,72$

IC al 95 %: (0,680, 0,760) o (68,0 %, 76,0 %)

Interpretación

Estamos 95 % confiados de que la proporción poblacional de estudiantes de NI que superan el nivel B1 en inglés está entre 68 % y 76 %.

Implicación práctica:

- Si la meta institucional es que al menos 75 % supere B1, no podemos afirmar con 95 % de confianza que se cumple (porque 75 % está en el límite superior)
- Necesitaríamos más datos o un nivel de confianza menor

IC por Departamento

Pregunta: ¿Varía la proporción de estudiantes que superan B1 entre departamentos?

```
library(dplyr)

# Calcular IC de proporción por departamento
ic_prop_depto <- icfes_ni %>%
  group_by(ESTU_DEPTO_RESIDE) %>%
  summarise(
    n = n(),
    exitos = sum(supera_B1, na.rm = TRUE),
    p_hat = exitos / n,
    ee = sqrt(p_hat * (1 - p_hat) / n),
    z_critico = qnorm(0.975),
    ic_inf = p_hat - z_critico * ee,
    ic_sup = p_hat + z_critico * ee
  ) %>%
  filter(n >= 30) # Solo depts con muestra suficiente

# Ordenar por p_hat
ic_prop_depto <- ic_prop_depto %>%
  arrange(desc(p_hat))
```

Forest Plot de Proporciones

```
library(ggplot2)

ggplot(ic_prop_depto,
       aes(x = p_hat, y = reorder(ESTU_DEPTO_RESIDE, p_hat))) +
  geom_point(size = 3, color = "darkgreen") +
  geom_errorbarh(aes(xmin = ic_inf, xmax = ic_sup),
                 height = 0.3, color = "darkgreen") +
  geom_vline(xintercept = weighted.mean(ic_prop_depto$p_hat,
                                         ic_prop_depto$n),
             linetype = "dashed", color = "red") +
  scale_x_continuous(labels = scales::percent) +
  labs(x = "Proporcion que supera B1 (IC 95%)",
       y = "Departamento",
       title = "Proporcion de Estudiantes de NI que Superan B1 en Ingles",
       subtitle = "Por departamento (n >= 30)") +
  theme_minimal()
```

Comparar Dos Proporciones

Pregunta: ¿Difiere la proporción de estudiantes que superan B1 entre IES públicas y privadas?

```
# Crear tabla de contingencia
tabla <- table(icfes_ni$TIPO_IES, icfes_ni$supera_B1)
print(tabla)

# Prueba de proporciones (adelanto de pruebas de hipotesis)
test_2prop <- prop.test(tabla, conf.level = 0.95)
print(test_2prop)

# Calcular IC separados
ic_publica <- prop.test(tabla[1,2], sum(tabla[1,]), conf.level = 0.95)
ic_privada <- prop.test(tabla[2,2], sum(tabla[2,]), conf.level = 0.95)

cat("IC publica:", round(ic_publica$conf.int, 4))
cat("\nIC privada:", round(ic_privada$conf.int, 4))
```

Nota: Si los dos IC NO se solapan, hay evidencia de diferencia significativa.

Planificación del Muestreo

Pregunta inversa: En lugar de calcular el IC dado n , ¿cuál debe ser n para obtener un IC con un margen de error deseado?

Aplicaciones:

- Encuesta de satisfacción: ¿cuántos estudiantes de NI encuestar para estimar el salario inicial promedio con error $\pm \$300,000$ COP?
- Estudio de mercado: ¿cuántos usuarios de Rappi necesito para estimar el tiempo promedio de entrega con precisión de ± 2 minutos?
- Asignar presupuesto: más $n \Rightarrow$ mayor costo de recolección

Componentes del problema:

- Margen de error deseado E
- Nivel de confianza $(1 - \alpha)$
- Estimación previa de la variabilidad (σ o s)

Fórmula de Tamaño de Muestra para μ

Recordemos que el margen de error es:

$$E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

Despejando n :

$$n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

Tamaño de muestra para estimar μ

$$n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

donde:

- E = margen de error deseado
- σ = desviación estándar poblacional (estimada de un estudio piloto o literatura)

Redondear siempre hacia arriba para garantizar la precisión deseada.

Ejemplo: Tamaño de Muestra para MOD_INGLES_PUNT

Escenario: Queremos estimar la media de MOD_INGLES_PUNT en NI con un margen de error de ± 2 puntos al 95 % de confianza. De estudios previos, sabemos que $\sigma \approx 18$.

```
# Parametros
E <- 2          # Margen de error deseado
sigma <- 18     # Desviacion estandar estimada
confianza <- 0.95
alpha <- 1 - confianza

# Valor critico
z_critico <- qnorm(1 - alpha/2)

# Calcular n
n <- (z_critico * sigma / E)^2

cat("z critico:", round(z_critico, 4))
cat("\nn calculado:", n)
cat("\nn redondeado hacia arriba:", ceiling(n))
```

Resultado: Necesitamos $n = \lceil 311,17 \rceil = 312$ estudiantes.

Relación entre n , E , y Nivel de Confianza

Efecto de diferentes parámetros:

1. **Mayor precisión (menor E)** $\Rightarrow$ mayor n

- Si queremos $E = 1$ en lugar de $E = 2$, entonces n se multiplica por $2^2 = 4$
- $n \propto 1/E^2$

2. **Mayor confianza** $\Rightarrow$ mayor n

- 95 % de confianza: $z = 1,96$
- 99 % de confianza: $z = 2,576$ (+31 % más grande)
- n aumenta en $(2,576/1,96)^2 = 1,73$, es decir, 73 % más

3. **Mayor variabilidad (σ)** $\Rightarrow$ mayor n

- $n \propto \sigma^2$

Sensibilidad del Tamaño de Muestra

```
# Explorar diferentes combinaciones
library(tidyr)

combinaciones <- expand.grid(
  E = c(1, 2, 3, 5),
  confianza = c(0.90, 0.95, 0.99)
)

combinaciones$z <- qnorm(1 - (1 - combinaciones$confianza)/2)
combinaciones$n <- ceiling((combinaciones$z * sigma / combinaciones$E)^2)

# Tabla pivotada
tabla_n <- combinaciones %>%
  select(E, confianza, n) %>%
  pivot_wider(names_from = confianza, values_from = n,
              names_prefix = "Conf_")

print(tabla_n)
```

Interpretación: A medida que E disminuye o la confianza aumenta, n crece rápidamente.

¿Qué Hacer si No Conocemos σ ?

Opciones:

1. **Estudio piloto:** Tomar una muestra pequeña ($n_{\text{piloto}} = 30 - 50$), calcular s y usar como estimación de σ .
2. **Literatura:** Buscar estudios previos similares y usar su σ reportada.
3. **Rango:** Si conocemos el rango aproximado de la variable, usar $\sigma \approx \text{rango}/4$ o $\text{rango}/6$.

```
# Ejemplo: estudio piloto
piloto <- sample(icfes_ni$MOD_INGLES_PUNT, 50, replace = FALSE)
sigma_estimado <- sd(piloto, na.rm = TRUE)

cat("Sigma estimado del piloto:", round(sigma_estimado, 2))

# Usar sigma_estimado para calcular n
n_final <- ceiling((qnorm(0.975) * sigma_estimado / 2)^2)
cat("\nTamano de muestra necesario:", n_final)
```

Fórmula de Tamaño de Muestra para p

Recordemos que el margen de error para una proporción es:

$$E = z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}}$$

Despejando n :

$$n = \frac{z_{\alpha/2}^2 \cdot p(1-p)}{E^2}$$

Problema


La fórmula requiere conocer p , pero eso es lo que queremos estimar.

Soluciones:

- Usar una estimación previa p^* (de estudios piloto o literatura)
- Usar $p^* = 0,5$ (enfoque conservador)

Enfoque Conservador: $p^* = 0,5$

Propiedad: El producto $p(1 - p)$ alcanza su máximo cuando $p = 0,5$.



Implicación: Usar $p^* = 0,5$ garantiza que n será suficiente **sin importar el valor verdadero de p** .

Fórmula conservadora

$$n = \frac{z_{\alpha/2}^2 \cdot 0,25}{F^2} = \frac{z_{\alpha/2}^2}{4F^2}$$

Ejemplo: Tamaño de Muestra para Proporción

Escenario: Queremos estimar la proporción de estudiantes de NI que superan B2 en inglés ($\text{MOD_INGLES_PUNT} \geq 180$) con un margen de error de $\pm 3\%$ al 95 % de confianza.

```
# Parametros
E <- 0.03          # Margen de error (3%)
confianza <- 0.95
z_critico <- qnorm(1 - (1 - confianza)/2)

# Metodo 1: Enfoque conservador (p* = 0.5)
n_conservador <- ceiling((z_critico^2 * 0.25) / E^2)
cat("n conservador (p*=0.5):", n_conservador)

# Metodo 2: Estimacion previa (supongamos p* = 0.20)
p_star <- 0.20
n_estimado <- ceiling((z_critico^2 * p_star * (1 - p_star)) / E^2)
cat("\nn con p*=0.20:", n_estimado)

# Diferencia
cat("\nAhorro de muestra:", n_conservador - n_estimado)
```

Comparación de Métodos

Resultados del ejemplo:

- Con $p^* = 0,5$ (conservador): $n = 1068$
- Con $p^* = 0,20$ (estimado): $n = 683$
- Ahorro: $1068 - 683 = 385$ estudiantes (36 % menos)

Trade-off:

- **Conservador:** Garantiza precisión sin importar p , pero puede ser costoso
- **Estimado:** Más eficiente, pero arriesgado si p^* está muy lejos de p

Recomendación

Si tienes una estimación razonable de p (de un piloto o literatura), úsala. Si no, usa $p^* = 0,5$ para estar seguro.

Función en R para Tamaño de Muestra

```
# Funcion personalizada
calcular_n_proporcion <- function(E, confianza = 0.95, p_star = 0.5) {
  z <- qnorm(1 - (1 - confianza)/2)
  n <- (z^2 * p_star * (1 - p_star)) / E^2
  return(ceiling(n))
}

# Ejemplos de uso
cat("n para E=0.03, conf=95 %, p*=0.5:",
    calcular_n_proporcion(0.03))

cat("\nn para E=0.05, conf=95 %, p*=0.5:",
    calcular_n_proporcion(0.05))

cat("\nn para E=0.03, conf=99 %, p*=0.5:",
    calcular_n_proporcion(0.03, confianza = 0.99))

cat("\nn para E=0.03, conf=95 %, p*=0.20:",
    calcular_n_proporcion(0.03, p_star = 0.20))
```

Muestreo Aleatorio Simple vs Estratificado

Muestreo Aleatorio Simple (MAS):

- Cada elemento tiene igual probabilidad de selección
- Fácil de implementar
- Puede no ser representativo de subgrupos

Ejemplo: Seleccionar 500 estudiantes de NI al azar de toda Colombia.

Muestreo Estratificado:

- Dividir la población en **estratos** homogéneos
- Muestrear dentro de cada estrato
- Garantiza representatividad

Ejemplo: Dividir por departamento, luego seleccionar proporcionalmente de cada uno.

Estratos comunes en educación

- Departamento o región
- Tipo de IES (pública/privada)
- Nivel socioeconómico
- Género

Ventajas del Muestreo Estratificado

1. Mayor precisión:

- Si los estratos son homogéneos internamente, la variabilidad dentro de cada estrato es menor que la variabilidad global
- Esto reduce el error estándar de las estimaciones

2. Representatividad garantizada:

- Asegura que cada subgrupo importante esté representado
- Evita muestras raras" (por ejemplo, todos de Bogotá)

3. Estimaciones por subgrupo:

- Permite calcular IC separados para cada estrato
- Útil para comparaciones regionales

4. Eficiencia administrativa:

- Facilita la logística de recolección de datos

Asignación Proporcional vs Óptima

Asignación proporcional:

$$n_i = n \cdot \frac{N_i}{N}$$

donde N_i = tamaño del estrato i , N = tamaño poblacional total.

Ejemplo: Si el 15 % de los estudiantes de NI están en Antioquia, asignamos el 15 % de la muestra a Antioquia.

Asignación óptima (Neyman):

$$n_i = n \cdot \frac{N_i \sigma_i}{\sum_{j=1}^k N_j \sigma_j}$$

Asigna más muestra a estratos con **mayor variabilidad** σ_i .

Limitación

La asignación óptima requiere conocer σ_i de antemano (estudios piloto o literatura).

Ejemplo: Asignación Proporcional por Departamento

```
# Supongamos que queremos  $n = 1000$  estudiantes de NI

# Paso 1: Conocer la distribucion poblacional
poblacion_depto <- icfes_ni %>%
  count(ESTU_DEPTO_RESIDE, name = "N_i") %>%
  mutate(peso = N_i / sum(N_i))

# Paso 2: Asignar muestra proporcionalmente
n_total <- 1000
poblacion_depto$n_i <- ceiling(n_total * poblacion_depto$peso)

# Ajuste fino: asegurar que  $\text{sum}(n_i) = n_{\text{total}}$ 
exceso <- sum(poblacion_depto$n_i) - n_total
if (exceso > 0) {
  # Reducir de los estratos mas grandes
  poblacion_depto$n_i[order(-poblacion_depto$N_i)[1:exceso]] <-
    poblacion_depto$n_i[order(-poblacion_depto$N_i)[1:exceso]] - 1
}

print(poblacion_depto)
```

Consideraciones Prácticas en el Diseño Muestral

1. Costo vs Precisión:

- Mayor $n \Rightarrow$ mayor precisión, pero también mayor costo
- Equilibrio: ¿cuánta precisión necesitamos realmente?

2. Tasa de respuesta:

- No todos los seleccionados responderán
- Ajustar: si esperamos 70 % de respuesta y queremos $n = 500$, seleccionar $500/0,7 \approx 715$

3. Datos faltantes:

- Aumentar n para compensar valores perdidos
- Métodos de imputación

4. Poder estadístico:

- Para pruebas de hipótesis (próximas sesiones), n debe ser suficiente para **detectar** diferencias relevantes

Tabla Maestra de Intervalos de Confianza

Parámetro	Condiciones	IC al $(1 - \alpha) \times 100 \%$
μ	σ conocida, n grande o población normal	$\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$
μ	σ desconocida, población normal o $n \geq 30$	$\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$
σ^2	Población normal	$\left(\frac{(n-1)s^2}{\chi^2_{\alpha/2}}, \frac{(n-1)s^2}{\chi^2_{1-\alpha/2}} \right)$
p	$n\hat{p} \geq 5$ y $n(1 - \hat{p}) \geq 5$	$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

Tabla de Tamaño de Muestra

Parámetro	Fórmula	Notas
μ	$n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$	Requiere estimación previa de σ
p	$n = \frac{z_{\alpha/2}^2 \cdot p^* (1-p^*)}{E^2}$	Usar $p^* = 0,5$ si no hay estimación previa

Recordar: Siempre redondear n hacia arriba.

Conexión con Pruebas de Hipótesis

Adelanto de la próxima unidad:

Relación IC - Pruebas de hipótesis

Si un IC al $(1 - \alpha) \times 100 \%$ NO contiene un valor θ_0 , entonces rechazamos $H_0 : \theta = \theta_0$ al nivel de significancia α .

Ejemplo:

- IC al 95 % para μ : (162, 168)
- $H_0 : \mu = 160$ vs $H_1 : \mu \neq 160$
- Como 160 NO está en (162, 168), rechazamos H_0 al nivel $\alpha = 0,05$

Ventaja de los IC: Proporcionan más información que solo rechazar.º "no rechazar" H_0 . Dan un rango de valores plausibles.

Resumen Conceptual de la Unidad 2

Lógica general de la inferencia:

1. **Muestra:** Observamos datos de una muestra aleatoria
2. **Estadístico:** Calculamos un estimador puntual ($\bar{x}$, $\hat{p}$, s^2)
3. **Distribución muestral:** Sabemos cómo se comporta el estadístico (TLC, distribuciones t , χ^2)
4. **IC:** Construimos un intervalo que probablemente contiene el parámetro
5. **Interpretación:** Comunicamos incertidumbre de forma cuantitativa

Próximos pasos:

- Unidad 3: Pruebas de hipótesis (¿es μ significativamente diferente de un valor?)
- Unidad 4: Regresión lineal (¿cómo se relacionan dos variables?)

Resumen de la Sesión

Hoy aprendimos:

1. IC para proporciones:

- $\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$
- Condición: $n\hat{p} \geq 5$ y $n(1 - \hat{p}) \geq 5$
- Funciones en R: `prop.test()`, `binom.test()`

2. Tamaño de muestra para medias:

- $n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$

3. Tamaño de muestra para proporciones:

- $n = \frac{z_{\alpha/2}^2 \cdot p^* (1-p^*)}{E^2}$
- Enfoque conservador: $p^* = 0,5$

4. Muestreo estratificado: Mayor precisión y representatividad

Próxima sesión: Fundamentos de pruebas de hipótesis (H_0 , H_1 , p-valor, errores tipo I y II).

Ejercicios para la Próxima Clase

Con los datos de ICFES:

1. Calcular IC al 95 % para la proporción de estudiantes de NI que superan B2 en inglés ($\text{MOD_INGLES_PUNT} \geq 180$)
2. Crear forest plot de proporciones por región (Caribe, Andina, Pacífico, etc.)
3. Determinar el tamaño de muestra necesario para estimar la media de $\text{MOD_RAZONA_CUANTITAT}$ con error ± 3 puntos al 99 % de confianza
4. Comparar IC de proporción de aprobación (puntaje global ≥ 300) entre IES públicas y privadas
5. **Desafío:** Diseñar un muestreo estratificado por departamento con asignación proporcional para $n = 800$

Lectura: Anderson et al., Capítulos 8-9 (Estimación e Intervalos de Confianza)

¡Gracias por su atención!

Preguntas y discusión