

# Sesión 5: IC para Proporciones y Tamaño de Muestra

## Completando la caja de herramientas de estimación

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana  
Facultad de Ciencias Económicas y Administrativas

Viernes 18 de septiembre de 2026

# Agenda

IC para Proporciones

Tamaño de Muestra para Medias

Tamaño de Muestra para Proporciones

Muestreo Estratificado y Consideraciones Prácticas

Resumen de toda la Unidad 2

Conclusiones

# Motivación: Estimar Proporciones

## Ejemplos de proporciones en educación:

- ¿Qué proporción de estudiantes de Ciencias Económicas alcanza nivel B1 en inglés?
- ¿Qué porcentaje de estudiantes aprueba el examen ICFES con más de 300 puntos globales?
- ¿Cuál es la tasa de deserción en el primer año?

## Ejemplo cercano

¿Qué proporción del salón usa iPhone vs Android? Si encuestas a 30 compañeros y 18 dicen iPhone,  $\hat{p} = 18/30 = 0,60$ . Pero, ¿qué tan preciso es ese 60 %? Para eso necesitamos un **intervalo de confianza**.

# Motivación: Estimar Proporciones (cont.)

## Diferencia con medias:

- Variable de interés: **categorica binaria** (éxito/fracaso, sí/no)
- Codificación: 1 = éxito, 0 = fracaso
- Proporción muestral:  $\hat{p} = \frac{\text{número de éxitos}}{n} = \frac{x}{n}$

**Objetivo:** Construir IC para la proporción poblacional  $p$ .

# Proporción Muestral $\hat{p}$

## Definition (Proporción muestral)

$$\hat{p} = \frac{x}{n}$$

donde:

- $x$  = número de éxitos en la muestra
- $n$  = tamaño de la muestra
- $\hat{p}$  estima la proporción poblacional  $p$

**Ejemplo:** En una muestra de  $n = 200$  estudiantes de Ciencias Económicas, 140 superan B1 en inglés.

$$\hat{p} = \frac{140}{200} = 0,70 = 70 \%$$

**Conexión con Bernoulli:** Cada estudiante es un ensayo Bernoulli con probabilidad  $p$  de éxito. Entonces  $x \sim \text{Binomial}(n, p)$ .

# Distribución Muestral de $\hat{p}$

## Propiedades:

- Valor esperado:  $E(\hat{p}) = p$  (insesgado)
- Varianza:  $\text{Var}(\hat{p}) = \frac{p(1-p)}{n}$
- Desviación estándar (error estándar):  $\text{DE}(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}$

## Teorema Central del Límite para proporciones

Si  $n$  es suficientemente grande, entonces:

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right) \quad \text{aproximadamente}$$

Es decir:

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \sim N(0, 1) \quad \text{aproximadamente}$$

# Condición de Aplicabilidad

¿Cuándo es válida la aproximación normal?

## Regla empírica

La aproximación normal es adecuada si:

$$n \cdot \hat{p} \geq 5 \quad \text{y} \quad n \cdot (1 - \hat{p}) \geq 5$$

**Interpretación:**

- Necesitamos al menos 5 éxitos y 5 fracasos en la muestra
- Garantiza que la distribución binomial no esté muy sesgada

**Ejemplo:**  $n = 200$ ,  $\hat{p} = 0,70$

- $n \cdot \hat{p} = 200 \times 0,70 = 140 \geq 5 \quad \checkmark$
- $n \cdot (1 - \hat{p}) = 200 \times 0,30 = 60 \geq 5 \quad \checkmark$
- Aproximación normal es válida

## IC para una Proporción

**Problema:** La fórmula teórica requiere conocer  $p$ , pero eso es lo que queremos estimar.

**Solución:** Reemplazar  $p$  por  $\hat{p}$  en el error estándar.

IC al  $(1 - \alpha) \times 100\%$  para  $p$

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Equivalentemente:

$$\left( \hat{p} - z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}, \quad \hat{p} + z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \right)$$

**Nota:** Usamos  $z$  (no  $t$ ) porque la fórmula del error estándar ya usa  $\hat{p}$  como estimador de  $p$ .

# Ejemplo: Proporción de Estudiantes que Superan B1

**Contexto:** En los datos ICFES, definimos éxito como  $\text{MOD\_INGLES\_PUNT} \geq 160$  (aproximadamente B1).

```
# Cargar datos
icfes_ni <- read.csv("datos/icfes_ni_2023.csv")

# Crear variable binaria (1 = supera B1, 0 = no supera)
icfes_ni$supera_B1 <- ifelse(icfes_ni$MOD_INGLES_PUNT >= 160, 1, 0)

# Calcular proporción muestral
n <- nrow(icfes_ni)
x <- sum(icfes_ni$supera_B1, na.rm = TRUE)
p_hat <- x / n

cat("Tamano de muestra:", n)
cat("\nExitos (supera B1):", x)
cat("\nProporción muestral:", round(p_hat, 4))

# Verificar condición de aplicabilidad
cat("\nn*p_hat =", n * p_hat)
cat("\nn*(1-p_hat) =", n * (1 - p_hat))
```

# Calcular IC Manualmente

```
# IC al 95% usando la formula
alpha <- 0.05
z_critico <- qnorm(1 - alpha/2)

# Error estandar
ee <- sqrt(p_hat * (1 - p_hat) / n)

# Margen de error
E <- z_critico * ee

# Limites del IC
ic_inf <- p_hat - E
ic_sup <- p_hat + E

cat("Error estandar:", round(ee, 4))
cat("\nMargen de error:", round(E, 4))
cat("\nIC al 95%: (", round(ic_inf, 4), ",",
    round(ic_sup, 4), ")")
cat("\nEn porcentaje: (", round(ic_inf*100, 2), "%",
    round(ic_sup*100, 2), "%)")
```

## Usar `prop.test()` en R

R tiene funciones integradas para IC de proporciones:

```
# Metodo 1: prop.test() (usa correccion de continuidad)
resultado_prop <- prop.test(x, n, conf.level = 0.95)
print(resultado_prop)

# Extraer IC
ic_prop <- resultado_prop$conf.int
cat("\nIC con prop.test():", round(ic_prop, 4))

# Metodo 2: binom.test() (metodo exacto, recomendado para n pequeno)
resultado_binom <- binom.test(x, n, conf.level = 0.95)
ic_binom <- resultado_binom$conf.int
cat("\nIC con binom.test():", round(ic_binom, 4))
```

### Diferencias:

- `prop.test()`: usa aproximación normal con corrección de continuidad
- `binom.test()`: usa distribución binomial exacta (mejor para  $n$  pequeño)

# Interpretación del Resultado

**Ejemplo hipotético:**  $n = 500$ ,  $x = 360$ ,  $\hat{p} = 0,72$

IC al 95 %:  $(0,680, 0,760)$  o  $(68,0 \%, 76,0 \%)$

## Interpretación

Estamos 95 % confiados de que la proporción poblacional de estudiantes de Ciencias Económicas que superan el nivel B1 en inglés está entre 68 % y 76 %.

*Pensemos en el ejemplo del salón:* si 18 de 30 usan iPhone ( $\hat{p} = 0,60$ ), el IC al 95 % sería aproximadamente  $(0,42, 0,78)$ . Es decir, la verdadera proporción de usuarios de iPhone en la uni podría estar entre 42 % y 78 %.

## Implicación práctica:

- Si la meta institucional es que al menos 75 % supere B1, no podemos afirmar con 95 % de confianza que se cumple (porque 75 % está en el límite superior)
- Necesitaríamos más datos o un nivel de confianza menor

# IC por Departamento

**Pregunta:** ¿Varía la proporción de estudiantes que superan B1 entre departamentos?

```
library(dplyr)
# Calcular IC de proporción por departamento
ic_prop_depto <- icfes_ni %>%
  group_by(ESTU_DEPTO_RESIDE) %>%
  summarise(
    n = n(),
    exitos = sum(supera_B1, na.rm = TRUE),
    p_hat = exitos / n,
    ee = sqrt(p_hat * (1 - p_hat) / n),
    z_critico = qnorm(0.975),
    ic_inf = p_hat - z_critico * ee,
    ic_sup = p_hat + z_critico * ee
  ) %>%
  filter(n >= 30) # Solo depts con muestra suficiente
# Ordenar por p_hat
ic_prop_depto <- ic_prop_depto %>% arrange(desc(p_hat))
head(ic_prop_depto, 10)
```

# Forest Plot de Proporciones

```
library(ggplot2)
ggplot(ic_prop_depto,
      aes(x = p_hat, y = reorder(ESTU_DEPTO_RESIDE, p_hat))) +
  geom_point(size = 3, color = "darkgreen") +
  geom_errorbarh(aes(xmin = ic_inf, xmax = ic_sup),
                height = 0.3, color = "darkgreen") +
  geom_vline(xintercept = weighted.mean(ic_prop_depto$p_hat,
                                         ic_prop_depto$n),
            linetype = "dashed", color = "red") +
  scale_x_continuous(labels = scales::percent) +
  labs(x = "Proporcion que supera B1 (IC 95%)",
       y = "Departamento",
       title = "Proporcion Estudiantes Ciencias Economicas Superan B1 en Ingles") +
  theme_minimal()
```

# Comparar Dos Proporciones

**Pregunta:** ¿Difiere la proporción de estudiantes que superan B1 entre IES públicas y privadas?

```
# Crear tabla de contingencia
tabla <- table(icfes_ni$TIPO_IES, icfes_ni$supera_B1)
print(tabla)

# Prueba de proporciones (adelanto de pruebas de hipotesis)
test_2prop <- prop.test(tabla, conf.level = 0.95)
print(test_2prop)

# Calcular IC separados
ic_publica <- prop.test(tabla[1,2], sum(tabla[1,]), conf.level = 0.95)
ic_privada <- prop.test(tabla[2,2], sum(tabla[2,]), conf.level = 0.95)

cat("IC publica:", round(ic_publica$conf.int, 4))
cat("\nIC privada:", round(ic_privada$conf.int, 4))
```

**Nota:** Si los dos IC NO se solapan, hay evidencia de diferencia significativa.

# Planificación del Muestreo

**Pregunta inversa:** En lugar de calcular el IC dado  $n$ , ¿cuál debe ser  $n$  para obtener un IC con un margen de error deseado?

## Aplicaciones:

- Encuesta de satisfacción: ¿cuántos estudiantes de Ciencias Económicas encuestar para estimar el salario inicial promedio con error  $\pm \$300,000$  COP?
- Estudio de mercado: ¿cuántos usuarios de Rappi necesito para estimar el tiempo promedio de entrega con precisión de  $\pm 2$  minutos?
- Asignar presupuesto: más  $n \Rightarrow$  mayor costo de recolección

## Ejemplo cotidiano

¿Cuántas personas necesitas encuestar para saber si más del 50 % de la uni prefiere Spotify a Apple Music, con un margen de error de  $\pm 5$  %?

# Planificación del Muestreo (cont.)

## Componentes del problema:

- Margen de error deseado  $E$
- Nivel de confianza  $(1 - \alpha)$
- Estimación previa de la variabilidad ( $\sigma$  o  $s$ )

# Fórmula de Tamaño de Muestra para $\mu$

Recordemos que el margen de error es  $E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ . Despejando  $n$ :

Tamaño de muestra para estimar  $\mu$

$$n = \left( \frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

donde:

- $E$  = margen de error deseado
- $\sigma$  = desviación estándar poblacional (estimada de un estudio piloto o literatura)

**Redondear siempre hacia arriba** para garantizar la precisión deseada.

# Ejemplo: Tamaño de Muestra para MOD\_INGLES\_PUNT

**Escenario:** Queremos estimar la media de MOD\_INGLES\_PUNT en Ciencias Económicas con un margen de error de  $\pm 2$  puntos al 95 % de confianza. De estudios previos,  $\sigma \approx 18$ .

```
# Parametros
E <- 2          # Margen de error deseado
sigma <- 18     # Desviacion estandar estimada
confianza <- 0.95
alpha <- 1 - confianza

# Valor critico
z_critico <- qnorm(1 - alpha/2)

# Calcular n
n <- (z_critico * sigma / E)^2

cat("z critico:", round(z_critico, 4))
cat("\nn calculado:", n)
cat("\nn redondeado hacia arriba:", ceiling(n))
```

**Resultado:** Necesitamos  $n = \lceil 311,17 \rceil = 312$  estudiantes.

# Relación entre $n$ , $E$ , y Nivel de Confianza

Efecto de diferentes parámetros:

1. Mayor precisión (menor  $E$ )  $\Rightarrow$  mayor  $n$

- Si queremos  $E = 1$  en lugar de  $E = 2$ , entonces  $n$  se multiplica por  $2^2 = 4$   
( $n \propto 1/E^2$ )

2. Mayor confianza  $\Rightarrow$  mayor  $n$

- 95 %:  $z = 1,96$  vs 99 %:  $z = 2,576$  (+31 %)
- $n$  aumenta en  $(2,576/1,96)^2 = 1,73$ , es decir, 73 % más

3. Mayor variabilidad ( $\sigma$ )  $\Rightarrow$  mayor  $n$  ( $n \propto \sigma^2$ )

# Sensibilidad del Tamaño de Muestra

```
# Explorar diferentes combinaciones
library(tidyr)

combinaciones <- expand.grid(
  E = c(1, 2, 3, 5),
  confianza = c(0.90, 0.95, 0.99)
)

combinaciones$z <- qnorm(1 - (1 - combinaciones$confianza)/2)
combinaciones$n <- ceiling((combinaciones$z * sigma / combinaciones$E)^2)

# Tabla pivotada
tabla_n <- combinaciones %>%
  select(E, confianza, n) %>%
  pivot_wider(names_from = confianza, values_from = n,
              names_prefix = "Conf_")

print(tabla_n)
```

**Interpretación:** A medida que  $E$  disminuye o la confianza aumenta,  $n$  crece rápidamente.

# ¿Qué Hacer si No Conocemos $\sigma$ ?

## Opciones:

1. **Estudio piloto:** Muestra pequeña ( $n_{\text{piloto}} = 30-50$ ), calcular  $s$  y usar como estimación de  $\sigma$ .
2. **Literatura:** Buscar estudios previos similares y usar su  $\sigma$  reportada.
3. **Rango:** Si conocemos el rango aproximado, usar  $\sigma \approx \text{rango}/4$  o  $\text{rango}/6$ .

```
# Ejemplo: estudio piloto
piloto <- sample(icfes_ni$MOD_INGLES_PUNT, 50, replace = FALSE)
sigma_estimado <- sd(piloto, na.rm = TRUE)

cat("Sigma estimado del piloto:", round(sigma_estimado, 2))

# Usar sigma_estimado para calcular n
n_final <- ceiling((qnorm(0.975) * sigma_estimado / 2)^2)
cat("\nTamano de muestra necesario:", n_final)
```

## Fórmula de Tamaño de Muestra para $p$

Recordemos que el margen de error para una proporción es:

$$E = z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}}$$

Despejando  $n$ :

$$n = \frac{z_{\alpha/2}^2 \cdot p(1-p)}{E^2}$$

### Problema


La fórmula requiere conocer  $p$ , pero eso es lo que queremos estimar.

### Soluciones:

- Usar una estimación previa  $p^*$  (de estudios piloto o literatura)
- Usar  $p^* = 0,5$  (enfoque conservador)

## Enfoque Conservador: $p^* = 0,5$

**Propiedad:** El producto  $p(1 - p)$  alcanza su máximo cuando  $p = 0,5$ .



**Implicación:** Usar  $p^* = 0,5$  garantiza que  $n$  será suficiente **sin importar el valor verdadero de  $p$** .

Fórmula conservadora

$$n = \frac{z_{\alpha/2}^2 \cdot 0,25}{E^2} = \frac{z_{\alpha/2}^2}{4E^2}$$

# Ejemplo: Tamaño de Muestra para Proporción

**Escenario:** Queremos estimar la proporción de estudiantes de Ciencias Económicas que superan B2 en inglés ( $\text{MOD\_INGLES\_PUNT} \geq 180$ ) con margen de error  $\pm 3\%$  al 95 %.

```
# Parametros
E <- 0.03; confianza <- 0.95
z_critico <- qnorm(1 - (1 - confianza)/2)

# Metodo 1: Enfoque conservador (p* = 0.5)
n_conservador <- ceiling((z_critico^2 * 0.25) / E^2)
cat("n conservador (p*=0.5):", n_conservador)

# Metodo 2: Estimacion previa (supongamos p* = 0.20)
p_star <- 0.20
n_estimado <- ceiling((z_critico^2 * p_star * (1 - p_star)) / E^2)
cat("\nn con p*=0.20:", n_estimado)
cat("\nAhorro de muestra:", n_conservador - n_estimado)
```

# Comparación de Métodos

## Resultados del ejemplo:

- Con  $p^* = 0,5$  (conservador):  $n = 1068$
- Con  $p^* = 0,20$  (estimado):  $n = 683$
- Ahorro:  $1068 - 683 = 385$  estudiantes (36 % menos)

## Trade-off:

- **Conservador:** Garantiza precisión sin importar  $p$ , pero puede ser costoso
- **Estimado:** Más eficiente, pero arriesgado si  $p^*$  está muy lejos de  $p$

## Recomendación

Si tienes una estimación razonable de  $p$  (de un piloto o literatura), úsala. Si no, usa  $p^* = 0,5$  para estar seguro.

*Volviendo a Spotify vs Apple Music:* si no tienes idea de la preferencia, usa  $p^* = 0,5$ . Si ya sabes que en tu facultad  $\approx 70\%$  usa Spotify, usa  $p^* = 0,70$  y necesitarás menos encuestados.

# Función en R para Tamaño de Muestra

```
# Funcion personalizada
calcular_n_proporcion <- function(E, confianza = 0.95, p_star = 0.5) {
  z <- qnorm(1 - (1 - confianza)/2)
  n <- (z^2 * p_star * (1 - p_star)) / E^2
  return(ceiling(n))
}

# Ejemplos de uso
cat("n para E=0.03, conf=95 %, p*=0.5:",
    calcular_n_proporcion(0.03))

cat("\nn para E=0.05, conf=95 %, p*=0.5:",
    calcular_n_proporcion(0.05))

cat("\nn para E=0.03, conf=99 %, p*=0.5:",
    calcular_n_proporcion(0.03, confianza = 0.99))

cat("\nn para E=0.03, conf=95 %, p*=0.20:",
    calcular_n_proporcion(0.03, p_star = 0.20))
```

# Muestreo Aleatorio Simple vs Estratificado

## Muestreo Aleatorio Simple (MAS):

- Cada elemento tiene igual probabilidad de selección
- Fácil de implementar
- Puede no ser representativo de subgrupos

**Ejemplo:** Seleccionar 500 estudiantes de Ciencias Económicas al azar de toda Colombia.

## Muestreo Estratificado:

- Dividir la población en **estratos** homogéneos
- Muestrear dentro de cada estrato
- Garantiza representatividad

**Ejemplo:** Dividir por departamento, luego seleccionar proporcionalmente de cada uno.

### Estratos comunes en educación

- Departamento o región
- Tipo de IES (pública/privada)
- Nivel socioeconómico
- Género

# Ventajas del Muestreo Estratificado

## 1. Mayor precisión:

- Si los estratos son homogéneos internamente, la variabilidad dentro de cada estrato es menor que la variabilidad global
- Esto reduce el error estándar de las estimaciones

## 2. Representatividad garantizada:

- Asegura que cada subgrupo importante esté representado
- Evita muestras raras" (por ejemplo, todos de Bogotá)

## 3. Estimaciones por subgrupo:

- Permite calcular IC separados para cada estrato
- Útil para comparaciones regionales

## 4. Eficiencia administrativa:

- Facilita la logística de recolección de datos

# Asignación Proporcional vs Óptima

Asignación proporcional:

$$n_i = n \cdot \frac{N_i}{N}$$

donde  $N_i$  = tamaño del estrato  $i$ ,  $N$  = tamaño poblacional total.

**Ejemplo:** Si el 15 % de los estudiantes de Ciencias Económicas están en Antioquia, asignamos el 15 % de la muestra a Antioquia.

Asignación óptima (Neyman):

$$n_i = n \cdot \frac{N_i \sigma_i}{\sum_{j=1}^k N_j \sigma_j}$$

Asigna más muestra a estratos con **mayor variabilidad**  $\sigma_i$ .

## Limitación

La asignación óptima requiere conocer  $\sigma_i$  de antemano (estudios piloto o literatura).

# Ejemplo: Asignación Proporcional por Departamento

```
# Supongamos que queremos n = 1000 estudiantes de Ciencias Economicas

# Paso 1: Conocer la distribucion poblacional
poblacion_depto <- icfes_ni %>%
  count(ESTU_DEPTO_RESIDE, name = "N_i") %>%
  mutate(peso = N_i / sum(N_i))

# Paso 2: Asignar muestra proporcionalmente
n_total <- 1000
poblacion_depto$n_i <- ceiling(n_total * poblacion_depto$peso)

# Ajuste fino: asegurar que sum(n_i) = n_total
exceso <- sum(poblacion_depto$n_i) - n_total
if (exceso > 0) {
  # Reducir de los estratos mas grandes
  poblacion_depto$n_i[order(-poblacion_depto$N_i)[1:exceso]] <-
    poblacion_depto$n_i[order(-poblacion_depto$N_i)[1:exceso]] - 1
}

print(poblacion_depto)
```

# Consideraciones Prácticas en el Diseño Muestral

## 1. Costo vs Precisión:

- Mayor  $n \Rightarrow$  mayor precisión, pero también mayor costo
- Equilibrio: ¿cuánta precisión necesitamos realmente?

## 2. Tasa de respuesta:

- No todos los seleccionados responderán
- Ajustar: si esperamos 70 % de respuesta y queremos  $n = 500$ , seleccionar  $500/0,7 \approx 715$

## 3. Datos faltantes:

- Aumentar  $n$  para compensar valores perdidos
- Métodos de imputación

## 4. Poder estadístico:

- Para pruebas de hipótesis (próximas sesiones),  $n$  debe ser suficiente para **detectar** diferencias relevantes

# Tabla Maestra de Intervalos de Confianza

| Parámetro  | Condiciones                                          | IC al $(1 - \alpha) \times 100 \%$                                                        |
|------------|------------------------------------------------------|-------------------------------------------------------------------------------------------|
| $\mu$      | $\sigma$ conocida, $n$ grande o población normal     | $\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$                                        |
| $\mu$      | $\sigma$ desconocida, población normal o $n \geq 30$ | $\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$                                        |
| $\sigma^2$ | Población normal                                     | $\left( \frac{(n-1)s^2}{\chi^2_{\alpha/2}}, \frac{(n-1)s^2}{\chi^2_{1-\alpha/2}} \right)$ |
| $p$        | $n\hat{p} \geq 5$ y $n(1 - \hat{p}) \geq 5$          | $\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$                            |

# Tabla de Tamaño de Muestra

| Parámetro | Fórmula                                                    | Notas                                        |
|-----------|------------------------------------------------------------|----------------------------------------------|
| $\mu$     | $n = \left( \frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$ | Requiere estimación previa de $\sigma$       |
| $p$       | $n = \frac{z_{\alpha/2}^2 \cdot p^* (1-p^*)}{E^2}$         | Usar $p^* = 0,5$ si no hay estimación previa |

**Recordar:** Siempre redondear  $n$  hacia arriba.

# Conexión con Pruebas de Hipótesis

Adelanto de la próxima unidad:

## Relación IC - Pruebas de hipótesis

Si un IC al  $(1 - \alpha) \times 100 \%$  NO contiene un valor  $\theta_0$ , entonces rechazamos  $H_0 : \theta = \theta_0$  al nivel de significancia  $\alpha$ .

**Ejemplo:**

- IC al 95 % para  $\mu$ : (162, 168)
- $H_0 : \mu = 160$  vs  $H_1 : \mu \neq 160$
- Como 160 NO está en (162, 168), rechazamos  $H_0$  al nivel  $\alpha = 0,05$

**Ventaja de los IC:** Proporcionan más información que solo rechazar.º "no rechazar"  $H_0$ . Dan un rango de valores plausibles.

# Resumen Conceptual de la Unidad 2

## Lógica general de la inferencia:

1. **Muestra:** Observamos datos de una muestra aleatoria
2. **Estadístico:** Calculamos un estimador puntual ( $\bar{x}$ ,  $\hat{p}$ ,  $s^2$ )
3. **Distribución muestral:** Sabemos cómo se comporta el estadístico (TLC, distribuciones  $t$ ,  $\chi^2$ )
4. **IC:** Construimos un intervalo que probablemente contiene el parámetro
5. **Interpretación:** Comunicamos incertidumbre de forma cuantitativa

## Próximos pasos:

- Unidad 3: Pruebas de hipótesis (¿es  $\mu$  significativamente diferente de un valor?)
- Unidad 4: Regresión lineal (¿cómo se relacionan dos variables?)

# Resumen de la Sesión

Hoy aprendimos:

## 1. IC para proporciones:

- $\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$
- Condición:  $n\hat{p} \geq 5$  y  $n(1 - \hat{p}) \geq 5$
- Funciones en R: `prop.test()`, `binom.test()`

## 2. Tamaño de muestra para medias:

- $n = \left( \frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$

## 3. Tamaño de muestra para proporciones:

- $n = \frac{z_{\alpha/2}^2 \cdot p^* (1-p^*)}{E^2}$
- Enfoque conservador:  $p^* = 0,5$

## 4. Muestreo estratificado: Mayor precisión y representatividad

**Próxima sesión:** Fundamentos de pruebas de hipótesis ( $H_0$ ,  $H_1$ , p-valor, errores tipo I y II).

# Ejercicios para la Próxima Clase

## Con los datos de ICFES:

1. Calcular IC al 95 % para la proporción de estudiantes de Ciencias Económicas que superan B2 en inglés ( $\text{MOD\_INGLES\_PUNT} \geq 180$ )
2. Crear forest plot de proporciones por región (Caribe, Andina, Pacífico, etc.)
3. Determinar el tamaño de muestra necesario para estimar la media de  $\text{MOD\_RAZONA\_CUANTITAT}$  con error  $\pm 3$  puntos al 99 % de confianza
4. Comparar IC de proporción de aprobación (puntaje global  $\geq 300$ ) entre IES públicas y privadas
5. **Desafío:** Diseñar un muestreo estratificado por departamento con asignación proporcional para  $n = 800$

**Lectura:** Anderson et al., Capítulos 8-9 (Estimación e Intervalos de Confianza)

¡Gracias por su atención!

Preguntas y discusión