

Sesión 6: Fundamentos de Pruebas de Hipótesis

H_0 , H_1 , p-valor, errores y potencia estadística

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Viernes 25 de septiembre de 2026

Agenda

Introducción a las Pruebas de Hipótesis

Error Tipo I, Tipo II y Nivel de Significancia

El p-valor

Prueba z para una Muestra (σ Conocida)

Prueba t para una Muestra (σ Desconocida)

Prueba t para Dos Muestras Independientes

d de Cohen y Tamaño del Efecto

Potencia Estadística

Relación entre IC y Pruebas de Hipótesis

Conclusiones

¿Qué es una Hipótesis Estadística?

Definition (Hipótesis estadística)

Una **hipótesis estadística** es una afirmación sobre un parámetro poblacional que puede ser verdadera o falsa.

Ejemplos:

- La media de inglés en NI es 160 puntos ($\mu = 160$)
- La proporción que supera B1 es mayor al 70 % ($p > 0,70$)
- IES públicas y privadas tienen el mismo rendimiento ($\mu_1 = \mu_2$)

Diferencia con IC: el IC estima un rango plausible para μ ; la prueba de hipótesis pregunta si hay evidencia suficiente para afirmar que $\mu \neq 160$.

Ejemplo cercano

¿Los que escuchan lofi realmente estudian más horas? H_0 : no hay diferencia. H_1 : sí hay diferencia.

Hipótesis Nula vs Hipótesis Alternativa

Hipótesis nula (H_0)

- Se asume verdadera inicialmente
- “No diferencia” o “no efecto”
- Contiene igualdad: $=$, $\leq$, $\geq$
- Buscamos **rechazarla** con evidencia

Hipótesis alternativa (H_1 o H_a)

- La afirmación que queremos probar
- Refleja el interés de investigación
- Contiene: $\neq$, $<$, o $>$
- Solo la aceptamos con **evidencia fuerte**

Analogía jurídica: H_0 = “inocente”, H_1 = “culpable”. Asumimos inocencia hasta que se pruebe culpabilidad.

Tres Formas de la Hipótesis Alternativa

1. Prueba de dos colas (bilateral):

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_1 : \mu \neq \mu_0$$

Pregunta: ¿Es μ **diferente** de μ_0 (mayor O menor)?

2. Prueba de cola derecha (unilateral):

$$H_0 : \mu \leq \mu_0 \quad \text{vs} \quad H_1 : \mu > \mu_0$$

Pregunta: ¿Es μ **mayor** que μ_0 ?

3. Prueba de cola izquierda (unilateral):

$$H_0 : \mu \geq \mu_0 \quad \text{vs} \quad H_1 : \mu < \mu_0$$

Pregunta: ¿Es μ **menor** que μ_0 ?

Nota: La forma depende de la pregunta de investigación.

Ejemplos con Datos ICFES

Ejemplo 1 (dos colas): ¿El puntaje promedio de inglés en NI es diferente de 160?

$$H_0 : \mu = 160 \quad \text{vs} \quad H_1 : \mu \neq 160$$

Ejemplo 2 (cola derecha): ¿El puntaje promedio de inglés en NI supera el umbral de B1 (160)?

$$H_0 : \mu \leq 160 \quad \text{vs} \quad H_1 : \mu > 160$$

Ejemplo 3 (cola izquierda): ¿El puntaje promedio de matemáticas en NI es inferior a 150?

$$H_0 : \mu \geq 150 \quad \text{vs} \quad H_1 : \mu < 150$$

Decisión: Depende del contexto y la pregunta. Si no hay razón para esperar una dirección específica, usar dos colas.

La Hipótesis Nula como “Statu Quo”

Filosofía:

- H_0 representa el estado actual del conocimiento o la creencia aceptada
- Solo la rechazamos si los datos muestran evidencia **fuerte** en contra
- Si no hay evidencia suficiente, mantenemos H_0 (NO la .aceptamos")

Ejemplos:

- H_0 : .^{El} nuevo método de enseñanza NO mejora el rendimiento"(statu quo)
- H_1 : .^{El} nuevo método SÍ mejora el rendimiento"(afirmación que queremos probar)

Importante

No rechazar H_0 NO es lo mismo que .aceptar H_0 ". Solo significa que no hay evidencia suficiente para rechazarla. Puede ser que:

- H_0 sea verdadera
- La muestra sea muy pequeña (falta de poder estadístico)

Analogía con un Juicio

Juicio		Prueba de hipótesis
Acusado	$\longleftrightarrow$	Hipótesis nula H_0
Inocente (presunción)	$\longleftrightarrow$	H_0 es verdadera (presunción)
Evidencia	$\longleftrightarrow$	Datos de la muestra
Veredicto "culpable"	$\longleftrightarrow$	Rechazar H_0
Veredicto "no culpable"	$\longleftrightarrow$	No rechazar H_0

Principio clave: Solo declaramos "culpable" (rechazamos H_0) si la evidencia es **más allá de una duda razonable**.

Nota: "No culpable" $\neq$ "inocente". Solo significa que no hay evidencia suficiente para condenar.

Dos Tipos de Errores

Decisiones posibles:

1. Rechazar H_0
2. No rechazar H_0

Realidad desconocida:

1. H_0 es verdadera
2. H_0 es falsa

Esto da lugar a 4 escenarios:

	H_0 verdadera	H_0 falsa
No rechazar H_0	Decisión correcta	Error tipo II (β)
Rechazar H_0	Error tipo I (α)	Decisión correcta

Error Tipo I (α)

Definition (Error tipo I)

Rechazar H_0 cuando en realidad es **verdadera**.

- También llamado **falso positivo**
- Probabilidad: $P(\text{rechazar } H_0 \mid H_0 \text{ verdadera}) = \alpha$
- En la analogía jurídica: condenar a un inocente

Ejemplo educativo: H_0 : “El nuevo programa NO mejora el rendimiento”. Error tipo I: concluir que funciona cuando no tiene efecto. Consecuencia: invertir recursos en un programa inefectivo.

Ejemplo Gen Z

Declarar que un producto es *viral* en TikTok cuando no lo es (falso positivo en marketing). Una marca invierte millones en algo que “todos quieren” pero nadie compra.

Error Tipo II (β)

Definition (Error tipo II)

No rechazar H_0 cuando en realidad es falsa.

- También llamado **falso negativo**
- Probabilidad: $P(\text{no rechazar } H_0 \mid H_0 \text{ falsa}) = \beta$
- En la analogía jurídica: absolver a un culpable

Ejemplo educativo: H_0 : “El programa NO mejora el rendimiento”. Error tipo II: concluir que no funciona cuando sí mejora. Consecuencia: descartar un programa efectivo.

Ejemplo Gen Z

Tu emprendimiento lanza un anuncio en Instagram que realmente atrae clientes, pero con solo 15 respuestas concluyes que “no sirve” y lo cancelas (falso negativo).

Tabla Resumen de Errores

Escenario	Error tipo I (α)	Error tipo II (β)
Definición	Rechazar H_0 verdadera	No rechazar H_0 falsa
Nombre alternativo	Falso positivo	Falso negativo
Analogía jurídica	Condenar inocente	Absolver culpable
Analogía médica	Diagnóstico positivo en sano	Diagnóstico negativo en enfermo
Control	Fijamos α (0.05, 0.01)	Depende de n , α , efecto

Nivel de Significancia α

Definition (Nivel de significancia)

El **nivel de significancia** α es la probabilidad máxima de cometer un error tipo I que estamos dispuestos a tolerar.

Valores comunes:

- $\alpha = 0,05$ (5 %): estándar en ciencias sociales
- $\alpha = 0,01$ (1 %): cuando queremos ser más conservadores
- $\alpha = 0,10$ (10 %): cuando el error tipo II es más costoso

Interpretación: Con $\alpha = 0,05$, aceptamos que en el 5 % de las pruebas (a largo plazo) rechazaremos H_0 incorrectamente.


Importante

α NO es la probabilidad de que H_0 sea verdadera. Es la probabilidad de rechazarla **si** es verdadera.

Trade-off entre α y β

Relación inversa:

- Si reducimos α (ser más estrictos para rechazar H_0), aumenta β
- Si aumentamos α (ser menos estrictos), disminuye β



Solución: Aumentar el tamaño de muestra n reduce TANTO α como β .

¿Qué es el p-valor?

Definition (p-valor)

El **p-valor** es la probabilidad de obtener un resultado tan extremo o más extremo que el observado, **asumiendo que H_0 es verdadera**.

Fórmula conceptual:

$$\text{p-valor} = P(\text{estadístico tan extremo o más} \mid H_0 \text{ verdadera})$$

Interpretación:

- p-valor **pequeño** $\Rightarrow$ datos incompatibles con $H_0 \Rightarrow$ evidencia contra H_0
- p-valor **grande** $\Rightarrow$ datos compatibles con $H_0 \Rightarrow$ no hay evidencia contra H_0

Regla de decisión

Si $\text{p-valor} < \alpha$, rechazamos H_0 .

Si $\text{p-valor} \geq \alpha$, no rechazamos H_0 .

El p-valor: ejemplo concreto

Ejemplo

Si comparas horas de estudio entre quienes escuchan lofi y quienes no, y el p-valor es 0.03, hay solo un 3 % de probabilidad de ver una diferencia tan grande **si realmente no hubiera diferencia**. Como $0,03 < 0,05$, rechazamos H_0 .

Recordar: El p-valor solo mide evidencia contra H_0 , no prueba que H_1 sea verdadera.

Errores Comunes de Interpretación del p-valor

Lo que el p-valor NO es

1. **NO** es $P(H_0 \text{ verdadera} \mid \text{datos})$
 - Es al revés: $P(\text{datos} \mid H_0 \text{ verdadera})$
2. **NO** es la probabilidad de que el resultado sea "por azar"
 - Todo en estadística involucra azar; el p-valor cuantifica qué tan compatible son los datos con H_0
3. **NO** mide la magnitud del efecto
 - Un p-valor pequeño puede deberse a un efecto pequeño con muestra grande
4. **NO** es la probabilidad de replicar el resultado


Escala Cualitativa del p-valor

p-valor	Evidencia contra H_0	Decisión ($\alpha = 0,05$)
$p < 0,01$	Muy fuerte	Rechazar H_0
$0,01 \leq p < 0,05$	Moderada	Rechazar H_0
$0,05 \leq p < 0,10$	Débil	No rechazar H_0
$p \geq 0,10$	Ninguna	No rechazar H_0

Notas:

- Esta es una guía general, no una regla rígida
- El umbral de 0.05 es convencional, no mágico
- En algunos campos (física de partículas), se usa $\alpha = 0,0000003$ (5 sigmas)
- En estudios exploratorios, a veces se tolera $\alpha = 0,10$

Visualización del p-valor (dos colas)



p-valor = área en rojo MÁS ALLÁ de $|t_{obs}|$ (ambas colas).

Si p-valor $< \alpha$, t_{obs} cae en la región de rechazo.

Estadístico de Prueba z

Supuestos:

- Muestra aleatoria simple de tamaño n
- Población normal O $n \geq 30$ (TLC)
- σ conocida

Estadístico de prueba

$$z = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$$

donde:

- μ_0 = valor hipotético de $H_0 : \mu = \mu_0$
- Si H_0 es verdadera, $z \sim N(0, 1)$

Interpretación: z mide cuántas desviaciones estándar está $\bar{x}$ del valor hipotético μ_0 .

Región de Rechazo y Valor Crítico

Prueba de dos colas: $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$

- Rechazar H_0 si $|z| > z_{\alpha/2}$
- p-valor = $2 \cdot P(Z > |z_{\text{obs}}|)$

Prueba de cola derecha: $H_0 : \mu \leq \mu_0$ vs $H_1 : \mu > \mu_0$

- Rechazar H_0 si $z > z_{\alpha}$
- p-valor = $P(Z > z_{\text{obs}})$

Prueba de cola izquierda: $H_0 : \mu \geq \mu_0$ vs $H_1 : \mu < \mu_0$

- Rechazar H_0 si $z < -z_{\alpha}$
- p-valor = $P(Z < z_{\text{obs}})$

Ejemplo: ¿La Media de Inglés es Mayor que 155? (1/2)

Pregunta: ¿El puntaje promedio de MOD_INGLES_PUNT en NI es significativamente mayor que 155?

Hipótesis: $H_0 : \mu \leq 155$ vs $H_1 : \mu > 155$

```
# Datos (simulados)
xbar <- 162.5
n <- 120
sigma <- 18 # Supuesto conocido
mu_0 <- 155
alpha <- 0.05

# Estadístico de prueba
z_obs <- (xbar - mu_0) / (sigma / sqrt(n))
cat("Estadístico z:", round(z_obs, 3))

# p-valor (cola derecha)
p_valor <- pnorm(z_obs, lower.tail = FALSE)
cat("\np-valor:", round(p_valor, 6))
```

Ejemplo: ¿La Media de Inglés es Mayor que 155? (2/2)

```
# Valor critico
z_critico <- qnorm(1 - alpha)
cat("Valor critico z:", round(z_critico, 3))

# Decision
if (p_valor < alpha) {
  cat("\nDecision: Rechazar H0 al nivel", alpha)
} else {
  cat("\nDecision: No rechazar H0 al nivel", alpha)
}
```

Resultado esperado:

- $z = 4,56$ (muy por encima de $z_{0,05} = 1,645$)
- $p\text{-valor} \approx 0,000003$ (extremadamente pequeño)
- Decisión: Rechazar H_0 con gran confianza
- Conclusión: Hay evidencia muy fuerte de que $\mu > 155$

Estadístico de Prueba t

Caso real: σ desconocida, usamos s .

Estadístico de prueba

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

donde:

- s = desviación estándar muestral
- Si H_0 es verdadera, $t \sim t(n-1)$

Regiones de rechazo:

- **Dos colas:** Rechazar si $|t| > t_{\alpha/2, n-1}$
- **Cola derecha:** Rechazar si $t > t_{\alpha, n-1}$
- **Cola izquierda:** Rechazar si $t < -t_{\alpha, n-1}$

Ejemplo: ¿La Media Supera el Umbral B1? (1/2)

Pregunta: ¿El puntaje promedio de inglés en NI supera el umbral B1 de 160 puntos?

Hipótesis: $H_0 : \mu \leq 160$ vs $H_1 : \mu > 160$

```
# Cargar datos reales
icfes_ni <- read.csv("datos/icfes_ni_2023.csv")
ingles <- icfes_ni$MOD_INGLES_PUNT

# Calcular estadísticos
n <- length(ingles)
xbar <- mean(ingles, na.rm = TRUE)
s <- sd(ingles, na.rm = TRUE)
mu_0 <- 160
```

Ejemplo: ¿La Media Supera el Umbral B1? (2/2)

```
# Estadístico t
t_obs <- (xbar - mu_0) / (s / sqrt(n))
cat("Estadístico t:", round(t_obs, 3))

# p-valor (cola derecha)
p_valor <- pt(t_obs, df = n - 1, lower.tail = FALSE)
cat("\np-valor:", round(p_valor, 6))
```

Nota: Usamos prueba t porque σ es desconocida y la estimamos con s .

Usar `t.test()` en R

```
# Metodo directo: t.test()
resultado <- t.test(ingles, mu = 160, alternative = "greater")

print(resultado)

# Extraer componentes
cat("\nEstadistico t:", resultado$statistic)
cat("\np-valor:", resultado$p.value)
cat("\nIC de una cola:", resultado$conf.int)

# Decision manual
alpha <- 0.05
if (resultado$p.value < alpha) {
  cat("\nDecision: Rechazar H0")
  cat("\nConcluimos que mu > 160")
} else {
  cat("\nDecision: No rechazar H0")
  cat("\nNo hay evidencia suficiente para afirmar que mu > 160")
}
```

Interpretación del Output de `t.test()`

One Sample `t`-test

`data:` ingles

`t` = 1.9135, `df` = 119, p-value = 0.02911

alternative hypothesis: true mean is greater than 160

95 percent confidence interval:

160.56 Inf

`sample` estimates:

mean of x

162.50

Interpretación:

- $t = 1,914$, $gl = 119$
- $p\text{-valor} = 0,0291 < 0,05 \Rightarrow$ Rechazamos H_0
- Conclusión: Hay evidencia suficiente (al 5 % de significancia) para afirmar que $\mu > 160$
- IC de una cola: $[160,56, \infty)$ no incluye valores ≤ 160

Comparar Dos Medias Poblacionales

Pregunta: ¿Difiere el rendimiento promedio entre dos grupos?

Ejemplos:

- ¿El puntaje de inglés difiere entre IES públicas y privadas?
- ¿El salario inicial promedio difiere entre hombres y mujeres en NI?
- ¿Estudiantes de Bogotá tienen mejor rendimiento que los de otras regiones?

Hipótesis:

$$H_0 : \mu_1 = \mu_2 \quad \text{vs} \quad H_1 : \mu_1 \neq \mu_2$$

(o $H_1 : \mu_1 > \mu_2$ o $H_1 : \mu_1 < \mu_2$)

Equivalente:

$$H_0 : \mu_1 - \mu_2 = 0 \quad \text{vs} \quad H_1 : \mu_1 - \mu_2 \neq 0$$

Estadístico de Prueba para Dos Muestras

Supuestos: Dos muestras aleatorias **independientes**; poblaciones normales o $n_1, n_2 \geq 30$; varianzas desconocidas.

Estadístico de prueba (Welch)

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - 0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

Grados de libertad (Welch): $gl = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1-1} + \frac{(s_2^2/n_2)^2}{n_2-1}}$

No necesitas memorizarla; R la calcula automáticamente.

Ejemplo: Inglés en IES Públicas vs Privadas

Pregunta: ¿Difiere el puntaje promedio de inglés entre IES públicas y privadas en NI?

Hipótesis:

$$H_0 : \mu_{\text{púb}} = \mu_{\text{priv}} \quad \text{vs} \quad H_1 : \mu_{\text{púb}} \neq \mu_{\text{priv}}$$

```
# Dividir datos por tipo de IES
publica <- icfes_ni %>%
  filter(TIPO_IES == "Pública") %>%
  pull(MOD_INGLES_PUNT)

privada <- icfes_ni %>%
  filter(TIPO_IES == "Privada") %>%
  pull(MOD_INGLES_PUNT)

# Prueba t de dos muestras
resultado <- t.test(publica, privada, var.equal = FALSE)
# var.equal = FALSE usa Welch (recomendado)

print(resultado)
```

Método Alternativo: Fórmula con ~

```
# Metodo mas elegante usando formula
resultado <- t.test(MOD_INGLES_PUNT ~ TIPO_IES,
                    data = icfes_ni,
                    var.equal = FALSE)

print(resultado)

# Extraer elementos
cat("Diferencia de medias:", diff(resultado$estimate))
cat("\np-valor:", resultado$p.value)
cat("\nIC para la diferencia:", resultado$conf.int)

# Interpretacion
if (resultado$p.value < 0.05) {
  cat("\nHay diferencia significativa al 5%")
} else {
  cat("\nNo hay diferencia significativa al 5%")
}
```

Nota: La fórmula y ~ grupo es estándar en R para modelos.

Significancia Estadística vs Significancia Práctica

Problema: Con muestras grandes, diferencias muy pequeñas pueden ser estadísticamente significativas (p-valor pequeño) pero **irrelevantes** en la práctica.

Ejemplo:

- $n_1 = n_2 = 10,000$
- $\bar{x}_1 = 162,5$, $\bar{x}_2 = 161,8$ (diferencia de 0.7 puntos)
- p-valor $< 0,001$ (muy significativo estadísticamente)
- ¿Es relevante una diferencia de 0.7 puntos en inglés?

Lección

Significancia estadística (p-valor pequeño) $\neq$ **Significancia práctica** (efecto relevante).

Necesitamos medir el **tamaño del efecto**.

d de Cohen

Definition (d de Cohen)

Una medida estandarizada del tamaño del efecto:

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_{\text{pooled}}} \quad \text{donde } s_{\text{pooled}} = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

Interpretación (Cohen, 1988):

- $|d| \approx 0,2$: efecto **pequeño** $|d| \approx 0,5$: efecto **mediano** $|d| \approx 0,8$: efecto **grande**

Ventaja: Independiente del tamaño de muestra y de las unidades de medida.

Calcular d de Cohen en R

```
# Opcion 1: Manual
n1 <- length(publica)
n2 <- length(privada)
s1 <- sd(publica, na.rm = TRUE)
s2 <- sd(privada, na.rm = TRUE)
xbar1 <- mean(publica, na.rm = TRUE)
xbar2 <- mean(privada, na.rm = TRUE)

# Desviacion estandar pooled
s_pooled <- sqrt(((n1 - 1) * s1^2 + (n2 - 1) * s2^2) / (n1 + n2 - 2))

# d de Cohen
d <- (xbar1 - xbar2) / s_pooled
cat("d de Cohen:", round(d, 3))

# Opcion 2: Paquete effsize
library(effsize)
resultado_cohen <- cohen.d(publica, privada, na.rm = TRUE)
print(resultado_cohen)
```

Ejemplo con Interpretación

Cohen's d

```
d estimate: 0.35 (small)
95 percent confidence interval:
  lower      upper
0.1842    0.5158
```

Interpretación:

- $d = 0,35$ (efecto pequeño-mediano)
- La diferencia entre IES públicas y privadas es de 0.35 desviaciones estándar
- IC para d : (0,18,0,52) (no incluye 0, consistente con $p\text{-valor} < 0,05$)

Conclusión: Aunque hay evidencia estadística de diferencia, el efecto es relativamente pequeño en magnitud práctica.

Reporte Completo: Estadística + Efecto

Recomendación: Siempre reportar TANTO la significancia estadística como el tamaño del efecto.

Ejemplo de reporte

“Se encontró una diferencia estadísticamente significativa en el puntaje promedio de inglés entre estudiantes de IES públicas ($M = 160,3$, $DE = 17,8$) y privadas ($M = 166,5$, $DE = 18,2$), $t(238) = -2,41$, $p = 0,017$, $d = 0,35$. Aunque la diferencia es significativa, el tamaño del efecto es pequeño.”

Elementos clave:

1. Estadísticos descriptivos (M , DE)
2. Estadístico de prueba (t) y gl
3. p-valor
4. Tamaño del efecto (d)
5. Interpretación contextual

¿Qué es la Potencia Estadística?

Definition (Potencia estadística)

$$\text{Potencia} = 1 - \beta = P(\text{rechazar } H_0 \mid H_0 \text{ falsa})$$

Es la probabilidad de **detectar** un efecto cuando realmente existe.

Interpretación:

- Alta potencia (ej. 0.80 o 80 %) = buena capacidad de detectar efectos reales
- Baja potencia (ej. 0.30) = es probable que NO detectemos un efecto aunque exista

Convención: Potencia mínima aceptable: 0.80 (80 %). Ideal: 0.90 o mayor.

Piensenlo así: la potencia es la capacidad de tu encuesta para detectar una diferencia real. Si encuestas a solo 10 personas sobre lofi y estudio, probablemente no detectarás nada aunque la diferencia exista.

Factores que Afectan la Potencia


1. **Tamaño de muestra (n):** Mayor $n \Rightarrow$ mayor potencia
2. **Nivel de significancia (α):** Mayor $\alpha \Rightarrow$ mayor potencia (pero más error tipo I)
3. **Tamaño del efecto:** Efectos grandes son más fáciles de detectar
4. **Variabilidad (σ):** Menor $\sigma \Rightarrow$ mayor potencia

Relación clave:

$$\text{Potencia} = f(n, \alpha, \text{efecto}, \sigma)$$

Control: El único factor que controlamos fácilmente es n (diseño del estudio).

Curva de Potencia



La potencia aumenta cuando el verdadero μ se aleja más de μ_0 (mayor tamaño del efecto).

Calcular Potencia en R

```
library(pwr)

# Potencia para prueba t de dos muestras
# Parametros: n, d (Cohen), sig.level, type, alternative

# Ejemplo: n = 120 por grupo, d = 0.5, alpha = 0.05
potencia <- pwr.t.test(n = 120, d = 0.5, sig.level = 0.05,
                      type = "two.sample",
                      alternative = "two.sided")

print(potencia)
cat("\nPotencia:", round(potencia$power, 3))
```

Interpretación: Con $n = 120$ por grupo, tenemos 95 % de probabilidad de detectar un efecto de $d = 0,5$ si existe.

Calcular Tamaño de Muestra Requerido

```
# Pregunta: Cuantos estudiantes necesito por grupo para  
# detectar un efecto de d = 0.3 con potencia 0.80?  
  
n_requerido <- pwr.t.test(d = 0.3, sig.level = 0.05,  
                        power = 0.80,  
                        type = "two.sample",  
                        alternative = "two.sided")  
  
print(n_requerido)  
cat("\nn por grupo:", ceiling(n_requerido$n))  
  
# Explorar diferentes escenarios  
efectos <- c(0.2, 0.3, 0.5, 0.8)  
n_por_efecto <- sapply(efectos, function(d) {  
  ceiling(pwr.t.test(d = d, sig.level = 0.05, power = 0.80,  
                    type = "two.sample")$n)  
})  
  
data.frame(d_Cohen = efectos, n_por_grupo = n_por_efecto)
```

Dos Caras de la Misma Moneda

Theorem (Equivalencia IC - Prueba de hipótesis)

*Si un IC al $(1 - \alpha) \times 100 \%$ para μ **NO contiene** el valor μ_0 , entonces rechazamos $H_0 : \mu = \mu_0$ al nivel de significancia α (prueba de dos colas).*

Ejemplo:

- IC al 95 % para μ : (162,3, 168,7)
- $H_0 : \mu = 160$ vs $H_1 : \mu \neq 160$
- Como 160 NO está en el IC, rechazamos H_0 al 5 %

Ventaja de los IC:

- Proporcionan más información que solo rechazar/no rechazar"
- Muestran el rango de valores plausibles para μ
- Facilitan la interpretación práctica

Verificar la Equivalencia en R (1/2)

```
# Prueba de hipotesis
resultado_test <- t.test(ingles, mu = 160,
                        alternative = "two.sided")

cat("p-valor:", resultado_test$p.value)
cat("\nIC al 95 %:", resultado_test$conf.int)

# Verificar si 160 esta en el IC
mu_0 <- 160
ic <- resultado_test$conf.int

if (mu_0 >= ic[1] & mu_0 <= ic[2]) {
  cat("\n160 esta en el IC -> No rechazar H0")
} else {
  cat("\n160 NO esta en el IC -> Rechazar H0")
}
```

Verificar la Equivalencia en R (2/2)

```
# Comparar con decision basada en p-valor
if (resultado_test$p.value < 0.05) {
  cat("\np-valor < 0.05 -> Rechazar H0")
} else {
  cat("\np-valor >= 0.05 -> No rechazar H0")
}

# Deben coincidir!
```

Resultado: Ambos métodos (IC y p-valor) llevan a la **misma conclusión**. Si μ_0 no está en el IC al 95 %, entonces $p\text{-valor} < 0,05$.

¿Cuándo Usar IC vs Prueba de Hipótesis?

Intervalos de Confianza:

- Enfoque en **estimación**
- ¿Cuál es el valor probable del parámetro?
- Proporcionan rango de valores
- Más informativos
- Útiles para reportar hallazgos

Pruebas de Hipótesis:

- Enfoque en **decisión**
- ¿Hay evidencia contra H_0 ?
- Proporcionan p-valor
- Más formales
- Útiles para comparaciones

Recomendación

En la práctica, **reportar ambos**: IC + prueba de hipótesis. Esto da una visión completa de los resultados.

Resumen de la Sesión

Hoy aprendimos:

1. **Hipótesis:** H_0 (nula) vs H_1 (alternativa)
2. **Errores:**
 - Tipo I (α): rechazar H_0 verdadera
 - Tipo II (β): no rechazar H_0 falsa
3. **p-valor:** Probabilidad de datos tan extremos dado H_0 verdadera
4. **Prueba z:** Para μ con σ conocida
5. **Prueba t:** Para μ con σ desconocida (una muestra y dos muestras)
6. **d de Cohen:** Medir tamaño del efecto
7. **Potencia:** Probabilidad de detectar un efecto real
8. **IC y pruebas:** Dos enfoques complementarios

Próxima sesión: Prueba t pareada, ANOVA, y pruebas no paramétricas.

Tabla Resumen: ¿Qué Prueba Usar?

Situación	Condición	Prueba
1 muestra, σ conocida	n grande o población normal	Prueba z
1 muestra, σ desconocida	Población normal o $n \geq 30$	Prueba t (una muestra)
2 muestras independientes	Poblaciones normales o $n_1, n_2 \geq 30$	Prueba t (dos muestras, Welch)
2 muestras pareadas	Diferencias normales o $n \geq 30$	Prueba t pareada (próxima sesión)
> 2 grupos	Normalidad, homocedasticidad	ANOVA (próxima sesión)

Ejercicios para la Próxima Clase

Con los datos de ICFES:

1. Probar $H_0 : \mu_{\text{inglés}} = 155$ vs $H_1 : \mu \neq 155$ para NI (dos colas)
2. Comparar el puntaje de MOD_RAZONA_CUANTITAT entre IES públicas y privadas (incluir d de Cohen)
3. Calcular la potencia de tu prueba del ejercicio 2 (usar `pwr`)
4. Determinar cuántos estudiantes necesitarías para detectar un efecto de $d = 0,4$ con potencia 0.85
5. **Desafío:** Comparar inglés entre género usando tanto IC como prueba de hipótesis, y verificar la equivalencia

Lectura: Anderson et al., Capítulo 9 (Pruebas de Hipótesis)

¡Gracias por su atención!

Preguntas y discusión