

Sesión 7: Pruebas para Dos Poblaciones, ANOVA y No Paramétricas

Comparando grupos: de la prueba t a Kruskal-Wallis

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Viernes 2 de octubre de 2026

Agenda

Prueba t Pareada (Muestras Dependientes)

ANOVA de Una Vía

Comparaciones Múltiples: Tukey HSD

Curva de Potencia para ANOVA

Pruebas No Paramétricas

Resumen de la Unidad 3 (hasta ahora)

Conclusiones

Muestras Independientes vs Dependientes

Hasta ahora: Prueba t para dos muestras **independientes**

- Grupos completamente distintos (ej. públicas vs privadas)
- Sin relación entre observaciones de un grupo y otro

Ahora: Muestras **dependientes (pareadas)**

- Mismos sujetos medidos dos veces (antes/después)
- Sujetos emparejados naturalmente (hermanos, pares matched)
- Cada observación en el grupo 1 tiene una contraparte específica en el grupo 2

Ejemplos:

- Puntaje Saber 11 vs Saber Pro del **mismo** estudiante
- Rendimiento antes vs después de una intervención
- Calificación de dos evaluadores sobre el **mismo** trabajo

Muestras Dependientes: ejemplo cotidiano

Screen time antes y después

Medir tu **screen time** ANTES y DESPUÉS de instalar una app de bienestar digital (ej. Forest, One Sec). Cada persona es su propio control: se comparan sus dos mediciones.

Características clave:

- La misma persona se mide dos veces $\Rightarrow$ datos pareados
- Cada par (x_{antes}, x_{despus}) está vinculado
- Se analizan las **diferencias** $d_i = x_{despus} - x_{antes}$

¿Cuándo Usar Prueba t Pareada?

Criterios:

1. Dos mediciones del mismo sujeto/unidad
2. O pares naturales (matched pairs)
3. Las diferencias individuales importan

Ventaja:

- Controla la variabilidad entre sujetos
- Mayor potencia que la prueba de dos muestras independientes
- Reduce el error tipo II

Ejemplo ICFES:

- Comparar inglés Saber 11 vs Saber Pro del mismo estudiante
- Problema: los datos ICFES actuales NO tienen esta vinculación (cada fila = un estudiante en un momento)
- Solución: usar datos simulados o buscar tabla de cruce

Hipótesis y Estadístico de Prueba

Enfoque: Trabajar con las **diferencias** $d_i = x_{1i} - x_{2i}$

Hipótesis:

$$H_0 : \mu_d = 0 \quad \text{vs} \quad H_1 : \mu_d \neq 0$$

donde μ_d = media poblacional de las diferencias.

Estadístico de prueba

$$t = \frac{\bar{d}}{s_d / \sqrt{n}}$$

donde $\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i$ (media de las diferencias), s_d = DE de las diferencias, n = número de pares, y $t \sim t(n-1)$ si H_0 es verdadera.

Ejemplo: Saber 11 vs Saber Pro (Simulado) - Parte 1

```
# Simular datos pareados (en la practica, vienen de una tabla de cruce)
set.seed(123)
n <- 80
saber11 <- rnorm(n, mean = 155, sd = 18)
saber_pro <- saber11 + rnorm(n, mean = 8, sd = 5)
# Saber Pro suele ser ligeramente mayor

# Calcular diferencias
diferencias <- saber_pro - saber11

# Descriptivos
cat("Media Saber 11:", round(mean(saber11), 2))
cat("\nMedia Saber Pro:", round(mean(saber_pro), 2))
cat("\nMedia de diferencias:", round(mean(diferencias), 2))
cat("\nDE de diferencias:", round(sd(diferencias), 2))
```

Ejemplo: Saber 11 vs Saber Pro (Simulado) - Parte 2

```
# Visualizar diferencias  
hist(diferencias, breaks = 15, col = "steelblue",  
     main = "Distribucion de las Diferencias",  
     xlab = "Saber Pro - Saber 11")  
abline(v = 0, col = "red", lwd = 2, lty = 2)
```


Realizar la Prueba t Pareada

```
# Metodo 1: t.test con paired = TRUE
resultado <- t.test(saber_pro, saber11, paired = TRUE)

print(resultado)

cat("\nEstadistico t:", resultado$statistic)
cat("\np-valor:", resultado$p.value)
cat("\nIC para mu_d:", resultado$conf.int)

# Metodo 2: t.test sobre las diferencias directamente
resultado2 <- t.test(diferencias, mu = 0)
# Es equivalente al metodo 1

# Decision
if (resultado$p.value < 0.05) {
  cat("\nConcluimos que hay diferencia significativa")
  cat("\nSaber Pro difiere de Saber 11")
} else {
  cat("\nNo hay evidencia de diferencia")
}
```

Visualización de Datos Pareados

```
library(ggplot2)

# Crear data frame
datos_pareados <- data.frame(
  id = rep(1:n, 2),
  examen = rep(c("Saber 11", "Saber Pro"), each = n),
  puntaje = c(saber11, saber_pro)
)

# Grafico de lineas conectando pares
ggplot(datos_pareados, aes(x = examen, y = puntaje, group = id)) +
  geom_line(alpha = 0.3, color = "gray50") +
  geom_point(alpha = 0.5) +
  stat_summary(aes(group = 1), fun = mean, geom = "line",
    color = "red", size = 1.5) +
  stat_summary(fun = mean, geom = "point",
    color = "red", size = 4) +
  labs(title = "Comparacion Pareada: Saber 11 vs Saber Pro",
    y = "Puntaje de Ingles") +
  theme_minimal()
```

Motivación: Comparar Más de Dos Grupos

Problema: Queremos comparar inglés entre 5 regiones de Colombia.

Opción incorrecta: Hacer múltiples pruebas t

- Comparar Caribe vs Andina, Caribe vs Pacífico, ..., etc.
- Con $k = 5$ grupos, tendríamos $\binom{5}{2} = 10$ comparaciones
- Problema: **inflación del error tipo I**

Inflación del error tipo I

Si hacemos m pruebas independientes al nivel α :

$$P(\text{al menos un error tipo I}) = 1 - (1 - \alpha)^m$$

Ejemplo: 10 pruebas con $\alpha = 0,05$: $P(\text{al menos un error}) = 1 - 0,95^{10} = 0,40$ (40 %!)

Motivación: Comparar Más de Dos Grupos (cont.)

Solución: ANOVA (Analysis of Variance)

- Compara las medias de **tres o más** grupos simultáneamente
- Controla el error tipo I global

Ejemplo cotidiano

¿Hay diferencia en el promedio de notas entre estudiantes que usan TikTok <1 h, $1-3$ h y >3 h al día? Tres grupos, una variable numérica $\Rightarrow$ ANOVA.

¿Qué es ANOVA?

Definition (ANOVA de una vía)

Una prueba que compara las medias de **tres o más** grupos simultáneamente, controlando el error tipo I global.

Hipótesis:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k \quad \text{vs} \quad H_1 : \text{al menos un par difiere}$$

Importante: H_1 NO dice *cuáles* grupos difieren, solo que **al menos uno** es distinto.

Nombre: “Analysis of Variance” porque comparamos variabilidad **entre** grupos vs variabilidad **dentro** de grupos.

Lógica de ANOVA

Idea central:

- Si H_0 es verdadera (todas las medias son iguales), la variabilidad entre grupos debería ser similar a la variabilidad dentro de grupos (solo ruido aleatorio)
- Si H_0 es falsa (medias diferentes), la variabilidad entre grupos será **mayor** que la variabilidad dentro de grupos

Razón F

$$F = \frac{\text{Variabilidad entre grupos}}{\text{Variabilidad dentro de grupos}} = \frac{\text{MSB}}{\text{MSW}}$$

- Si F es grande $\Rightarrow$ evidencia contra H_0
- Si H_0 es verdadera, $F \sim F(k - 1, N - k)$ (distribución F)

Partición de la Variabilidad Total

Suma de cuadrados total (SST):

$$SST = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x})^2$$

Mide la variabilidad total de todos los datos.

Descomposición:

$$SST = SSB + SSW$$

- **SSB (between):** $\sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2$ = variabilidad entre grupos
- **SSW (within):** $\sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2$ = variabilidad dentro de grupos

Cuadrados medios:

$$MSB = \frac{SSB}{k - 1}, \quad MSW = \frac{SSW}{N - k}$$

Tabla ANOVA

Fuente	SS	df	MS	F
Entre grupos	SSB	$k - 1$	$\frac{SSB}{k-1}$	$\frac{MSB}{MSW}$
Dentro grupos	SSW	$N - k$	$\frac{SSW}{N-k}$	
Total	SST	$N - 1$		

Notación:

- k = número de grupos
- $N = \sum_{i=1}^k n_i$ = tamaño total de la muestra
- n_i = tamaño del grupo i

p-valor: $P(F_{k-1, N-k} > F_{\text{obs}})$

Ejemplo: Inglés por Macro-Región - Parte 1

```
# Crear variable de macro-region (simplificacion)
icfes_ni$MACRO_REGION <- ifelse(
  icfes_ni$ESTU_DEPTO_RESIDE %in%
    c("Atlantico", "Bolívar", "Cesar", "Córdoba", "La Guajira",
      "Magdalena", "Sucre", "San Andres"),
  "Caribe",
  ifelse(
    icfes_ni$ESTU_DEPTO_RESIDE %in%
      c("Antioquia", "Bogotá", "Boyacá", "Caldas", "Cundinamarca",
        "Huila", "Norte Santander", "Quindío", "Risaralda",
        "Santander", "Tolima"),
    "Andina",
```

Ejemplo: Inglés por Macro-Región - Parte 2

```
# Continuacion: macro-region
  ifelse(
    icfes_ni$ESTU_DEPTO_RESIDE %in%
      c("Choco", "Cauca", "Narino", "Valle"),
    "Pacifica",
    ifelse(
      icfes_ni$ESTU_DEPTO_RESIDE %in%
        c("Amazonas", "Caqueta", "Guainia", "Guaviare",
          "Meta", "Putumayo", "Vaupes", "Vichada"),
        "Orinoquia-Amazonia", "Otras"
    )
  )
)
```

Realizar ANOVA en R

```
# Estadísticas descriptivas por region
library(dplyr)
desc_regiones <- icfes_ni %>%
  group_by(MACRO_REGION) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT, na.rm = TRUE),
    sd = sd(MOD_INGLES_PUNT, na.rm = TRUE)
  )
print(desc_regiones)

# ANOVA
modelo_anova <- aov(MOD_INGLES_PUNT ~ MACRO_REGION, data = icfes_ni)

# Ver tabla ANOVA
summary(modelo_anova)
```

Interpretar Output de ANOVA

```
      Df Sum Sq Mean Sq F value Pr(>F)
MACRO_REGION      4  12458   3114.5    9.876 1.24e-07 ***
Residuals     495 156123    315.4
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Interpretación:

- $F = 9,876$ con $gl = (4, 495)$
- $p\text{-valor} < 0,001 \Rightarrow$ Rechazamos H_0
- Conclusión: Hay evidencia de que al menos una macro-región tiene media diferente de las demás
- **Pregunta pendiente:** ¿Cuáles regiones difieren? (Tukey HSD)

Supuestos de ANOVA

Para que ANOVA sea válida, se requiere:

1. **Normalidad:** Los residuos deben seguir una distribución normal
 - Verificar con QQ-plot o Shapiro-Wilk
 - Robusta si n es grande (TLC)
2. **Homocedasticidad:** Las varianzas de los grupos deben ser iguales
 - Verificar con prueba de Levene o gráfico de residuos
 - Regla empírica: $\max(s_i) / \min(s_i) < 2$
3. **Independencia:** Las observaciones deben ser independientes
 - Garantizada por diseño de muestreo

Si los supuestos no se cumplen: Considerar transformación de datos o prueba no paramétrica (Kruskal-Wallis).

Verificar Supuestos - Parte 1

```
# 1. Grafico QQ de residuos
qqnorm(residuals(modelo_anova))
qqline(residuals(modelo_anova), col = "red")

# 2. Prueba de Shapiro-Wilk (si n no es muy grande)
shapiro.test(residuals(modelo_anova)[1:5000])
# Nota: Shapiro-Wilk tiene limite de n

# 3. Prueba de Levene para homocedasticidad
library(car)
leveneTest(MOD_INGLES_PUNT ~ MACRO_REGION, data = icfes_ni)

# 4. Grafico de residuos vs valores ajustados
plot(modelo_anova, which = 1)
# Debe verse sin patron sistematico
```

Verificar Supuestos - Parte 2

```
# 5. Boxplot por grupo (visualizar homogeneidad)  
boxplot(MOD_INGLES_PUNT ~ MACRO_REGION, data = icfes_ni,  
        col = "lightblue", ylab = "Puntaje Ingles",  
        main = "Distribucion por Macro-Region")
```

El Problema de las Comparaciones Múltiples

Situación: ANOVA nos dice que HAY diferencias, pero no DÓNDE.

¿Podemos hacer pruebas t entre todos los pares?

- Con $k = 5$ grupos: $\binom{5}{2} = 10$ comparaciones
- Inflación del error tipo I (como vimos antes)

Solución: Métodos de comparaciones múltiples que controlan la **tasa de error familiar** (FWER: Family-Wise Error Rate).

Métodos comunes:

- **Tukey HSD** (Honestly Significant Difference): compara todos los pares
- **Bonferroni**: ajusta α dividiéndolo por el número de comparaciones
- **Scheffé**: más conservador, útil para comparaciones complejas
- **Dunnett**: compara todos vs un control

Recomendación: Tukey HSD es el más usado para comparaciones post-hoc.

Tukey HSD: Honestly Significant Difference

Idea: Ajustar el valor crítico para tener en cuenta las múltiples comparaciones.

Intervalo de confianza simultáneo al $(1 - \alpha)$

Para cada par (i, j) :

$$(\bar{x}_i - \bar{x}_j) \pm q_{\alpha, k, N-k} \cdot \sqrt{\frac{MSW}{2} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}$$

donde $q_{\alpha, k, N-k}$ es el valor crítico de la distribución **studentized range**.

Interpretación:

- Si el IC NO incluye 0, los grupos i y j difieren significativamente
- Controla FWER al nivel α para **todas** las comparaciones simultáneamente

Realizar Tukey HSD en R

```
# Prueba de Tukey HSD
tukey_resultado <- TukeyHSD(modelo_anova, conf.level = 0.95)

print(tukey_resultado)

# Visualizar resultados
plot(tukey_resultado, las = 1, cex.axis = 0.7)
abline(v = 0, col = "red", lty = 2)
```

Output: Tabla con todas las comparaciones pareadas

- **diff:** Diferencia de medias entre los grupos
- **lwr, upr:** Límites del IC ajustado
- **p adj:** p-valor ajustado

Interpretar Resultados de Tukey

```
Tukey multiple comparisons of means  
95% family-wise confidence level
```

```
Fit: aov(formula = MOD_INGLES_PUNT ~ MACRO_REGION, data = icfes_ni)
```

```
$MACRO_REGION
```

	diff	lwr	upr	p adj
Caribe-Andina	-8.35421	-14.2893	-2.41915	0.001823
Orinoquia-Andina	-5.12334	-18.6574	8.41069	0.852164
Pacifica-Andina	-6.78912	-13.5628	-0.01545	0.049231
Pacifica-Caribe	1.56509	-5.9721	9.10230	0.980561
Orinoquia-Caribe	3.23087	-10.5362	17.00796	0.960027
Pacifica-Orinoquia	-1.66578	-15.9483	12.61671	0.995643

Interpretación:

- Caribe vs Andina: $p\text{-adj} = 0,0018 < 0,05 \Rightarrow$ Diferencia significativa (Caribe 8.4 puntos menor)
- Pacífica vs Andina: $p\text{-adj} = 0,049 < 0,05 \Rightarrow$ Diferencia significativa (Pacífica 6.8 puntos menor)
- Otras comparaciones: No significativas

Visualización de Resultados Tukey

```
library(ggplot2)
library(broom)

# Extraer resultados de Tukey en formato tidy
tukey_df <- tidy(tukey_resultado)

# Grafico de forest plot
ggplot(tukey_df, aes(x = estimate, y = comparison)) +
  geom_point(size = 3) +
  geom_errorbarh(aes(xmin = conf.low, xmax = conf.high),
    height = 0.2) +
  geom_vline(xintercept = 0, linetype = "dashed",
    color = "red", size = 1) +
  labs(x = "Diferencia de medias (IC 95 % ajustado)",
    y = "Comparacion",
    title = "Tukey HSD: Comparaciones Multiples",
    subtitle = "Diferencias significativas si IC no incluye 0") +
  theme_minimal()
```

Tamaño del Efecto en ANOVA: f de Cohen

Definition (f de Cohen)

$$f = \sqrt{\frac{\sum_{i=1}^k \pi_i (\mu_i - \mu)^2}{\sigma^2}}$$

donde $\pi_i = n_i/N$ (proporción del grupo i), $\mu = \sum \pi_i \mu_i$ (media global).

Interpretación (Cohen, 1988):

- $f \approx 0,10$: efecto **pequeño**
- $f \approx 0,25$: efecto **mediano**
- $f \approx 0,40$: efecto **grande**

Nota: f mide cuánto varían las medias de los grupos en relación a la variabilidad dentro de los grupos.

Calcular Potencia para ANOVA

```
library(pwr)

# Potencia para ANOVA de una via
# k = numero de grupos, n = tamano por grupo, f = f de Cohen

# Ejemplo: 5 grupos, n = 100 por grupo, f = 0.25, alpha = 0.05
potencia_anova <- pwr.anova.test(k = 5, n = 100, f = 0.25,
                                sig.level = 0.05)

print(potencia_anova)
cat("\nPotencia:", round(potencia_anova$power, 3))

# Calcular n requerido para potencia 0.80
n_requerido <- pwr.anova.test(k = 5, f = 0.25, sig.level = 0.05,
                              power = 0.80)

cat("\nn requerido por grupo:", ceiling(n_requerido$n))
```

Explorar Diferentes Escenarios

```
# Tabla de n requerido para diferentes efectos
efectos <- c(0.10, 0.25, 0.40)
k_grupos <- c(3, 5, 10)

resultados <- expand.grid(f = efectos, k = k_grupos)
resultados$n_por_grupo <- sapply(1:nrow(resultados), function(i) {
  ceiling(pwr.anova.test(k = resultados$k[i],
                        f = resultados$f[i],
                        sig.level = 0.05,
                        power = 0.80)$n)
})

# Tabla pivotada
library(tidyr)
tabla_n <- resultados %>%
  pivot_wider(names_from = k, values_from = n_por_grupo,
             names_prefix = "k=")

print(tabla_n)
```

Observación: Efectos pequeños requieren muestras MUCHO más grandes.

¿Cuándo Usar Pruebas No Paramétricas?

Situaciones:

1. **Datos ordinales** (ej. escala Likert: 1=malo, 2=regular, ..., 5=excelente)
2. **Distribuciones muy sesgadas** o con outliers extremos
3. **Muestras pequeñas** donde no se puede verificar normalidad
4. **Violación de supuestos** de las pruebas paramétricas

Ventajas:

- Menos supuestos (no requieren normalidad)
- Robustas a outliers
- Válidas para datos ordinales

Desventajas:

- **Menos potentes** que las paramétricas si los supuestos se cumplen
- Interpretación menos directa (trabajan con rangos, no con medias)

Pruebas No Paramétricas: ejemplo cotidiano

Ratings de apps

Datos de rating en apps (1–5 estrellas) no siguen una distribución normal: son ordinales y discretos. Aquí conviene usar Mann-Whitney o Kruskal-Wallis en lugar de t o ANOVA.

Regla práctica:

- Si la variable es ordinal (escalas, rankings) $\Rightarrow$ no paramétrica
- Si hay outliers extremos o asimetría fuerte $\Rightarrow$ considerar no paramétrica
- Si n es grande y la distribución es razonable $\Rightarrow$ paramétrica (TLC)

Pruebas No Paramétricas Comunes

Situación	Paramétrica	No paramétrica
1 muestra	Prueba t	Wilcoxon signed-rank
2 muestras independientes	Prueba t	Mann-Whitney-Wilcoxon
2 muestras pareadas	Prueba t pareada	Wilcoxon signed-rank
k muestras independientes	ANOVA	Kruskal-Wallis
k muestras pareadas	ANOVA repetidas	Friedman

Principio: Las pruebas no paramétricas trabajan con **rangos** en lugar de valores originales.

Mann-Whitney-Wilcoxon (U de Mann-Whitney)

Uso: Alternativa a la prueba t de dos muestras independientes.

Hipótesis:

H_0 : Las dos distribuciones son idénticas

H_1 : Las distribuciones difieren en localización

Método:

1. Combinar todas las observaciones y asignar rangos
2. Calcular la suma de rangos para cada grupo
3. Comparar con la distribución nula

Interpretación: Si rechazamos H_0 , concluimos que un grupo tiende a tener valores **mayores** (o menores) que el otro, pero NO necesariamente medias diferentes.

Ejemplo: Mann-Whitney en R – Parte 1

```
# Comparar ingles entre genero (si la distribucion no es normal)

# Dividir por genero
hombres <- icfes_ni %>%
  filter(ESTU_GENERO == "M") %>%
  pull(MOD_INGLES_PUNT)

mujeres <- icfes_ni %>%
  filter(ESTU_GENERO == "F") %>%
  pull(MOD_INGLES_PUNT)

# Prueba de Mann-Whitney
resultado_mw <- wilcox.test(hombres, mujeres,
                           alternative = "two.sided")
```

Ejemplo: Mann-Whitney en R – Parte 2

```
print(resultado_mw)

cat("\nEstadístico W:", resultado_mw$statistic)
cat("\np-valor:", resultado_mw$p.value)

# Decision
if (resultado_mw$p.value < 0.05) {
  cat("\nHay diferencia significativa entre generos")
} else {
  cat("\nNo hay diferencia significativa")
}
```

Comparar Paramétrica vs No Paramétrica

```
# Prueba t
resultado_t <- t.test(hombres, mujeres)
cat("Prueba t:")
cat("\n t =", resultado_t$statistic)
cat("\n p-valor =", resultado_t$p.value)

# Mann-Whitney
resultado_mw <- wilcox.test(hombres, mujeres)
cat("\n\nMann-Whitney:")
cat("\n W =", resultado_mw$statistic)
cat("\n p-valor =", resultado_mw$p.value)

# Comparar conclusiones
cat("\n\nAmbas pruebas coinciden?",
    (resultado_t$p.value < 0.05) == (resultado_mw$p.value < 0.05))
```

Nota: Si los datos son aproximadamente normales, ambas pruebas deberían dar resultados similares. Si difieren mucho, investigar outliers o asimetría.

Kruskal-Wallis: Alternativa No Paramétrica a ANOVA

Uso: Comparar $k \geq 3$ grupos cuando los supuestos de ANOVA no se cumplen.

Hipótesis:

H_0 : Las k distribuciones son idénticas

H_1 : Al menos una distribución difiere en localización

Método:

1. Asignar rangos a todas las observaciones (ignorando grupos)
2. Calcular la suma de rangos para cada grupo
3. Estadístico H (similar a χ^2):

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1)$$

donde R_i = suma de rangos del grupo i .

Si H_0 es verdadera, $H \sim \chi^2(k-1)$ aproximadamente.

Ejemplo: Kruskal-Wallis en R

```
# Comparar ingles entre macro-regiones (alternativa no parametrica)

resultado_kw <- kruskal.test(MOD_INGLES_PUNT ~ MACRO_REGION,
                             data = icfes_ni)

print(resultado_kw)

cat("\nEstadistico H (chi-cuadrado):", resultado_kw$statistic)
cat("\n\ngl:", resultado_kw$parameter)
cat("\nnp-valor:", resultado_kw$p.value)

# Decision
if (resultado_kw$p.value < 0.05) {
  cat("\nHay diferencia significativa entre regiones")
  cat("\n(al menos una difiere)")
} else {
  cat("\nNo hay diferencia significativa")
}
```


Comparaciones Post-hoc para Kruskal-Wallis

```
# Kruskal-Wallis no incluye comparaciones multiples automaticas
# Opcion 1: Usar Dunn test (paquete dunn.test)
library(dunn.test)

dunn_resultado <- dunn.test(icfes_ni$MOD_INGLES_PUNT,
                           icfes_ni$MACRO_REGION,
                           method = "bonferroni")
# method: "bonferroni", "holm", "hochberg", "bh", etc.

# Opcion 2: Pairwise Wilcoxon con ajuste
pairwise_resultado <- pairwise.wilcox.test(
  icfes_ni$MOD_INGLES_PUNT,
  icfes_ni$MACRO_REGION,
  p.adjust.method = "bonferroni"
)

print(pairwise_resultado)
```

Nota: El ajuste de Bonferroni es conservador pero simple. Otras opciones: Holm, Hochberg, Benjamini-Hochberg (FDR).

¿Cuándo Usar Paramétrica vs No Paramétrica?

Guía de decisión:

1. Verificar supuestos:

- QQ-plot, Shapiro-Wilk para normalidad
- Levene para homocedasticidad
- Tamaño de muestra

2. Si los supuestos se cumplen: Usar prueba paramétrica

- Mayor potencia
- Interpretación más directa (medias)

3. Si los supuestos NO se cumplen:

- Intentar transformación (log, raíz cuadrada)
- Si persiste, usar prueba no paramétrica

4. Si los datos son ordinales: Siempre usar no paramétrica


Consejo: Con muestras grandes ($n \geq 30$ por grupo), la prueba t y ANOVA son **robustas** a desviaciones moderadas de la normalidad (TLC).

Tabla Resumen: ¿Qué Prueba Usar?

Situación	Datos	Paramétrica	No paramétrica
1 muestra	Cuantitativos	Prueba t (1 muestra)	Wilcoxon signed-rank
2 muestras independientes	Cuantitativos	Prueba t (2 muestras)	Mann-Whitney-Wilcoxon
2 muestras pareadas	Cuantitativos	Prueba t pareada	Wilcoxon signed-rank
k muestras independientes	Cuantitativos	ANOVA + Tukey HSD	Kruskal-Wallis + Dunn
2 proporciones	Catégoricos	Prueba z para 2 prop.	(Próxima sesión: χ^2)
k proporciones	Catégoricos	(Próxima sesión: χ^2)	(Próxima sesión: χ^2)

Próxima sesión (después del parcial): Pruebas χ^2 para independencia y bondad de ajuste.

Flujo de Decisión



Si los supuestos no se cumplen, cambiar a la prueba no paramétrica correspondiente.

Resumen de la Sesión

Hoy aprendimos:

1. **Prueba t pareada:** Para muestras dependientes
 - Trabajar con las diferencias: $t = \frac{\bar{d}}{s_d/\sqrt{n}}$
2. **ANOVA de una vía:** Comparar ≥ 3 grupos
 - $F = \text{MSB}/\text{MSW}$
 - Supuestos: normalidad, homocedasticidad, independencia
3. **Tukey HSD:** Comparaciones múltiples post-hoc
 - Controla FWER al nivel α
4. **Potencia en ANOVA:** f de Cohen, tamaño de muestra
5. **Pruebas no paramétricas:**
 - Mann-Whitney (alternativa a t de 2 muestras)
 - Kruskal-Wallis (alternativa a ANOVA)

Próxima sesión: ¡Parcial! (cubre Sesiones 1-7)

Preparación para el Parcial

Temas a repasar:

1. **Sesiones 1-3:** Estadística descriptiva, visualización, muestreo, correlación
2. **Sesiones 4-5:** Estimación puntual, IC (medias, varianzas, proporciones), tamaño de muestra
3. **Sesión 6:** Pruebas de hipótesis, p-valor, errores tipo I/II, potencia, d de Cohen
4. **Sesión 7 (hoy):** Prueba t pareada, ANOVA, Tukey, no paramétricas

Habilidades clave:

- Interpretar output de R (`t.test()`, `aov()`, `summary()`)
- Verificar supuestos (normalidad, homocedasticidad)
- Elegir la prueba adecuada según la situación
- Reportar resultados completos (estadístico, gl, p-valor, IC, tamaño del efecto)

Recurso: Repasar ejercicios de las sesiones anteriores con datos ICFES.

Ejercicios para Practicar

Con los datos de ICFES:

1. Comparar MOD_RAZONA_CUANTITAT antes/después de una intervención (simular datos pareados)
2. Realizar ANOVA comparando inglés entre 5 departamentos (elegir 5 con n grande)
3. Aplicar Tukey HSD y reportar qué departamentos difieren
4. Verificar supuestos de ANOVA (QQ-plot, Levene)
5. Comparar inglés entre 3 niveles socioeconómicos usando Kruskal-Wallis
6. Calcular potencia de ANOVA con $k = 5$, $n = 100$, $f = 0,30$
7. **Desafío:** Crear un reporte completo de análisis comparativo (descriptivos + visualización + prueba + interpretación)

Lectura: Anderson et al., Capítulos 10-11 (Comparación de Medias, ANOVA)

¡Gracias por su atención!

Preguntas y discusión

¡Mucho éxito en el parcial!