

Sesión 8: Chi-Cuadrado: Independencia y Bondad de Ajuste

Probando asociación entre variables categóricas

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Vie 16 oct 2026

Agenda

Tablas de contingencia

Prueba χ^2 de independencia

V de Cramér

Prueba χ^2 de bondad de ajuste

Comparación de múltiples proporciones

Resumen U3 completa

¿Qué es una tabla de contingencia?

Definición

Una **tabla de contingencia** (o tabla cruzada) resume la distribución conjunta de dos variables categóricas, mostrando las frecuencias observadas de cada combinación de categorías.

Estructura básica:

- Filas: categorías de la variable 1
- Columnas: categorías de la variable 2
- Celdas: número de observaciones en cada combinación
- Márgenes: totales por fila y columna

Ejemplo en nuestro contexto

¿Cómo se relaciona el nivel de inglés MCER (A-, A1, A2, B1, B+) con el tipo de IES (pública/privada) entre estudiantes de Negocios Internacionales?

Construyendo una tabla de contingencia en R

```
# Cargar datos ICFES para Negocios Internacionales
icfes_ni <- read.csv("datos/icfes_ni_2025.csv")

# Crear tabla de contingencia: nivel MCER x tipo IES
tabla_obs <- table(icfes_ni$NIVEL_MCER, icfes_ni$TIPO_IES)
tabla_obs
```

```
#           privada publica
# A-         245      312
# A1         580      698
# A2         892      756
# B1         623      384
# B+         410      185
```

Interpretación

Hay 892 estudiantes de IES privadas con nivel A2 en inglés.

Frecuencias marginales

Frecuencias marginales (totales por fila/columna):

```
# Totales por fila (nivel MCER)
```

```
margin.table(tabla_obs, 1)
```

```
#   A-   A1   A2   B1   B+
```

```
#  557 1278 1648 1007 595
```

```
# Totales por columna (tipo IES)
```

```
margin.table(tabla_obs, 2)
```

```
# privada publica
```

```
#    2750    2335
```

Frecuencias relativas

```
# Proporciones del total  
prop.table(tabla_obs)  
  
# Proporciones por fila (% dentro de cada nivel MCER)  
prop.table(tabla_obs, 1)  
  
# Proporciones por columna (% dentro de cada tipo IES)  
prop.table(tabla_obs, 2)
```

Cada tipo de proporción responde una pregunta diferente:

- Total: ¿qué porcentaje del total cae en esta celda?
- Por fila: ¿cómo se distribuye cada nivel MCER entre tipos de IES?
- Por columna: ¿cómo se distribuye cada tipo de IES entre niveles MCER?

Visualización: mosaico

```
# Grafico de mosaico
mosaicplot(tabla_obs,
  main = "Nivel MCER x Tipo IES",
  xlab = "Nivel MCER",
  ylab = "Tipo IES",
  color = c("steelblue", "coral"))

# Alternativa: barplot apilado
barplot(tabla_obs,
  legend = TRUE,
  col = c("#1f77b4", "#ff7f0e", "#2ca02c", "#d62728", "#9467bd"),
  main = "Distribucion por tipo de IES",
  xlab = "Tipo IES",
  ylab = "Frecuencia")
```

Observación visual

Parece haber una diferencia: las IES privadas tienen mayor proporción de estudiantes en niveles B1 y B+. ¿Es estadísticamente significativa?

Hipótesis de independencia

Pregunta de investigación

¿El nivel de inglés MCER es **independiente** del tipo de IES?

Hipótesis:

- H_0 : El nivel MCER y el tipo de IES son **independientes** (no hay asociación entre las dos variables)
- H_1 : Existe **asociación** entre el nivel MCER y el tipo de IES (las variables están relacionadas)

Nivel de significancia

Usaremos $\alpha = 0,05$ (estándar en ciencias sociales).

Frecuencias esperadas bajo independencia

Si las dos variables fueran **independientes**, ¿cuántas observaciones esperaríamos en cada celda?

Fórmula

La frecuencia esperada en la celda (i, j) es:

$$E_{ij} = \frac{R_i \times C_j}{n}$$

donde R_i = total fila i , C_j = total columna j , n = total general.

Frecuencias esperadas: ejemplo

Ejemplo: celda (A2, privada)

$$E_{A2,privada} = \frac{1648 \times 2750}{5085} = \frac{4,532,000}{5085} \approx 891,24$$

Observamos 892, esperábamos 891.24 (muy cercano).

Lógica

- $R_i = 1648$ (total de estudiantes con nivel A2)
- $C_j = 2750$ (total de estudiantes en IES privadas)
- $n = 5085$ (total general)

Si las variables fueran independientes, la proporción de A2 sería la misma en ambos tipos de IES.

El estadístico χ^2

Medimos la **discrepancia total** entre frecuencias observadas y esperadas:

Estadístico de prueba

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

donde:

- O_{ij} = frecuencia observada en celda (i, j)
- E_{ij} = frecuencia esperada en celda (i, j)
- r = número de filas
- c = número de columnas

Interpretación:

- χ^2 cercano a 0 $\Rightarrow$ observado $\approx$ esperado $\Rightarrow$ independencia plausible
- χ^2 grande $\Rightarrow$ gran discrepancia $\Rightarrow$ evidencia contra independencia

Distribución χ^2 y grados de libertad

Bajo H_0 (independencia), el estadístico χ^2 sigue aproximadamente una distribución chi-cuadrado con:

$$gl = (r - 1)(c - 1)$$

En nuestro ejemplo:

- $r = 5$ niveles MCER (A-, A1, A2, B1, B+)
- $c = 2$ tipos IES (privada, pública)
- $gl = (5 - 1)(2 - 1) = 4 \times 1 = 4$

Regla de decisión

Rechazamos H_0 si:

$$\chi_{\text{calc}}^2 > \chi_{\alpha, gl}^2$$

o equivalentemente, si el p-valor $< \alpha$.

Condición de validez

Requisito importante

La aproximación χ^2 es válida si:

$$E_{ij} \geq 5 \quad \text{en al menos el 80 \% de las celdas}$$

Si esta condición NO se cumple:

- Combinar categorías con frecuencias bajas
- Usar la prueba exacta de Fisher (solo para tablas 2×2)
- Aumentar el tamaño muestral

En nuestro ejemplo:

Todas las celdas tienen $E_{ij} > 100$, así que la condición se cumple ampliamente.

Aplicación en R: `chisq.test()`

```
# Realizar la prueba chi-cuadrado
resultado <- chisq.test(tabla_obs)
resultado

# Pearson's Chi-squared test
#
# data: tabla_obs
# X-squared = 186.42, df = 4, p-value < 2.2e-16

# Ver las frecuencias esperadas
resultado$expected
```

#		<i>privada</i>	<i>publica</i>
#	A-	301.20	255.80
#	A1	691.06	586.94
#	A2	891.24	756.76
#	B1	544.40	462.60
#	B+	321.60	272.90

Interpretación del resultado

Output de R

- $\chi^2 = 186,42$, $gl = 4$, $p\text{-valor} < 2,2 \times 10^{-16}$ (prácticamente 0)

Conclusión:

- Como $p\text{-valor} < 0,05$, rechazamos H_0 .
- Existe evidencia **muy fuerte** de que el nivel de inglés MCER y el tipo de IES **NO son independientes**.
- Hay una asociación estadísticamente significativa entre ambas variables.

Importante

Rechazar H_0 indica **asociación**, pero no implica causalidad.
La prueba NO nos dice qué tan **fuerte** es la asociación.

Visualizando las diferencias

```
# Calcular residuos estandarizados
residuos <- resultado$residuals
residuos
```

#		privada	publica
#	A-	-3.24	3.51
#	A1	-4.23	4.58
#	A2	0.03	-0.03
#	B1	3.37	-3.65
#	B+	4.93	-5.34

```
# Los residuos estandarizados > |2| indican celdas
# con diferencias importantes respecto a independencia
```

Interpretación:

- IES privadas tienen **más** estudiantes B1 y B+ de lo esperado (+3.37, +4.93)
- IES privadas tienen **menos** estudiantes A- y A1 de lo esperado (-3.24, -4.23)
- La situación es simétrica para IES públicas

Visualización gráfica de residuos

```
# Mapa de calor de residuos estandarizados
library(ggplot2)
library(reshape2)

residuos_df <- melt(resultado$residuals)
names(residuos_df) <- c("Nivel", "TipoIES", "Residuo")

ggplot(residuos_df, aes(x = TipoIES, y = Nivel, fill = Residuo)) +
  geom_tile(color = "white") +
  scale_fill_gradient2(low = "blue", mid = "white", high = "red",
                       midpoint = 0, limits = c(-6, 6)) +
  geom_text(aes(label = round(Residuo, 2)), size = 5) +
  labs(title = "Residuos estandarizados: Nivel MCER x Tipo IES",
       x = "Tipo de IES", y = "Nivel MCER") +
  theme_minimal()
```

Lectura del gráfico

Azul = menos de lo esperado; Rojo = más de lo esperado

Midiendo la fuerza de la asociación

La prueba χ^2 nos dice si **hay asociación**, pero no **qué tan fuerte** es.

V de Cramér

Es una medida de asociación para tablas de contingencia:

$$V = \sqrt{\frac{\chi^2}{n \times (\min(r, c) - 1)}}$$

donde χ^2 = estadístico chi-cuadrado, n = tamaño muestral, r = filas, c = columnas.

Rango: $V \in [0, 1]$

- $V = 0 \Rightarrow$ independencia completa
- $V = 1 \Rightarrow$ asociación perfecta

Cálculo de V de Cramér en R

```
# Calcular V de Cramer
chi2 <- resultado$statistic
n <- sum(tabla_obs)
min_dim <- min(nrow(tabla_obs), ncol(tabla_obs))

V <- sqrt(chi2 / (n * (min_dim - 1)))
V
# [1] 0.1915

# Alternativa con paquete DescTools
library(DescTools)
CramerV(tabla_obs)
# [1] 0.1915
```

V de Cramér: cálculo manual

Cálculo paso a paso

$$V = \sqrt{\frac{186,42}{5085 \times (2 - 1)}} = \sqrt{\frac{186,42}{5085}} = \sqrt{0,0367} \approx 0,1915$$

Datos usados:

- $\chi^2 = 186,42$ (del resultado de `chisq.test()`)
- $n = 5085$ (total de observaciones)
- $\text{mín}(r, c) - 1 = \text{mín}(5, 2) - 1 = 1$

Interpretación de V de Cramér

Reglas de pulgar generales:

- $V < 0,1 \Rightarrow$ asociación **muy débil**
- $0,1 \leq V < 0,3 \Rightarrow$ asociación **moderada**
- $V \geq 0,3 \Rightarrow$ asociación **fuerte**

En nuestro ejemplo:

- $V = 0,1915$ (entre 0.1 y 0.3)
- Asociación **moderada** entre nivel MCER y tipo de IES
- Estadísticamente significativa ($p\text{-valor} < 0,001$), pero la magnitud del efecto es moderada

Significancia estadística vs práctica

Una asociación puede ser estadísticamente significativa ($p\text{-valor}$ pequeño) pero de magnitud modesta en términos prácticos. Siempre reportar ambos: $p\text{-valor}$ Y tamaño del efecto.

Ejemplo adicional: Estrato × Región

```
# El estrato socioeconomico es independiente de la region?
tabla_estrato_region <- table(icfes_ni$ESTRATO, icfes_ni$REGION)

chi_est_reg <- chisq.test(tabla_estrato_region)
chi_est_reg

# X-squared = 523.67, df = 20, p-value < 2.2e-16

# V de Cramer
V_est_reg <- sqrt(chi_est_reg$statistic /
                  (sum(tabla_estrato_region) *
                   (min(dim(tabla_estrato_region)) - 1)))
V_est_reg

# [1] 0.226

# Asociacion moderada y estadisticamente significativa
```

¿Qué es bondad de ajuste?

Pregunta diferente

En la prueba de **independencia**, comparamos dos variables categóricas observadas. En la prueba de **bondad de ajuste**, comparamos una variable observada con una distribución teórica esperada.

Hipótesis:

- H_0 : Los datos provienen de la distribución especificada
- H_1 : Los datos NO provienen de esa distribución

Ejemplos de preguntas

- ¿Los niveles MCER se distribuyen uniformemente?
- ¿El puntaje de inglés sigue una distribución normal?
- ¿La proporción de estudiantes por región coincide con la distribución poblacional de Colombia?

Estadístico de bondad de ajuste

Fórmula

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

donde:

- O_i = frecuencia observada en la categoría i
- E_i = frecuencia esperada en la categoría i (según la distribución teórica)
- k = número de categorías

Grados de libertad:

$$gl = k - p - 1$$

donde p = número de parámetros estimados de los datos.

- Si la distribución teórica está completamente especificada: $p = 0$
- Si estimamos la media y desviación estándar de los datos: $p = 2$

Ejemplo 1: Distribución uniforme de niveles MCER

Pregunta: ¿Los 5 niveles MCER se distribuyen uniformemente?

```
# Frecuencias observadas
niveles <- table(icfes_ni$NIVEL_MCER)
niveles
#   A-   A1   A2   B1   B+
#  557 1278 1648 1007 595

# Bajo uniformidad, esperaríamos n/5 en cada nivel
n <- sum(niveles)
esperadas_unif <- rep(n / 5, 5) # [1] 1017 1017 1017 1017 1017

# Prueba chi-cuadrado
chisq.test(niveles, p = rep(1/5, 5))
# X-squared = 574.23, df = 4, p-value < 2.2e-16
```

Conclusión: Rechazamos H_0 . La distribución NO es uniforme.

Visualización: observado vs esperado (uniforme)

```
# Comparar graficamente
library(ggplot2)
df_comp <- data.frame(
  Nivel = names(niveles),
  Observado = as.numeric(niveles),
  Esperado = esperadas_unif
)
df_comp_long <- melt(df_comp, id.vars = "Nivel")

ggplot(df_comp_long, aes(x = Nivel, y = value, fill = variable)) +
  geom_bar(stat = "identity", position = "dodge") +
  labs(title = "Niveles MCER: observado vs uniforme",
       x = "Nivel MCER", y = "Frecuencia") +
  scale_fill_manual(values = c("steelblue", "coral")) +
  theme_minimal()
```

Observación

Hay un pico en A2 y menor frecuencia en los extremos (A- y B+).

Ejemplo 2: ¿El puntaje de inglés sigue una distribución normal?

Estrategia:

1. Dividir el rango de MOD_INGLES_PUNT en intervalos
2. Calcular frecuencias observadas en cada intervalo
3. Calcular frecuencias esperadas bajo normalidad con μ y σ muestrales
4. Aplicar prueba χ^2 de bondad de ajuste

```
# Parametros muestrales
media <- mean(icfes_ni$MOD_INGLES_PUNT, na.rm = TRUE)
desv <- sd(icfes_ni$MOD_INGLES_PUNT, na.rm = TRUE)

media # 158.3
desv  # 22.7

# Crear intervalos (e.g., 10 intervalos equidistantes)
breaks <- seq(min(icfes_ni$MOD_INGLES_PUNT, na.rm = TRUE),
               max(icfes_ni$MOD_INGLES_PUNT, na.rm = TRUE),
               length.out = 11)
```

Frecuencias esperadas bajo normalidad

```
# Frecuencias observadas
obs_counts <- table(cut(icfes_ni$MOD_INGLES_PUNT,
                        breaks = breaks, include.lowest = TRUE))

# Probabilidades bajo N(media, desv^2)
probs <- numeric(10)
for(i in 1:10) {
  probs[i] <- pnorm(breaks[i+1], mean = media, sd = desv) -
    pnorm(breaks[i], mean = media, sd = desv)
}

# Frecuencias esperadas
n <- sum(!is.na(icfes_ni$MOD_INGLES_PUNT))
esp_counts <- n * probs
```

Prueba de bondad de ajuste: normalidad

```
# Prueba chi-cuadrado (df = 10 - 2 - 1 = 7)
chisq.test(obs_counts, p = probs)

# X-squared = 45.82, df = 7, p-value = 2.1e-07
```

Conclusión: Rechazamos H_0 . La distribución del puntaje NO es normal.

Nota sobre los grados de libertad

$g| = k - p - 1 = 10 - 2 - 1 = 7$, donde $p = 2$ porque estimamos μ y σ de los datos.

Alternativa: Test de Shapiro-Wilk

Para probar normalidad en variables continuas, el test de **Shapiro-Wilk** es más potente:

```
# Test de Shapiro-Wilk (solo funciona con n <= 5000)
set.seed(123)
muestra <- sample(icfes_ni$MOD_INGLES_PUNT, 5000)
shapiro.test(muestra)

# Shapiro-Wilk normality test
# data: muestra
# W = 0.9823, p-value < 2.2e-16
```

Interpretación

H_0 : los datos provienen de una distribución normal.

$p\text{-valor} < 0,001 \Rightarrow$ rechazamos H_0 : los puntajes de inglés NO siguen una distribución normal.

Visualización: Q-Q plot

```
# Q-Q plot para evaluar normalidad visualmente  
qqnorm(icfes_ni$MOD_INGLES_PUNT,  
       main = "Q-Q Plot: Puntaje de Ingles",  
       pch = 20, col = "steelblue")  
qqline(icfes_ni$MOD_INGLES_PUNT, col = "red", lwd = 2)  
  
# Si los datos fueran normales, los puntos deberían  
# seguir aproximadamente la línea roja
```

Interpretación del Q-Q plot

- Puntos alineados con la línea $\Rightarrow$ normalidad
- Desviaciones en las colas $\Rightarrow$ distribución con colas más pesadas/ligeras
- Patrón en S $\Rightarrow$ asimetría

En nuestro caso: las colas superiores se desvían, indicando asimetría negativa.

Ejemplo 3: Distribución regional esperada

Pregunta: ¿La distribución regional de estudiantes NI refleja la distribución poblacional de Colombia?

```
# Frecuencias observadas
obs_region <- table(icfes_ni$REGION)

# Proporciones poblacionales de Colombia (ejemplo hipotetico)
# Andina: 34%, Caribe: 21%, Pacifica: 18%, Orinoquia: 3%,
# Amazonia: 2%, Bogota: 22%
prop_poblacion <- c(Andina = 0.34, Caribe = 0.21,
                    Pacifica = 0.18, Orinoquia = 0.03,
                    Amazonia = 0.02, Bogota = 0.22)

# Prueba chi-cuadrado
chisq.test(obs_region, p = prop_poblacion)

# X-squared = 128.56, df = 5, p-value < 2.2e-16
```

Conclusión: La distribución regional de estudiantes NI NO refleja la distribución poblacional (posiblemente por concentración de programas en ciertas regiones).

Extensión: k proporciones

Pregunta: ¿La proporción de estudiantes que supera B1 es igual en las 5 regiones principales?

Esto es equivalente a una tabla de contingencia $2 \times k$:

- Fila 1: supera B1 (B1 o B+)
- Fila 2: no supera B1 (A-, A1, A2)
- k columnas: una por cada región

Hipótesis

- $H_0: p_1 = p_2 = \dots = p_k$ (todas las proporciones son iguales)
- H_1 : al menos una proporción es diferente

Usamos la prueba χ^2 de independencia (equivalente) o `prop.test()` en R.

Aplicación: prop.test() para k proporciones

```
# Crear variable binaria: supera B1
icfes_ni$SUPERA_B1 <- ifelse(icfes_ni$NIVEL_MCER %in% c("B1", "B+"),
                             1, 0)

# Tabla 2x5: supera B1 x region
tabla_b1_region <- table(icfes_ni$SUPERA_B1, icfes_ni$REGION)

# Prueba chi-cuadrado de independencia
chisq.test(tabla_b1_region)

# X-squared = 38.72, df = 4, p-value = 7.8e-08

# Alternativa: prop.test
prop.test(tabla_b1_region)

# 5-sample test for equality of proportions without continuity correction
# X-squared = 38.72, df = 4, p-value = 7.8e-08
```

Conclusión: La proporción que supera B1 difiere significativamente entre regiones.

Visualización de proporciones por región


```
# Calcular proporciones por region
prop_b1_region <- prop.table(tabla_b1_region, 2)

# Grafico de barras
barplot(prop_b1_region,
        main = "Proporcion que supera B1 por region",
        xlab = "Region",
        ylab = "Proporcion",
        legend = c("No supera B1", "Supera B1"),
        col = c("coral", "steelblue"),
        beside = FALSE)
```

Observación

Bogota y la region Andina muestran las proporciones mas altas de estudiantes que superan B1.

Diagrama de flujo: ¿Qué prueba usar?



Resumen: Pruebas para variables numéricas

Comparación de medias

- **1 media:** t-test de una muestra
 $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$ (o $>$, $<$)
- **2 medias independientes:** t-test de dos muestras
 $H_0 : \mu_1 = \mu_2$ vs $H_1 : \mu_1 \neq \mu_2$
- **2 medias pareadas:** t-test pareado
 $H_0 : \mu_d = 0$ vs $H_1 : \mu_d \neq 0$
- **3+ medias:** ANOVA de un factor
 $H_0 : \mu_1 = \mu_2 = \dots = \mu_k$ vs $H_1 : \text{al menos una diferente}$

Alternativas no paramétricas (si los supuestos de normalidad no se cumplen):

- 2 grupos: Mann-Whitney U (Wilcoxon rank-sum)
- 3+ grupos: Kruskal-Wallis

Resumen: Pruebas para variables categóricas

Prueba χ^2 de independencia

- Compara dos variables categóricas — H_0 : son independientes
- $\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$, $gl = (r - 1)(c - 1)$
- Tamaño del efecto: V de Cramér

Prueba χ^2 de bondad de ajuste

- Compara datos observados con una distribución teórica
- H_0 : los datos siguen la distribución especificada
- $\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i}$, $gl = k - p - 1$
- Alternativa para normalidad: Shapiro-Wilk

Recomendaciones finales

Siempre verificar supuestos

- χ^2 : $E_{ij} \geq 5$ en al menos 80 % de celdas
- t-test: normalidad (o n grande), homocedasticidad
- ANOVA: normalidad, homocedasticidad, independencia

Reportar resultados completos

- Estadístico de prueba, grados de libertad y p-valor
- Tamaño del efecto (V de Cramér, Cohen's d, η^2 , etc.)
- Intervalos de confianza cuando sea aplicable
- Interpretación en contexto

Próxima sesión

Siguiente tema

Regresión lineal simple (OLS): modelando la relación entre dos variables numéricas.