

Sesión 9: Regresión Lineal Simple (OLS)

El método de mínimos cuadrados ordinarios

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Vie 23 oct 2026

Agenda

Introducción a la regresión

Método de mínimos cuadrados (OLS)

Supuestos de Gauss-Markov

Coeficiente de determinación R^2

Pruebas de significancia

Modelo con variable dummy

Ejemplo completo en R

Motivación: más allá de la correlación

Hasta ahora

Hemos estudiado la **correlación** r entre dos variables numéricas, que mide la fuerza y dirección de la relación lineal.

Limitaciones de la correlación:

- Solo mide asociación, no permite predecir
- Es simétrica: $\text{cor}(X, Y) = \text{cor}(Y, X)$
- No distingue variable dependiente de independiente

Pregunta de investigación

¿Podemos **predecir** el desempeño en inglés en Saber Pro a partir del puntaje de inglés en Saber 11? Necesitamos un **modelo de regresión**.

Analogía: Imaginen que quieren predecir su nota del parcial a partir de las horas de estudio. La regresión es la herramienta que les permite hacer esa predicción de forma sistemática.

El modelo de regresión lineal simple

Definición

El modelo de **regresión lineal simple** relaciona una variable dependiente Y con una variable independiente X mediante una línea recta:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

donde:

- Y_i = valor observado de la variable dependiente (respuesta)
- X_i = valor de la variable independiente (predictor, regressor)
- β_0 = intercepto (valor de Y cuando $X = 0$)
- β_1 = pendiente (cambio en Y por cada unidad de cambio en X)
- ε_i = error aleatorio (desviación del modelo)

Interpretación: β_0 y β_1 son **parámetros poblacionales** (desconocidos). Los estimaremos con $\hat{\beta}_0$ y $\hat{\beta}_1$ usando los datos.

Ecuación estimada y valores ajustados

La ecuación estimada (fitted line) es:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

- $\hat{Y}_i$ = valor **predicho** (ajustado) de Y para la observación i
- $e_i = Y_i - \hat{Y}_i$ = **residuo** (error de predicción)

Ejemplo

Si $\hat{\beta}_0 = 45$ y $\hat{\beta}_1 = 1,8$, la ecuación es:

$$\widehat{\text{MOD_INGLES_PUNT}} = 45 + 1,8 \times \text{INGLES_SABER11_PUNT}$$

Para un estudiante con puntaje 60 en Saber 11:

$$\hat{Y} = 45 + 1,8 \times 60 = 45 + 108 = 153$$

Si su puntaje real en Saber Pro es 158, el residuo es $e = 158 - 153 = 5$.

Visualización: scatter plot + línea de regresión

```
# Cargar datos ICFES para Ciencias Economicas
icfes_ni <- read.csv("datos/icfes_ni_2025.csv")

# Scatter plot con linea de regresion
library(ggplot2)

ggplot(icfes_ni, aes(x = INGLES_SABER11_PUNT,
                    y = MOD_INGLES_PUNT)) +
  geom_point(alpha = 0.3, color = "steelblue") +
  geom_smooth(method = "lm", se = TRUE, color = "red",
            fill = "pink", alpha = 0.2) +
  labs(title = "Relacion entre ingles Saber 11 y Saber Pro",
       x = "Puntaje ingles Saber 11",
       y = "Puntaje ingles Saber Pro (MOD_INGLES_PUNT)") +
  theme_minimal()
```

La banda sombreada representa el intervalo de confianza del 95 % para la línea de regresión.

¿Qué línea elegir?

Hay infinitas líneas que pasan por la nube de puntos. ¿Cuál es la **mejor**?

Criterio: minimizar los errores

Queremos que los residuos $e_i = Y_i - \hat{Y}_i$ sean lo más pequeños posible en conjunto.

Opciones:

- Minimizar $\sum |e_i|$ (suma de errores absolutos)
- Minimizar $\max |e_i|$ (error máximo)
- Minimizar $\sum e_i^2$ (suma de errores al cuadrado) $\leftarrow$ **OLS**

Método de Mínimos Cuadrados Ordinarios (OLS)

Definición

El método **OLS** (Ordinary Least Squares) elige $\hat{\beta}_0$ y $\hat{\beta}_1$ que minimizan:

$$\text{SSE} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

En otras palabras: OLS busca la línea que minimiza los errores de predicción al cuadrado — la línea que mejor “le pega” a los datos.

Derivación: ecuaciones normales

Para minimizar $SSE = \sum (Y_i - \beta_0 - \beta_1 X_i)^2$, tomamos las derivadas parciales respecto a β_0 y β_1 e igualamos a cero:

Derivada respecto a β_0 :

$$\frac{\partial SSE}{\partial \beta_0} = -2 \sum (Y_i - \beta_0 - \beta_1 X_i) = 0$$

$$\Rightarrow \sum Y_i = n\beta_0 + \beta_1 \sum X_i$$

Derivada respecto a β_1 :

$$\frac{\partial SSE}{\partial \beta_1} = -2 \sum X_i (Y_i - \beta_0 - \beta_1 X_i) = 0$$

$$\Rightarrow \sum X_i Y_i = \beta_0 \sum X_i + \beta_1 \sum X_i^2$$

Estas son las **ecuaciones normales**. Resolviéndolas obtenemos los estimadores OLS.

Fórmulas de los estimadores OLS

Estimador de la pendiente

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{S_{XY}}{S_{XX}}$$

donde:

- $S_{XY} = \sum (X_i - \bar{X})(Y_i - \bar{Y})$ = suma de productos cruzados
- $S_{XX} = \sum (X_i - \bar{X})^2$ = suma de cuadrados de X

Estimador del intercepto

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Propiedad importante: La línea OLS **siempre** pasa por el punto $(\bar{X}, \bar{Y})$.

Relación con la correlación

El estimador OLS de la pendiente se puede escribir como:

$$\hat{\beta}_1 = r \times \frac{s_Y}{s_X}$$

donde r = correlación de Pearson, s_Y = desviación estándar de Y , s_X = desviación estándar de X .

Interpretación:

- Si $r = 0 \Rightarrow \hat{\beta}_1 = 0$ (no hay relación lineal)
- Si $s_X = s_Y$ y $r = 1 \Rightarrow \hat{\beta}_1 = 1$ (relación 1 a 1)
- El signo de $\hat{\beta}_1$ es el mismo que el de r

Nota

Aunque $\hat{\beta}_1$ depende de r , la regresión aporta más información: cuantifica el cambio esperado en Y por unidad de cambio en X . Por ejemplo, no solo sabemos que horas de estudio y nota están correlacionadas, sino que cada hora adicional sube la nota en $\hat{\beta}_1$ puntos.

Aplicación en R: `lm()`

```
# Ajustar modelo de regresion lineal simple
modelo1 <- lm(MOD_INGLES_PUNT ~ INGLES_SABER11_PUNT,
              data = icfes_ni)

# Ver coeficientes estimados
coef(modelo1)

#           (Intercept)  INGLES_SABER11_PUNT
#           45.23             1.82

# Interpretar
# beta_0 = 45.23: puntaje esperado en Saber Pro si Saber 11 = 0
# beta_1 = 1.82: por cada punto adicional en Saber 11,
#               esperamos 1.82 puntos mas en Saber Pro
```

Cuidado con la extrapolación

$\hat{\beta}_0 = 45,23$ representa el intercepto teórico, pero en la práctica nadie obtiene 0 en Saber 11. No interprete el intercepto fuera del rango de los datos.

Valores ajustados y residuos

```
# Valores ajustados (predicciones)
y_hat <- fitted(modelo1)
head(y_hat)

# 153.2 158.4 162.1 147.8 ...

# Residuos
residuos <- residuals(modelo1)
head(residuos)

# 4.8 -2.4 1.9 -3.8 ...

# Verificar: la suma de residuos es (casi) 0
sum(residuos)

# [1] -1.42e-12 (numericamente 0)

# Verificar: la correlacion entre X y residuos es (casi) 0
cor(icfes_ni$INGLES_SABER11_PUNT, residuos)

# [1] -3.5e-17 (numericamente 0)
```

Propiedades OLS: $\sum e_i = 0$ y $\sum X_i e_i = 0$ (ortogonalidad).

Visualización de residuos

```
# Grafico de residuos vs valores ajustados  
plot(fitted(modelo1), residuals(modelo1),  
     xlab = "Valores ajustados",  
     ylab = "Residuos",  
     main = "Residuos vs Valores Ajustados",  
     pch = 20, col = "steelblue")  
abline(h = 0, col = "red", lwd = 2, lty = 2)  
  
# Idealmente, los residuos deberian estar dispersos  
# aleatoriamente alrededor de 0, sin patron visible
```

Diagnóstico

- Patrón en forma de embudo $\Rightarrow$ heterocedasticidad
- Patrón curvo $\Rightarrow$ no linealidad
- Dispersión aleatoria $\Rightarrow$ supuestos plausibles

Los supuestos clásicos de regresión lineal

Para que OLS sea el **Mejor Estimador Lineal Insesgado** (BLUE: Best Linear Unbiased Estimator), se requieren los siguientes supuestos:

1. **Linealidad:** $E(Y|X) = \beta_0 + \beta_1 X$

La relación entre X e Y es lineal en los parámetros.

2. **Independencia:** Las observaciones son independientes entre sí.

3. **Homocedasticidad:** $\text{Var}(\varepsilon_i|X_i) = \sigma^2$ (constante)

La varianza del error es constante para todos los valores de X .

4. **Normalidad:** $\varepsilon_i \sim N(0, \sigma^2)$

Los errores se distribuyen normalmente (necesario para inferencia).

5. **Exogeneidad:** $E(\varepsilon_i|X_i) = 0$

El error no está correlacionado con X (no hay sesgo de endogeneidad).

Consecuencias de violar los supuestos

Violación de linealidad

⇒ Estimadores sesgados. Solución: transformar variables (log, cuadrática, etc.) o usar modelos no lineales.

Violación de independencia

⇒ Errores estándar incorrectos (muy optimistas). Solución: errores estándar robustos a cluster.

Violación de homocedasticidad

⇒ Estimadores no eficientes, errores estándar sesgados. Solución: errores estándar robustos (HC) o WLS.

Violación de normalidad

⇒ Inferencia (pruebas t, IC) no válida en muestras pequeñas. Solución: bootstrap, transformaciones, o confiar en TCL si n es grande.

Verificación de supuestos: gráficos diagnósticos

```
# R proporciona 4 graficos diagnosticos automaticos
par(mfrow = c(2, 2)) # 2x2 panel
plot(modelo1)
par(mfrow = c(1, 1)) # restaurar

# 1. Residuals vs Fitted: verifica linealidad y homocedasticidad
# 2. Q-Q Plot: verifica normalidad de residuos
# 3. Scale-Location: verifica homocedasticidad
# 4. Residuals vs Leverage: identifica observaciones influyentes
```

Lectura:

- Residuals vs Fitted: línea roja horizontal y dispersión uniforme $\Rightarrow$ OK
- Q-Q Plot: puntos sobre la diagonal $\Rightarrow$ normalidad
- Scale-Location: línea horizontal $\Rightarrow$ homocedasticidad
- Residuals vs Leverage: puntos fuera de las bandas de Cook $\Rightarrow$ outliers influyentes

Descomposición de la variabilidad: $SST = SSR + SSE$

La variabilidad total de Y se descompone en dos partes:

Sumas de cuadrados

- **SST** (Total Sum of Squares): $\sum (Y_i - \bar{Y})^2$
Variabilidad total de Y respecto a su media.
- **SSR** (Regression Sum of Squares): $\sum (\hat{Y}_i - \bar{Y})^2$
Variabilidad **explicada** por el modelo.
- **SSE** (Error Sum of Squares): $\sum (Y_i - \hat{Y}_i)^2 = \sum e_i^2$
Variabilidad **no explicada** (residual).

Relación fundamental:

$$SST = SSR + SSE$$

Dividiendo por SST:

$$1 = \frac{SSR}{SST} + \frac{SSE}{SST}$$

Coeficiente de determinación R^2

Definición

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

Interpretación:

- R^2 = proporción de la variabilidad de Y **explicada** por X
- Rango: $R^2 \in [0, 1]$
- $R^2 = 0 \Rightarrow X$ no explica nada de Y ($SSR = 0$)
- $R^2 = 1 \Rightarrow$ ajuste perfecto ($SSE = 0$, todos los puntos sobre la línea)

Ejemplo

Si $R^2 = 0,65$, el 65 % de la variabilidad del puntaje de inglés en Saber Pro se explica por el puntaje en Saber 11. El 35 % restante se debe a otros factores.

Coeficiente de determinación R^2 (cont.)

Analogía: R^2 en su vida

¿Qué porcentaje de la variación en sus notas se explica por horas de estudio?

- Si $R^2 = 0,6$, el 60 % de las diferencias en notas se explican por cuánto estudian.
- El 40 % restante depende de otros factores (sueño, método de estudio, etc.).

Nota importante

R^2 es siempre positivo (es un cuadrado), pero r puede ser negativo. El signo de la relación se ve en $\hat{\beta}_1$ (o en r), no en R^2 .

Relación entre R^2 y correlación

En regresión lineal simple (un solo predictor), se cumple:

$$R^2 = r^2$$

donde r es el coeficiente de correlación de Pearson entre X e Y .

Ejemplo:

- Si $r = 0,8 \Rightarrow R^2 = 0,64$ (64 % de variabilidad explicada)
- Si $r = -0,5 \Rightarrow R^2 = 0,25$ (25 % de variabilidad explicada)

Calculando R^2 en R

```
# Obtener  $R^2$  del modelo
summary(modelo1)$r.squared

# [1] 0.6524

# Verificar con la correlacion
r <- cor(icfes_ni$MOD_INGLES_PUNT,
         icfes_ni$INGLES_SABER11_PUNT,
         use = "complete.obs")
r^2

# [1] 0.6524

# Calcular manualmente SST, SSR, SSE
SST <- sum((icfes_ni$MOD_INGLES_PUNT - mean(icfes_ni$MOD_INGLES_PUNT))^2)
SSE <- sum(residuals(modelo1)^2)
SSR <- SST - SSE

R2_manual <- SSR / SST
R2_manual

# [1] 0.6524
```

Precauciones al interpretar R^2

R^2 alto $\nRightarrow$ causalidad

Una correlación alta no implica que X **cause** Y . Puede haber:

- Causalidad inversa (Y causa X)
- Variables omitidas (confounders)
- Correlación espuria

R^2 alto $\nRightarrow$ buen modelo de predicción

Un modelo puede tener R^2 alto en la muestra pero predecir mal fuera de la muestra (overfitting).

R^2 bajo $\nRightarrow$ modelo inútil

Incluso con R^2 bajo, el modelo puede revelar una relación importante y estadísticamente significativa. En ciencias sociales, $R^2 = 0,20$ puede ser razonable.

Varianza del error y MSE

Para hacer inferencia sobre los parámetros, necesitamos estimar $\sigma^2 = \text{Var}(\varepsilon_i)$.

Estimador de σ^2

$$s^2 = \text{MSE} = \frac{\text{SSE}}{n - 2}$$

donde $n - 2$ son los grados de libertad (n observaciones menos 2 parámetros estimados).

MSE = Mean Squared Error (cuadrado medio del error residual).

La raíz cuadrada de MSE se llama **error estándar de la regresión**: $s = \sqrt{\text{MSE}}$ = residual standard error.

Interpretación

s representa la desviación estándar típica de los residuos. Si $s = 12$, en promedio los valores observados se desvían ± 12 puntos de la línea de regresión.

Error estándar de $\hat{\beta}_1$

El estimador $\hat{\beta}_1$ tiene una distribución muestral con:

$$SE(\hat{\beta}_1) = \frac{s}{\sqrt{\sum (X_i - \bar{X})^2}} = \frac{s}{\sqrt{S_{XX}}}$$

Interpretación:

- Mayor variabilidad en X (mayor S_{XX}) $\Rightarrow$ menor error estándar (estimación más precisa)
- Mayor variabilidad residual (s alto) $\Rightarrow$ mayor error estándar (estimación menos precisa)

Distribución bajo los supuestos

Si los errores son normales:

$$\frac{\hat{\beta}_1 - \beta_1}{SE(\hat{\beta}_1)} \sim t_{n-2}$$

Prueba t para la pendiente

Hipótesis más común

- $H_0 : \beta_1 = 0$ (no hay relación lineal entre X e Y)
- $H_1 : \beta_1 \neq 0$ (existe relación lineal)

Estadístico de prueba: $t = \hat{\beta}_1 / \text{SE}(\hat{\beta}_1) \sim t_{n-2}$ bajo H_0 .

Regla de decisión:

- Rechazamos H_0 si $|t| > t_{\alpha/2, n-2}$ o si p-valor $< \alpha$

Interpretación

Si rechazamos H_0 , concluimos que la pendiente es **estadísticamente diferente de cero**, es decir, existe una relación lineal significativa entre X e Y .

Intervalo de confianza para β_1

Un IC del $(1 - \alpha) \times 100 \%$ para β_1 es:

$$\hat{\beta}_1 \pm t_{\alpha/2, n-2} \times SE(\hat{\beta}_1)$$

Interpretación:

- Con 95 % de confianza, el verdadero valor de β_1 está en este intervalo.
- Si el intervalo **no contiene 0**, la pendiente es significativa al nivel α .

Ejemplo

IC 95 % para β_1 : [1,65, 1,99]

- No contiene 0 $\Rightarrow$ la relación es significativa
- Interpretación: con 95 % de confianza, por cada punto adicional en Saber 11, el puntaje en Saber Pro aumenta entre 1.65 y 1.99 puntos

Aplicación en R: summary(lm())

```
# Resumen completo del modelo
summary(modelo1)

# Call:
# lm(formula = MOD_INGLES_PUNT ~ INGLES_SABER11_PUNT, data = icfes_ni)
#
# Residuals:
#      Min       1Q   Median       3Q      Max
# -45.231  -8.124   0.342   8.567  39.128
#
# Coefficients:
#              Estimate Std. Error t value Pr(>|t|)
# (Intercept)    45.2314     1.2345   36.64  <2e-16 ***
# INGLES_SABER11_PUNT  1.8234     0.0198   92.09  <2e-16 ***
# ---
# Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#
# Residual standard error: 12.35 on 5083 degrees of freedom
# Multiple R-squared:  0.6524, Adjusted R-squared:  0.6523
# F-statistic: 8481 on 1 and 5083 DF, p-value: < 2.2e-16
```

Interpretando el output de `summary()`

Coefficients:

- Estimate: $\hat{\beta}_0 = 45,23$, $\hat{\beta}_1 = 1,82$
- Std. Error: $SE(\hat{\beta}_0) = 1.23$, $SE(\hat{\beta}_1) = 0.020$
- t value: $t = \hat{\beta}/SE(\hat{\beta}) = 92.09$ para β_1
- $Pr(>|t|)$: p-valor $< 2 \times 10^{-16}$ (altamente significativo)

Residual standard error: $s = 12,35$ (desviación típica de residuos)

Multiple R-squared: $R^2 = 0,6524$ (65.24 % de variabilidad explicada)

F-statistic: $F = 8481$, p-valor $< 2,2 \times 10^{-16}$ (prueba global)

Conclusión

Existe una relación lineal **muy significativa** entre el inglés de Saber 11 y Saber Pro. Por cada punto adicional en Saber 11, esperamos 1.82 puntos más en Saber Pro.

Intervalos de confianza para los coeficientes

```
# IC 95% para todos los coeficientes
confint(modelo1, level = 0.95)

#           2.5 %    97.5 %
# (Intercept)    42.81136  47.65144
# INGLES_SABER11_PUNT  1.78455  1.86225

# IC 99% (mas amplio)
confint(modelo1, level = 0.99)

#           0.5 %    99.5 %
# (Intercept)    42.05312  48.40968
# INGLES_SABER11_PUNT  1.77345  1.87335
```

Interpretación:

- Con 95 % de confianza, $\beta_1 \in [1,78, 1,86]$
- El intervalo no contiene 0 $\Rightarrow$ la relación es significativa

Prueba F global

En regresión simple, la **prueba F global** es equivalente a la prueba t para β_1 :

Hipótesis

- $H_0: \beta_1 = 0$ (el modelo no es útil)
- $H_1: \beta_1 \neq 0$ (el modelo es útil)

Estadístico:

$$F = \frac{MSR}{MSE} = \frac{SSR/1}{SSE/(n-2)} \sim F_{1,n-2} \quad \text{bajo } H_0$$

Relación con prueba t:

$$F = t^2$$

En regresión simple, F y t dan la misma conclusión. En regresión múltiple, F prueba si **todos** los coeficientes son cero simultáneamente (veremos en S10).

Variables dummy (indicadoras)

Una **variable dummy** es una variable binaria que toma valores 0 o 1 para representar categorías.

Ejemplo

Queremos comparar el puntaje de inglés entre IES privadas y públicas:

$$\text{PRIVADA} = \begin{cases} 1 & \text{si IES privada} \\ 0 & \text{si IES pública} \end{cases}$$

Otro ejemplo cercano: una variable que vale 1 si usan iPad en clase y 0 si no, o 1 si trabajan y 0 si no.

Variables dummy: modelo e interpretación

Modelo:

$$\text{MOD_INGLES_PUNT}_i = \beta_0 + \beta_1 \times \text{PRIVADA}_i + \varepsilon_i$$

Interpretación:

- β_0 = puntaje promedio en IES públicas (cuando PRIVADA = 0)
- $\beta_0 + \beta_1$ = puntaje promedio en IES privadas (cuando PRIVADA = 1)
- β_1 = diferencia promedio entre IES privadas y públicas

Regresión con dummy en R

```
# Crear variable dummy
icfes_ni$PRIVADA <- ifelse(icfes_ni$TIPO_IES == "privada", 1, 0)

# Ajustar modelo
modelo_dummy <- lm(MOD_INGLES_PUNT ~ PRIVADA, data = icfes_ni)

summary(modelo_dummy)

# Coefficients:
#               Estimate Std. Error t value Pr(>|t|)
# (Intercept)  154.82      0.42    368.62  <2e-16 ***
# PRIVADA       7.35       0.58    12.67   <2e-16 ***
#
# Residual standard error: 20.23 on 5083 DF
# Multiple R-squared:  0.0306, Adjusted R-squared:  0.0304
```

Interpretación:

- Puntaje promedio en IES públicas: $\hat{\beta}_0 = 154,82$
- Puntaje promedio en IES privadas: $154,82 + 7,35 = 162,17$
- Diferencia: $\hat{\beta}_1 = 7,35$ puntos (significativa, $p < 0,001$)

Equivalencia con prueba t de dos muestras

La regresión con una dummy es equivalente a una prueba t de dos muestras independientes:

```
# Prueba t tradicional
t.test(MOD_INGLES_PUNT ~ TIPO_IES, data = icfes_ni,
       var.equal = TRUE)

# Two Sample t-test
#
# data: MOD_INGLES_PUNT by TIPO_IES
# t = -12.67, df = 5083, p-value < 2.2e-16
# 95 percent confidence interval:
#  -8.486 -6.214
# sample estimates:
# mean in group privada mean in group publica
#           162.17           154.82
```

Observación

El estadístico t de la regresión ($t = 12,67$) es idéntico (en valor absoluto) al de la prueba t de dos muestras. La regresión es una generalización poderosa.

Visualización: boxplot por grupo

```
# Comparar graficamente
library(ggplot2)

ggplot(icfes_ni, aes(x = TIPO_IES, y = MOD_INGLES_PUNT,
                    fill = TIPO_IES)) +
  geom_boxplot(alpha = 0.7) +
  geom_hline(yintercept = coef(modelo_dummy)[1],
            linetype = "dashed", color = "blue", size = 1) +
  geom_hline(yintercept = coef(modelo_dummy)[1] + coef(modelo_dummy)[2],
            linetype = "dashed", color = "red", size = 1) +
  labs(title = "Puntaje de ingles por tipo de IES",
       x = "Tipo de IES",
       y = "MOD_INGLES_PUNT") +
  scale_fill_manual(values = c("steelblue", "coral")) +
  theme_minimal()
```

Las líneas punteadas muestran los valores predichos por el modelo ($\hat{\beta}_0$ y $\hat{\beta}_0 + \hat{\beta}_1$).

Ejemplo integrador: paso a paso

Pregunta: ¿Cómo se relaciona el puntaje cuantitativo en Saber Pro (MOD_RAZONA_CUANT_PUNT) con el puntaje de inglés en Saber 11?

```
# 1. Exploracion inicial
plot(icfes_ni$INGLES_SABER11_PUNT,
     icfes_ni$MOD_RAZONA_CUANT_PUNT,
     xlab = "Ingles Saber 11",
     ylab = "Razonamiento Cuantitativo Saber Pro",
     main = "Relacion entre ingles y razonamiento cuantitativo",
     pch = 20, col = rgb(0, 0, 1, 0.3))

# 2. Calcular correlacion
cor(icfes_ni$INGLES_SABER11_PUNT,
     icfes_ni$MOD_RAZONA_CUANT_PUNT,
     use = "complete.obs")

# [1] 0.58 (correlacion moderada-alta)
```

Ejemplo integrador: ajuste del modelo

```
# 3. Ajustar modelo de regresion
modelo2 <- lm(MOD_RAZONA_CUANT_PUNT ~ INGLES_SABER11_PUNT,
              data = icfes_ni)

# 4. Ver resumen
summary(modelo2)

# Coefficients:
#               Estimate Std. Error t value Pr(>|t|)
# (Intercept)    98.456      1.834   53.68  <2e-16 ***
# INGLES_SABER11_PUNT 0.987      0.029   34.03  <2e-16 ***
#
# Residual standard error: 18.36 on 5083 DF
# Multiple R-squared:  0.3364, Adjusted R-squared:  0.3363

# 5. IC 95% para los coeficientes
confint(modelo2)

#               2.5 %   97.5 %
# (Intercept)    94.8604 102.051
# INGLES_SABER11_PUNT 0.9296  1.044
```

Ejemplo integrador: diagnóstico

```
# 6. Graficos diagnosticos
par(mfrow = c(2, 2))
plot(modelo2)
par(mfrow = c(1, 1))

# 7. Verificar supuestos
# Normalidad de residuos
shapiro.test(sample(residuals(modelo2), 5000))

# W = 0.9967, p-value = 0.0002
# Leve desviacion de normalidad, pero con n grande
# el TCL asegura validez asintotica

# Homocedasticidad (test de Breusch-Pagan)
library(lmtest)
bptest(modelo2)

# BP = 23.45, p-value = 1.3e-06
# Hay evidencia de heterocedasticidad
# (varianza no constante)
```

Ejemplo integrador: predicción

```
# 8. Hacer predicciones
# Prediccion puntual para Saber 11 = 70
nuevo_dato <- data.frame(INGLES_SABER11_PUNT = 70)
predict(modelo2, newdata = nuevo_dato)

# [1] 167.55

# Prediccion con IC 95%
predict(modelo2, newdata = nuevo_dato, interval = "confidence")

#      fit      lwr      upr
# 1 167.55 166.23 168.87

# Prediccion con IP 95% (prediction interval)
predict(modelo2, newdata = nuevo_dato, interval = "prediction")

#      fit      lwr      upr
# 1 167.55 131.42 203.68
```

Diferencia: IC para la **media** vs IP para una **observación individual** (IP siempre más amplio).

Ejemplo integrador: visualización final

```
# 9. Grafico con linea de regresion e intervalos
library(ggplot2)

ggplot(icfes_ni, aes(x = INGLES_SABER11_PUNT,
                    y = MOD_RAZONA_CUANT_PUNT)) +
  geom_point(alpha = 0.2, color = "steelblue") +
  geom_smooth(method = "lm", se = TRUE, color = "red",
             fill = "pink", alpha = 0.3) +
  labs(title = "Ingles (Saber 11) vs Razonamiento Cuantitativo (Saber Pro)",
       subtitle = paste("R^2 = 0.336, p < 0.001"),
       x = "Puntaje Ingles Saber 11",
       y = "Puntaje Razonamiento Cuantitativo Saber Pro") +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5),
        plot.subtitle = element_text(hjust = 0.5))
```

Resumen de la sesión

Conceptos clave

- Modelo de regresión lineal simple: $Y = \beta_0 + \beta_1 X + \varepsilon$
- OLS minimiza $\sum e_i^2$ para estimar $\hat{\beta}_0$ y $\hat{\beta}_1$
- La línea OLS pasa por $(\bar{X}, \bar{Y})$
- R^2 mide la proporción de variabilidad explicada
- Supuestos de Gauss-Markov: linealidad, independencia, homocedasticidad, normalidad, exogeneidad

Inferencia

- Prueba t para $H_0 : \beta_1 = 0$
- IC para β_1 : $\hat{\beta}_1 \pm t_{\alpha/2, n-2} \times SE(\hat{\beta}_1)$
- Regresión con dummy $\equiv$ t-test de dos muestras

Próxima sesión

Regresión lineal múltiple

Incorporar varios predictores simultáneamente: por ejemplo, predecir su nota controlando por horas de estudio, screen time, y si trabajan.