

Sesión 10: Regresión Lineal Múltiple

Múltiples regresores, OVB y multicolinealidad

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Vie 30 oct 2026

Agenda

Modelo de regresión múltiple

Ejemplo: modelo completo del inglés en NI

R^2 y R^2 ajustado

Pruebas de significancia

Sesgo por variable omitida (OVB)

VIF y multicolinealidad

Selección de modelos: AIC y BIC

Interacciones

Resumen

Más allá de un solo predictor

Limitación de la regresión simple

En regresión simple ($Y = \beta_0 + \beta_1 X + \varepsilon$), solo consideramos **un** predictor. Pero en la práctica, múltiples factores influyen en Y simultáneamente.

Ejemplo: El puntaje de inglés en Saber Pro puede depender de:

- Puntaje en Saber 11, estrato socioeconómico, tipo de IES
- Nivel educativo de los padres, región del país, ingresos del hogar

Objetivo de regresión múltiple

Estimar el efecto de cada predictor **controlando por** (manteniendo constantes) los demás predictores.

Analogía: Quieren predecir su nota del parcial controlando por horas de estudio, screen time diario, y si trabajan. La regresión múltiple permite aislar el efecto de cada factor.

El modelo de regresión lineal múltiple

Modelo poblacional

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \varepsilon_i$$

donde:

- Y_i = variable dependiente (respuesta)
- $X_{1i}, X_{2i}, \dots, X_{pi}$ = variables independientes (predictores, regresores)
- β_0 = intercepto
- β_j = coeficiente de X_j ($j = 1, 2, \dots, p$)
- ε_i = error aleatorio

Interpretación de β_j :

β_j representa el cambio esperado en Y cuando X_j aumenta en una unidad, **manteniendo constantes todas las demás variables** (ceteris paribus).

Ecuación estimada

Estimamos los parámetros $\beta_0, \beta_1, \dots, \beta_p$ usando OLS (mínimos cuadrados ordinarios), obteniendo:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i} + \dots + \hat{\beta}_p X_{pi}$$

Residuos:

$$e_i = Y_i - \hat{Y}_i$$

OLS minimiza:

$$\text{SSE} = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Interpretación matricial

En álgebra matricial: $\hat{\beta} = (X'X)^{-1}X'Y$

(No entraremos en detalle, pero R usa esta fórmula internamente)

Sintaxis en R: $lm(Y \sim X1 + X2 + \dots)$

```
# Cargar datos ICFES para Negocios Internacionales
icfes_ni <- read.csv("datos/icfes_ni_2025.csv")

# Regresion multiple: MOD_INGLES_PUNT como funcion de
# varias variables
modelo_mult <- lm(MOD_INGLES_PUNT ~
  INGLES_SABER11_PUNT +
  ESTRATO +
  PRIVADA +
  EDUCACION_PADRE,
  data = icfes_ni)

# Ver coeficientes
coef(modelo_mult)
```

#	(Intercept)	INGLES_SABER11_PUNT	ESTRATO
#	32.45	1.67	2.13
#	PRIVADA	EDUCACION_PADRE	
#	3.82	1.25	

Interpretación de los coeficientes

Del modelo anterior:

$$\widehat{\text{MOD_INGLES}} = 32,45 + 1,67 \times \text{Saber11} + 2,13 \times \text{Estrato} + 3,82 \times \text{Privada} + 1,25 \times \text{EducPadre}$$

Interpretaciones ceteris paribus:

- $\hat{\beta}_1 = 1,67$: Por cada punto adicional en Saber 11, el puntaje de inglés en Saber Pro aumenta **en promedio** 1.67 puntos, **manteniendo constantes** estrato, tipo de IES y educación del padre.
- $\hat{\beta}_2 = 2,13$: Por cada nivel adicional de estrato, el puntaje aumenta 2.13 puntos, **controlando por** los demás factores.
- $\hat{\beta}_3 = 3,82$: Los estudiantes de IES privadas obtienen 3.82 puntos más que los de públicas, **en promedio**, controlando por las demás variables.
- $\hat{\beta}_4 = 1,25$: Por cada año adicional de educación del padre, el puntaje aumenta 1.25 puntos (ceteris paribus).

Modelo extendido con transformaciones

```
# Crear variables dummy para region (referencia: Andina)
icfes_ni$REGION_CARIBE <- ifelse(icfes_ni$REGION == "Caribe", 1, 0)
icfes_ni$REGION_PACIFICA <- ifelse(icfes_ni$REGION == "Pacifica", 1, 0)
icfes_ni$REGION_ORINOQUIA <- ifelse(icfes_ni$REGION == "Orinoquia", 1, 0)
icfes_ni$REGION_BOGOTA <- ifelse(icfes_ni$REGION == "Bogota", 1, 0)

# Transformacion logaritmica de ingresos (reduce asimetria)
icfes_ni$LOG_INGRESOS <- log(icfes_ni$INGRESOS + 1)

# Modelo completo
modelo_completo <- lm(MOD_INGLES_PUNT ~
  INGLES_SABER11_PUNT +
  ESTRATO +
  PRIVADA +
  LOG_INGRESOS +
  REGION_CARIBE +
  REGION_PACIFICA +
  REGION_ORINOQUIA +
  REGION_BOGOTA,
  data = icfes_ni)
```


Resultados del modelo completo

```
summary(modelo_completo)
```

```
# Coefficients:
```

```
#               Estimate Std. Error t value Pr(>|t|)
# (Intercept)      28.342      2.145   13.21 < 2e-16 ***
# INGLES_SABER11_PUNT 1.612      0.025   64.48 < 2e-16 ***
# ESTRATO           1.876      0.312    6.01 2.1e-09 ***
# PRIVADA            3.254      0.672    4.84 1.3e-06 ***
# LOG_INGRESOS       2.145      0.421    5.09 3.6e-07 ***
# REGION_CARIBE      -2.543      0.834   -3.05 0.00230 **
# REGION_PACIFICA     -1.267      0.752   -1.68 0.09234 .
# REGION_ORINOQUIA    -4.123      1.234   -3.34 0.00084 ***
# REGION_BOGOTA       5.234      0.812    6.44 1.3e-10 ***
# ---
```

```
# Residual standard error: 10.85 on 5076 DF
```

```
# Multiple R-squared: 0.7145, Adjusted R-squared: 0.7140
```

```
# F-statistic: 1586 on 8 and 5076 DF, p-value: < 2.2e-16
```

Interpretación del modelo completo

Variables continuas:

- INGLES_SABER11_PUNT: $\hat{\beta} = 1,61$ (altamente significativo)
Por cada punto adicional en Saber 11, +1.61 en Saber Pro (controlando por todo lo demás)
- ESTRATO: $\hat{\beta} = 1,88$ (significativo)
Por cada nivel de estrato, +1.88 puntos
- LOG_INGRESOS: $\hat{\beta} = 2,15$ (significativo)
Interpretación: un aumento del 1 % en ingresos $\Rightarrow$ +0.0215 puntos
(semi-elasticidad: $\beta/100$)

Variable dummy:

- PRIVADA: $\hat{\beta} = 3,25$ (significativo)
IES privadas obtienen 3.25 puntos más que públicas, en promedio, controlando por estrato, ingresos, región, etc.

Interpretación de dummies regionales

Región de referencia: Andina (omitida para evitar multicolinealidad perfecta)

Coeficientes regionales (relativo a Andina):

- REGION_CARIBE: $\hat{\beta} = -2,54$ (significativo)
Estudiantes del Caribe obtienen 2.54 puntos **menos** que los de la Andina (controlando por todo)
- REGION_PACIFICA: $\hat{\beta} = -1,27$ (no significativo, $p = 0.092$)
No hay diferencia estadísticamente significativa con Andina
- REGION_ORINOQUIA: $\hat{\beta} = -4,12$ (significativo)
Orinoquia obtiene 4.12 puntos menos que Andina
- REGION_BOGOTA: $\hat{\beta} = +5,23$ (altamente significativo)
Bogotá obtiene 5.23 puntos **más** que Andina

Nota

Siempre se omite una categoría de referencia en variables categóricas para evitar colinealidad perfecta (dummy variable trap).

R^2 en regresión múltiple

El R^2 se define igual que en regresión simple:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

Problema: R^2 siempre aumenta (o se mantiene) al agregar variables, incluso si son irrelevantes.

Ejemplo

- Modelo 1: $Y \sim X_1 \Rightarrow R^2 = 0,65$
- Modelo 2: $Y \sim X_1 + X_2 \Rightarrow R^2 = 0,66$
- Modelo 3: $Y \sim X_1 + X_2 + X_3 \Rightarrow R^2 = 0,662$

Incluso si X_3 es ruido puro, R^2 no disminuirá.

R^2 en regresión múltiple (cont.)

Consecuencia

No podemos comparar modelos con diferente número de variables usando solo R^2 . Necesitamos una medida que **penalice** la complejidad. Es como agregar filtros a una foto: siempre se ve “mejor”, pero no necesariamente más real.

Solución: El R^2 ajustado (R^2_{adj}) penaliza por el número de variables incluidas en el modelo.

R^2 ajustado

Definición

$$R_{\text{adj}}^2 = 1 - \frac{\text{SSE}/(n - p - 1)}{\text{SST}/(n - 1)} = 1 - \frac{\text{MSE}}{\text{MST}}$$

donde n = observaciones, p = predictores, MSE = cuadrado medio del error, MST = cuadrado medio total.

Propiedades:

- $R_{\text{adj}}^2 \leq R^2$
- R_{adj}^2 puede disminuir si agregamos una variable irrelevante
- Penaliza por el número de predictores
- Útil para comparar modelos con diferente número de variables

Comparación: R^2 vs R^2 ajustado

```
# Modelo simple
modelo1 <- lm(MOD_INGLES_PUNT ~ INGLES_SABER11_PUNT,
              data = icfes_ni)
summary(modelo1)$r.squared    # 0.6524
summary(modelo1)$adj.r.squared # 0.6523

# Modelo multiple (4 variables)
modelo2 <- lm(MOD_INGLES_PUNT ~ INGLES_SABER11_PUNT +
              ESTRATO + PRIVADA + LOG_INGRESOS,
              data = icfes_ni)
summary(modelo2)$r.squared    # 0.6982
summary(modelo2)$adj.r.squared # 0.6979

# Modelo completo (8 variables)
summary(modelo_completo)$r.squared    # 0.7145
summary(modelo_completo)$adj.r.squared # 0.7140
```

Observación: R^2_{adj} es ligeramente menor que R^2 . La diferencia crece cuando agregamos muchas variables poco útiles.

¿Cuándo usar R^2 ajustado?

Regla práctica

- Para **reportar** el ajuste de un modelo: usar ambos (R^2 y R^2_{adj})
- Para **comparar** modelos con diferente número de variables: usar R^2_{adj}
- Para **seleccionar** el mejor modelo: complementar con AIC/BIC (siguiente sección)

Precaución

R^2_{adj} NO es una probabilidad ni una proporción estricta. Puede ser negativo si el modelo es muy malo (aunque en la práctica esto es raro).

Interpretación aproximada

Si $R^2_{\text{adj}} = 0,714$, aproximadamente el 71 % de la variabilidad de Y se explica por los predictores, ajustando por el número de variables.

Prueba F global

Hipótesis

- $H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$ (todos los coeficientes son cero; el modelo no es útil)
- $H_1: \text{Al menos un } \beta_j \neq 0$ (al menos un predictor es útil)

Estadístico:

$$F = \frac{\text{MSR}}{\text{MSE}} = \frac{\text{SSR}/p}{\text{SSE}/(n-p-1)} \sim F_{p,n-p-1} \quad \text{bajo } H_0$$

Regla de decisión:

- Rechazamos H_0 si $F > F_{\alpha,p,n-p-1}$ o si p-valor $< \alpha$

Interpretación

Si rechazamos H_0 , concluimos que **al menos una** variable predictora tiene efecto significativo sobre Y . El modelo en conjunto es útil.

Relación entre F y R^2

El estadístico F se puede expresar en función de R^2 :

$$F = \frac{R^2/p}{(1 - R^2)/(n - p - 1)}$$

Interpretación:

- R^2 alto $\Rightarrow F$ alto $\Rightarrow$ modelo significativo
- R^2 cercano a 0 $\Rightarrow F$ cercano a 0 $\Rightarrow$ modelo no útil

Ejemplo

Modelo con $R^2 = 0,714$, $p = 8$, $n = 5085$:

$$F = \frac{0,714/8}{(1 - 0,714)/(5085 - 8 - 1)} = \frac{0,08925}{0,0000564} \approx 1583$$

Con p-valor $< 2,2 \times 10^{-16}$, rechazamos H_0 : el modelo es altamente significativo.

Prueba t individual

Hipótesis para cada coeficiente

- $H_0: \beta_j = 0$ (el predictor X_j NO tiene efecto, controlando por los demás)
- $H_1: \beta_j \neq 0$ (el predictor X_j sí tiene efecto)

Estadístico: $t_j = \hat{\beta}_j / \text{SE}(\hat{\beta}_j) \sim t_{n-p-1}$ bajo H_0 . Rechazamos H_0 si $|t_j| > t_{\alpha/2, n-p-1}$ o si p-valor $< \alpha$.

Diferencia con regresión simple

En regresión múltiple, la prueba t para β_j evalúa el efecto de X_j **controlando por todas las demás variables**. El resultado puede cambiar drásticamente si agregamos o quitamos predictores.

Interpretando el output de summary()

```
summary(modelo_completo)
```

```
# Coefficients:
```

#	Estimate	Std. Error	t value	Pr(> t)	
# (Intercept)	28.342	2.145	13.21	< 2e-16	***
# INGLES_SABER11_PUNT	1.612	0.025	64.48	< 2e-16	***
# ESTRATO	1.876	0.312	6.01	2.1e-09	***
# PRIVADA	3.254	0.672	4.84	1.3e-06	***
# LOG_INGRESOS	2.145	0.421	5.09	3.6e-07	***
# REGION_CARIBE	-2.543	0.834	-3.05	0.00230	**
# REGION_PACIFICA	-1.267	0.752	-1.68	0.09234	.
# REGION_ORINOQUIA	-4.123	1.234	-3.34	0.00084	***
# REGION_BOGOTA	5.234	0.812	6.44	1.3e-10	***

Conclusión:

- Todas las variables son significativas **excepto** REGION_PACIFICA ($p = 0.092$)
- La región Pacífica no difiere significativamente de la Andina (al 5 %)

Significancia conjunta vs individual

Posible discrepancia

Es posible que:

- La prueba F global sea significativa, pero ningún coeficiente individual lo sea
- O viceversa (raro en la práctica)

Causas: multicolinealidad, tamaño muestral pequeño, efectos débiles pero múltiples.

Recomendación

Siempre reportar ambas pruebas (F global e individuales). Si hay discrepancia, investigar multicolinealidad (VIF) y considerar eliminar variables redundantes.

¿Qué es el sesgo por variable omitida?

Definición

El **sesgo por variable omitida** (Omitted Variable Bias, OVB) ocurre cuando:

1. Omitimos una variable relevante del modelo
2. Esa variable está correlacionada con al menos uno de los predictores incluidos

En este caso, los coeficientes estimados están **sesgados**.

Ejemplo

Si omitimos ESTRATO del modelo $\text{Inglés} = \beta_0 + \beta_1 \times \text{Privada} + \varepsilon$, y ESTRATO está correlacionado con PRIVADA, entonces $\hat{\beta}_1$ **sobre-estima** el efecto de IES privada.

Analogía: Si no controlan por nivel socioeconómico, podrían pensar que tener iPad mejora las notas, cuando en realidad es que familias de mayores ingresos compran iPads **y además** invierten más en educación.

Fórmula del sesgo

Si el modelo verdadero es:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

Pero estimamos el modelo omitido:

$$Y = \gamma_0 + \gamma_1 X_1 + u$$

Entonces el sesgo de $\hat{\gamma}_1$ es:

$$E(\hat{\gamma}_1) = \beta_1 + \beta_2 \times \frac{\text{Cov}(X_1, X_2)}{\text{Var}(X_1)}$$

Dirección del sesgo:

- Si $\beta_2 > 0$ y $\text{Cov}(X_1, X_2) > 0 \Rightarrow$ sesgo positivo (sobre-estimación)
- Si $\beta_2 > 0$ y $\text{Cov}(X_1, X_2) < 0 \Rightarrow$ sesgo negativo (sub-estimación)

Ejemplo empírico: efecto de IES privada

Modelo simple (omite ESTRATO):

```
modelo_omitido <- lm(MOD_INGLES_PUNT ~ PRIVADA, data = icfes_ni)
coef(modelo_omitido)
```

```
# (Intercept)    PRIVADA
#      154.82         7.35
```

Modelo controlando por ESTRATO:

```
modelo_con_estrato <- lm(MOD_INGLES_PUNT ~ PRIVADA + ESTRATO,
                        data = icfes_ni)
coef(modelo_con_estrato)
```

```
# (Intercept)    PRIVADA    ESTRATO
#      148.34         4.12         2.87
```


Ejemplo empírico: efecto de IES privada (cont.)

Observación: El coeficiente de PRIVADA cae de 7.35 a 4.12 al controlar por ESTRATO. El efecto aparente de IES privada estaba **inflado** por el sesgo de variable omitida.

Dirección del sesgo

- ESTRATO correlacionado positivamente con PRIVADA ($\text{Cov} > 0$)
- ESTRATO tiene efecto positivo en inglés ($\beta_2 > 0$)
- $\Rightarrow$ Sesgo positivo: $\hat{\gamma}_1 > \beta_1$ (sobre-estimación)

Verificar la correlación entre PRIVADA y ESTRATO

```
# Correlacion entre PRIVADA y ESTRATO
cor(icfes_ni$PRIVADA, icfes_ni$ESTRATO)

# [1] 0.38 (correlacion positiva moderada)

# Tabla cruzada
table(icfes_ni$PRIVADA, icfes_ni$ESTRATO)

#           1  2  3  4  5  6
#  0  456 823 512 387 123 34 (publicas)
#  1  234 512 687 823 412 82 (privadas)

# Media de estrato por tipo IES
tapply(icfes_ni$ESTRATO, icfes_ni$PRIVADA, mean)

#           0           1
#    2.43    3.21

# Los estudiantes de IES privadas tienen estrato mas alto
```

Conclusión: ESTRATO está correlacionado con PRIVADA, y afecta el puntaje de inglés. Omitir ESTRATO genera OVB.

Implicaciones del OVB

Problema para inferencia causal

Si queremos estimar el **efecto causal** de IES privada sobre inglés, debemos controlar por **todas** las variables confusoras. De lo contrario, el coeficiente NO representa el efecto causal.

Estrategias para mitigar OVB:

- Incluir todas las variables relevantes (si están disponibles)
- Usar variables instrumentales (IV)
- Diseños experimentales o cuasi-experimentales (RCT, DiD, RD)

Regla de oro

Nunca concluir causalidad solo con regresión observacional. Si ven que “usar iPad” se asocia con mejores notas, pregúntense: ¿qué variable omitida podría explicar ambas cosas?

¿Qué es la multicolinealidad?

Definición

La **multicolinealidad** ocurre cuando dos o más predictores están **altamente correlacionados** entre sí.

Tipos:

- **Perfecta:** Una variable es combinación lineal exacta de otras (raro; R lo detecta automáticamente)
- **Alta:** Correlación fuerte pero no perfecta (común en datos observacionales)

Consecuencias:

- Errores estándar **inflados**, intervalos de confianza muy amplios
- Coeficientes inestables, dificultad para detectar significancia individual

¿Qué es la multicolinealidad? (cont.)

Analogía

Horas en TikTok y horas en Instagram miden casi lo mismo (screen time en redes). Si meten ambas en el modelo, hay multicolinealidad: el modelo no puede separar el efecto de cada una.

Importante

La multicolinealidad **no afecta** R^2 ni la capacidad de predicción del modelo. Solo afecta la interpretación de los coeficientes individuales.

Factor de Inflación de la Varianza (VIF)

Definición

El **VIF** (Variance Inflation Factor) mide cuánto se infla la varianza de $\hat{\beta}_j$ debido a la correlación con otros predictores.

Para cada predictor X_j :

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

donde R_j^2 es el R^2 de la regresión auxiliar:

$$X_j = \alpha_0 + \alpha_1 X_1 + \cdots + \alpha_{j-1} X_{j-1} + \alpha_{j+1} X_{j+1} + \cdots + \alpha_p X_p + e$$

Es decir, regresamos X_j sobre todos los demás predictores.

Interpretación:

- $\text{VIF} = 1 \Rightarrow X_j$ no está correlacionado con otros predictores
- $\text{VIF} = 5 \Rightarrow$ la varianza de $\hat{\beta}_j$ es 5 veces mayor que si X_j fuera independiente

Reglas de pulgar para VIF

Umbrales comunes:

- $VIF < 5 \Rightarrow$ multicolinealidad **baja** (aceptable)
- $5 \leq VIF < 10 \Rightarrow$ multicolinealidad **moderada** (preocupante)
- $VIF \geq 10 \Rightarrow$ multicolinealidad **severa** (requiere acción)

Soluciones si VIF es alto

1. **Eliminar una de las variables correlacionadas** (la menos importante teóricamente)
2. **Combinar variables:** crear un índice o promedio
3. **Componentes principales (PCA):** reducir dimensionalidad
4. **Regularización:** Ridge regression (penaliza coeficientes grandes)
5. **Aumentar el tamaño muestral** (reduce errores estándar en general)

Calcular VIF en R

```
# Instalar paquete car (si no esta instalado)
# install.packages("car")
library(car)

# Calcular VIF para el modelo completo
vif(modelo_completo)

#      INGLES_SABER11_PUNT      ESTRATO
#              1.23              2.87
#      PRIVADA      LOG_INGRESOS
#              3.45              4.12
#      REGION_CARIBE      REGION_PACIFICA
#              1.18              1.09
#      REGION_ORINOQUIA      REGION_BOGOTA
#              1.05              1.32

# Todos los VIF < 5 => multicolinealidad baja
```

Conclusión: No hay problemas serios de multicolinealidad en este modelo.

Ejemplo con multicolinealidad severa

```
# Crear una variable casi perfectamente correlacionada
icfes_ni$ESTRATO_x2 <- icfes_ni$ESTRATO * 2 + rnorm(nrow(icfes_ni), 0, 0.1)

cor(icfes_ni$ESTRATO, icfes_ni$ESTRATO_x2)

# [1] 0.9998 (correlacion casi perfecta)

# Ajustar modelo con ambas
modelo_colin <- lm(MOD_INGLES_PUNT ~ ESTRATO + ESTRATO_x2,
                  data = icfes_ni)

vif(modelo_colin)

#      ESTRATO  ESTRATO_x2
#      5432.12    5432.12

# VIF extremadamente alto => multicolinealidad severa
# Los errores estandar seran enormes
```

Solución: Eliminar una de las dos variables (son redundantes).

Criterios de información: AIC y BIC

Problema

Queremos elegir el **mejor** modelo entre varios candidatos. ¿Cómo balanceamos ajuste y complejidad?

Dos criterios populares:

1. **AIC** (Akaike Information Criterion):

$$\text{AIC} = n \ln\left(\frac{\text{SSE}}{n}\right) + 2(p + 1)$$

2. **BIC** (Bayesian Information Criterion):

$$\text{BIC} = n \ln\left(\frac{\text{SSE}}{n}\right) + (p + 1) \ln(n)$$

Interpretación: Menor AIC/BIC $\Rightarrow$ mejor modelo. BIC penaliza más la complejidad que AIC.

AIC vs BIC

AIC:

- Derivado de teoría de información (Kullback-Leibler divergence)
- Penaliza con $2(p + 1)$; favorece modelos más complejos
- Mejor para predicción

BIC:

- Derivado de teoría bayesiana
- Penaliza con $(p + 1) \ln(n)$; si $n > 8$, BIC penaliza más que AIC
- Favorece modelos más simples (parsimonia); mejor para inferencia

Regla práctica

- Si el objetivo es **predicción**: usar AIC
- Si el objetivo es **inferencia/interpretación**: usar BIC

Calcular AIC y BIC en R

```
# Modelo 1: solo Saber 11
modelo1 <- lm(MOD_INGLES_PUNT ~ INGLES_SABER11_PUNT,
              data = icfes_ni)

# Modelo 2: + estrato y privada
modelo2 <- lm(MOD_INGLES_PUNT ~ INGLES_SABER11_PUNT +
              ESTRATO + PRIVADA,
              data = icfes_ni)

# Modelo 3: modelo completo (8 variables)
# (ya ajustado: modelo_completo)

# Comparar AIC
AIC(modelo1, modelo2, modelo_completo)

#
```

	df	AIC
# modelo1	3	42345.2
# modelo2	5	41823.6
# modelo_completo	10	41234.8

```
# Menor AIC => modelo_completo es el mejor segun AIC
```

Comparar con BIC

```
# Comparar BIC
BIC(modelo1, modelo2, modelo_completo)

#           df      BIC
# modelo1      3  42367.1
# modelo2      5  41856.8
# modelo_completo 10  41302.4

# Menor BIC => modelo_completo tambien es el mejor segun BIC

# Diferencia AIC
AIC(modelo2) - AIC(modelo_completo)

# [1] 588.8 (modelo_completo es 589 puntos mejor en AIC)

# Diferencia BIC
BIC(modelo2) - BIC(modelo_completo)

# [1] 554.4
```

Conclusión: El modelo completo es sustancialmente mejor que los modelos más simples según ambos criterios.

Selección automática con step()

```
# Selección automática hacia atrás (backward)  
# Inicia con el modelo completo y va eliminando variables  
modelo_backward <- step(modelo_completo, direction = "backward")  
  
# Muestra los pasos:  
# Step 1: elimina REGION_PACIFICA (no significativa)  
# Step 2: se detiene (todas las demás son significativas)  
  
# Modelo final  
summary(modelo_backward)  
  
# Puede hacerse también forward (hacia adelante) o both (ambos)  
# backward: inicia con todas las variables, elimina una a una  
# forward: inicia sin variables, agrega una a una  
# both: combinación de ambos
```

Selección automática con `step()` (cont.)

Precaución

La selección automática puede llevar a overfitting y problemas de inferencia (p-valores inflados). Úsela como exploración, pero siempre valide con teoría y conocimiento del problema.

Tipos de selección

- **backward:** inicia con todas las variables, elimina una a una
- **forward:** inicia sin variables, agrega una a una
- **both:** combinación de ambos (stepwise)

¿Qué es una interacción?

Definición

Una **interacción** ocurre cuando el efecto de una variable X_1 sobre Y **depende del nivel** de otra variable X_2 .

Modelo con interacción:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 (X_1 \times X_2) + \varepsilon$$

Interpretación:

- β_1 = efecto de X_1 cuando $X_2 = 0$
- β_2 = efecto de X_2 cuando $X_1 = 0$
- β_3 = cómo cambia el efecto de X_1 cuando X_2 aumenta en 1 unidad

¿Qué es una interacción? (cont.)

Ejemplo conceptual

¿El efecto de IES privada sobre inglés es el **mismo** para todos los estratos, o es **mayor** en estratos altos? Similar a preguntarse: ¿el efecto de usar iPad en las notas es igual para todos, o depende de si además tienen acceso a internet en casa?

Interpretación matemática de la interacción

Modelo con interacción:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 (X_1 X_2) + \varepsilon$$

Reordenando:

$$Y = \beta_0 + (\beta_1 + \beta_3 X_2) X_1 + \beta_2 X_2 + \varepsilon$$

El efecto marginal de X_1 es:

$$\frac{\partial Y}{\partial X_1} = \beta_1 + \beta_3 X_2$$

Interpretación:

- Si $\beta_3 = 0 \Rightarrow$ no hay interacción (efecto constante)
- Si $\beta_3 > 0 \Rightarrow$ el efecto de X_1 aumenta cuando X_2 aumenta
- Si $\beta_3 < 0 \Rightarrow$ el efecto de X_1 disminuye cuando X_2 aumenta

Ejemplo: interacción PRIVADA × ESTRATO

Pregunta: ¿El efecto de IES privada varía según el estrato?

```
# Modelo con interaccion
modelo_interaccion <- lm(MOD_INGLES_PUNT ~
                          PRIVADA * ESTRATO,
                          data = icfes_ni)

summary(modelo_interaccion)

# Coefficients:
#               Estimate Std. Error t value Pr(>|t|)
# (Intercept)    149.23      1.12  133.24 < 2e-16 ***
# PRIVADA         2.34       1.87   1.25  0.21123
# ESTRATO         2.67       0.38   7.03  2.3e-12 ***
# PRIVADA:ESTRATO 0.89       0.52   1.71  0.08734 .
#
# Residual standard error: 19.45 on 5081 DF
# Multiple R-squared: 0.3512, Adjusted R-squared: 0.3508
```

Interpretación del modelo con interacción

Ecuación estimada:

$$\widehat{\text{MOD_INGLES}} = 149,23 + 2,34 \times \text{PRIVADA} + 2,67 \times \text{ESTRATO} + 0,89 \times (\text{PRIVADA} \times \text{ESTRATO})$$

Efecto de PRIVADA según ESTRATO:

$$\frac{\partial \text{Inglés}}{\partial \text{PRIVADA}} = 2,34 + 0,89 \times \text{ESTRATO}$$

- Estrato 1: efecto = $2,34 + 0,89 \times 1 = 3,23$ puntos
- Estrato 3: efecto = $2,34 + 0,89 \times 3 = 5,01$ puntos
- Estrato 5: efecto = $2,34 + 0,89 \times 5 = 6,79$ puntos

Interpretación: El efecto de IES privada **aumenta** con el estrato (0.89 puntos adicionales por cada nivel de estrato), aunque la interacción es solo marginalmente significativa ($p = 0.087$).

Visualización de la interacción

```
# Crear grafico de interaccion
library(ggplot2)

# Predecir para diferentes combinaciones
predicciones <- expand.grid(
  PRIVADA = c(0, 1),
  ESTRATO = 1:6
)
predicciones$MOD_INGLES_PUNT <- predict(modelo_interaccion,
                                       newdata = predicciones)

ggplot(predicciones, aes(x = ESTRATO, y = MOD_INGLES_PUNT,
                        color = factor(PRIVADA), group = PRIVADA)) +
  geom_line(size = 1.2) +
  geom_point(size = 3) +
  labs(title = "Interaccion PRIVADA x ESTRATO",
       x = "Estrato", y = "Puntaje ingles predicho",
       color = "Tipo IES") +
  scale_color_manual(values = c("blue", "red"),
                    labels = c("Publica", "Privada")) +
  theme_minimal()
```

Interacción entre dos variables continuas

```
# Ejemplo: interaccion INGLES_SABER11 x LOG_INGRESOS
modelo_cont_int <- lm(MOD_INGLES_PUNT ~
                      INGLES_SABER11_PUNT * LOG_INGRESOS,
                      data = icfes_ni)

summary(modelo_cont_int)

# Coefficients:
#
#               Estimate Std. Error t value Pr(>|t|)
# (Intercept)      22.345      3.821   5.85 5.2e-09 ***
# INGLES_SABER11_PUNT      1.523      0.062  24.56 < 2e-16 ***
# LOG_INGRESOS        1.234      0.512   2.41  0.0160 *
# INGLES_SABER11_PUNT:LOG_INGRESOS 0.023      0.009   2.56  0.0105 *
#
# La interaccion es significativa (p = 0.01)
```

Interpretación: El efecto de Saber 11 sobre Saber Pro es **mayor** en estudiantes de hogares con mayores ingresos.

Resumen de regresión múltiple

Conceptos clave

- Modelo: $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon$
- β_j = efecto de X_j **controlando por** las demás variables
- OLS minimiza $\sum e_i^2$ para estimar $\hat{\beta}_0, \dots, \hat{\beta}_p$
- R_{adj}^2 penaliza por número de variables
- AIC/BIC balancean ajuste y complejidad

Pruebas de significancia

- Prueba F global: $H_0 : \beta_1 = \dots = \beta_p = 0$
- Prueba t individual: $H_0 : \beta_j = 0$ (controlando por los demás)
- Reportar ambas + IC 95 %

Problemas comunes y soluciones

Sesgo por variable omitida (OVB)

- Omitir variables relevantes correlacionadas con X sesga $\hat{\beta}$
- Solución: incluir todas las variables confusoras

Multicolinealidad

- Predictores altamente correlacionados $\Rightarrow$ errores estándar inflados
- Detectar con VIF (> 5 preocupante, > 10 severo)
- Solución: eliminar variables redundantes, PCA, regularización

Interacciones

- El efecto de X_1 depende de X_2 : $Y \sim X_1 \times X_2$
- β_3 = cómo cambia el efecto de X_1 con X_2

Checklist para análisis de regresión múltiple

1. **Exploración inicial:** scatter plots, correlaciones
2. **Ajustar modelo:** `lm(Y ~ X1 + X2 + ...)`
3. **Evaluar ajuste:** R^2 , R^2_{adj} , prueba F global
4. **Significancia individual:** pruebas t, p-valores, IC 95 %
5. **Diagnóstico:**
 - Residuos: `plot(modelo)`
 - Multicolinealidad: `vif(modelo)`
 - Normalidad: Shapiro-Wilk, Q-Q plot
 - Homocedasticidad: Breusch-Pagan test
6. **Selección de modelo:** AIC/BIC, validación cruzada
7. **Interacciones:** explorar si los efectos son condicionales
8. **Reportar:** tabla de coeficientes, IC, R^2 , interpretación

Ejemplo final: reporte profesional

Objetivo: Modelar el puntaje de inglés en Saber Pro para estudiantes de Negocios Internacionales.

Variables:

- Dependiente: MOD_INGLES_PUNT
- Independientes: Saber 11, estrato, tipo IES, log(ingresos), región

Resultados:

- $R^2_{adj} = 0,714$ (71.4 % de variabilidad explicada)
- Prueba F: $F = 1586$, $p < 0,001$ (modelo altamente significativo)
- Todos los predictores significativos excepto Región Pacífica
- $VIF < 5$ para todas las variables (sin multicolinealidad severa)
- Residuos aproximadamente normales (Shapiro $p = 0.08$)
- Leve heterocedasticidad (Breusch-Pagan $p = 0.03$), considerar errores robustos

Conclusión: El modelo ajusta bien y revela efectos significativos de Saber 11, estrato, tipo de IES, ingresos y región sobre el desempeño en inglés.

Próximos pasos

Temas avanzados (fuera del alcance de este curso)

- Diagnósticos avanzados: influential points (Cook's distance), leverage
- Errores estándar robustos (HC, HAC)
- Modelos no lineales: polinomios, splines, GAM
- Regresión regularizada: Ridge, Lasso, Elastic Net
- Regresión logística (para variables dependientes binarias)

Recursos recomendados

- Wooldridge, J. (2019). *Introductory Econometrics*. Capítulos 3-7.
- James, G. et al. (2021). *An Introduction to Statistical Learning*. Capítulo 3.
- R Documentation: `?lm`, `?summary.lm`, `?vif`