

Sesión 11: Diagnósticos de Regresión

Validando los supuestos del modelo OLS

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Viernes 6 de noviembre de 2026

Agenda

¿Por qué importan los diagnósticos?

Los 4 gráficos diagnósticos de R

Heterocedasticidad y Breusch-Pagan

Autocorrelación y Durbin-Watson

Observaciones influyentes: Cook's D

Errores estándar robustos (Huber-White)

Ejemplo integrado en R

Resumen

Los supuestos del modelo OLS

Resumen: el modelo clásico de regresión lineal

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

Supuestos clave (Gauss-Markov):

1. **Linealidad:** la relación entre Y y las X es lineal
2. **Exogeneidad:** $E(\varepsilon_i|X) = 0$
3. **Homocedasticidad:** $\text{Var}(\varepsilon_i|X) = \sigma^2$ (constante)
4. **No autocorrelación:** $\text{Cor}(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$
5. **Normalidad** (para inferencia): $\varepsilon_i \sim N(0, \sigma^2)$

Resultado fundamental

Si se cumplen los supuestos 1-4, OLS es **BLUE** (Best Linear Unbiased Estimator). Si además se cumple 5, las pruebas t y F son válidas.

¿Qué pasa si se violan los supuestos?

Supuesto violado	Consecuencia	Síntoma
Linealidad	Estimadores sesgados	Patrón en residuos
Exogeneidad	Estimadores sesgados	Variable omitida
Homocedasticidad	EE incorrectos, ineficiente	Embudo en residuos
No autocorrelación	EE incorrectos	Patrón temporal
Normalidad	IC y pruebas inválidas	Q-Q desviado

Ejemplo: heterocedasticidad


Los $\hat{\beta}$ siguen insesgados, pero los errores estándar son **incorrectos** $\Rightarrow$ los IC y las pruebas t son **inválidas**.

El papel de los diagnósticos

Diagnósticos = verificar supuestos *después* de estimar

Los diagnósticos nos permiten detectar problemas con el modelo ajustado y decidir si necesitamos:

- Transformar variables
- Agregar/eliminar variables
- Usar errores estándar robustos
- Cambiar de modelo (ej: pasar a logit, poisson, etc.)



Herramientas diagnósticas en R

Principales funciones:

- `plot(modelo)`: genera 4 gráficos diagnósticos automáticamente
- `residuals(modelo)`: extrae los residuos $e_i = Y_i - \hat{Y}_i$
- `fitted(modelo)`: extrae los valores ajustados $\hat{Y}_i$
- `rstandard(modelo)`: residuos estandarizados
- `cooks.distance(modelo)`: distancia de Cook para cada observación
- `lmtest::bptest(modelo)`: test de Breusch-Pagan (heterocedasticidad)
- `lmtest::dwtest(modelo)`: test de Durbin-Watson (autocorrelación)
- `car::vif(modelo)`: factor de inflación de la varianza (multicolinealidad)

Estrategia

Comenzar con `plot(modelo)` y luego profundizar con tests formales según lo que se observe.

Los 4 gráficos de `plot(modelo)`

Generación automática en R

```
# Ajustar modelo
modelo <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
             ESTU_GENERO + PUNT_INGLES_S11, data = ni_data)

# Generar los 4 graficos diagnosticos
par(mfrow = c(2, 2))
plot(modelo)
```

Los 4 gráficos son:

1. **Residuals vs Fitted**: detecta no linealidad y heterocedasticidad
2. **Normal Q-Q**: verifica normalidad de residuos
3. **Scale-Location**: detecta heterocedasticidad
4. **Residuals vs Leverage**: identifica observaciones influyentes

Gráfico 1: Residuals vs Fitted

¿Qué muestra?


- Eje X: valores ajustados $\hat{Y}_i$
- Eje Y: residuos e_i
- Línea roja: tendencia suavizada (loess)

¿Qué buscar?

- **Ideal**: puntos dispersos aleatoriamente alrededor de $y = 0$, línea roja horizontal
- **Problema 1**: línea roja con curvatura $\Rightarrow$ no linealidad
- **Problema 2**: forma de embudo $\Rightarrow$ heterocedasticidad


Gráfico 1: Patrones visuales

Patrón ideal



Dispersión constante alrededor de cero.

Patrón problemático



Curvatura en la línea roja.

Gráfico 2: Normal Q-Q

¿Qué muestra?

- Eje X: cuantiles teóricos de $N(0, 1)$
- Eje Y: residuos estandarizados
- Línea diagonal: referencia para normalidad perfecta

¿Qué buscar?


- **Ideal**: puntos siguen la línea diagonal
- **Problema**: desviación sistemática:
 - Colas pesadas: puntos se alejan en los extremos
 - Asimetría: curvatura en S

Interpretación

Desviaciones leves son normales. Preocuparse solo si la desviación es marcada y afecta muchos puntos.


Gráfico 2: Patrones Q-Q

Normalidad (bueno)



Puntos cerca de la línea diagonal.

Colas pesadas (malo)



Puntos se alejan en los extremos.

Gráfico 3: Scale-Location

¿Qué muestra?

- Eje X: valores ajustados $\hat{Y}_i$
- Eje Y: $\sqrt{|\text{residuos estandarizados}|}$
- Línea roja: tendencia suavizada

¿Para qué sirve?


- Detecta heterocedasticidad de manera más clara que Residuals vs Fitted
- Al elevar al cuadrado (bueno, raíz cuadrada), se enfatiza la dispersión

¿Qué buscar?

- **Ideal**: línea roja horizontal, puntos con dispersión constante
- **Problema**: línea roja con pendiente $\Rightarrow$ heterocedasticidad


Gráfico 3: Patrones Scale-Location

Homocedasticidad



Línea roja horizontal.

Heterocedasticidad



Línea roja con pendiente.

Gráfico 4: Residuals vs Leverage

¿Qué muestra?

- Eje X: leverage (apalancamiento) h_{ii}
- Eje Y: residuos estandarizados
- Líneas punteadas: isolíneas de distancia de Cook


Conceptos clave:

- **Leverage**: qué tan extremo es X_i respecto al centro de los datos
- **Residuo**: qué tan lejos está Y_i de $\hat{Y}_i$
- **Observación influyente**: alto leverage + alto residuo

¿Qué buscar?

- Puntos fuera de las líneas de Cook $D > 0,5$ o $D > 1$
- Estas observaciones cambian mucho los coeficientes

Gráfico 4: Interpretación



El punto rojo tiene alto leverage y alto residuo $\Rightarrow$ influyente

Ejemplo en R: generando los 4 gráficos

```
# Cargar datos
ni_data <- read.csv("icfes_ni.csv")

# Estimar modelo
modelo <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
             ESTU_GENERO + PUNT_INGLES_S11, data = ni_data)

# Generar los 4 graficos diagnosticos
par(mfrow = c(2, 2)) # 2x2 grid
plot(modelo)
par(mfrow = c(1, 1)) # volver a 1x1
```


Ejemplo en R: gráficos individuales

```
# Para ver cada grafico individualmente:  
plot(modelo, which = 1) # Residuals vs Fitted  
plot(modelo, which = 2) # Q-Q plot  
plot(modelo, which = 3) # Scale-Location  
plot(modelo, which = 5) # Residuals vs Leverage (es el #5, no el #4)
```

Nota

El gráfico 4 por defecto es Cook's distance, pero el más útil para observaciones influyentes es el 5 (Residuals vs Leverage).

Interpretación conjunta de los gráficos

Gráfico	Detecta	Solución
Residuals vs Fitted	No linealidad	Transformar Y o X
	Heterocedasticidad	Errores robustos
Normal Q-Q	No normalidad	Transformar Y, o confiar TCL
Scale-Location	Heterocedasticidad	Errores robustos
Residuals vs Leverage	Obs. influyentes	Investigar, quizás eliminar

Estrategia práctica de diagnóstico

Pasos a seguir

1. Ajustar el modelo
2. Generar los 4 gráficos con `plot(modelo)`
3. Si se observan problemas, realizar tests formales (Breusch-Pagan, etc.)
4. Aplicar correcciones según sea necesario
5. Re-estimar y verificar de nuevo

El supuesto de homocedasticidad

Definición formal

Homocedasticidad: la varianza del error es constante para todas las observaciones.

$$\text{Var}(\varepsilon_i | X_1, X_2, \dots, X_k) = \sigma^2 \quad \text{para todo } i$$

Heterocedasticidad: la varianza del error NO es constante.

$$\text{Var}(\varepsilon_i | X) = \sigma_i^2 \quad (\text{varía con } i)$$

Ejemplo de homocedasticidad

Estudiantes de todos los estratos tienen la misma dispersión en inglés después de controlar por las X .

Ejemplo de heterocedasticidad

Estudiantes de estratos bajos tienen mayor variabilidad en inglés que los de estratos altos (después de controlar).

Consecuencias de la heterocedasticidad

Impacto en OLS

- Los coeficientes $\hat{\beta}$ siguen siendo insesgados
- Pero ya NO son eficientes (BLUE se pierde)
- Los errores estándar calculados por OLS son incorrectos
- Los IC y las pruebas t y F son inválidas

¿Por qué los errores estándar son incorrectos?

La fórmula estándar asume varianza constante σ^2 : $\text{Var}(\hat{\beta}) = \sigma^2(X'X)^{-1}$.
Con heterocedasticidad, la varianza verdadera es:

$$\text{Var}(\hat{\beta}) = (X'X)^{-1}X'\Omega X(X'X)^{-1}$$

donde $\Omega = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2)$.

Test de Breusch-Pagan

Hipótesis

H_0 : Homocedasticidad (varianza constante) H_1 : Heterocedasticidad

Procedimiento:

1. Estimar el modelo original y obtener los residuos e_i
2. Calcular e_i^2 (residuos al cuadrado)
3. Regresar e_i^2 contra TODAS las variables X del modelo original:

$$e_i^2 = \gamma_0 + \gamma_1 X_{1i} + \gamma_2 X_{2i} + \cdots + \gamma_k X_{ki} + u_i$$

4. Extraer el R^2 de esta regresión auxiliar

Test de Breusch-Pagan: estadístico y decisión

Procedimiento (continuación):

5. Calcular el estadístico de prueba:

$$BP = n \cdot R^2 \sim \chi_k^2$$

donde n = tamaño de muestra, k = número de variables explicativas (sin contar la constante)

6. Si $BP > \chi_{k,\alpha}^2$ (o si $p < \alpha$), rechazamos $H_0 \Rightarrow$ hay heterocedasticidad

Breusch-Pagan en R

```
library(lmtest)

# Estimar modelo
modelo <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
             ESTU_GENERO + PUNT_INGLES_S11, data = ni_data)

# Test de Breusch-Pagan
bptest(modelo)
```


Breusch-Pagan en R: interpretación

Ejemplo de output

```
studentized Breusch-Pagan test
```

```
data:  modelo
```

```
BP = 38.472, df = 4, p-value = 8.741e-08
```

Interpretación:

- $BP = 38,472$ con $df = 4$ (4 variables explicativas)
- $p < 0,001 \Rightarrow$ rechazamos H_0
- **Conclusión:** hay evidencia de heterocedasticidad

Variantes del test de Breusch-Pagan

Breusch-Pagan estándar

Asume que los errores al cuadrado se distribuyen χ^2 . Versión más común.

Breusch-Pagan estudentizado (por defecto en R)

Usa residuos estudentizados en lugar de residuos crudos. Más robusto a no normalidad.

$$BP = n \cdot R^2 \sim \chi_k^2$$

Test de White

Variante más general: incluye cuadrados y productos cruzados de las X .


$$e_i^2 = \gamma_0 + \gamma_1 X_{1i} + \gamma_2 X_{2i} + \gamma_3 X_{1i}^2 + \gamma_4 X_{2i}^2 + \gamma_5 X_{1i} X_{2i} + u_i$$

Detecta formas más complejas de heterocedasticidad, pero usa más grados de libertad.

Regla práctica: comenzar con Breusch-Pagan. Si hay muchas variables, usar White.


Visualización de heterocedasticidad

Homocedasticidad (bueno)



Dispersión constante alrededor de cero.

Heterocedasticidad (malo)



Embudo: dispersión crece con $\hat{Y}$.

El supuesto de no autocorrelación

Definición

No autocorrelación: los errores de diferentes observaciones no están correlacionados: $\text{Cor}(\varepsilon_i, \varepsilon_j) = 0$ para todo $i \neq j$. **Autocorrelación:** $\text{Cor}(\varepsilon_i, \varepsilon_{i-1}) \neq 0$.

¿Cuándo es común?

- **Series de tiempo:** observaciones consecutivas (PIB mensual, ventas diarias)
- **Datos espaciales:** observaciones vecinas
- Menos común en corte transversal

Consecuencias

Similar a heterocedasticidad:

- $\hat{\beta}$ sigue insesgado
- Pero ineficiente
- Errores estándar incorrectos
- IC y pruebas inválidas

Test de Durbin-Watson

Hipótesis

H_0 : No hay autocorrelación de primer orden

H_1 : Hay autocorrelación de primer orden

Estadístico de Durbin-Watson:

$$DW = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}$$

Interpretación (rango: $0 \leq DW \leq 4$):

- $DW \approx 2$: no autocorrelación
- $DW < 2$: autocorrelación positiva (errores consecutivos con mismo signo)
- $DW > 2$: autocorrelación negativa (errores consecutivos con signos opuestos)

Regla práctica: si $1,5 < DW < 2,5$, probablemente no hay problema.

Durbin-Watson en R

```
library(lmtest)

# Test de Durbin-Watson
dwtest(modelo)
```

Ejemplo de output

Durbin-Watson test

```
data:  modelo
DW = 1.9823, p-value = 0.4521
alternative hypothesis: true autocorrelation is greater than 0
```

Durbin-Watson: interpretación

Interpretación del ejemplo:


- $DW = 1,9823 \approx 2 \Rightarrow$ no hay autocorrelación
- $p = 0,4521 > 0,05 \Rightarrow$ no rechazamos H_0
- **Conclusión:** no hay evidencia de autocorrelación de primer orden

Nota

En datos de corte transversal (como ICFES), la autocorrelación es rara. El test es más relevante para series de tiempo.

Visualización de autocorrelación


Sin autocorrelación



Patrón aleatorio, sin tendencias.

Con autocorrelación positiva, el DW será significativamente menor que 2. En el ejemplo de la derecha, podríamos tener $DW \approx 0,5$.

Con autocorrelación positiva



Rachas: positivos seguidos de positivos.

Conceptos: leverage y residuos

Leverage (apalancamiento)

Mide qué tan extremo es el valor de X_i respecto al centro de los datos.

$$h_{ii} = \text{diagonal de } H = X(X'X)^{-1}X'$$

- $0 \leq h_{ii} \leq 1$, $\sum h_{ii} = k + 1$
- Promedio: $\bar{h} = (k + 1)/n$
- Alto leverage: $h_{ii} > 2\bar{h}$

Residuo

Mide qué tan lejos está Y_i de $\hat{Y}_i$:

$$e_i = Y_i - \hat{Y}_i$$

Un residuo grande indica que el modelo no ajusta bien esa observación.

Distancia de Cook

Definición

Mide cuánto cambiarían TODOS los coeficientes $\hat{\beta}$ si elimináramos la observación i .


$$D_i = \frac{e_i^2}{p \cdot MSE} \cdot \frac{h_{ii}}{(1 - h_{ii})^2}$$

donde e_i = residuo, p = número de parámetros, MSE = error cuadrático medio, h_{ii} = leverage.

Interpretación:

- D_i combina residuo grande y leverage alto
- Observación con alto D_i es **influyente**: afecta mucho los coeficientes
- Regla de pulgar: $D_i > \frac{4}{n}$ merece investigación
- Valores $D_i > 1$ son muy influyentes

Tipos de observaciones



- Normales: bajo leverage, bajo residuo $\Rightarrow D_i$ bajo
- Outlier: bajo leverage, alto residuo $\Rightarrow D_i$ moderado
- Alto leverage: alto leverage, bajo residuo $\Rightarrow D_i$ bajo (no influyente)
- Influyente: alto leverage Y alto residuo $\Rightarrow D_i$ alto

Calculando la distancia de Cook en R

```
# Extraer distancia de Cook para cada observacion
cook_d <- cooks.distance(modelo)

# Ver las 5 observaciones mas influyentes
head(sort(cook_d, decreasing = TRUE), 5)

# Identificar observaciones con  $D > 4/n$ 
n <- nrow(ni_data)
umbral <- 4 / n
influyentes <- which(cook_d > umbral)

# Ver cuantas y cuales observaciones son influyentes
length(influyentes)
ni_data[influyentes, ]
```

Graficando la distancia de Cook

```
# Graficar distancia de Cook
plot(cook_d, type = "h", lwd = 2, col = "steelblue",
     main = "Distancia de Cook",
     ylab = "Cook's distance", xlab = "Observacion")
abline(h = umbral, col = "red", lty = 2, lwd = 2)
text(x = n*0.8, y = umbral*1.5, labels = "Umbral  $4/n$ ", col = "red")
```

Interpretación del gráfico

Las barras que sobrepasan la línea roja ($4/n$) corresponden a observaciones influyentes que merecen investigación.

¿Qué hacer con observaciones influyentes?

NO eliminar automáticamente

Eliminar observaciones sin justificación es manipular los datos. Siempre investigar primero.

Pasos a seguir:

1. **Verificar datos:** ¿Es un error de entrada de datos? ¿Valor imposible?
2. **Contextualizar:** ¿Es un caso especial legítimo?
3. **Re-estimar sin la observación:** ¿Cambian las conclusiones?
4. **Reportar sensibilidad:** “Resultados robustos a exclusión de obs. influyentes” o “Las conclusiones cambian al excluir...”

Observaciones influyentes: ejemplo

Ejemplo: error de datos

Si una observación tiene `MOD_INGLES_PUNT = 300` (máximo 100), es claramente un error $\Rightarrow$ eliminar.

Ejemplo: caso legítimo

Si una observación es un estudiante con puntaje 95 en inglés pero estrato 1, es raro pero legítimo $\Rightarrow$ NO eliminar, pero reportar sensibilidad.

Análisis de sensibilidad

```
# Modelo completo
modelo_completo <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
                      ESTU_GENERO + PUNT_INGLES_S11, data = ni_data)

# Identificar observaciones influyentes
cook_d <- cooks.distance(modelo_completo)
influyentes <- which(cook_d > 4 / nrow(ni_data))

# Modelo sin observaciones influyentes
ni_sin_inf <- ni_data[-influyentes, ]
modelo_sin_inf <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
                    ESTU_GENERO + PUNT_INGLES_S11,
                    data = ni_sin_inf)

# Comparar coeficientes
library(texreg)
screenreg(list(modelo_completo, modelo_sin_inf),
          custom.model.names = c("Completo", "Sin influyentes"))
```

Si los coeficientes cambian mucho, los resultados son sensibles a esas observaciones.

La solución a la heterocedasticidad

Errores estándar robustos (Huber-White)

Ante heterocedasticidad, podemos:

- Transformar las variables para reducir heterocedasticidad (ej: log)
- Usar WLS (Weighted Least Squares) si conocemos la estructura de σ_i^2
- O simplemente usar **errores estándar robustos**

Ventajas de los errores robustos:

- Los coeficientes $\hat{\beta}$ NO cambian (mismos valores que OLS estándar)
- Solo cambian los errores estándar (se corrigen)
- Los IC y pruebas t se vuelven válidos
- No requiere especificar la forma de heterocedasticidad

Regla práctica

Si hay heterocedasticidad (BP rechaza H_0), SIEMPRE reportar errores robustos.

Tipos de errores robustos

Tipo	Descripción
HC0	Versión original de White. No corrige por grados de libertad.
HC1	Corrección por grados de libertad: $\frac{n}{n-k}$. Más común en econometría.
HC2	Usa leverage: $\frac{e_i^2}{1-h_{ii}}$. Más robusto.
HC3	Versión más conservadora: $\frac{e_i^2}{(1-h_{ii})^2}$. Recomendado para n pequeño.

¿Cuál usar?

- **HC1**: el más común, recomendado por defecto
- **HC3**: si la muestra es pequeña ($n < 250$) o hay alto leverage
- En la práctica, los resultados suelen ser muy similares

Errores robustos en R

```
library(sandwich) # para vcovHC
library(lmtest)   # para coeftest

# Modelo OLS estandar
modelo <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
             ESTU_GENERO + PUNT_INGLES_S11, data = ni_data)

# Tabla con errores estandar clasicos (NO robustos)
summary(modelo)

# Tabla con errores estandar robustos (HC1)
coeftest(modelo, vcov = vcovHC(modelo, type = "HC1"))

# Tambien puedes usar HC3
coeftest(modelo, vcov = vcovHC(modelo, type = "HC3"))
```

Nota: `vcovHC` calcula la matriz de varianza-covarianza robusta, y `coeftest` la usa para recalcular los errores estándar y las pruebas *t*.

Comparación: errores estándar clásicos

Errores estándar clásicos (OLS)

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	120.345	3.215	37.434	< 2e-16	***
ESTU_ESTRATO	2.134	0.421	5.068	4.32e-07	***
PRIVADA	8.765	1.234	7.103	1.56e-12	***
ESTU_GENERO	-1.543	0.987	-1.563	0.118	
PUNT_INGLES_S11	0.512	0.034	15.059	< 2e-16	***

Comparación: errores estándar robustos

Errores estándar robustos (HC1)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	120.345	3.654	32.936	< 2e-16 ***
ESTU_ESTRATO	2.134	0.512	4.168	3.18e-05 ***
PRIVADA	8.765	1.543	5.681	1.52e-08 ***
ESTU_GENERO	-1.543	1.087	-1.419	0.156
PUNT_INGLES_S11	0.512	0.041	12.488	< 2e-16 ***

Los coeficientes son idénticos, pero los SE aumentaron (especialmente para PRIVADA). Algunas variables pueden perder significancia.

Intervalos de confianza robustos

```
# IC con errores estandar clasicos
confint(modelo)

# IC con errores robustos HC1
coefci(modelo, vcov = vcovHC(modelo, type = "HC1"))
```

IC clásicos (95 %)

	2.5 %	97.5 %
ESTU_ESTRATO	1.309	2.959
PRIVADA	6.347	11.183

IC robustos (95 %)

	2.5 %	97.5 %
ESTU_ESTRATO	1.130	3.138
PRIVADA	5.740	11.790

Los IC robustos son más amplios (reflejan la mayor incertidumbre por heterocedasticidad).

¿Cuándo usar errores robustos?

Situación	Acción	Razón
Breusch-Pagan rechaza H_0	Usar robustos	Heterocedasticidad detectada
Breusch-Pagan no rechaza H_0	Opcional	No hay evidencia de heteroced.
Muestra grande ($n > 1000$)	Usar robustos	Casi no cuesta nada
Publicación académica	Usar robustos	Estándar en econometría

Recomendación general

En econometría moderna, es estándar reportar **siempre** errores robustos, incluso si Breusch-Pagan no rechaza H_0 .

Limitaciones de los errores robustos

Importante

Los errores robustos NO corrigen sesgos. Si el modelo está mal especificado (variable omitida, no linealidad), los errores robustos no ayudan.

Ejemplo completo: diagnósticos paso a paso

```
# 1. Cargar datos
ni_data <- read.csv("icfes_ni.csv")

# 2. Estimar modelo
modelo <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
             ESTU_GENERO + PUNT_INGLES_S11, data = ni_data)

# 3. Resumen basico
summary(modelo)

# 4. Graficos diagnosticos
par(mfrow = c(2, 2))
plot(modelo)
par(mfrow = c(1, 1))
# Revisar: patron/embudo, Q-Q, Scale-Location, Cook
```

Ejemplo completo: tests formales

```
library(lmtest); library(car)

# 5. Heterocedasticidad ( $p < 0.05 \Rightarrow$  heteroced.)
bptest(modelo)

# 6. Autocorrelacion ( $DW \sim 2 \Rightarrow$  ok)
dwtest(modelo)

# 7. Multicolinealidad ( $VIF > 10 \Rightarrow$  severa)
vif(modelo)

# 8. Observaciones influyentes
cook_d <- cooks.distance(modelo)
influyentes <- which(cook_d > 4 / nrow(ni_data))
length(influyentes)
ni_data[influyentes, ]
```

Ejemplo completo: corrección con errores robustos

```
library(sandwich); library(texreg)

# 9. Errores robustos
coeftest(modelo, vcov = vcovHC(modelo, type = "HC1"))

# 10. Comparar clasicos vs robustos
screenreg(list(modelo, modelo),
  override.se = list(NULL, sqrt(diag(vcovHC(modelo, "HC1")))),
  override.pvalues = list(NULL,
    coeftest(modelo, vcovHC(modelo, "HC1"))[, 4]),
  custom.model.names = c("OLS clasico", "OLS robusto"))
```

Ejemplo completo: análisis de sensibilidad

```
# 11. Analisis de sensibilidad (sin influyentes)
if (length(influyentes) > 0) {
  modelo_sin_inf <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
                      ESTU_GENERO + PUNT_INGLES_S11,
                      data = ni_data[-influyentes, ])
  screenreg(list(modelo, modelo_sin_inf),
            custom.model.names = c("Completo", "Sin influyentes"))
}
```

Interpretación del ejemplo

Hallazgos esperados con datos ICFES de NI:

1. **Heterocedasticidad:** BP probablemente rechaza H_0 . Estratos bajos tienen mayor variabilidad $\Rightarrow$ errores robustos HC1
2. **Normalidad:** Q-Q con desviación leve en colas. No crítico con n grande (TCL)
3. **Obs. influyentes:** probablemente algunas (5-10). Verificar si son errores o casos legítimos; reportar sensibilidad
4. **Autocorrelación:** $DW \approx 2$ (no hay problema en corte transversal)
5. **Multicolinealidad:** VIF probablemente bajo (variables poco correlacionadas)

Checklist de diagnósticos

Protocolo estándar – después de estimar cualquier modelo OLS:

1. Generar `plot(modelo)` y revisar los 4 gráficos
2. Realizar `bptest(modelo)` para heterocedasticidad
3. Si hay heterocedasticidad, usar `coeftest(modelo, vcovHC(...))`
4. Verificar `vif(modelo)` para multicolinealidad
5. Identificar obs. influyentes con `cooks.distance(modelo)`
6. Investigar influyentes y reportar análisis de sensibilidad
7. Reportar resultados con errores robustos si hay heterocedasticidad

Importante

Nunca reportar resultados OLS sin verificar supuestos. Los diagnósticos son parte fundamental del análisis.

Tabla resumen: problemas y soluciones

Problema	Test	Detección	Solución
Heterocedasticidad	Breusch-Pagan	Embudo en residuos, Scale-Location con pendiente	Errores robustos (HC1 o HC3)
Autocorrelación	Durbin-Watson	Rachas en residuos, $DW \ll 2$ o $DW \gg 2$	Errores robustos (HAC)
No normalidad	Q-Q plot	Desviación de línea, colas pesadas	Transformar Y / TCL
No linealidad	Res. vs Fitted	Patrón curvo, línea roja curvada	Transformar X o Y
Obs. influyentes	Cook's D	$D_i > 4/n$, puntos extremos	Investigar, sensibilidad
Multicolinealidad	VIF	$VIF > 10$	Eliminar var. / PCA

Próxima sesión

Sesión 12: Integración y Análisis Aplicado

Aplicaremos TODO lo aprendido en el curso a un análisis completo con datos ICFES:

- Pipeline estadístico completo: pregunta → datos → EDA → IC → pruebas → modelo → diagnósticos → conclusiones
- Análisis de NI: ¿qué determina el puntaje de inglés?
- Interpretación de resultados para política educativa
- Retroalimentación del Problem Set 8

Para la próxima clase

Traer:

- Laptop con R y los paquetes: lmtest, sandwich, car, texreg
- Datos ICFES de NI (disponibles en Moodle)
- Dudas sobre diagnósticos de regresión

¡Gracias!

Preguntas y discusión

Contacto:

jaime.polanco@javeriana.edu.co

Horario de atención: Miércoles 14:00-16:00