

Sesión 12: Integración y Análisis Aplicado

El pipeline estadístico completo con datos ICFES

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Viernes 13 de noviembre de 2026

Agenda

El pipeline estadístico

Paso 1: Pregunta de investigación

Paso 2: Cargar y limpiar datos

Paso 3: EDA

Paso 4: Intervalos de confianza

Paso 5: Pruebas de hipótesis

Paso 6: Modelo de regresión


Paso 7: Diagnósticos

Paso 8: Conclusiones y recomendaciones

Retroalimentación PS8

Resumen

El pipeline estadístico completo



El pipeline estadístico: proceso iterativo

El análisis estadístico es un proceso iterativo

- Cada paso informa el siguiente
- Los diagnósticos pueden llevarnos a re-especificar el modelo
- Las conclusiones pueden generar nuevas preguntas
- Los datos cuentan una historia — nuestro trabajo es descubrirla con rigor

Analogía: es como cocinar

Primero los ingredientes (datos), luego la preparación (limpieza), la cocción (modelo), y la presentación del plato (conclusiones). Si queman algo en la cocción (diagnósticos fallan), toca volver atrás y ajustar.

¿Por qué importa el pipeline completo?

Mal análisis

- Saltar directamente a regresión
- No explorar los datos
- Ignorar supuestos
- No verificar diagnósticos
- Reportar solo p-valores

Es como publicar un TikTok sin editar: sale cualquier cosa.

Buen análisis

- Comenzar con una pregunta clara
- Explorar antes de modelar
- Verificar supuestos
- Diagnosticar problemas
- Reportar efecto + incertidumbre

Es como un video bien producido: guión, grabación, edición, revisión y publicación.

Objetivo de hoy: aplicar el pipeline completo a datos ICFES de Negocios Internacionales.

Caso de estudio: competencia en inglés en NI

Contexto

Los programas de Negocios Internacionales requieren dominio del inglés como competencia clave. El examen Saber Pro evalúa esta competencia con la prueba de inglés (MOD_INGLES_PUNT, escala 0-300, convertible a niveles MCER: A-, A1, A2, B1, B2).

Pregunta de investigación:

¿Qué factores socioeconómicos y académicos determinan el desempeño en inglés de estudiantes de Negocios Internacionales en Colombia?

Relevancia:

- Informar políticas de admisión y nivelación
- Identificar grupos vulnerables que requieren apoyo
- Evaluar la equidad en el acceso a formación en inglés

Formulando una buena pregunta de investigación

Características de una buena pregunta

- **Clara:** términos bien definidos
- **Medible:** variables observables
- **Relevante:** tiene implicaciones prácticas o teóricas
- **Acotada:** no demasiado amplia ni demasiado estrecha

Recuerden la sesión de descriptiva (S01): primero hay que saber *qué* queremos medir antes de calcular medias y desviaciones. La pregunta es el GPS de todo el análisis.

Formulando una buena pregunta: ejemplo

Pregunta vaga

"¿Por qué algunos estudiantes son mejores en inglés?"

Problemas:

- ¿Qué es "mejor"?
- ¿Qué estudiantes?
- ¿Qué factores?

Pregunta específica

"¿Cuál es el efecto del estrato socioeconómico y del tipo de IES en el puntaje de inglés en Saber Pro para estudiantes de NI?"

Bien definida:

- Variable dependiente: puntaje inglés
- Variables independientes: estrato, tipo IES
- Población: estudiantes NI

Operacionalización de variables

Concepto	Variable	Medición
Competencia en inglés	MOD_INGLES_PUNT	Escala 0-300 (continua)
	NIVEL_MCER	A-, A1, A2, B1, B2 (ordinal)
Nivel socioeconómico	ESTU_ESTRATO	1-6 (ordinal)
Tipo de institución	PRIVADA	0 = pública, 1 = privada
Desempeño previo	PUNT_INGLES_S11	Puntaje Saber 11 (continua)
Género	ESTU_GENERO	M / F (binaria)
Región	REGION	Andina, Caribe, etc. (categórica)

Nota: La operacionalización conecta conceptos abstractos con mediciones concretas.

Cargando los datos

```
# Cargar datos ICFES
icfes <- read.csv("icfes_saber_pro_2023.csv")

# Inspeccion inicial
str(icfes)      # Estructura de los datos
head(icfes)     # Primeras 6 filas
dim(icfes)      # Dimensiones (filas x columnas)
names(icfes)     # Nombres de las columnas

# Ver estadisticos basicos
summary(icfes)
```

Cargando los datos: output

Output esperado

```
'data.frame':  234567 obs. of  42 variables:  
 $ ESTU_CONSECUTIVO      : int   1 2 3 4 5 ...  
 $ PROGRAMA              : chr  "MEDICINA" "DERECHO" "INGENIERIA CIVIL" ...  
 $ MOD_INGLES_PUNT       : num  165 142 178 NA 155 ...  
 $ ESTU_ESTRATO          : int   3 2 4 1 3 ...  
 ...
```

Filtrando y creando variables

```
library(dplyr)

# Filtrar solo estudiantes de Negocios Internacionales
ni_data <- icfes %>%
  filter(PROGRAMA == "NEGOCIOS INTERNACIONALES")

# Ver cuantos estudiantes quedaron
nrow(ni_data)

# Crear variable PRIVADA
ni_data <- ni_data %>%
  mutate(PRIVADA = ifelse(TIPO_IES == "PRIVADA", 1, 0))
```

Creando variable REGION

```
# Crear variable REGION
ni_data <- ni_data %>%
  mutate(REGION = case_when(
    DEPTO %in% c("CUNDINAMARCA", "BOYACA", "SANTANDER") ~ "Andina",
    DEPTO %in% c("ATLANTICO", "BOLIVAR", "MAGDALENA") ~ "Caribe",
    DEPTO %in% c("VALLE", "CAUCA", "NARINO") ~ "Pacifico",
    DEPTO %in% c("META", "CASANARE") ~ "Orinoquia",
    TRUE ~ "Otra"
  ))
```

Tratando valores faltantes

```
# Identificar valores faltantes
summary(ni_data$MOD_INGLES_PUNT)
sum(is.na(ni_data$MOD_INGLES_PUNT))

# Ver patron de valores faltantes
colSums(is.na(ni_data))

# Eliminar filas con NA en variables clave
ni_data <- ni_data %>%
  filter(!is.na(MOD_INGLES_PUNT),
         !is.na(ESTU_ESTRATO),
         !is.na(PUNT_INGLES_S11))

# Ver cuantas observaciones quedaron
nrow(ni_data)
```

Valores faltantes: consideraciones

Importante

- `na.omit()` elimina TODAS las filas con algún NA (puede ser demasiado drástico)
- Mejor: eliminar NA solo en variables clave
- Reportar cuántas observaciones se perdieron y por qué

Es como limpiar su playlist de Spotify: no borren todo, solo las canciones que realmente no sirven. Cada dato que eliminan es información que pierden.

Verificando la limpieza

```
# Estadísticos descriptivos de variables clave
summary(ni_data %>% select(MOD_INGLES_PUNT, ESTU_ESTRATO,
                          PUNT_INGLES_S11, PRIVADA))

# Verificar rangos válidos
# El puntaje de inglés debe estar entre 0 y 300
ni_data <- ni_data %>%
  filter(MOD_INGLES_PUNT >= 0 & MOD_INGLES_PUNT <= 300)

# Verificar que el estrato esté entre 1 y 6
ni_data <- ni_data %>%
  filter(ESTU_ESTRATO >= 1 & ESTU_ESTRATO <= 6)

# Crear tabla de frecuencias para variables categóricas
table(ni_data$PRIVADA)
table(ni_data$REGION)
table(ni_data$ESTU_GENERO)
```

Siempre verificar: rangos válidos, categorías correctas, no haya valores imposibles.

EDA: estadísticos descriptivos

```
library(dplyr)

# Estadísticos básicos para MOD_INGLES_PUNT
ni_data %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT),
    mediana = median(MOD_INGLES_PUNT),
    de = sd(MOD_INGLES_PUNT),
    minimo = min(MOD_INGLES_PUNT),
    maximo = max(MOD_INGLES_PUNT),
    q25 = quantile(MOD_INGLES_PUNT, 0.25),
    q75 = quantile(MOD_INGLES_PUNT, 0.75)
  )
```

EDA: interpretación de descriptivos

Output esperado

n	media	mediana	de	minimo	maximo	q25	q75
2834	154.3	152.0	18.7	95.0	245.0	141.0	167.0

Interpretación:

- Media $\approx$ mediana $\Rightarrow$ distribución aproximadamente simétrica
- DE = 18.7 puntos (variabilidad moderada)
- Rango: 95-245 (amplitud de 150 puntos)

EDA: desagregación por estrato y tipo de IES

```
# Por estrato socioeconomico
ni_data %>%
  group_by(ESTU_ESTRATO) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT),
    de = sd(MOD_INGLES_PUNT)
  )

# Por tipo de IES
ni_data %>%
  group_by(PRIVADA) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT),
    de = sd(MOD_INGLES_PUNT)
  )
```

EDA: desagregación por región

```
# Por region
ni_data %>%
  group_by(REGION) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT),
    de = sd(MOD_INGLES_PUNT)
  ) %>%
  arrange(desc(media)) # ordenar por media descendente
```

EDA: hallazgos preliminares

Hallazgos esperados (ilustrativos)

Estrato	n	Media	DE
1	234	138.5	20.3
2	567	145.2	18.9
3	891	152.8	17.5
4	678	161.4	16.2
5	345	169.7	15.8
6	119	178.3	14.5

Observaciones:

- Relación positiva entre estrato y puntaje (gradiente claro)
- La variabilidad (DE) disminuye al aumentar el estrato
- Estudiantes de estrato 6 puntúan 40 puntos más que estrato 1 (diferencia sustantiva)

EDA: hallazgos preliminares (cont.)

Pregunta: ¿Esta diferencia es estadísticamente significativa? → necesitamos pruebas formales.

Recuerden S03 (muestreo): estas son estadísticas *muestrales* — necesitamos IC y pruebas para saber si reflejan la población.

EDA: visualizaciones

```
library(ggplot2)

# Histograma de puntaje de ingles
ggplot(ni_data, aes(x = MOD_INGLES_PUNT)) +
  geom_histogram(binwidth = 10, fill = "steelblue", color = "white") +
  labs(title = "Distribucion del puntaje de ingles en NI",
       x = "Puntaje ingles", y = "Frecuencia") +
  theme_minimal()

# Boxplot por estrato
ggplot(ni_data, aes(x = factor(ESTU_ESTRATO), y = MOD_INGLES_PUNT,
                        fill = factor(ESTU_ESTRATO))) +
  geom_boxplot() +
  labs(title = "Puntaje de ingles por estrato socioeconomico",
       x = "Estrato", y = "Puntaje ingles") +
  theme_minimal() +
  theme(legend.position = "none")
```

EDA: scatterplot Saber 11 vs Saber Pro

```
# Scatterplot: puntaje Saber 11 vs Saber Pro
ggplot(ni_data, aes(x = PUNT_INGLES_S11, y = MOD_INGLES_PUNT)) +
  geom_point(alpha = 0.3, color = "steelblue") +
  geom_smooth(method = "lm", se = TRUE, color = "red") +
  labs(title = "Relacion entre Saber 11 y Saber Pro (ingles)",
        x = "Puntaje ingles Saber 11",
        y = "Puntaje ingles Saber Pro") +
  theme_minimal()
```


EDA: proporción que alcanza B1

```
# Barplot: proporción que alcanza B1 por tipo de IES
ni_data <- ni_data %>%
  mutate(ALCANZA_B1 = MOD_INGLES_PUNT >= 169)

ni_data %>%
  group_by(PRIVADA) %>%
  summarise(prop_B1 = mean(ALCANZA_B1)) %>%
  ggplot(aes(x = factor(PRIVADA, labels = c("Publica", "Privada")),
            y = prop_B1, fill = factor(PRIVADA))) +
  geom_col() +
  scale_y_continuous(labels = scales::percent) +
  labs(title = "Proporción que alcanza B1 por tipo de IES",
       x = "", y = "Proporción") +
  theme_minimal() +
  theme(legend.position = "none")
```

IC para la media por región

```
library(dplyr)

# Calcular IC para cada region
ic_regiones <- ni_data %>%
  group_by(REGION) %>%
  summarise(
    n = n(),
    media = mean(MOD_INGLES_PUNT),
    de = sd(MOD_INGLES_PUNT),
    ee = de / sqrt(n),
    t_crit = qt(0.975, n - 1),
    lim_inf = media - t_crit * ee,
    lim_sup = media + t_crit * ee
  )

print(ic_regiones)
```

IC para la media por región: resultados

Output esperado

REGION	n	media	de	ee	t_crit	lim_inf	lim_sup
Andina	1234	156.2	17.8	0.51	1.96	155.2	157.2
Caribe	567	148.5	19.3	0.81	1.96	146.9	150.1
Pacifico	789	152.1	18.5	0.66	1.96	150.8	153.4
Orinoquia	134	145.3	21.2	1.83	1.98	141.7	148.9

Forest plot de IC por región

```
library(ggplot2)

ggplot(ic_regiones, aes(x = REGION, y = media)) +
  geom_point(size = 3, color = "steelblue") +
  geom_errorbar(aes(ymin = lim_inf, ymax = lim_sup), width = 0.2) +
  coord_flip() +
  labs(title = "Puntaje promedio de ingles por region (IC 95 %)",
       x = "", y = "Puntaje promedio ingles") +
  theme_minimal()
```

Interpretación del forest plot:

- Barras horizontales = IC 95 %
- Si dos IC NO se superponen, hay diferencia significativa
- Región Andina tiene el puntaje más alto
- Orinoquia tiene mayor incertidumbre (IC más amplio) debido a menor n

IC para proporciones

```
# Proporción que alcanza B1 (>=169) por tipo de IES
ni_data %>%
  group_by(PRIVADA) %>%
  summarise(
    n = n(),
    exitos = sum(ALCANZA_B1),
    prop = mean(ALCANZA_B1),
    ee = sqrt(prop * (1 - prop) / n),
    z_crit = qnorm(0.975),
    lim_inf = prop - z_crit * ee,
    lim_sup = prop + z_crit * ee
  )
```

IC para proporciones: resultados

Output esperado

PRIVADA	n	exitos	prop	ee	z_crit	lim_inf	lim_sup
0	987	234	0.237	0.014	1.96	0.210	0.264
1	1847	658	0.356	0.011	1.96	0.334	0.378

Interpretación: Los IC no se superponen $\Rightarrow$ diferencia significativa: IES privadas tienen mayor proporción que alcanza B1 (35.6 % vs 23.7 %).

Prueba t: pública vs privada

```
# Test t de dos muestras  
t.test(MOD_INGLES_PUNT ~ PRIVADA, data = ni_data, var.equal = FALSE)
```

Output esperado

Welch Two Sample t-test

data: MOD_INGLES_PUNT by PRIVADA

t = -11.234, df = 1678.5, p-value < 2.2e-16

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-13.56 -9.42

sample estimates:

mean in group 0	mean in group 1
148.2	159.7

Prueba t: conclusión

Conclusión:

- $t = -11,23$, $p < 0,001 \Rightarrow$ diferencia altamente significativa
- Estudiantes de IES privadas puntúan 11.5 puntos más en promedio
- IC 95 %: [9.42, 13.56] puntos

ANOVA: diferencias entre regiones

```
# ANOVA de un factor
anova_regiones <- aov(MOD_INGLES_PUNT ~ REGION, data = ni_data)
summary(anova_regiones)

# Test post-hoc de Tukey
TukeyHSD(anova_regiones)
```

Output ANOVA

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
REGION	3	45678	15226	52.34	< 2e-16 ***
Residuals	2830	823456	291		

Conclusión:

- $F(3, 2830) = 52,34$, $p < 0,001 \Rightarrow$ hay diferencias significativas entre regiones
- Tukey identifica qué pares difieren (ej: Andina vs Caribe: $p < 0,001$)

Chi-cuadrado: asociación nivel MCER × tipo IES

```
# Crear variable nivel MCER
ni_data <- ni_data %>%
  mutate(NIVEL_MCER = case_when(
    MOD_INGLES_PUNT < 142 ~ "A-",
    MOD_INGLES_PUNT < 169 ~ "A1-A2",
    TRUE ~ "B1+"
  ))

# Tabla de contingencia
tabla <- table(ni_data$NIVEL_MCER, ni_data$PRIVADA)
print(tabla)

# Test chi-cuadrado
chisq.test(tabla)
```

Chi-cuadrado: resultados

Output chi-cuadrado

```
Pearson's Chi-squared test  
X-squared = 87.345, df = 2, p-value < 2.2e-16
```

Conclusión: Hay asociación significativa entre nivel MCER y tipo de IES.

Tamaño del efecto: d de Cohen

```
library(effsize)

# d de Cohen para diferencia publica vs privada
cohen.d(MOD_INGLES_PUNT ~ PRIVADA, data = ni_data)
```

Output

```
Cohen's d
d estimate: 0.62 (medium)
95 percent confidence interval:
  lower      upper
  0.51      0.73
```

Tamaño del efecto: interpretación

Interpretación:

- $d = 0,62$ (efecto mediano: $0.2 =$ pequeño, $0.5 =$ mediano, $0.8 =$ grande)
- La diferencia pública-privada es significativa Y sustantiva
- El tamaño del efecto cuantifica la relevancia práctica

Modelo simple: solo estrato

```
# Modelo simple
modelo1 <- lm(MOD_INGLES_PUNT ~ ESTU ESTRATO, data = ni_data)
summary(modelo1)
```

Output (ilustrativo)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	125.345	1.234	101.5	<2e-16 ***
ESTU ESTRATO	7.234	0.345	20.9	<2e-16 ***

Residual standard error: 16.8 on 2832 degrees of freedom

Multiple R-squared: 0.134, Adjusted R-squared: 0.133

Interpretación:

- Cada punto adicional de estrato se asocia con 7.2 puntos más en inglés
- $R^2 = 0,134 \Rightarrow$ el estrato explica 13.4 % de la varianza en inglés
- Queda mucha varianza sin explicar (86.6 %)

Modelo múltiple: agregando variables

```
# Modelo multiple
modelo2 <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
              ESTU_GENERO + PUNT_INGLES_S11, data = ni_data)
summary(modelo2)
```

Output (ilustrativo)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	45.234	3.456	13.08	<2e-16 ***
ESTU_ESTRATO	2.134	0.421	5.07	4.3e-07 ***
PRIVADA	5.432	1.234	4.40	1.1e-05 ***
ESTU_GENEROM	-1.543	0.987	-1.56	0.118
PUNT_INGLES_S11	0.876	0.034	25.76	<2e-16 ***

Residual standard error: 12.3 on 2829 degrees of freedom

Multiple R-squared: 0.428, Adjusted R-squared: 0.427

Modelo múltiple: conclusiones

Conclusiones:

- Controlando por otras variables, el efecto del estrato se reduce ($7.2 \rightarrow 2.1$)
- El puntaje en Saber 11 es el predictor más fuerte ($t = 25,76$)
- $R^2 = 0,428 \Rightarrow$ el modelo explica 42.8 % de la varianza

Sesgo de variable omitida (OVB)

Comparación modelo1 vs modelo2

	Modelo 1 (solo estrato)	Modelo 2 (múltiple)
ESTU_ESTRATO	7.234***	2.134***
PRIVADA	—	5.432***
PUNT_INGLES_S11	—	0.876***
R^2	0.134	0.428

OVB: explicación del cambio

¿Por qué cambia el coeficiente de estrato?

- En modelo1, ESTU_ESTRATO captura TANTO su efecto directo COMO el efecto indirecto de variables omitidas correlacionadas (PRIVADA, PUNT_S11)
- Estudiantes de estrato alto tienden a ir a IES privadas y tener mejor Saber 11
- Al incluir estas variables en modelo2, el efecto de estrato se “purifica”
- El efecto causal verdadero del estrato es ~2.1 puntos (controlado)

Recuerden S06 (OLS múltiple): controlar variables es como aislar el efecto de un solo ingrediente en una receta — hay que mantener todo lo demás constante para saber qué aporta cada uno.

Interpretación de coeficientes

```
# Extraer coeficientes con IC  
confint(modelo2)
```

Interpretación de cada coeficiente (*ceteris paribus*):

- **ESTU_ESTRATO = 2.134**: subir un estrato se asocia con 2.1 puntos más en inglés, manteniendo constantes IES, género y Saber 11.
- **PRIVADA = 5.432**: estudiar en IES privada se asocia con 5.4 puntos más, manteniendo constantes estrato, género y Saber 11.
- **PUNT_INGLES_S11 = 0.876**: cada punto adicional en Saber 11 se asocia con 0.88 puntos más en Saber Pro.
- **ESTU_GENERO = -1.543** (no significativo, $p = 0,118$): hombres puntúan 1.5 puntos menos que mujeres, pero la diferencia no es estadísticamente significativa.

Recordar: estos son efectos *parciales*, no causales (datos observacionales).

Diagnósticos gráficos

```
# Los 4 graficos diagnosticos  
par(mfrow = c(2, 2))  
plot(modelo2)  
par(mfrow = c(1, 1))
```

Revisión visual:

1. **Residuals vs Fitted:** ¿Hay patrón? ¿Embudo?
 - Buscar: línea roja horizontal, puntos dispersos aleatoriamente
2. **Q-Q plot:** ¿Normalidad de residuos?
 - Buscar: puntos cerca de la línea diagonal
3. **Scale-Location:** ¿Homocedasticidad?
 - Buscar: línea roja horizontal
4. **Residuals vs Leverage:** ¿Observaciones influyentes?
 - Buscar: puntos dentro de las líneas de Cook

Test de Breusch-Pagan

```
library(lmtest)

# Test de heterocedasticidad
bptest(modelo2)
```

Output esperado

studentized Breusch-Pagan test

data: modelo2

BP = 38.472, df = 4, p-value = 8.741e-08

Conclusión:

- $p < 0,001 \Rightarrow$ rechazamos H_0 de homocedasticidad
- Hay evidencia de heterocedasticidad
- Solución: usar errores estándar robustos

Observaciones influyentes

```
# Distancia de Cook
cook_d <- cooks.distance(modelo2)

# Umbral
umbral <- 4 / nrow(ni_data)

# Identificar influyentes
influyentes <- which(cook_d > umbral)
length(influyentes)

# Ver las 5 observaciones mas influyentes
ni_data[head(order(cook_d, decreasing = TRUE), 5), ]

# Graficar
plot(cook_d, type = "h", main = "Distancia de Cook")
abline(h = umbral, col = "red", lty = 2)
```

Acción: si hay observaciones con $D_i > 4/n$, investigar (¿error de datos? ¿caso especial?). Si son legítimas, reportar análisis de sensibilidad.

Síntesis de hallazgos

Principales resultados del análisis

1. **Desempeño general:** El puntaje promedio de inglés en NI es 154.3 ($DE = 18.7$), equivalente a nivel A2/B1 en el MCER.
2. **Gradiente socioeconómico:** Existe una relación positiva entre estrato y puntaje. Controlando por otras variables, cada estrato adicional se asocia con 2.1 puntos más (IC 95 %: [1.3, 2.9]).
3. **Brecha público-privada:** Estudiantes de IES privadas puntúan 5.4 puntos más que los de públicas (IC 95 %: [3.0, 7.8]), controlando por estrato y desempeño previo.
4. **Persistencia del desempeño:** El puntaje en Saber 11 es el predictor más fuerte ($\beta = 0,88$, $t = 25,8$). Las brechas vienen desde el colegio — como cuando el algoritmo de una red social te encasilla desde el principio.
5. **No se encontraron diferencias por género** ($p = 0,118$).

Implicaciones para política educativa

Recomendaciones

1. **Nivelación al ingreso:** Implementar cursos de nivelación en inglés para estudiantes de estratos 1-2 y de IES públicas.
2. **Intervención temprana:** Dado que el desempeño en Saber 11 es altamente predictivo, las políticas deben enfocarse en mejorar la enseñanza del inglés en secundaria, no solo en educación superior.
3. **Equidad en recursos:** Las IES públicas requieren mayor inversión en recursos para la enseñanza del inglés (laboratorios, profesores nativos, materiales).
4. **Becas para inmersión:** Expandir programas de becas para intercambios internacionales, priorizando estudiantes de estratos bajos.
5. **Monitoreo continuo:** Evaluar periódicamente el progreso en inglés durante la carrera, no solo al final (Saber Pro).

Limitaciones del análisis

Limitaciones metodológicas

- **Causalidad vs correlación:** Los coeficientes representan asociaciones, no efectos causales. No podemos afirmar que estudiar en IES privada “causa” mayor puntaje (puede haber selección).
- **Variables omitidas:** No controlamos por calidad del profesor, horas de estudio, motivación, experiencia previa con el inglés fuera del colegio, etc.
- **Heterocedasticidad:** Aunque usamos errores robustos, la heterocedasticidad indica que el modelo ajusta mejor a algunos grupos que a otros.
- **Generalización:** Los resultados son específicos para NI en Colombia en 2023. Pueden no aplicar a otros programas o países.

Futuras investigaciones

Líneas de investigación futura

- Estudios experimentales (ej: asignación aleatoria a programas de nivelación)
- Análisis longitudinales (seguimiento de cohortes)
- Incorporar variables de proceso (horas de clase, metodologías)

Retroalimentación Problem Set 8

Errores comunes observados

1. **No reportar diagnósticos:** Estimar OLS sin verificar supuestos.
 - Solución: SIEMPRE hacer `plot(modelo)` y Breusch-Pagan
2. **Interpretar coeficientes sin controles:** Decir ".^{el} estrato causa X" sin controlar por confundidores.
 - Solución: usar lenguaje de asociación ("se asocia con"), no causal
3. **Ignorar errores robustos:** Reportar errores estándar clásicos ante heterocedasticidad.
 - Solución: usar `vcovHC` cuando Breusch-Pagan rechaza H_0
4. **No reportar tamaño del efecto:** Enfocarse solo en p-valores.
 - Solución: reportar coeficientes, IC, y R^2
5. **Gráficos sin etiquetas:** Ejes sin nombres, sin título.
 - Solución: usar `labs()` en `ggplot`

Buenas prácticas observadas

Ejemplos de excelencia

- **Análisis exploratorio robusto:** Desagregar por múltiples grupos, graficar antes de modelar.
- **Comparación de modelos:** Reportar modelo simple y múltiple, discutir OVB.
- **Análisis de sensibilidad:** Re-estimar sin observaciones influyentes, reportar si cambian conclusiones.
- **Visualizaciones efectivas:** Forest plots, boxplots comparativos, scatterplots con línea de regresión.
- **Interpretación contextualizada:** Conectar resultados estadísticos con implicaciones para NI (ej: ".^Esta brecha equivale a medio nivel MCER").
- **Código reproducible:** Scripts bien comentados, con estructura clara (carga → limpieza → EDA → modelos).

Recordatorio: El código es parte del informe. Debe ser legible y reproducible.


Rúbrica para el proyecto final

Criterio	Descripción	Puntos
Pregunta de investigación	Clara, medible, relevante	10
Limpieza de datos	Tratamiento de NA, valores atípicos, creación de variables	10
EDA	Estadísticos descriptivos, visualizaciones, desagregación	15
Inferencia	IC, pruebas de hipótesis, interpretación	15
Modelo de regresión	Especificación, interpretación, comparación	20
Diagnósticos	Gráficos, tests, correcciones (errores robustos)	15
Conclusiones	Síntesis, implicaciones, limitaciones	10
Código reproducible	Scripts claros, comentados, reproducibles	5
Total		100

Entrega: Informe en PDF (≤ 15 páginas) + código R (.R o .Rmd) + datos.

Fecha límite: Viernes 20 de noviembre, 23:59h (Moodle).

El pipeline estadístico: repaso



Lecciones clave

Principios del análisis estadístico riguroso

1. **Explorar antes de modelar:** Los datos deben "hablarte." antes de imponer un modelo.
2. **Controlar confundidores:** Un modelo simple puede ser engañoso (OVB).
3. **Verificar supuestos:** OLS sin diagnósticos es como postear sin revisar — puede salir muy mal.
4. **Reportar incertidumbre:** Un coeficiente sin IC o error estándar es incompleto.
5. **Interpretar en contexto:** Los números cobran sentido al conectarlos con la pregunta original.
6. **Reconocer limitaciones:** Un buen análisis admite lo que NO puede concluir.
7. **Ser reproducible:** Tu código es tu receta. Otros (y tú en el futuro) deben poder replicar tus resultados.

Próxima sesión: repaso final

Sesión 13: Repaso Final y Preparación para el Examen

- Mapa conceptual del curso (4 unidades)
- Repaso de fórmulas clave (IC, pruebas, regresión)
- Problemas tipo examen
- Estrategias para el examen final
- Instrucciones del proyecto final

Para la próxima clase

Traer:

- Todas tus dudas del semestre
- Hoja de fórmulas (draft para el examen)
- Calculadora

¡Gracias!

Preguntas y discusión

Contacto:

jaime.polanco@javeriana.edu.co

Horario de atención: Miércoles 14:00-16:00