

Sesión 13: Repaso Final

Preparación para el examen final integrado

Prof. Jaime Polanco Jiménez

Pontificia Universidad Javeriana
Facultad de Ciencias Económicas y Administrativas

Viernes 20 de noviembre de 2026

Agenda

Mapa del curso

Repaso U1: Conceptos clave

Repaso U2: Fórmulas de IC

Repaso U3: Pruebas de hipótesis

Repaso U4: Regresión


Problemas tipo examen

Estructura del examen final

Instrucciones del proyecto

Cierre

Las 4 unidades del curso




Las 4 unidades del curso: conexiones

Cómo se conectan las unidades

- **U1 (Descriptiva + Probabilidad):** Fundamento — entender los datos y las distribuciones
- **U2 (IC):** Cuantificar incertidumbre — ¿qué tan preciso es nuestro estimador?
- **U3 (Pruebas):** Tomar decisiones con datos — ¿hay diferencia? ¿hay asociación?
- **U4 (Regresión):** Modelar relaciones — ¿cómo se relaciona Y con X? ¿cuánto?

Todo se integra: en un análisis completo usamos las 4 unidades (como vimos en S12).

Diagrama de conexiones conceptuales



Cronología de sesiones

Sesión	Tema	Unidad	Peso
S01	Estadística descriptiva numérica	U1	10 %
S02	Estadística descriptiva gráfica	U1	5 %
S03	Muestreo y correlación	U1	10 %
S04	Estimadores y MLE	U1-U2	10 %
S05	OLS simple	U4	15 %
S06	OLS múltiple	U4	15 %
S07	Diagnósticos y logit	U4	5 %
S08	Intervalos de confianza	U2	10 %
S09	Bootstrap y tamaño de muestra	U2	5 %
S10	Errores tipo I/II y potencia	U3	10 %
S11	Pruebas paramétricas (t, ANOVA)	U3	15 %
S12	Integración y análisis aplicado	U1-U4	20 %
S13	Repaso final	—	—

Nota: El examen final es **acumulativo** — cubre las 4 unidades, con énfasis en U2-U4.

U1: Medidas de tendencia central y dispersión

Medidas de tendencia central

- **Media:** $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ (sensible a valores extremos)
- **Mediana:** valor que divide los datos en 50 %-50 % (robusta)
- **Moda:** valor más frecuente

Medidas de dispersión

- **Varianza:** $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
- **Desviación estándar:** $s = \sqrt{s^2}$ (mismas unidades que x)
- **Rango intercuartílico:** $IQR = Q_3 - Q_1$ (robusto)
- **Coeficiente de variación:** $CV = \frac{s}{\bar{x}}$ (dispersión relativa)

U1: Medidas de forma

Asimetría y curtosis

- **Asimetría:** $g_1 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^3}{s^3}$ ($g_1 > 0$: sesgada a derecha; $g_1 < 0$: sesgada a izquierda)
- **Curtosis:** $g_2 = \frac{\frac{1}{n} \sum (x_i - \bar{x})^4}{s^4} - 3$ ($g_2 > 0$: colas pesadas; $g_2 < 0$: colas ligeras)

U1: Correlación de Pearson

Correlación de Pearson

Mide asociación **lineal** entre dos variables continuas.

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

- $-1 \leq r \leq 1$
- $r > 0$: relación positiva; $r < 0$: relación negativa
- $|r|$ cercano a 1: relación fuerte; cercano a 0: relación débil
- **Limitación**: solo detecta relaciones lineales

U1: Correlación de Spearman

Correlación de Spearman

Mide asociación **monotónica** usando rangos.

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

donde d_i es la diferencia entre los rangos de x_i y y_i .

- Robusta a valores extremos
- Detecta relaciones no lineales (pero monotónicas)

U1: Paradoja de Simpson

Ejemplo clásico

Tasa de éxito por tratamiento y género:

	Tratamiento A	Tratamiento B	Mejor
Hombres	$80/100 = 80 \%$	$90/120 = 75 \%$	A
Mujeres	$20/40 = 50 \%$	$10/30 = 33 \%$	A
Total	$100/140 = 71 \%$	$100/150 = 67 \%$	A

Pero si solo miramos el total:

	Tratamiento A	Tratamiento B
Total	$100/140 = 71 \%$	$100/150 = 67 \%$

¡A es mejor en ambos grupos, pero B parece mejor en el agregado!

Lección: Siempre desagregar por variables confundidoras (género, estrato, región, etc.).

U1: Distribución normal

Distribución normal

$$X \sim N(\mu, \sigma^2) \Rightarrow f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

- Funciones en R: `dnorm(x, mean, sd)`, `pnorm(q, ...)`, `qnorm(p, ...)`, `rnorm(n, ...)`
- Regla 68-95-99.7: 68 % dentro de $\mu \pm \sigma$, 95 % dentro de $\mu \pm 2\sigma$, 99.7 % dentro de $\mu \pm 3\sigma$

U1: Teorema Central del Límite

Teorema Central del Límite (TCL)

Si $X_1, X_2, \dots, X_n$ son iid con $E(X_i) = \mu$ y $\text{Var}(X_i) = \sigma^2$, entonces:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{cuando } n \rightarrow \infty$$

O equivalentemente:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Implicación: Podemos hacer inferencia sobre μ incluso si X no es normal (con n grande).

U1: Distribución t de Student

Distribución t de Student

$$t = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}$$

- Se usa cuando σ es desconocida (estimamos con s)
- Parámetro: grados de libertad $df = n - 1$
- Más dispersa que $N(0, 1)$ para n pequeño; converge a $N(0, 1)$ cuando $n \rightarrow \infty$
- En R: `pt(q, df)`, `qt(p, df)`

U1: Distribución χ^2 (chi-cuadrado)

Distribución χ^2 (chi-cuadrado)

$$\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$$

- Se usa para inferencia sobre varianzas
- También en pruebas de independencia y bondad de ajuste
- Parámetro: grados de libertad df
- En R: `pchisq(q, df)`, `qchisq(p, df)`

U2: IC para la media (σ conocida)

Caso 1: σ conocida (raro en la práctica)

$$IC_{1-\alpha} : \quad \bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

- Usar distribución normal estándar: $z_{0,025} = 1,96$ para 95 %

U2: IC para la media (σ desconocida)

Caso 2: σ desconocida (caso común)

$$IC_{1-\alpha} : \quad \bar{x} \pm t_{\alpha/2, n-1} \cdot \frac{s}{\sqrt{n}}$$

- Usar distribución t con $df = n - 1$
- $t_{0,025, n-1}$ se obtiene con `qt(0.975, n-1)`
- Para n grande ($n > 30$), $t_{n-1} \approx z$ (1.96 para 95 %)

Ejemplo

$n = 50$, $\bar{x} = 154,3$, $s = 18,7$. IC 95 % para μ :

$$154,3 \pm t_{0,025,49} \cdot \frac{18,7}{\sqrt{50}} = 154,3 \pm 2,01 \cdot 2,64 = 154,3 \pm 5,31 = [149,0, 159,6]$$

U2: IC para la varianza

IC para σ^2

$$IC_{1-\alpha} : \left[\frac{(n-1)s^2}{\chi_{\alpha/2, n-1}^2}, \frac{(n-1)s^2}{\chi_{1-\alpha/2, n-1}^2} \right]$$

- Basado en $\frac{(n-1)s^2}{\sigma^2} \sim \chi_{n-1}^2$
- Asimétrico (la distribución χ^2 es asimétrica)
- Requiere normalidad de los datos (más sensible que el IC para μ)

Ejemplo

$n = 50$, $s^2 = 349,69$. IC 95 % para σ^2 : $\chi_{0,025,49}^2 = 70,22$, $\chi_{0,975,49}^2 = 31,55$. IC:
 $\left[\frac{49 \cdot 349,69}{70,22}, \frac{49 \cdot 349,69}{31,55} \right] = [244,0, 543,5]$. El IC para σ es $[\sqrt{244,0}, \sqrt{543,5}] = [15,6, 23,3]$.

U2: IC para proporciones

IC para p (método de Wald)

$$IC_{1-\alpha} : \hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

donde $\hat{p} = \frac{x}{n}$ (proporción muestral).

- Requiere $n\hat{p} \geq 10$ y $n(1 - \hat{p}) \geq 10$ (regla de pulgar)
- Si no se cumple, usar método exacto (Wilson, Clopper-Pearson)

Ejemplo

$n = 200$, $x = 75$ estudiantes alcanzan B1. $\hat{p} = 75/200 = 0,375$. IC 95 %:

$$0,375 \pm 1,96 \cdot \sqrt{\frac{0,375 \cdot 0,625}{200}} = 0,375 \pm 0,067 = [0,308, 0,442]$$

Interpretación: Entre 30.8 % y 44.2 % de estudiantes alcanzan B1 (95 % de confianza).

U2: Tamaño de muestra para μ

Tamaño de muestra para estimar μ con margen de error E

$$n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

- Si σ es desconocida, usar estimación piloto o $\sigma \approx \frac{\text{rango}}{4}$
- Ejemplo: ¿Cuántos estudiantes necesito para estimar μ con $E = 2$ puntos (95 % conf)?

$$n = \left(\frac{1,96 \cdot 18,7}{2} \right)^2 = (18,35)^2 = 337$$

U2: Tamaño de muestra para p

Tamaño de muestra para estimar p con margen de error E

$$n = \left(\frac{z_{\alpha/2}}{E} \right)^2 \cdot p(1 - p)$$

- Si p es desconocida, usar $p = 0,5$ (escenario conservador, maximiza $p(1 - p)$)
- Ejemplo: ¿Cuántos estudiantes para estimar proporción con $E = 0,03$ (95 % conf)?

$$n = \left(\frac{1,96}{0,03} \right)^2 \cdot 0,5 \cdot 0,5 = (65,33)^2 \cdot 0,25 = 1067$$

U2: Tabla resumen de fórmulas de IC

Parámetro	Fórmula IC	Condiciones
μ (σ conocida)	$\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$	n grande o $X \sim N$
μ (σ desconocida)	$\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$	n grande o $X \sim N$
σ^2	$\left[\frac{(n-1)s^2}{\chi^2_{\alpha/2, n-1}}, \frac{(n-1)s^2}{\chi^2_{1-\alpha/2, n-1}} \right]$	$X \sim N$
p	$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$	$n\hat{p} \geq 10, n(1-\hat{p}) \geq 10$
$\mu_1 - \mu_2$	$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2, df} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$	Welch, df aprox.

U2: Valores críticos comunes

Recordar:

- Para 95 %: $\alpha = 0,05$, $\alpha/2 = 0,025$, $z_{0,025} = 1,96$
- Para 90 %: $\alpha = 0,10$, $\alpha/2 = 0,05$, $z_{0,05} = 1,645$
- Para 99 %: $\alpha = 0,01$, $\alpha/2 = 0,005$, $z_{0,005} = 2,576$

U3: Pasos de una prueba de hipótesis

Pasos

1. **Plantear hipótesis:** H_0 (nula) vs H_1 (alternativa)
2. **Elegir nivel de significancia:** α (típicamente 0.05)
3. **Calcular estadístico de prueba:** t , z , F , χ^2 , etc.
4. **Calcular p-valor:** probabilidad de observar un estadístico tan extremo (o más) si H_0 es cierta
5. **Decisión:** si $p < \alpha$, rechazar H_0 ; si $p \geq \alpha$, no rechazar H_0
6. **Conclusión:** interpretar en el contexto del problema

U3: Errores tipo I y II

Errores tipo I y II

- **Error tipo I:** Rechazar H_0 cuando es verdadera (falso positivo). Probabilidad = α .
- **Error tipo II:** No rechazar H_0 cuando es falsa (falso negativo). Probabilidad = β .
- **Potencia:** $1 - \beta$ = probabilidad de rechazar H_0 cuando es falsa (detectar el efecto).

U3: Tabla de pruebas paramétricas

Situación	Prueba	Estadístico	gl
1 muestra, μ	t de 1 muestra	$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$	$n - 1$
2 muestras indep.	t de 2 muestras	$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$	Welch
2 muestras pareadas	t pareada	$t = \frac{\bar{d}}{s_d/\sqrt{n}}$	$n - 1$
≥ 3 grupos	ANOVA	$F = \frac{MS_{entre}}{MS_{dentro}}$	$(k - 1, n - k)$
Indep. (tabla)	χ^2 indep.	$\chi^2 = \sum \frac{(O-E)^2}{E}$	$(r - 1)(c - 1)$
Bondad de ajuste	χ^2 bondad	$\chi^2 = \sum \frac{(O-E)^2}{E}$	$k - 1$
Correlación	t para ρ	$t = r\sqrt{\frac{n-2}{1-r^2}}$	$n - 2$

U3: Prueba t de una muestra

Hipótesis

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_1 : \mu \neq \mu_0 \quad (\text{bilateral})$$

O $H_1 : \mu > \mu_0$ (unilateral derecha) o $H_1 : \mu < \mu_0$ (unilateral izquierda).

Estadístico

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}$$

U3: Prueba t de una muestra — ejemplo

Ejemplo

$n = 50$, $\bar{x} = 154,3$, $s = 18,7$. Probar $H_0 : \mu = 150$ vs $H_1 : \mu \neq 150$ ($\alpha = 0,05$).

$$t = \frac{154,3 - 150}{18,7/\sqrt{50}} = \frac{4,3}{2,64} = 1,63$$

p -valor (bilateral) = $2 \cdot P(T_{49} > 1,63) = 2 \cdot 0,055 = 0,11 > 0,05$.

Conclusión: No rechazamos H_0 . No hay evidencia suficiente de que $\mu \neq 150$.

U3: Prueba t de dos muestras (Welch)

Hipótesis

$$H_0 : \mu_1 = \mu_2 \quad \text{vs} \quad H_1 : \mu_1 \neq \mu_2$$

Estadístico (Welch, no asume varianzas iguales)

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

con grados de libertad aproximados (fórmula compleja, R lo calcula).

U3: Prueba t de Welch — ejemplo

Ejemplo en R

```
t.test(MOD_INGLES_PUNT ~ PRIVADA, data = ni_data,  
       var.equal = FALSE) # Welch (por defecto)
```

Si $p < 0,05$, rechazamos $H_0 \Rightarrow$ hay diferencia significativa.

U3: ANOVA de un factor

Hipótesis

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k \quad \text{vs} \quad H_1 : \text{al menos un } \mu_i \text{ es diferente}$$

Estadístico F

$$F = \frac{MS_{entre}}{MS_{dentro}} = \frac{SS_{entre}/(k-1)}{SS_{dentro}/(n-k)} \sim F_{k-1, n-k}$$

$$SS_{entre} = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2 \text{ (entre grupos),} \quad SS_{dentro} = \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2 \text{ (dentro de grupos)}$$

U3: ANOVA — post-hoc

Post-hoc: Tukey HSD

Si ANOVA rechaza H_0 , usar Tukey para identificar qué pares difieren.

```
anova_modelo <- aov(MOD_INGLES_PUNT ~ REGION, data = ni_data)
TukeyHSD(anova_modelo)
```


U3: Chi-cuadrado de independencia

Hipótesis

H_0 : Las variables son independientes vs H_1 : Las variables están asociadas

Estadístico

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{(r-1)(c-1)}$$

donde:

- O_{ij} = frecuencia observada en celda (i, j)
- $E_{ij} = \frac{\text{total fila } i \cdot \text{total columna } j}{n}$ (frecuencia esperada bajo H_0)

U3: Chi-cuadrado — ejemplo

Ejemplo en R

```
tabla <- table(ni_data$NIVEL_MCER, ni_data$PRIVADA)
chisq.test(tabla)
```

Si $p < 0,05$, rechazamos $H_0 \Rightarrow$ hay asociación entre nivel MCER y tipo IES.

U3: Pruebas no paramétricas

¿Cuándo usar no paramétricas?

- Datos **no** normales y n pequeño (TCL no aplica)
- Datos ordinales (rangos)
- Presencia de valores extremos (outliers)

Paramétrica	No paramétrica	Uso
t de 1 muestra	Wilcoxon signed-rank	1 muestra, mediana
t de 2 muestras	Mann-Whitney (Wilcoxon)	2 muestras indep.
t pareada	Wilcoxon signed-rank pareada	2 muestras pareadas
ANOVA	Kruskal-Wallis	≥ 3 grupos

U3: No paramétricas — ejemplo

Ejemplo: Mann-Whitney en R

```
wilcox.test(MOD_INGLES_PUNT ~ PRIVADA, data = ni_data)
```

Prueba si las medianas de los dos grupos son diferentes.

U3: d de Cohen (tamaño del efecto)

d de Cohen (para t-test)

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_{pooled}}$$

donde $s_{pooled} = \sqrt{\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2}}$.

Interpretación:

- $|d| < 0,2$: efecto trivial
- $0,2 \leq |d| < 0,5$: efecto pequeño
- $0,5 \leq |d| < 0,8$: efecto mediano
- $|d| \geq 0,8$: efecto grande

U3: Potencia

Potencia

Probabilidad de rechazar H_0 cuando es falsa. Depende de:

- Tamaño del efecto (mayor $d \Rightarrow$ mayor potencia)
- Tamaño de muestra (mayor $n \Rightarrow$ mayor potencia)
- Nivel α (mayor $\alpha \Rightarrow$ mayor potencia, pero más error tipo I)

Objetivo: potencia $\geq 0,80$ (80 %).

U4: Modelo de regresión lineal simple

Modelo

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

donde:

- Y_i = variable dependiente, X_i = variable independiente
- β_0 = intercepto, β_1 = pendiente (efecto de X sobre Y)
- ε_i = error (ruido)

Estimadores OLS

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{Cov(X, Y)}{Var(X)} \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Interpretación: $\hat{\beta}_1$ es el cambio en Y asociado con un cambio unitario en X .

U4: Modelo de regresión múltiple

Modelo

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \varepsilon_i$$

Interpretación de $\hat{\beta}_j$

$\hat{\beta}_j$ es el cambio en Y asociado con un cambio unitario en X_j , **manteniendo constantes** las demás variables (ceteris paribus).

U4: Regresión múltiple — ejemplo

Ejemplo

$$\widehat{\text{MOD_INGLES}} = 45,2 + 2,1 \cdot \text{ESTRATO} + 5,4 \cdot \text{PRIVADA} + 0,88 \cdot \text{PUNT_S11}$$

- $\hat{\beta}_{\text{ESTRATO}} = 2,1$: subir un estrato se asocia con 2.1 puntos más en inglés, *controlando* por tipo IES y puntaje S11.
- $\hat{\beta}_{\text{PRIVADA}} = 5,4$: estudiar en privada se asocia con 5.4 puntos más, *controlando* por estrato y puntaje S11.

U4: R^2 (coeficiente de determinación)

R^2

$$R^2 = \frac{SS_{reg}}{SS_{total}} = 1 - \frac{SS_{res}}{SS_{total}}$$

donde:

- $SS_{total} = \sum (Y_i - \bar{Y})^2$ (varianza total de Y)
- $SS_{reg} = \sum (\hat{Y}_i - \bar{Y})^2$ (varianza explicada por el modelo)
- $SS_{res} = \sum (Y_i - \hat{Y}_i)^2$ (varianza no explicada, residuos)

Interpretación: proporción de la varianza de Y explicada por las X . Rango:
 $0 \leq R^2 \leq 1$.

U4: R^2 ajustado

R^2 ajustado

$$R^2_{adj} = 1 - \frac{SS_{res}/(n - k - 1)}{SS_{total}/(n - 1)}$$

- Penaliza por número de variables k
- Usar para comparar modelos con distinto número de variables
- Puede disminuir al agregar variables irrelevantes (a diferencia de R^2)

U4: Prueba t para β_j

Prueba t para β_j

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0$$

$$t = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim t_{n-k-1}$$

- Si $p < 0,05$, rechazamos $H_0 \Rightarrow X_j$ es significativa
- Aparece en la tabla de `summary(modelo)`

U4: Prueba F global

Prueba F global

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \quad \text{vs} \quad H_1 : \text{al menos un } \beta_j \neq 0$$

$$F = \frac{SS_{reg}/k}{SS_{res}/(n-k-1)} = \frac{R^2/k}{(1-R^2)/(n-k-1)} \sim F_{k,n-k-1}$$

- Prueba si el modelo completo es útil
- Si $p < 0,05$, al menos una variable es significativa

U4: Sesgo de variable omitida (OVB)

Problema

Si omitimos una variable Z que:

1. Afecta a Y (correlacionada con Y)
2. Está correlacionada con X

Entonces $\hat{\beta}_X$ estará **sesgado** (capturará parte del efecto de Z).

Ejemplo

Modelo simple: $\text{INGLES} = \beta_0 + \beta_1 \text{ESTRATO} + \varepsilon \Rightarrow \hat{\beta}_1 = 7,2$

Modelo múltiple: $\text{INGLES} = \beta_0 + \beta_1 \text{ESTRATO} + \beta_2 \text{PRIVADA} + \beta_3 \text{PUNT_S11} + \varepsilon \Rightarrow \hat{\beta}_1 = 2,1$

El efecto se reduce porque en el modelo simple capturaba TAMBIÉN el efecto de PRIVADA y PUNT_S11.

U4: Multicolinealidad

Multicolinealidad

Cuando dos o más variables independientes están altamente correlacionadas entre sí.

Consecuencias:

- Errores estándar inflados (menor precisión)
- Coeficientes inestables (cambian mucho al agregar/quitar variables)
- Dificultad para identificar el efecto individual de cada variable

U4: VIF (Variance Inflation Factor)

VIF

$$VIF_j = \frac{1}{1 - R_j^2}$$

donde R_j^2 es el R^2 de la regresión de X_j contra las demás X .

Regla de pulgar:

- $VIF < 5$: no hay problema
- $5 \leq VIF < 10$: multicolinealidad moderada (cuidado)
- $VIF \geq 10$: multicolinealidad severa (eliminar variable o usar PCA)

U4: Diagnósticos de regresión

Checklist

1. **Gráficos diagnósticos:** `plot(modelo)` (4 gráficos)
 - Residuals vs Fitted: ¿linealidad? ¿homocedasticidad?
 - Q-Q: ¿normalidad?
 - Scale-Location: ¿homocedasticidad?
 - Residuals vs Leverage: ¿observaciones influyentes?
2. **Breusch-Pagan:** heterocedasticidad
 - Si $p < 0,05$, usar errores robustos (HC1)
3. **Cook's distance:** observaciones influyentes ($D_i > 4/n$)
4. **VIF:** multicolinealidad ($VIF > 10 \Rightarrow$ considerar eliminar variable)

U4: Errores robustos

```
library(sandwich)
library(lmtest)

# Modelo OLS
modelo <- lm(MOD_INGLES_PUNT ~ ESTU_ESTRATO + PRIVADA +
             PUNT_INGLES_S11, data = ni_data)

# Test de heterocedasticidad
bptest(modelo)

# Si hay heterocedasticidad, usar errores robustos
coeftest(modelo, vcov = vcovHC(modelo, type = "HC1"))

# IC robustos
coefci(modelo, vcov = vcovHC(modelo, type = "HC1"))
```

U4: Errores robustos — recordar

Recordar:

- Los coeficientes $\hat{\beta}$ NO cambian
- Solo cambian los errores estándar (y por tanto, los p-valores y los IC)
- Los errores robustos corrigen para heterocedasticidad

Problema 1: Interpretar output de regresión

Output de `summary(lm(...))`

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)    45.234      3.456   13.08 < 2e-16 ***
ESTU_ESTRATO     2.134      0.421    5.07 4.3e-07 ***
PRIVADA         5.432      1.234    4.40 1.1e-05 ***
PUNT_INGLES_S11  0.876      0.034   25.76 < 2e-16 ***

Residual standard error: 12.3 on 2830 degrees of freedom
Multiple R-squared:  0.428, Adjusted R-squared:  0.427
F-statistic: 706.4 on 3 and 2830 DF,  p-value: < 2.2e-16
```

Preguntas:

1. Interpretar el coeficiente de PRIVADA.
2. ¿Es ESTU_ESTRATO significativo al 5 %? ¿Cómo lo sabes?
3. ¿Qué proporción de la varianza en inglés explica el modelo?
4. ¿El modelo completo es útil? ¿Cómo lo sabes?

Problema 1: Soluciones (parte 1)

1. Interpretar PRIVADA:

- Estudiar en IES privada se asocia con 5.432 puntos más en inglés, controlando por estrato y puntaje en Saber 11.
- IC 95 %: $5,432 \pm 1,96 \cdot 1,234 = 5,432 \pm 2,42 = [3,01, 7,85]$

2. ¿ESTRATO significativo?

- Sí, $p = 4,3 \times 10^{-7} < 0,05 \Rightarrow$ rechazamos $H_0 : \beta_{\text{ESTRATO}} = 0$
- También: $|t| = 5,07 > 1,96$ (aproximación)

Problema 1: Soluciones (parte 2)

3. Varianza explicada:

- $R^2 = 0,428 \Rightarrow$ el modelo explica 42.8 % de la varianza en inglés
- 57.2 % queda sin explicar (otros factores no incluidos)

4. Modelo útil:

- Sí, $F(3, 2830) = 706,4$, $p < 0,001 \Rightarrow$ al menos una variable es significativa
- De hecho, las tres lo son

Problema 2: IC y prueba de hipótesis

Datos

Una muestra de $n = 100$ estudiantes de NI tiene puntaje promedio de inglés $\bar{x} = 158,5$ con desviación estándar $s = 20,3$.

Preguntas:

1. Construir un IC 95 % para la media poblacional μ .
2. Probar $H_0 : \mu = 155$ vs $H_1 : \mu \neq 155$ al 5 % de significancia.
3. ¿Cuál es la conclusión de la prueba? ¿Es consistente con el IC?

Problema 2: Soluciones

1. $IC : 158,5 \pm t_{0,025,99} \cdot \frac{20,3}{\sqrt{100}} = 158,5 \pm 1,984 \cdot 2,03 = 158,5 \pm 4,03 = [154,5, 162,5]$
2. $t = \frac{158,5-155}{20,3/\sqrt{100}} = \frac{3,5}{2,03} = 1,72, p = 2 \cdot P(T_{99} > 1,72) \approx 0,088$
3. No rechazamos H_0 ($p = 0,088 > 0,05$). Sí, consistente: 155 está dentro del IC $[154,5, 162,5]$.

Problema 3: Chi-cuadrado de independencia

Tabla de contingencia

	A-	A1-A2	B1+
Pública	120	350	80
Privada	80	450	220

Preguntas:

1. Plantear las hipótesis para probar si hay asociación entre tipo de IES y nivel MCER.
2. Calcular la frecuencia esperada para la celda (Pública, B1+) bajo H_0 .
3. Si el estadístico $\chi^2 = 45,6$ con $df = 2$, ¿cuál es la conclusión al 5 %?

Problema 3: Soluciones

1. H_0 : tipo IES y nivel MCER son independientes. H_1 : están asociados.
2. $E = \frac{550 \cdot 300}{1300} = 126,9$ (total fila pública = 550, total col B1+ = 300, total = 1300)
3. $\chi^2_{0,05,2} = 5,99$. Como $45,6 > 5,99$, rechazamos $H_0 \Rightarrow$ hay asociación.

Problema 4: OVB y multicolinealidad

Dos modelos

Modelo A: $\text{INGLES} = 125,3 + 7,2 \cdot \text{ESTRATO}$, $R^2 = 0,13$

Modelo B: $\text{INGLES} = 45,2 + 2,1 \cdot \text{ESTRATO} + 5,4 \cdot \text{PRIVADA} + 0,88 \cdot \text{PUNT_S11}$, $R^2 = 0,43$

Preguntas:

1. ¿Por qué el coeficiente de ESTRATO cambió de 7.2 a 2.1?
2. ¿Cuál modelo es mejor para estimar el efecto causal del estrato? ¿Por qué?
3. Si en Modelo B el VIF de ESTRATO es 1.8 y el de PRIVADA es 12.5, ¿qué problema hay?

Problema 4: Soluciones

1. Sesgo de variable omitida (OVB). En A, ESTRATO captura el efecto de PRIVADA y PUNT_S11.
2. Modelo B, porque controla por confundidores (PRIVADA y PUNT_S11 correlacionados con ESTRATO).
3. Multicolinealidad severa entre PRIVADA y otra variable ($VIF = 12.5 > 10$). Considerar eliminar PRIVADA o investigar cuál variable está correlacionada.

Problema 5: Ensayo corto

Pregunta abierta

Supón que eres asesor del Ministerio de Educación. Basándote en los resultados de los modelos de regresión vistos en clase (efecto de estrato, tipo IES, puntaje Saber 11), propón DOS políticas concretas para reducir la brecha en inglés entre estudiantes de estratos bajos y altos. Justifica tus recomendaciones con evidencia estadística.

Extensión: 1 página (máximo).

Criterios de evaluación:

- **Uso de evidencia:** ¿Cita coeficientes, IC, tamaños del efecto?
- **Coherencia:** ¿Las políticas abordan las brechas identificadas?
- **Viabilidad:** ¿Son políticas realistas?
- **Claridad:** ¿Escrito de manera clara y concisa?

Estructura del examen final

Información general

- **Fecha:** Viernes 27 de noviembre de 2026
- **Horario:** 8:30 - 10:00 (90 minutos)
- **Formato:** Presencial, individual, cerrado (no internet, no apuntes)
- **Permitido:** Calculadora científica + hoja A4 de fórmulas (ambas caras, manuscrita o impresa)

Partes del examen

Partes del examen

1. **Conceptual** (30 puntos): Opción múltiple (10 preguntas) + Verdadero/Falso (10 afirmaciones)
2. **Cálculo** (30 puntos): Problemas numéricos (IC, pruebas, regresión) — mostrar trabajo
3. **Interpretación** (20 puntos): Analizar output de R (tablas de regresión, gráficos diagnósticos)
4. **Ensayo** (20 puntos): Pregunta abierta (tipo problema 5) — aplicar estadística a decisiones

Total: 100 puntos

Contenidos del examen (por unidad)

Unidad	Temas clave	Peso
U1	Descriptiva, correlación, paradoja Simpson, TCL	15 %
U2	IC para μ , σ^2 , p , tamaño de muestra	25 %
U3	Pruebas t, ANOVA, χ^2 , potencia, tamaño efecto	30 %
U4	Regresión OLS, R^2 , diagnósticos, errores robustos	30 %

Énfasis

El examen es **acumulativo**, pero con mayor peso en U2-U4 (inferencia y modelado). Se espera que integres conceptos de múltiples unidades (ej: usar TCL para justificar un IC, diagnosticar un modelo con Breusch-Pagan, interpretar coeficientes controlando por confundidores).

Estrategias de estudio

Preparación para el examen

1. **Repasar slides y problem sets:** Enfócate en los ejercicios resueltos en clase y los PS.
2. **Practicar cálculos a mano:** Calcula IC, pruebas t, χ^2 con calculadora (sin R).
3. **Crear hoja de fórmulas:** Resume las fórmulas clave (IC, estadísticos de prueba, R^2 , VIF, etc.). Esto también es una forma de estudio.
4. **Repasar interpretaciones:** Practica interpretar output de R (tablas de `summary()`, `confint()`, `bptest()`).
5. **Estudiar en grupo:** Explica conceptos a tus compañeros (mejor forma de aprender).
6. **Hacer simulacros:** Cronométrate resolviendo problemas tipo examen.

Recursos de estudio

Recursos

- Slides de todas las sesiones (Moodle)
- Problem Sets 1-8 con soluciones
- Grabaciones de las clases (Moodle)

Hoja de fórmulas: ¿qué incluir?

Sugerencias:

- IC para μ (z y t)
- IC para σ^2 (χ^2)
- IC para p
- Tamaño de muestra
- Estadístico t (1, 2 muestras, pareada)
- Estadístico F (ANOVA)
- χ^2 de independencia
- χ^2 de bondad de ajuste
- Correlación Pearson y Spearman
- OLS: $\hat{\beta}_0, \hat{\beta}_1$
- R^2 y R^2_{adj}
- Prueba t para β_j
- Prueba F global
- VIF
- d de Cohen
- Potencia
- Valores críticos comunes

Importante

La hoja de fórmulas NO sustituye el entendimiento. Úsala como apoyo, no como muleta.

Proyecto final: presentación oral

Logística

- **Fecha:** Viernes 27 de noviembre, 7:00-8:20 (antes del examen)
- **Duración:** 10 minutos por grupo + 3 minutos de preguntas
- **Formato:** Presencial, con slides (PowerPoint, Beamer, etc.)
- **Grupos:** 3-4 estudiantes (ya definidos)

Contenido de la presentación

1. **Pregunta de investigación** (1 min): ¿Qué se quiere responder?
2. **Datos y método** (2 min): Fuente, limpieza, variables, modelo
3. **Resultados** (5 min): EDA, IC, pruebas, regresión, diagnósticos (con visualizaciones)
4. **Conclusiones** (2 min): Hallazgos clave, implicaciones, limitaciones

Proyecto final: informe escrito

Logística

- **Entrega:** Viernes 27 de noviembre, 7:00 (al inicio de la presentación)
- **Formato:** PDF, máximo 15 páginas (sin contar anexos)
- **Incluir:** Código R (.R o .Rmd) + datos (si es posible)

Estructura del informe

1. **Introducción** (1-2 págs): Contexto, pregunta, relevancia
2. **Datos y método** (2-3 págs): Descripción de datos, limpieza, variables, modelo
3. **Resultados** (6-8 págs): EDA, IC, pruebas, regresión, diagnósticos
4. **Conclusiones** (2-3 págs): Hallazgos, implicaciones, limitaciones
5. **Referencias y Anexos** (código R, tablas adicionales)

Rúbrica del proyecto (recordatorio)

Criterio	Informe	Presentación
Pregunta de investigación	10 %	10 %
Limpieza de datos	10 %	—
EDA	15 %	20 %
Inferencia (IC, pruebas)	15 %	15 %
Modelo de regresión	20 %	25 %
Diagnósticos	15 %	10 %
Conclusiones	10 %	15 %
Código reproducible	5 %	—
Claridad y visualizaciones	—	15 %
Total	100 %	100 %

Nota final del proyecto: 60 % informe + 40 % presentación.

Consejos para el proyecto: errores comunes

Errores comunes a evitar

- **No reportar diagnósticos:** Siempre verificar supuestos (Breusch-Pagan, Cook's D, etc.)
- **Gráficos sin etiquetas:** Todos los ejes, títulos, leyendas deben estar etiquetados
- **Interpretar sin controlar:** "El estrato causa X" sin controlar por confundidores
- **Solo reportar p-valores:** Reportar coeficientes, IC, tamaño del efecto (R^2 , d de Cohen)
- **Código no reproducible:** Scripts desorganizados, sin comentarios, rutas absolutas

Consejos para el proyecto: buenas prácticas

Buenas prácticas

- **Comenzar temprano:** No dejar todo para última hora
- **Dividir tareas:** Cada miembro del grupo responsable de una parte (EDA, modelo, etc.)
- **Iterar:** Compartir borradores, recibir retroalimentación, mejorar
- **Visualizar bien:** Forest plots, boxplots, scatterplots con líneas de regresión
- **Contextualizar:** Conectar resultados estadísticos con implicaciones para NI

Resumen: habilidades técnicas

Habilidades técnicas

- Describir y visualizar datos (U1)
- Cuantificar incertidumbre con intervalos de confianza (U2)
- Tomar decisiones con pruebas de hipótesis (U3)
- Modelar relaciones con regresión lineal (U4)
- Diagnosticar y corregir problemas en modelos (U4)
- Programar en R para análisis reproducible

Resumen: habilidades conceptuales

Habilidades conceptuales

- Pensar críticamente sobre datos (¿de dónde vienen? ¿qué sesgos hay?)
- Distinguir correlación de causalidad
- Reconocer limitaciones de los métodos (supuestos, datos observacionales)
- Comunicar resultados a audiencias no técnicas
- Integrar múltiples técnicas en un análisis completo (pipeline estadístico)

Más allá del curso

¿Cómo usar estadística en tu carrera?

- **Negocios Internacionales:** Análisis de mercados, evaluación de políticas comerciales, estudios de competitividad
- **Consultoría:** Diagnósticos basados en datos, evaluación de impacto
- **Política pública:** Diseño y evaluación de programas sociales
- **Investigación académica:** Tesis, artículos, proyectos de grado

Recursos para seguir aprendiendo

- **Libros:** "The Effect"(Huntington-Klein), "Causal Inference: The Mixtape"(Cunningham)
- **Cursos online:** Coursera (Data Science Specialization), edX (Statistics and R)
- **Comunidades:** R-Ladies, Stack Overflow, Cross Validated
- **Práctica:** Kaggle, datos abiertos (DANE, Banco Mundial)

Reflexión final

"La estadística no es solo matemáticas.
Es una forma de pensar sobre el mundo
con rigor, humildad y curiosidad.

Gracias por su esfuerzo, participación y compromiso a lo largo del semestre.
Ha sido un placer acompañarlos en este viaje.

¡Éxito en el examen y en el proyecto!

Horarios de consulta antes del examen

Sesiones de repaso adicionales

- **Lunes 24 de noviembre:** 14:00-16:00 (oficina 305) — Repaso de U2 (IC) y U3 (pruebas)
- **Miércoles 26 de noviembre:** 14:00-16:00 (oficina 305) — Repaso de U4 (regresión) y problemas tipo examen
- **Jueves 26 de noviembre:** 10:00-12:00 (por Zoom) — Sesión de preguntas abiertas (cualquier tema)

Contacto

- Email: jaime.polanco@javeriana.edu.co
- Responderé emails hasta el jueves 26 a las 18:00
- No enviar preguntas el viernes (día del examen)

¡Gracias!

Preguntas finales

Contacto:

jaime.polanco@javeriana.edu.co

Horario de atención: Lun y Mié 14:00-16:00 (esta semana)

Nos vemos el viernes 27 a las 7:00 para las presentaciones.